

PROYECTO FINAL DE INGENIERÍA

Plataforma de apoyo al análisis
estructural de resonancia magnética
lumbar mediante segmentación anatómica
asistida por inteligencia artificial.

Autor/es:

Asplanatti Enzo Andrea - LU: 1145364

Fabrello Francisco Ezequiel - LU: 1150122

Carrera:

Ingeniería en informática

Tutor/es:

Sacco, Andrés Damián

Año:

2026

PROYECTO FINAL DE INGENIERÍA

PLATAFORMA DE APOYO AL ANÁLISIS ESTRUCTURAL DE RESONANCIA MAGNÉTICA LUMBAR MEDIANTE SEGMENTACIÓN ANATÓMICA ASISTIDA POR INTELIGENCIA ARTIFICIAL

Asplanatti, Enzo – LU 1145364

Ingeniería Informática

Fabrello, Francisco – LU 1150122

Ingeniería Informática

Tutor:

Sacco, Andrés Damián,

**(UADE) Universidad Argentina de la Empresa Lima 757, Ciudad Autónoma
de Buenos Aires, Argentina.**

2026

UADE

**UNIVERSIDAD ARGENTINA DE LA EMPRESA
FACULTAD DE INGENIERÍA Y CIENCIAS EXACTAS**

Agradecimientos

Queremos expresar nuestro sincero agradecimiento a todas las personas que hicieron posible este Proyecto Final de Ingeniería.

En primer lugar, a nuestro tutor, Andrés Damián Sacco, por su guía, su disponibilidad y sus observaciones a lo largo del desarrollo del trabajo, que fueron fundamentales para dar forma y rigor a la propuesta.

A los profesionales de diagnóstico por imágenes que participaron de las entrevistas y compartieron con generosidad su experiencia y su tiempo. En particular, agradecemos a la Dra. Susana Torres (M.N. 179537) y al Dr. Gonzalo Brito (M.P. 96798) por su disposición y sus aportes. Estos no solo validaron la pertinencia del proyecto, sino que orientaron decisiones concretas de alcance, como la incorporación del plano axial al análisis.

A la Universidad Argentina de la Empresa y a los docentes del Departamento de Tecnología Informática, por la formación recibida a lo largo de la carrera.

Finalmente, a nuestras familias y amigos, por el apoyo, la paciencia y el acompañamiento constante durante todo este proceso.

El índice desarrolla hasta tres niveles de titulación, dentro del máximo de cuatro admitido por la cátedra.

Índice

1	Introducción	14
2	Planteamiento del problema	15
3	Justificación	16
4	Objetivos	17
4.1	Objetivo general	17
4.2	Objetivos específicos	17
5	Alcance	18
5.1	Funcionalidades incluidas	18
5.2	Estructuras y mediciones contempladas	18
5.3	Validación incluida	19
5.4	Exclusiones del alcance	19
5.5	Privacidad y gestión de datos	20
5.6	Alcance del documento final	20
6	Estado del arte	21
6.1	Propósito y alcance del estado del arte	21
6.2	Estrategia de búsqueda y criterios de selección	21
6.3	Datasets y benchmarks para RM lumbar	22
6.3.1	SPIDER como dataset base del MVP	22
6.3.2	LumbarDISC como referencia complementaria	23
6.3.3	Dataset de Sudirman y Al-Kafri como referencia axial	24
6.3.4	Conclusión parcial sobre datasets	24
6.4	Segmentación automática de estructuras lumbares	25
6.4.1	U-Net, nnU-Net y enfoques auto-configurables	25
6.4.2	SPINEPS y segmentación multi-estructura	25
6.4.3	Clasificación degenerativa y sistemas complementarios	26
6.4.4	Segmentación axial sobre RM lumbar	26
6.4.5	Conclusión parcial sobre segmentación	26
6.5	Mediciones cuantitativas derivadas de segmentaciones	27
6.6	Visualización, revisión profesional y salida estructurada	27

6.7	Soluciones comerciales y regulatorias	28
6.7.1	CoLumbo	28
6.7.2	MSKai	28
6.7.3	RemedyLogic AI MRI Lumbar Spine Reader	28
6.7.4	Prenuvo	29
6.7.5	Conclusión parcial sobre competencia	29
6.8	Herramientas abiertas y sustitutos parciales	30
6.9	Limitaciones detectadas en los antecedentes	31
6.10	Brecha identificada y justificación del PFI	31
6.11	Matriz comparativa de antecedentes	32
6.12	Análisis competitivo: matriz FODA y fuerzas de Porter	35
6.12.1	Matriz FODA	35
6.12.2	Fuerzas competitivas de Porter	36
6.13	Conclusiones del estado del arte	38
7	Marco teórico	39
7.1	Propósito y alcance del marco teórico	39
7.2	Resonancia magnética lumbar	39
7.2.1	Principio general de la resonancia magnética	39
7.2.2	Secuencias T1 y T2 en columna lumbar	40
7.2.3	Planos sagital y axial	40
7.3	Anatomía lumbar relevante para el prototipo	41
7.3.1	Organización general de la región lumbar	41
7.3.2	Estructuras anatómicas de interés	41
7.4	Representación computacional de imágenes médicas	42
7.4.1	Imagen médica como matriz con metadatos	42
7.4.2	Formatos DICOM y NIfTI	43
7.4.3	Normalización y preprocesamiento	43
7.5	Segmentación de imágenes médicas	43
7.5.1	Definición	43
7.5.2	Tipos de segmentación relevantes	43
7.5.3	Desafíos en RM lumbar	44
7.6	Aprendizaje supervisado y anotaciones de referencia	44
7.6.1	Concepto de ground truth	44
7.6.2	Entrenamiento, validación y prueba	45
7.7	Modelos de aprendizaje profundo para segmentación	45
7.7.1	Redes neuronales convolucionales	45

7.7.2	Arquitecturas encoder-decoder	45
7.7.3	U-Net	45
7.7.4	nnU-Net	45
7.7.5	Attention U-Net y modelos híbridos CNN-Transformer	46
7.7.6	Frameworks especializados en imagen médica	46
7.8	Mediciones cuantitativas derivadas de máscaras	46
7.8.1	Máscaras como base geométrica	46
7.8.2	Mediciones posibles en RM lumbar	46
7.8.3	Límites clínicos de las mediciones	47
7.9	Métricas de evaluación de segmentación	47
7.9.1	Necesidad de evaluación cuantitativa	47
7.9.2	Coeficiente Dice	47
7.9.3	Intersección sobre Unión	48
7.9.4	Distancia de Hausdorff y HD95	48
7.9.5	Normalized Surface Dice	48
7.9.6	Interpretación responsable de métricas	48
7.10	Visualización, interacción y salida estructurada	48
7.10.1	Visualización superpuesta	48
7.10.2	Salida estructurada editable	49
7.10.3	Trazabilidad	49
7.10.4	Generación de preinformes estructurados	49
7.11	Inteligencia artificial asistiva y rol profesional	50
7.11.1	Sistemas de apoyo a la decisión clínica	50
7.11.2	Humano en el circuito	50
7.11.3	Diferencia entre asistencia y diagnóstico autónomo	50
7.12	Privacidad, ética y límites normativos	51
7.13	Síntesis conceptual	51
7.14	Conclusión del marco teórico	52
8	User research, elicitación y análisis preliminar de requerimientos	53
8.1	Propósito del capítulo	53
8.2	Diseño del relevamiento	53
8.3	Perfil de profesionales entrevistados	54
8.4	Criterio de tratamiento de las transcripciones	54
8.5	Matriz de hallazgos	55
8.6	Lectura analítica de los hallazgos	57
8.7	Aspectos no consolidados o diferidos	58

8.8	User persona preliminar	59
8.9	Necesidades detectadas	60
8.10	Épicas iniciales y criterios de aceptación	61
8.11	Encuesta cuantitativa a profesionales	61
8.11.1	Criterio de inclusión y dimensionamiento de la muestra	61
8.11.2	Resultados	62
8.11.3	Síntesis de la encuesta	66
8.12	Conclusión del capítulo	66
9	Requerimientos funcionales, no funcionales y trazabilidad	67
9.1	Propósito del capítulo	67
9.2	Fuentes y criterios de formalización	67
9.3	Actores y responsabilidades	67
9.4	Estados de requerimiento y criterio de prioridad	68
9.5	Flujos alternativos y excepciones	69
9.6	Historias de usuario priorizadas	69
9.7	Requerimientos funcionales	71
9.8	Requerimientos no funcionales	73
9.9	Requerimientos de validación	74
9.10	Matriz de trazabilidad resumida	75
9.11	Control de alcance y requerimientos diferidos	76
9.12	Actualización técnica de alcance final	76
9.13	Conclusión del capítulo	77
10	Diseño de la solución, arquitectura y selección tecnológica	78
10.1	Propósito y enfoque arquitectónico	78
10.2	Decisiones arquitectónicas derivadas de los requerimientos	79
10.3	Vista lógica	80
10.3.1	Arquitectura lógica consolidada	80
10.3.2	Modelo de datos	82
10.3.3	Diagrama de clases	85
10.4	Vista de procesos	86
10.4.1	Flujo end-to-end de una corrida	86
10.4.2	Arquitectura de red, protocolos y seguridad	88
10.5	Vista de desarrollo	88
10.5.1	Distribución por repositorios y responsabilidades	88
10.5.2	Estrategia de datos, modelos y ciclo de vida de artifacts	89

10.5.3	Selección tecnológica y justificación	89
10.5.4	Alternativas evaluadas	91
10.6	Vista física (despliegue)	92
10.6.1	Arquitectura actual de validación	92
10.6.2	Arquitectura objetivo en Google Cloud	92
10.6.3	Estado real del despliegue Cloud	95
10.7	Vista de escenarios (+1)	95
10.8	Diseño de interfaz: wireframes y decisiones de diseño	95
10.8.1	Criterios de diseño derivados del user research	96
10.8.2	Esquemas de las pantallas principales	96
10.8.3	Decisiones de diseño y alternativas descartadas	97
11	Capacidades del prototipo	99
11.1	Cómo leer este capítulo	99
11.2	Ingesta y preparación del estudio	99
11.3	Segmentación sagital	100
11.4	Segmentación axial	101
11.5	Mediciones geométricas	103
11.6	Asignación de nivel anatómico	104
11.7	Visualización y navegación por cortes	105
11.8	Revisión profesional y salida editable	106
11.9	Persistencia, reapertura y trazabilidad	107
11.10	Seguridad y estados degradados	107
11.11	Capacidades desarrolladas y no expuestas	108
11.11.1	Estimación de hallazgos estructurales por nivel	108
11.11.2	Clasificación de estenosis subarticular	110
11.12	Demo Mode y validación funcional reproducible	110
11.13	Disponibilidad productiva de modelos y extensiones	110
11.14	Capacidades extendidas de revisión y análisis	111
11.15	Estado consolidado de las capacidades	111
12	Metodología de desarrollo y validación técnica	113
12.1	Enfoque de trabajo	113
12.2	Sistemas de identificación	113
12.3	Ciclo de trabajo y coordinación	114
12.3.1	Automatización de integración y publicación	115
12.4	Criterios de listo, terminado y evidencia	117

12.5	Validación por capas y pruebas	117
12.6	Diferencia entre instancias de validación	118
12.6.1	Validación profesional final pendiente	118
12.7	Limitaciones metodológicas	119
13	Resultados de la evaluación técnica	120
13.1	Propósito y alcance de la evaluación	120
13.2	Protocolo de evaluación	120
13.3	Resultados de segmentación	121
13.4	Umbral de calidad y estado del artifact axial	122
13.5	Advertencia sobre la partición de prueba axial	122
13.6	Verificación por contraste de las mediciones derivadas	122
13.7	Una medición implementada y no publicada	123
13.8	Resultados finales de validación técnica por capa	124
13.9	Validación técnica en Google Cloud	125
13.10	Niveles de validación y alcance	126
13.11	Resultados de la validación profesional cualitativa	126
13.11.1	Ficha de la sesión con la Dra. Susana Torres	127
13.11.2	Ficha de la sesión con la Dra. Claudia Cejas	127
13.11.3	Síntesis transversal	128
13.11.4	Validación profesional final pendiente	129
13.12	Limitaciones de la evaluación	129
13.13	Conclusión del capítulo	130
14	Modelo de negocio y viabilidad económica	132
14.1	Alcance y política de evidencia	132
14.2	Modelo de negocio	133
14.3	Justificación del modelo SaaS B2B	133
14.4	Segmentación de clientes: Starter, Professional y Enterprise	134
14.5	Pricing por volumen de estudios	134
14.6	Estructura de ingresos	135
14.7	Estructura de costos	135
14.7.1	Costos variables: infraestructura Cloud medida	135
14.7.2	Costo variable por escenario	136
14.7.3	Costos fijos del negocio	137
14.8	Metodología financiera a 36 meses	137
14.9	Escenarios financieros: Pesimista, Base y Optimista	138

14.10	Resultado del escenario Base conservador	139
14.11	Análisis de sensibilidad	139
14.12	Propuesta de Base Comercial Objetivo	140
14.13	Comparación entre el Base conservador y el Base Comercial Objetivo	140
14.14	Limitaciones del modelo económico	141
14.15	Interpretación final	142
15	Planificación académica general	144
15.1	Criterio de planificación	144
15.2	Planificación por entregables	144
15.3	Gestión de cambios	145
15.4	Riesgos de planificación	145
15.5	Conclusión de la planificación	146
A	Cronograma del proyecto	147
A.1	Calendario académico	147
A.2	Diagrama de Gantt	148
A.3	Desvíos respecto de la planificación original	149
B	Glosario de términos	150
C	Anatomía de la columna lumbar y los discos intervertebrales	156
C.1	Esquema simplificado de columna lumbar sagital	156
C.2	Esquema conceptual de segmentación.	157
D	Transcripciones de las entrevistas	158
D.1	Entrevista 1 (EN-01) - Dra. Susana Torres (M.N. 179537)	158
D.2	Entrevista 2 (EN-02) - Dr. Gonzalo Brito	162
D.3	Entrevista 3 (EN-03) - Dra. Claudia Cejas	165
D.4	Entrevista 4 (EN-04) - Dr. Bruno Bregonzi	169
D.5	Entrevista 5 (EN-05) - Dr. Eduardo Luis Castiglione	172
E	Configuración de entrenamiento de los modelos	177
E.1	Parámetros de entrenamiento	177
E.2	Aumentación de datos	178
E.3	Controles de calidad al cierre del entrenamiento	179
E.4	Trazabilidad de los artifacts	179
F	Evolución técnica del desarrollo	180

F.1	Evolución técnica alcanzada	180
F.1.1	Etapas fundacional y separación en tres repositorios	180
F.1.2	Backlogs técnicos por repositorio	181
F.1.3	Bloques coordinados de producto	181
F.1.4	Estado resultante para la entrega del 50 %	185
F.2	Evolución del producto visible	185
F.3	Evolución del pipeline de inferencia	187
F.4	Organización interna del módulo de inteligencia artificial	188
F.5	Cierre técnico final y fuente canónica	188
G	Registro de decisiones arquitectónicas	190
ADR-001	— Separación de Frontend, Backend y AI Module	190
ADR-002	— Spring Boot para el Backend y Python/FastAPI para el AI Module	190
ADR-003	— Backend como única frontera pública hacia el AI Module	191
ADR-004	— PostgreSQL para persistencia transaccional	191
ADR-005	— PyTorch como runtime de inferencia y ONNX Runtime diferido	191
ADR-006	— Separación entre código fuente y artefactos de datos y modelos	192
ADR-007	— Google Cloud como arquitectura objetivo de despliegue	192
ADR-008	— Inferencia fail-closed y revisión profesional obligatoria	193
ADR-009	— Demo Mode determinístico y no clínico	193
ADR-010	— Integración parcial del dominio Patient	193
ADR-011	— No aprendizaje automático desde correcciones profesionales	194
H	Validación profesional cualitativa	195
H.1	Propósito y alcance	195
H.2	Metodología de las sesiones	195
H.3	VP-01 — Sesión con la Dra. Susana Torres	196
H.4	VP-02 — Sesión con la Dra. Claudia Cejas	197
H.5	Síntesis transversal de hallazgos	199
H.6	Trazabilidad entre observaciones y decisiones de producto	200
H.7	Limitaciones de esta instancia	201
H.8	Validación cruzada profesional final pendiente	201
	Referencias	202

Lista de Figuras

8.1	Perfil de los encuestados (pregunta 1) y obtención de mediciones en el flujo actual (pregunta 3). Fuente: elaboración propia sobre la encuesta.	63
8.2	Mediciones cuantitativas más valiosas (pregunta 9) y requisitos de confianza en la segmentación (pregunta 7). Fuente: elaboración propia sobre la encuesta. . .	64
8.3	Acuerdo sobre confianza y transparencia (pregunta 11), disposición a adoptarla (pregunta 12) y principales barreras (pregunta 13). Fuente: elaboración propia sobre la encuesta.	65
10.1	Diagrama de contexto del sistema. Fuente: elaboración propia.	78
10.2	Arquitectura general por componentes. Fuente: elaboración propia.	82
10.3	Arquitectura del visor volumétrico. Fuente: elaboración propia.	83
10.4	Modelo de datos relacional (PostgreSQL). Fuente: elaboración propia.	84
10.5	Diagrama de clases del dominio y servicios. Fuente: elaboración propia.	86
10.6	Flujo de interacción end-to-end. Fuente: elaboración propia.	87
10.7	Arquitectura objetivo de despliegue en Google Cloud. Fuente: elaboración propia.	94
10.8	Wireframe de baja fidelidad del workspace multiplanar propuesto, incluyendo visualización sagital y axial, navegación full-series, superposición de resultados y panel de mediciones vinculadas al nivel anatómico. Fuente: elaboración propia.	98
10.9	Wireframe de baja fidelidad del flujo de revisión profesional y preinforme, mostrando la trazabilidad entre el resultado automático, la corrección del profesional, el estado de revisión y la salida estructurada revisable. Fuente: elaboración propia.	98
11.1	Acceso con estado de cuenta pendiente de aprobación y worklist de estudios. Fuente: elaboración propia.	100
11.2	Carga de un estudio DICOM con sus series identificadas y clasificadas. Fuente: elaboración propia.	100
11.3	Workspace sagital con la máscara superpuesta sobre la imagen original. Fuente: elaboración propia.	101
11.4	Workspace axial con la máscara superpuesta sobre la imagen original. Fuente: elaboración propia.	102
11.5	Panel de mediciones con la estructura, el plano y el corte de origen de cada valor. Fuente: elaboración propia.	104
11.6	Navegación por cortes del volumen con el resultado vinculado a su corte. Fuente: elaboración propia.	106

11.7	Controles de revisión profesional sobre una estructura segmentada. Fuente: elaboración propia.	106
11.8	Preinforme automático revisable con estructuras, mediciones y estado de revisión. Fuente: elaboración propia.	106
11.9	Historial de corridas y reapertura de un estudio ya procesado. Fuente: elaboración propia.	107
11.10	Estado degradado informado de forma explícita ante indisponibilidad del módulo de inferencia. Fuente: elaboración propia.	108
12.1	Sistemas de identificación utilizados en el proyecto	114
12.2	Flujo automatizado de construcción y publicación de imágenes de contenedor mediante GitHub Actions, Workload Identity Federation y Artifact Registry. La promoción hacia Cloud Run se mantiene como una acción controlada. Fuente: elaboración propia.	116
A.1	Diagrama de Gantt del Proyecto Final de Ingeniería, marzo a diciembre de 2026. Fuente: elaboración propia.	148
C.1	Esquema simplificado de vértebras lumbares, discos intervertebrales y canal espinal en vista sagital. Fuente: elaboración propia.	157
C.2	Esquema conceptual del pasaje desde una RM lumbar hacia máscaras de segmentación. Fuente: elaboración propia.	157

Lista de Tablas

6.1	Estrategia de búsqueda y selección de fuentes.	22
6.2	Comparación entre soluciones comerciales y el alcance del PFI.	29
6.3	Brecha funcional que justifica el PFI.	32
6.4	Síntesis de antecedentes y relación con el PFI.	33
6.5	Matriz FODA del PFI.	35
6.6	Análisis de las cinco fuerzas competitivas aplicado al PFI.	37
7.1	Síntesis del marco teórico y vinculación con el PFI.	51
8.1	Matriz de hallazgos	55
8.2	Aspectos no consolidados o diferidos	58
8.3	User persona preliminar	59
8.4	Necesidades detectadas	60
9.1	Actores y responsabilidades	67
9.2	Estados de requerimiento y criterio de prioridad	68
9.3	Historias de usuario priorizadas	69
9.4	Requerimientos funcionales	71
9.5	Requerimientos no funcionales	74
9.6	Requerimientos de validación	75
9.7	Matriz de trazabilidad resumida	75
10.1	Componentes funcionales del prototipo	79
10.10	Estado final de despliegue Cloud por recurso.	95
10.11	Relación entre zonas de la interfaz, necesidades del relevamiento y requerimientos	96
11.1	Formatos admitidos y uso previsto.	100
11.2	Correspondencia entre clases del modelo axial y estructuras anatómicas.	101
11.3	Catálogo de mediciones derivadas de las máscaras.	103
11.4	Desempeño de la estimación estructural sobre la partición sellada.	108
11.5	Estado final de modelos y extensiones.	110
11.6	Estado de las capacidades al cierre de esta entrega.	111
13.1	Partición de los conjuntos de datos empleados en el entrenamiento y la evaluación.	120
13.2	Coeficiente Dice sobre la partición retenida, por modelo.	121
13.3	Verificación por contraste de las mediciones sobre el estudio de referencia.	123

13.4	Validación técnica final del prototipo.	124
13.5	Validación técnica de Cloud, extremo a extremo (Etapas 6–10B).	125
13.6	Costo y performance Cloud medidos (Etapa 10/10B).	125
13.7	Cambios de producto derivados de la validación profesional cualitativa.	128
14.1	Roles económicos distinguidos en el modelo de negocio.	133
14.2	Planes comerciales propuestos (Base Comercial Objetivo).	134
14.3	Costos Cloud observados (evidencia experimental, Etapa 10/10B).	135
14.4	Costo variable Cloud por escenario.	136
14.5	Comparación de escenarios financieros a 36 meses.	138
14.6	Indicadores del escenario Base conservador, mes 36.	139
14.7	Sensibilidad del VAN sobre el escenario Base.	139
14.8	Base conservador frente a Base Comercial Objetivo.	141
15.1	Estado consolidado de entregables y actividades de cierre del proyecto.	144
A.1	Hitos académicos del proyecto.	147
A.2	Distribución temporal de las actividades por carril.	148
A.3	Desvíos registrados y justificación técnica.	149
E.1	Configuración comparada del entrenamiento de ambos modelos.	177
E.2	Transformaciones de aumentación aplicadas durante el entrenamiento.	178
E.3	Condiciones evaluadas antes de promover un artifact.	179
F.1	Bloques coordinados de producto, de P8 a P10.9.	182
F.2	Evolución de la implementación del pipeline de IA.	187
H.1	Trazabilidad entre observaciones profesionales y decisiones de producto.	200

1 Introducción

El análisis de imágenes médicas es un campo donde la ingeniería informática puede aportar herramientas de apoyo para tareas de segmentación, medición, visualización y documentación. En particular, la resonancia magnética (RM) de columna lumbar permite observar estructuras como cuerpos vertebrales, discos intervertebrales y canal espinal, cuyo análisis requiere criterio profesional y una correcta interpretación anatómica. En este contexto existe una oportunidad de asistencia informática: automatizar tareas operativas que hoy pueden requerir revisión manual o semimanual, sin sustituir la decisión del especialista. La segmentación anatómica asistida por inteligencia artificial puede servir como base para visualizar regiones de interés, calcular mediciones geométricas simples y organizar resultados de manera trazable.

El presente Proyecto Final de Ingeniería propone el diseño y desarrollo de un prototipo funcional de software para RM lumbar. Inicialmente centrado en el plano sagital, el proyecto incorporó además el plano axial como complemento, a partir de un hallazgo del relevamiento con profesionales, y admite estudios en formatos estándar de imagen médica (DICOM, .ima o .mha). El MVP contempla la carga y normalización de estudios, la segmentación de vértebras, discos intervertebrales y canal espinal, la extracción de mediciones cuantitativas acotadas, la visualización superpuesta de máscaras y la generación de una salida estructurada editable, incluido un preinforme automático revisable. El sistema se plantea como herramienta de apoyo: no emite diagnósticos, no recomienda tratamientos y no reemplaza al profesional. El desarrollo se apoya principalmente en datasets públicos anotados, especialmente SPIDER para el plano sagital y el conjunto de Sudirman / Al-Kafri para el plano axial, lo que favorece la reproducibilidad académica y permite validar técnicamente las segmentaciones contra máscaras de referencia. Esta decisión también reduce la dependencia inicial de datos clínicos privados y mantiene el alcance dentro de una prueba de concepto verificable.

La organización del documento avanza desde la definición del problema hacia la fundamentación y el diseño del prototipo. Los primeros capítulos presentan el problema, la justificación, los objetivos, el alcance y la solución propuesta. Luego se desarrollan el estado del arte y el marco teórico, que establecen los antecedentes y conceptos necesarios para comprender las decisiones técnicas del proyecto. En etapas posteriores del documento final se incorporarán user research, requerimientos, arquitectura, metodología, implementación, validación, resultados y conclusiones.

2 Planteamiento del problema

La interpretación de resonancias magnéticas lumbares requiere revisar secuencias, identificar estructuras anatómicas, comparar niveles y, cuando corresponde, realizar mediciones. Aunque los visores médicos actuales permiten observar imágenes y efectuar mediciones manuales, la delimitación de estructuras y la organización de resultados cuantitativos pueden seguir dependiendo de tareas manuales o semimanuales. En RM lumbar, tanto en el plano sagital como en el axial, estructuras como cuerpos vertebrales, discos intervertebrales y canal espinal son relevantes para el análisis estructural. Su delimitación manual puede consumir tiempo, variar entre observadores y generar resultados difíciles de reutilizar si no quedan asociados a una estructura, un nivel anatómico y una imagen de origen. Esta situación afecta especialmente la trazabilidad de mediciones y observaciones cuando se trabaja con capturas, registros dispersos o informes redactados sin una salida estructurada.

El problema central que aborda este proyecto puede formularse de la siguiente manera:

Existe una oportunidad de asistencia informática en el análisis estructural de resonancias magnéticas lumbares, dado que la segmentación de estructuras anatómicas, la obtención de mediciones simples y la generación de salidas revisables aún pueden requerir tareas manuales, variables y poco integradas dentro de un mismo flujo funcional.

La dificultad no se ubica en reemplazar la interpretación profesional, sino en asistir tareas operativas específicas. Un sistema de apoyo puede proponer segmentaciones, calcular mediciones geométricas y presentar resultados visuales, pero debe permitir revisión, corrección o descarte por parte del usuario. Desde una perspectiva de ingeniería, el desafío consiste en integrar carga de imágenes, preprocesamiento, segmentación automática, mediciones, visualización superpuesta y salida editable en un flujo coherente. La solución debe ser trazable, reproducible y acotada al contexto académico, sin presentarse como producto clínico certificado ni como sistema de diagnóstico autónomo.

3 Justificación

El proyecto se justifica desde una perspectiva técnica, académica y funcional. Desde el punto de vista técnico, la disponibilidad de datasets públicos anotados y de modelos de segmentación médica permite construir prototipos reproducibles sin depender inicialmente de datos privados. SPIDER ofrece una base alineada con el MVP porque incluye RM lumbares sagitales y máscaras de referencia para vértebras, discos intervertebrales y canal espinal; el conjunto de Sudirman / Al-Kafri aporta, de forma complementaria, cortes axiales anotados sobre los niveles discales inferiores; y RSNA / LumbarDISC se suma como dataset complementario empleado en la línea degenerativa por nivel, sin constituir una base de segmentación anatómica primaria. Junto con arquitecturas como U-Net o nnU-Net, este contexto permite enfocar el aporte en la integración de un flujo completo, no solo en el entrenamiento de un modelo aislado.

Desde el punto de vista académico, la propuesta combina procesamiento de imágenes, inteligencia artificial, diseño de software, validación técnica e interacción con usuarios expertos. Esta articulación resulta pertinente para un Proyecto Final de Ingeniería porque exige traducir antecedentes técnicos en un sistema funcional, documentado y evaluable.

Desde el punto de vista funcional, el prototipo puede aportar valor como soporte al análisis estructural de RM lumbar. Las máscaras permitirán visualizar regiones de interés, las mediciones aportarán datos geométricos acotados y la salida editable organizará resultados para revisión profesional. La herramienta se mantiene dentro de un enfoque asistivo: el usuario conserva el control sobre interpretación, corrección y uso final de la información. El estado del arte muestra avances en datasets, modelos, herramientas abiertas y productos comerciales, pero esos elementos suelen aparecer separados o dentro de soluciones cerradas. La brecha que justifica el PFI está en integrar segmentación, mediciones simples, visualización, salida editable y validación técnica/cualitativa en un prototipo académico reproducible.

Finalmente, trabajar con datos públicos reduce riesgos de privacidad durante esta etapa. En una evolución posterior, en la que se contemple conservar estudios de pacientes para habilitar una historia clínica y el seguimiento longitudinal, el tratamiento de datos deberá ajustarse a la normativa vigente (en particular la Ley N.º 25.326 de Protección de los Datos Personales), con almacenamiento seguro, acceso restringido y seudonimización. Para el alcance actual, la justificación se concentra en demostrar factibilidad técnica y utilidad funcional dentro de un MVP responsable.

4 Objetivos

4.1 Objetivo general

Diseñar y desarrollar un prototipo funcional de software que analice resonancias magnéticas lumbares en los planos sagital y axial para segmentar estructuras anatómicas relevantes, obtener un conjunto acotado de mediciones cuantitativas y generar una salida visual y estructurada editable (incluido un preinforme automático revisable) que asista al profesional sin reemplazar su criterio clínico.

4.2 Objetivos específicos

Para alcanzar el objetivo general, se definen los siguientes objetivos específicos:

1. Relevar antecedentes académicos, datasets públicos, herramientas abiertas y soluciones comerciales relacionadas con el análisis asistido de RM lumbar.
2. Identificar la brecha funcional que justifica un prototipo académico orientado a segmentación, mediciones, visualización y salida editable.
3. Definir el alcance del MVP, incluyendo estructuras anatómicas, funcionalidades, validación prevista y exclusiones clínicas, técnicas y regulatorias.
4. Analizar necesidades de potenciales usuarios mediante actividades de user research vinculadas con la revisión de RM lumbar.
5. Diseñar e implementar un pipeline de carga, normalización, preprocesamiento, segmentación, postprocesamiento y visualización.
6. Adaptar o implementar un modelo de segmentación para vértebras, discos intervertebrales y canal espinal en el plano sagital, y un módulo complementario de segmentación axial (disco, elemento posterior, saco tecal y área entre elementos anterior y posterior).
7. Desarrollar mediciones geométricas simples derivadas de las máscaras generadas.
8. Diseñar una interfaz, una salida estructurada editable y un preinforme automático revisable que permitan revisar resultados sin constituir un informe clínico automático.
9. Evaluar técnicamente el prototipo mediante métricas de segmentación y comparación contra anotaciones de referencia.
10. Complementar la validación técnica con revisión cualitativa profesional y documentar decisiones, limitaciones, resultados y trabajos futuros.

5 Alcance

El proyecto se limita a un MVP académico para análisis asistido de RM lumbar en los planos sagital y axial. Su propósito es automatizar tareas operativas de segmentación, medición, visualización y documentación estructurada, manteniendo la revisión profesional como condición central.

5.1 Funcionalidades incluidas

El prototipo contempla:

- carga de estudios de RM lumbar en formatos estándar (DICOM, .ima o .mha), en los planos sagital y axial, provenientes de datasets públicos o fuentes compatibles con el entorno de desarrollo;
- normalización y preprocesamiento de imágenes;
- segmentación automática de cuerpos vertebrales, discos intervertebrales y canal espinal en el plano sagital, y de disco, elemento posterior, saco tecal y área entre elementos anterior y posterior en el plano axial;
- visualización de máscaras superpuestas sobre la imagen original;
- cálculo de mediciones geométricas simples asociadas a estructuras segmentadas;
- organización de resultados por estructura y, cuando sea posible, por nivel lumbar;
- generación de una salida estructurada editable y de un preinforme automático revisable;
- evaluación técnica mediante métricas cuantitativas y revisión cualitativa profesional.

5.2 Estructuras y mediciones contempladas

El MVP se concentra en vértebras, discos intervertebrales y canal espinal en el plano sagital, y en disco, elemento posterior, saco tecal y área entre elementos anterior y posterior en el plano axial, porque esas estructuras se encuentran alineadas con los datasets base y permiten obtener mediciones morfométricas simples. Las mediciones podrán incluir:

- áreas proyectadas de estructuras segmentadas;
- dimensiones relativas de discos intervertebrales;
- medidas aproximadas del canal espinal en plano sagital;
- área del saco tecal en sección transversal sobre cortes axiales;
- anchos foraminales aproximados sobre cortes axiales;
- comparaciones simples entre niveles o estructuras.

Estas salidas se presentan como datos geométricos revisables. No se interpretarán auto-

máticamente como patologías ni se traducirán en recomendaciones clínicas.

5.3 Validación incluida

La validación se plantea en tres bloques de validación incluidos en el alcance actual. El primero es la evaluación de modelos: una comparación técnica cuantitativa entre las máscaras generadas y las anotaciones de referencia del conjunto de datos utilizado, mediante métricas de solapamiento como el coeficiente Dice y la intersección sobre unión. Sus resultados se informan en el Capítulo 13, junto con el protocolo de partición y las limitaciones que los acotan. El segundo es la validación técnica del producto y su infraestructura, que incluye tanto la verificación de software e integración como sesiones de revisión profesional cualitativa del prototipo con dos profesionales, orientadas a utilidad, flujo, comprensión, priorización funcional y confianza sobre una versión intermedia del producto; esa evidencia no constituye validación clínica, diagnóstica ni comparación contra ground truth. La validación cruzada profesional final, sobre estudios concretos con lectura independiente, procesamiento del sistema y comparación documentada de niveles, segmentaciones, mediciones, hallazgos, omisiones y falsos positivos, continúa pendiente; la validación clínica continúa fuera del alcance de este trabajo.

5.4 Exclusiones del alcance

Quedan fuera del alcance:

- diagnóstico clínico automático, entendido como la atribución de una entidad clínica a un paciente con valor asistencial;
- clasificación de patologías degenerativas expuesta al usuario: las estimaciones desarrolladas en esa línea se evalúan y documentan en la sección 11.11.1, y permanecen fuera del producto por la heterogeneidad de su desempeño;
- recomendación terapéutica;
- reemplazo del criterio médico;
- uso clínico real del sistema;
- validación clínica multicéntrica;
- integración completa con sistemas hospitalarios, PACS o RIS;
- certificación regulatoria como software médico;
- scoring clínico o comparación longitudinal calibrada de progresión (la comparación longitudinal descriptiva existe en el flujo demo/subjectRef, pero no constituye evaluación clínica de progresión);
- entrenamiento sobre datos privados no anonimizados;
- desarrollo de un producto comercial final.

Las capacidades desarrolladas durante el proyecto que quedan fuera de este alcance se documentan en la sección 11.11, junto con el motivo de su exclusión.

5.5 Privacidad y gestión de datos

En el alcance actual, el desarrollo y la validación se realizan sobre datasets públicos o de-identificados. Durante la ingesta de estudios DICOM se minimizan y sanitizan los identificadores, y los contratos públicos utilizan identificadores seudónimos (subjectRef). No se afirma uso clínico real de datos de pacientes. Para habilitar, a futuro, una historia clínica por paciente, se preservaría esta separación y seudonimización conforme a la Ley 25.326.

5.6 Alcance del documento final

La presente entrega establece el problema, la justificación, el alcance, la solución propuesta, el estado del arte, el marco teórico, el user research, los requerimientos, la arquitectura, el desarrollo del producto, la metodología, la implementación técnica y los resultados de la evaluación de segmentación. Quedan diferidos para el documento final de cierre la validación cruzada profesional final, el análisis de negocio, la discusión, las conclusiones y los trabajos futuros definitivos. La validación cualitativa de producto con dos profesionales se incorpora como evidencia de utilidad y priorización, con las limitaciones declaradas en el Capítulo 13 y el Anexo H.

6 Estado del arte

6.1 Propósito y alcance del estado del arte

Este capítulo releva antecedentes académicos, datasets públicos, herramientas abiertas y soluciones comerciales relacionadas con el análisis asistido de resonancias magnéticas (RM) lumbares. El objetivo no es presentar todos los avances disponibles en inteligencia artificial médica, sino identificar qué componentes existentes se relacionan con el alcance del PFI y qué brecha concreta justifica el desarrollo del prototipo. A lo largo del documento se emplea vocabulario técnico de imagen médica y aprendizaje profundo; los términos especializados se definen en el Anexo B (Glosario).

El proyecto se limita a un prototipo funcional para RM lumbar, con el plano sagital como base anatómica principal y un módulo axial complementario, centrado en la segmentación de estructuras anatómicas relevantes, la extracción de un conjunto acotado de mediciones geométricas, la visualización superpuesta de resultados y la generación de una salida estructurada editable para revisión profesional. Se excluye el diagnóstico autónomo, la certificación regulatoria, la integración hospitalaria completa y la validación clínica multicéntrica.

A partir de ese alcance, el estado del arte se organiza en cinco preguntas directrices:

- ¿Qué datasets públicos permiten entrenar o evaluar segmentación anatómica en RM lumbar?
- ¿Qué modelos y sistemas recientes segmentan vértebras, discos intervertebrales y canal espinal?
- ¿Qué antecedentes existen sobre mediciones cuantitativas derivadas de segmentaciones?
- ¿Qué soluciones comerciales evidencian relevancia real del problema?
- ¿Qué combinación de componentes queda todavía abierta para un prototipo académico reproducible?

Durante la elaboración del relevamiento, se identificó adicionalmente un dataset público con cobertura del plano axial complementario a SPIDER. Su análisis y eventual incorporación se desarrolla en la sección 6.3.3 y se integra en la matriz comparativa final.

6.2 Estrategia de búsqueda y criterios de selección

La revisión se realizó con un enfoque narrativo y orientado a la ingeniería del prototipo. Se priorizaron fuentes con trazabilidad verificable: artículos revisados por pares, preprints técnicos con autores identificables, repositorios oficiales de datos, documentación de benchmarks y documentos regulatorios oficiales de la FDA. No se incorporaron referencias cuya autoría, título, DOI, URL o existencia no pudiera verificarse. La Tabla 6.1 sintetiza las fuentes consultadas, los

términos de búsqueda empleados y los criterios de inclusión y exclusión aplicados.

TABLA 6.1: Estrategia de búsqueda y selección de fuentes.

Elemento	Criterio utilizado
Fuentes consultadas	Google Scholar, PubMed, Scientific Data, Nature Methods, Zenodo, Kaggle/RSNA, documentación FDA 510(k) y sitios oficiales de proyectos o datasets.
Términos principales	lumbar spine MRI segmentation, intervertebral disc segmentation, spinal canal segmentation, lumbar MRI quantitative measurement, structured radiology reporting, automated radiological image processing software.
Periodo priorizado	2020–2026, incorporando referencias anteriores únicamente cuando funcionan como antecedente metodológico central.
Criterios de inclusión	Relación directa con RM lumbar, segmentación espinal, datasets públicos, mediciones cuantitativas, revisión profesional o software médico regulado comparable.
Criterios de exclusión	Referencias no verificables, trabajos centrados solo en clasificación diagnóstica sin segmentación, datasets privados sin descripción suficiente, sistemas sin relación con RM lumbar o soluciones que prometen diagnóstico autónomo fuera del alcance del PFI.

Esta estrategia no pretende constituir una revisión sistemática exhaustiva bajo protocolo PRISMA. Su finalidad es construir un mapa de antecedentes suficiente para justificar decisiones de alcance, datos, validación y diferenciación técnica del PFI.

6.3 Datasets y benchmarks para RM lumbar

La disponibilidad de datos anotados es un condicionante central para cualquier sistema de segmentación automática en imágenes médicas. En columna lumbar, muchos trabajos históricos se apoyaron en datasets privados, de tamaño limitado o provenientes de un único centro, lo que dificulta la comparación entre métodos. Por este motivo, los datasets públicos con máscaras anatómicas de referencia son especialmente relevantes.

6.3.1 SPIDER como dataset base del MVP

SPIDER es el antecedente más directamente alineado con el proyecto. Van der Graaf et al. presentan un dataset multicéntrico público de RM lumbar con segmentaciones de referencia de vértebras, discos intervertebrales y canal espinal [1]. El conjunto incluye 447 series sagitales

T1 y T2 de 218 pacientes con antecedente de dolor lumbar, recolectadas en cuatro hospitales de los Países Bajos (un centro médico universitario, dos hospitales regionales y uno ortopédico). Además, el trabajo incluye valores de referencia para algoritmos de segmentación y un challenge continuo para comparar modelos.

La relevancia de SPIDER para este PFI es directa por cuatro razones:

- Contiene las mismas estructuras anatómicas previstas para el MVP: vértebras, discos intervertebrales y canal espinal.
- Provee máscaras de referencia que permiten entrenamiento supervisado o ajuste de modelos.
- Habilita validación técnica cuantitativa mediante comparación contra anotaciones expertas.
- Reduce la dependencia de datos clínicos privados, favoreciendo la reproducibilidad académica.

SPIDER no resuelve por sí mismo el problema completo. No provee una interfaz final para el profesional, no genera una plantilla editable y no define qué mediciones deben presentarse al usuario. Su aporte se ubica en la base de datos y en el benchmark de segmentación. Por lo tanto, el valor del PFI consiste en construir sobre esta base los módulos de medición, visualización, revisión y salida estructurada.

6.3.2 LumbarDISC como referencia complementaria

LumbarDISC, asociado a la competencia RSNA Lumbar Spine Degenerative Classification, constituye un dataset de mayor escala orientado al análisis de degeneración lumbar por nivel [2]. El conjunto incluye 2.697 pacientes y 8.593 series de RM lumbar provenientes de ocho instituciones, con anotaciones de neurorradiólogos y radiólogos musculoesqueléticos para clasificar estenosis del canal, receso subarticular y forámenes neurales.

Su relación con el PFI es complementaria de las dos fuentes centrales: SPIDER en el plano sagital y Sudirman / Al-Kafri en el axial. A diferencia de lo previsto en la propuesta inicial, este conjunto se incorporó de forma efectiva como tercer dataset complementario. Sirvió de base para la línea de hallazgos degenerativos por nivel, orientada a la evaluación interna de estenosis central, foraminal y subarticular, y aportó un estudio DICOM real utilizado para la validación técnica del flujo de ingesta. No reemplaza a SPIDER ni a Sudirman / Al-Kafri, y su tarea principal, la clasificación diagnóstica integral, permanece fuera del alcance del prototipo. El detalle de esta incorporación se documenta en el Anexo F.

6.3.3 Dataset de Sudirman y Al-Kafri como referencia axial

Durante el relevamiento del estado del arte se identificó un dataset público adicional con propiedades complementarias a SPIDER: el dataset publicado por Al-Kafri, Sudirman, Natalia, Meidia, Afriliana, Al-Rashdan, Bashtawi y Al-Jumaily en 2019 [3], distribuido en Mendeley Data bajo licencia CC BY 4.0. Incluye estudios de 515 pacientes con dolor lumbar adquiridos en Irbid Specialty Hospital (Jordania) entre 2015 y 2016, con secuencias T1 y T2 en planos sagital y axial, todos en formato DICOM Siemens (.ima).

La incorporación de este conjunto se documentó inicialmente como una ampliación a evaluar en la entrega del 25 %. Tras el análisis de factibilidad técnica y la consolidación del relevamiento con profesionales, el módulo axial pasó a integrarse efectivamente en el prototipo, según se documenta en los capítulos 5, 8 y 11.

A diferencia de SPIDER, Sudirman incluye cortes axiales nativos sobre los tres niveles discales inferiores (L3/L4, L4/L5 y L5/S1), con anotaciones de segmentación que cubren cuatro regiones de interés: disco intervertebral (IVD), elemento posterior (PE), saco tecal (TS) y área entre elementos anterior y posterior (AAP). La anotación fue realizada por cinco anotadores supervisados por un radiólogo experto, con consolidación final en máscaras de 320×320 píxeles. La cobertura es completa: las 1.545 máscaras finales (515 pacientes $\times$ 3 niveles) preservan los tres niveles discales más relevantes para patología degenerativa lumbar.

La inspección técnica de los headers DICOM confirmó que las series T1 y T2 axiales del mismo paciente comparten pixel spacing (0,6875 mm), slice thickness (4 mm), dimensiones (320×320) y posiciones espaciales prácticamente idénticas, lo que evidencia un co-registro nativo entre ambas secuencias. Esta propiedad permite reutilizar las máscaras anotadas sobre T1 para entrenamiento o validación sobre T2 sin necesidad de registro adicional. La relevancia para el PFI es directa por cuatro razones: amplía la cobertura anatómica al plano axial sin alterar el módulo sagital principal, mantiene la licencia abierta que asegura reproducibilidad académica, ofrece anotaciones de cuatro regiones de interés complementarias a las de SPIDER y permite validación cruzada en los niveles donde se concentra la patología clínica.

6.3.4 Conclusión parcial sobre datasets

El análisis de datasets identifica una combinación operativa clara: SPIDER aporta cobertura sagital con segmentaciones anatómicas primarias, constituye la base del MVP y es la fuente del modelo de hallazgos por nivel; Sudirman / Al-Kafri aporta la base axial anatómica complementaria; y RSNA / LumbarDISC se incorpora como tercer dataset complementario, utilizado en la línea de estenosis y como estudio DICOM real para la validación técnica. Esta distinción evita mezclar segmentación anatómica primaria con clasificación clínica degenerativa y cubre ambos planos de adquisición sin recurrir a datasets privados o de calidad inferior; RSNA

/ LumbarDISC no reemplaza las bases de segmentación anatómica.

6.4 Segmentación automática de estructuras lumbares

La segmentación automática de imágenes médicas mediante aprendizaje profundo se apoya principalmente en arquitecturas encoder-decoder, variantes de U-Net y sistemas auto-configurables. En RM lumbar, los antecedentes relevantes se concentran en segmentar estructuras anatómicas y optimizar métricas técnicas, aunque con menor foco en la integración de esos resultados en un flujo revisable por el profesional.

6.4.1 U-Net, nnU-Net y enfoques auto-configurables

U-Net y sus variantes constituyen una base metodológica recurrente en segmentación biomédica. En particular, nnU-Net fue propuesto por Isensee et al. como un método auto-configurable que adapta preprocesamiento, arquitectura, entrenamiento y postprocesamiento a distintas tareas de segmentación [4]. Su fortaleza radica en ofrecer un pipeline robusto y reproducible sin requerir rediseñar manualmente todos los hiperparámetros para cada dataset.

En el contexto de este PFI, nnU-Net tiene valor como baseline y como referencia metodológica. No necesariamente debe ser la arquitectura final única, pero sí permite comparar el rendimiento de cualquier alternativa más liviana o adaptada a las restricciones de hardware del proyecto. En una tesis de desarrollo, esta comparación es relevante porque evita evaluar el prototipo solo por funcionamiento visual.

6.4.2 SPINEPS y segmentación multi-estructura

SPINEPS, desarrollado por Möller et al., representa uno de los antecedentes más completos de segmentación espinal reciente [5]. El sistema propone un enfoque de dos fases para segmentación semántica e instancia de 14 estructuras espinales en imágenes T2 sagitales, incluyendo subestructuras vertebrales, discos intervertebrales, canal espinal, médula y sacro. El trabajo utiliza SPIDER y un subconjunto del German National Cohort para entrenamiento y evaluación.

SPINEPS demuestra que la segmentación multi-estructura de columna en RM sagital es técnicamente viable y puede apoyarse en código y modelos públicos. Sin embargo, su objetivo principal sigue siendo la segmentación. No está orientado a generar una salida editable para revisión radiológica ni a integrar mediciones cuantitativas simples en una plantilla de resultados. Por ello, es un antecedente fuerte para el módulo de segmentación, pero no cubre la totalidad del pipeline propuesto.

6.4.3 Clasificación degenerativa y sistemas complementarios

SpineNetV2 aborda el análisis de RM de columna desde una perspectiva complementaria: detección, etiquetado vertebral y gradación radiológica de discos intervertebrales [6, 7] (para una introducción a la anatomía de la columna lumbar y los discos intervertebrales, véase el Anexo B). Este enfoque es útil para contextualizar la automatización de la lectura lumbar, pero no equivale al objetivo del PFI. La salida principal de un sistema de clasificación es una categoría o grado; la salida principal requerida para el MVP es una máscara anatómica revisable desde la cual puedan derivarse mediciones.

La diferencia entre clasificación y segmentación es metodológicamente importante. La clasificación puede apoyar inferencias sobre estados degenerativos, mientras que la segmentación delimita regiones anatómicas. Para el PFI, las máscaras son imprescindibles porque habilitan visualización superpuesta, trazabilidad y cálculo de mediciones geométricas.

6.4.4 Segmentación axial sobre RM lumbar

La segmentación automática del plano axial constituye una línea de antecedentes parcialmente diferenciada de la sagital. Al-Kafri et al. [3] propusieron un pipeline de segmentación semántica basado en SegNet sobre cortes axiales T1 de los tres niveles discales inferiores, evaluando la delimitación de cuatro regiones (disco, elemento posterior, saco tecal y área entre elementos anterior y posterior) como base para la detección de estenosis lumbar. Posteriormente, Natalia et al. [8] extendieron este trabajo con un pipeline de medición automática de diámetro anteroposterior y anchos foraminales sobre las mismas máscaras axiales.

Estos antecedentes refuerzan dos puntos de diseño relevantes para el PFI. Primero, que la segmentación axial sobre estructuras lumbares es técnicamente viable con arquitecturas convolucionales estándar y datos públicos. Segundo, que las máscaras axiales habilitan un conjunto de mediciones cuantitativas distinto al sagital, particularmente aquellas que dependen de la sección transversal del canal y del saco tecal, mediciones que la literatura clínica considera más informativas que el diámetro anteroposterior aislado en presencia de cambios degenerativos posteriores.

6.4.5 Conclusión parcial sobre segmentación

Los antecedentes técnicos demuestran que la segmentación lumbar automática es factible y cuenta con modelos de referencia. La brecha no se encuentra en demostrar por primera vez que una red neuronal puede segmentar vértebras, discos o canales, sino en integrar esa capacidad en un prototipo funcional que conecte segmentación, medición, visualización y revisión profesional.

6.5 Mediciones cuantitativas derivadas de segmentaciones

Las máscaras de segmentación pueden emplearse como base para obtener mediciones geométricas, como alturas discales, áreas aproximadas, diámetros del canal y dimensiones vertebrales. Perumal et al. proponen un pipeline de aprendizaje profundo que mide de forma automática el diámetro anteroposterior del saco tecal en RM lumbar sagital, evidenciando el interés por reducir la subjetividad y la variabilidad entre observadores en las mediciones de estructuras espinales [9].

En el contexto del PFI, las mediciones no deben presentarse como inferencias diagnósticas autónomas. Deben formularse como salidas geométricas derivadas de máscaras, revisables por el profesional. Esta precisión evita confundir cuantificación anatómica con diagnóstico clínico. Por ejemplo, un diámetro del canal puede ser un dato cuantitativo útil, pero su interpretación como estenosis leve, moderada o severa excede el MVP si no existe validación clínica específica.

La revisión de antecedentes permite extraer tres criterios de diseño:

- Toda medición debe estar asociada a una estructura segmentada visible.
- Toda medición debe poder ser revisada, corregida o descartada por el usuario.
- La salida debe distinguir entre valor automático, valor revisado y eventual corrección manual.

Estos criterios conectan el estado del arte con el diseño del prototipo y con la validación cualitativa posterior.

6.6 Visualización, revisión profesional y salida estructurada

La utilidad de una segmentación médica no depende únicamente de sus métricas de solapamiento. Para un profesional, el resultado debe ser visualmente revisable, comprensible y modificable. En este sentido, la visualización superpuesta y la salida estructurada editable son componentes esenciales del flujo propuesto.

La revisión de productos comerciales muestra que el flujo «segmentar – medir – exportar resultados para revisión» ya existe en software médico. CoLumbo, por ejemplo, declara funcionalidades de segmentación, medición, etiquetado por umbrales y exportación de resultados para revisión, modificación y aprobación del usuario [10]. Esta evidencia es relevante porque confirma que las segmentaciones no se utilizan únicamente como resultado visual, sino como base para mediciones y documentación.

No obstante, en el PFI la salida estructurada debe mantenerse dentro de un alcance académico y no diagnóstico. Debe funcionar como plantilla editable derivada de estructuras y mediciones, no como informe clínico automático. La finalidad es documentar valores y facilitar revisión, no reemplazar el razonamiento del radiólogo o especialista.

6.7 Soluciones comerciales y regulatorias

Además de los antecedentes académicos, existen soluciones comerciales que abordan problemas cercanos al PFI. Su análisis no busca demostrar que el proyecto compite de igual a igual con productos clínicos, sino evidenciar que el problema tiene relevancia real y que el alcance académico debe diferenciarse con precisión.

6.7.1 CoLumbo

CoLumbo fue registrado ante la FDA como software de postprocesamiento y medición para imágenes DICOM de RM lumbar. Su documentación indica que provee mediciones cuantitativas, segmentación de características, etiquetado por umbrales y exportación de resultados a un reporte revisable por el usuario [10]. Además, declara explícitamente que no produce ni recomienda diagnóstico o tratamiento médico, y que el usuario debe revisar y aprobar los resultados.

Este producto es la referencia comercial más cercana al flujo funcional del PFI. Sin embargo, su naturaleza es distinta: se trata de software médico regulado y cerrado. El PFI no busca replicar su madurez clínica ni regulatoria, sino construir un prototipo académico reproducible que permita auditar datos, arquitectura, mediciones y validación.

6.7.2 MSKai

MSKai también fue registrado como software automatizado de procesamiento radiológico aplicado a RM lumbar T2 [11]. Su documentación lo vincula con identificación, segmentación, medición y exportación de resultados para revisión profesional. Esto confirma que la categoría tecnológica no es aislada y que existe más de una solución orientada a automatizar mediciones y reporte en columna lumbar.

La diferencia con el PFI reside nuevamente en el alcance. MSKai apunta a un entorno clínico comercial; el prototipo académico se limita a segmentación anatómica primaria, mediciones simples, visualización superpuesta y salida editable, sin diagnóstico autónomo ni certificación.

6.7.3 RemedyLogic AI MRI Lumbar Spine Reader

RemedyLogic AI MRI Lumbar Spine Reader (RAI) fue registrado como software de procesamiento radiológico automatizado para RM lumbar [12]. Su foco se relaciona con mediciones cuantitativas y asistencia a la revisión por usuarios calificados. Este antecedente refuerza que la automatización de mediciones lumbares constituye una línea real dentro del software médico.

RAI, al igual que los otros productos comerciales, opera como una solución cerrada de mercado. Para el PFI, su valor principal es contextual: confirma necesidad y madurez de la categoría, pero no reemplaza el aporte académico de construir un pipeline transparente y

reproducibile.

6.7.4 Prenuvo

Prenuvo opera servicios de resonancia magnética de cuerpo completo (whole-body MRI) con flujos de segmentación y reporte estructurado de hallazgos. En su práctica interna, las segmentaciones son revisadas por profesionales médicos en un esquema de triple chequeo, lo que evidencia una tendencia comercial hacia pipelines que combinan IA con revisión médica estratificada. Aunque no se trata de un dispositivo médico regulado por la FDA como CoLumbo, MSKai o RemedyLogic, su modelo operativo es relevante como referencia para el PFI: confirma la importancia de la calidad de los datos anotados como factor crítico del rendimiento del sistema, aspecto explícitamente señalado en el relevamiento profesional realizado para este proyecto.

6.7.5 Conclusión parcial sobre competencia

La existencia de CoLumbo, MSKai y RAI no invalida el proyecto. Por el contrario, confirma que el flujo de RM lumbar, segmentación, mediciones y salida revisable responde a una necesidad real. La diferencia es que estos productos son cerrados, comerciales y regulados, mientras que el PFI se formula como prototipo académico auditable. La Tabla 6.2 sintetiza esta comparación entre las cuatro soluciones comerciales o cuasi-comerciales relevadas y el alcance del PFI.

TABLA 6.2: Comparación entre soluciones comerciales y el alcance del PFI.

Solución	Naturaleza	Funcionalidades relevantes	Diferencia frente al PFI
CoLumbo	Software médico regulado	Segmentación, medición, etiquetado por umbrales y reporte revisable.	Producto cerrado y clínico. El PFI busca reproducibilidad académica, no certificación ni diagnóstico.
MSKai	Software médico regulado	Análisis de RM lumbar T2 con segmentación, medición y exportación de resultados.	Enfoque comercial. El PFI se limita a prototipo técnico validable sobre datos públicos.

Solución	Naturaleza	Funcionalidades relevantes	Diferencia frente al PFI
RemedyLogic RAI	Software médico regulado	Postprocesamiento y mediciones cuantitativas para revisión profesional.	Orientado a integración clínica. El PFI no contempla PACS/RIS ni uso clínico real.
Prenuvo	Servicio comercial de imagen + IA (no regulado como dispositivo médico)	Segmentación de cuerpo completo y reporte estructurado, con revisión médica en triple chequeo.	Servicio comercial cerrado y centrado en whole-body. El PFI es académico, acotado a lumbar y reproducible sobre datos públicos.
PFI propuesto	Prototipo académico	Segmentación sagital de vértebras, discos y canal sobre SPIDER; módulo axial complementario sobre los niveles L3/L4-L5/S1 con anotaciones nativas de Sudirman; mediciones simples derivadas de ambos planos; visualización superpuesta; salida editable.	Aporte centrado en integración reproducible, trazabilidad y validación técnica/cualitativa sobre dos planos de adquisición, sin diagnóstico autónomo ni integración hospitalaria.

6.8 Herramientas abiertas y sustitutos parciales

Además de los productos comerciales, existen herramientas abiertas que pueden resolver partes del problema. Plataformas como 3D Slicer permiten visualizar, segmentar y analizar imágenes médicas; frameworks como MONAI ofrecen componentes de entrenamiento, transformación y evaluación para inteligencia artificial médica; y visores DICOM o web como OHIF pueden servir como referencia para visualización.

Estas herramientas no reemplazan el PFI porque no integran por sí mismas el flujo específico propuesto. 3D Slicer es potente pero generalista; MONAI es un ecosistema de desarrollo, no un producto final para usuarios; OHIF es un visor extensible, no un motor de segmentación lumbar ni un generador de mediciones. Su valor para la tesis es técnico: pueden inspirar componentes o justificar decisiones de implementación, pero no constituyen una solución completa al problema definido.

6.9 Limitaciones detectadas en los antecedentes

La revisión permite identificar cinco limitaciones recurrentes:

- Foco aislado en segmentación. Muchos trabajos concluyen al reportar métricas como Dice o distancia de superficie, sin integrar resultados en una interfaz revisable o una salida editable.
- Reproducibilidad limitada. Parte de los antecedentes utiliza datasets privados o no publica todos los elementos necesarios para replicar entrenamiento y evaluación.
- Separación entre medición y revisión profesional. La literatura técnica suele derivar métricas, pero no siempre define cómo deben ser revisadas, corregidas o documentadas por el usuario.
- Productos cerrados. Las soluciones comerciales validan la necesidad, pero no permiten auditar completamente datos, modelos, reglas de medición o criterios internos.
- Foco predominantemente sagital. Los datasets públicos con segmentaciones de referencia se concentran históricamente en el plano sagital. La incorporación de Sudirman al relevamiento permite cubrir parcialmente esta limitación con un dataset axial anotado de 515 pacientes sobre los niveles donde se concentra la patología degenerativa, manteniendo la trazabilidad y la reproducibilidad académica.

Estas limitaciones no implican ausencia de avances, sino una oportunidad de integración académica. El PFI puede aportar valor al conectar componentes conocidos en un pipeline controlado, trazable y evaluable.

6.10 Brecha identificada y justificación del PFI

En la revisión realizada no se identificó un trabajo académico reproducible que combine simultáneamente los siguientes elementos dentro del mismo flujo funcional:

- Segmentación de vértebras, discos intervertebrales y canal espinal en RM lumbar sagital, con cobertura axial complementaria sobre los niveles discales inferiores.
- Extracción de mediciones geométricas simples derivadas de máscaras.
- Visualización superpuesta para revisión profesional.
- Salida estructurada editable, no diagnóstica.
- Validación técnica contra anotaciones expertas de un dataset público.
- Cobertura del plano axial mediante un módulo complementario validado sobre Sudirman, sin alterar la base sagital del MVP.
- Revisión cualitativa complementaria por profesional del área.

La brecha no se ubica en inventar una arquitectura de segmentación completamente nueva

ni en superar el estado del arte en una única métrica. El aporte está en integrar de forma acotada y reproducible componentes que la literatura y el mercado tratan de manera separada: dataset público, segmentación, mediciones, visualización, revisión y salida editable. La Tabla 6.3 detalla esta brecha funcional y los componentes que el PFI integra de forma conjunta.

TABLA 6.3: Brecha funcional que justifica el PFI.

Componente	Estado del arte relevado	Aporte esperado del PFI
Dataset público	SPIDER provee RM lumbar con máscaras de referencia.	Usarlo como base técnica para entrenamiento/evaluación del MVP.
Segmentación	nnU-Net y SPINEPS muestran viabilidad técnica.	Implementar o adaptar segmentación acotada a vértebras, discos y canales.
Mediciones	Existen trabajos sobre medición cuantitativa, a menudo con datos privados.	Derivar mediciones simples y trazables desde máscaras revisables.
Visualización	Herramientas abiertas y productos comerciales permiten la visualización.	Superponer máscaras y valores en una interfaz orientada a revisión.
Salida editable	Productos comerciales incluyen reportes revisables, pero cerrados.	Generar una plantilla académica simple, editable y no diagnóstica.
Validación	Papers priorizan métricas técnicas; productos priorizan uso clínico/regulatorio.	Combinar validación cuantitativa con revisión cualitativa profesional.
Cobertura de plano	SPIDER cubre sagital; Sudirman cubre axial con anotaciones nativas.	Integrar ambos planos en un pipeline único con módulo principal sagital y módulo axial complementario.

6.11 Matriz comparativa de antecedentes

Para sintetizar la revisión y facilitar la comparación directa entre los antecedentes analizados, la Tabla 6.4 resume cada trabajo según sus capacidades principales y su relación con el alcance del PFI. De este modo se evidencian las coincidencias, las diferencias y los aspectos que ningún antecedente cubre por completo.

TABLA 6.4: Síntesis de antecedentes y relación con el PFI.

Antecedente	Tipo	Datos	Tarea principal	Aporte al PFI	Limitación / Uso recomendado
SPIDER [1]	Dataset y benchmark	447 series; 218 pacientes; 4 hospitales.	Segmentación de vértebras, discos y canal espinal.	Base directa para entrenamiento y validación técnica.	No incluye interfaz, mediciones ni salida editable. Uso: dataset principal del MVP.
Al-Kafri et al. [3] / Sudirman	Dataset axial	515 pacientes; 1.545 máscaras axiales; T1/T2 sagital y axial, DICOM.	Segmentación axial de 4 ROIs (IVD, PE, TS, AAP) sobre L3/L4-L5/S1.	Habilita módulo axial complementario con máscaras nativas y T1/T2 co-registrados.	Anotaciones realizadas sobre T1; el co-registro DICOM permite transferir a T2. Uso: dataset axial complementario del MVP.
nnU-Net [4]	Método de segmentación	Múltiples datasets médicos.	Pipeline auto-configurable.	Baseline robusto para segmentación biomédica.	No es específico de la salida radiológica lumbar. Uso: referencia metodológica o baseline.
SPINEPS [5]	Sistema abierto	SPIDER + German National Cohort.	Segmentación semántica e instancia de 14 estructuras.	Demuestra viabilidad multi-estructura en RM sagital.	No genera plantilla editable ni flujo de revisión profesional. Uso: comparador técnico de segmentación.

Antecedente	Tipo	Datos	Tarea principal	Aporte al PFI	Limitación / Uso recomendado
LumbarDISC [2]	Dataset complementario	2.697 pacientes; 8.593 series.	Clasificación degenerativa por nivel.	Habilita la línea de hallazgos degenerativos por nivel y aporta un estudio DICOM real para validación técnica.	No es base de segmentación anatómica primaria. Uso: tercer dataset complementario; no reemplaza las bases de segmentación anatómica.
SpineNetV2 [6, 7]	Sistema académico	Dataset clínico privado.	Detección, etiquetado y gradación radiológica.	Antecedente de análisis lumbar automatizado.	Clasifica/gradúa; no entrega máscaras para mediciones del MVP. Uso: contexto, no base principal.
Perumal et al. [9]	Trabajo técnico	Propuesta técnica (revisada por pares).	Segmentación y medición cuantitativa.	Refuerza la viabilidad de medir estructuras espinales.	No resuelve salida editable ni validación del usuario. Uso: justificación del módulo de medición.
CoLumbo [10]	Producto regulado	RM lumbar DICOM.	Segmentación, medición y reporte revisable.	Valida relevancia comercial del flujo propuesto.	Producto cerrado y clínico. Uso: competencia directa.
MSKai [11]	Producto regulado	RM lumbar T2 DICOM.	Segmentación, medición y exportación de resultados.	Confirma la madurez de la categoría.	Software cerrado de uso clínico. Uso: competencia directa/regulatoria.

Antecedente	Tipo	Datos	Tarea principal	Aporte al PFI	Limitación / Uso recomendado
RemedyLogic RAI [12]	Producto regulado	RM lumbar DICOM.	Mediciones cuantitativas y revisión por usuario.	Referencia directa para mediciones revisables.	Integración clínica y entorno comercial. Uso: competencia directa/adyacente.

6.12 Análisis competitivo: matriz FODA y fuerzas de Porter

Las secciones anteriores relevaron antecedentes académicos, datasets, herramientas abiertas y soluciones comerciales. Esta sección organiza ese material mediante dos herramientas de análisis competitivo, con el objetivo de explicitar la posición del PFI frente a las alternativas existentes y las condiciones del entorno en el que se inscribe. El análisis no supone que el prototipo compita comercialmente con productos regulados, sino que delimita con precisión dónde aporta valor diferencial y qué factores condicionan su evolución.

6.12.1 Matriz FODA

TABLA 6.5: Matriz FODA del PFI.

Fortalezas	Debilidades
Reproducibilidad completa sobre datasets públicos anotados (SPIDER, Sudirman / Al-Kafri, RSNA / LumbarDISC), sin dependencia de datos clínicos privados.	Ausencia de certificación regulatoria y de validación clínica, que impide competir en el terreno donde operan las soluciones reguladas relevadas. La condición es coherente con el alcance académico declarado en el Capítulo 5.
Trazabilidad extremo a extremo entre imagen, máscara, medición, nivel anatómico y decisión profesional.	Sin integración con sistemas hospitalarios, PACS o RIS, lo que limita la inserción en flujos clínicos existentes.
Cobertura de dos planos de adquisición en un mismo flujo funcional, con módulo sagital principal y módulo axial complementario.	Los modelos sagital y axial se apoyan en datasets y conjuntos de clases distintos, sin registro validado entre secuencias.
Revisión profesional obligatoria por diseño: el sistema propone y el usuario acepta, corrige, observa o descarta.	El módulo axial no alcanza el umbral de calidad definido por el propio proyecto en la métrica que lo evalúa, y su artefact permanece registrado como candidato.

Fortalezas	Debilidades
Código, contratos, modelos y criterios de medición auditables, frente a productos comerciales cerrados.	Evaluación profesional limitada a dos sesiones de seguimiento con participantes del relevamiento inicial, sin evaluación independiente sobre el producto integrado.
Validación técnica cuantitativa contra anotaciones de referencia, complementada con revisión cualitativa profesional.	Recursos de cómputo limitados frente a los disponibles en desarrollos comerciales o de grandes consorcios.
Oportunidades	Amenazas
No se identificaron alternativas abiertas que integren segmentación, medición, visualización, revisión y salida editable en un mismo flujo; las herramientas existentes resuelven partes del problema.	Existencia de productos regulados que ya cubren el flujo en entornos clínicos: CoLumbo, MSKai y RemedyLogic AI MRI Lumbar Spine Reader.
Disponibilidad creciente de datasets públicos con segmentaciones de referencia, que reduce la barrera de entrada técnica.	Barrera regulatoria elevada para cualquier evolución hacia uso clínico, con procesos de autorización prolongados y costosos.
Necesidad comprobada en el relevamiento con profesionales, tanto cualitativo como cuantitativo.	Dependencia crítica de la calidad de las anotaciones de referencia, señalada como factor determinante del rendimiento en el relevamiento profesional.
Interés documentado en la reducción de la variabilidad entre observadores en mediciones de estructuras espinales.	Evolución rápida del estado del arte en segmentación espinal, que puede desactualizar decisiones técnicas del prototipo.
Posibilidad de evolucionar hacia comparación longitudinal descriptiva, línea no cubierta por las alternativas relevadas.	Sistemas académicos y abiertos con financiamiento sostenido que podrían ampliar su alcance hacia el flujo completo.

La lectura conjunta de la matriz indica que el diferencial del PFI no se ubica en el rendimiento algorítmico, donde los antecedentes ya demuestran viabilidad, sino en la integración auditable de componentes que la literatura y el mercado tratan por separado. Las debilidades identificadas son coherentes con un alcance académico declarado y no comprometen la validez de la prueba de concepto, siempre que el documento mantenga explícitos sus límites.

6.12.2 Fuerzas competitivas de Porter

TABLA 6.6: Análisis de las cinco fuerzas competitivas aplicado al PFI.

Fuerza	Intensidad	Fundamento y consecuencia para el proyecto
Rivalidad entre competidores	Alta en el segmento clínico, baja en el académico	Tres productos regulados y un servicio comercial cubren el flujo en entornos clínicos. Ninguno se presenta como prototipo académico reproducible, de modo que la rivalidad directa sobre el nicho del PFI es reducida.
Amenaza de nuevos entrantes	Media	La disponibilidad de datasets públicos y de métodos auto-configurables reduce la barrera técnica. La barrera regulatoria, en cambio, permanece alta para quien aspire a uso clínico.
Amenaza de productos sustitutos	Media-alta	La medición manual sobre visores DICOM sigue siendo el sustituto principal, y herramientas abiertas como 3D Slicer, MONAI y OHIF resuelven partes del flujo. Ninguna lo integra por completo.
Poder de negociación de proveedores	Bajo	Los insumos centrales son datasets con licencia abierta, frameworks de código abierto e infraestructura de nube intercambiable entre proveedores.
Poder de negociación de compradores	Alto	El profesional decide la adopción y el relevamiento mostró que condiciona su confianza a la transparencia del sistema y a la posibilidad de corregir cada resultado. Ese requisito, más que una preferencia, opera como condición de uso.

El resultado del análisis refuerza la estrategia adoptada. Frente a un poder de compradores elevado y a competidores cerrados, el diferencial sostenible del prototipo se apoya en la trazabilidad, la auditabilidad y la revisión humana obligatoria, atributos que las soluciones comerciales no exponen y que el relevamiento profesional identificó como determinantes de la confianza.

6.13 Conclusiones del estado del arte

El estado del arte muestra avances sólidos en segmentación automática de RM lumbar, disponibilidad creciente de datasets públicos y desarrollo de soluciones comerciales orientadas a medición y reporte asistido. Sin embargo, también evidencia que los componentes necesarios para el MVP suelen aparecer separados. Los datasets aportan anotaciones; los modelos generan máscaras; algunos trabajos derivan mediciones; y los productos comerciales integran flujos cerrados de revisión.

El PFI se justifica al integrar esos componentes en un prototipo académico acotado, reproducible y revisable: segmentación de estructuras lumbares principales sobre el plano sagital, módulo axial complementario sobre los niveles discales inferiores, mediciones cuantitativas simples derivadas de ambos planos, visualización superpuesta y salida editable bajo control profesional. La incorporación de Sudirman al relevamiento amplía la cobertura prevista en la propuesta inicial sin modificar su núcleo: SPIDER continúa siendo la base principal del MVP y la decisión metodológica de evitar diagnóstico autónomo se mantiene intacta. La existencia de CoLumbo, MSKai, Prenuvo y RAI confirma la relevancia del problema, pero no reemplaza el proyecto porque su naturaleza es comercial, cerrada y regulatoria. El aporte de la tesis se ubica en la trazabilidad técnica, la validación con datos públicos sobre dos planos de adquisición y la construcción de un flujo funcional sin diagnóstico autónomo.

7 Marco teórico

7.1 Propósito y alcance del marco teórico

Este capítulo desarrolla los conceptos necesarios para comprender y justificar el diseño del prototipo propuesto. A diferencia del estado del arte, cuyo objetivo es relevar antecedentes, datasets, algoritmos y soluciones existentes, el marco teórico establece las bases conceptuales sobre las cuales se apoya el proyecto: la resonancia magnética lumbar como modalidad de imagen, las estructuras anatómicas de interés, la representación computacional de imágenes médicas, los fundamentos de segmentación, los modelos de aprendizaje profundo, las métricas de evaluación, las mediciones cuantitativas derivadas y el rol asistivo de la inteligencia artificial en el flujo profesional.

El alcance teórico se mantiene alineado con el objetivo del PFI: desarrollar un prototipo funcional que analice resonancias magnéticas lumbares en los planos sagital y axial, segmente vértebras, discos intervertebrales y canal espinal, extraiga mediciones cuantitativas acotadas, permita visualización superpuesta y genere una salida estructurada editable revisable por el profesional. En consecuencia, no se abordan en profundidad tareas clínicas que quedan fuera del MVP, tales como diagnóstico autónomo, clasificación integral de patologías degenerativas, integración hospitalaria completa, certificación regulatoria o validación clínica multicéntrica.

Idea guía del marco teórico. Una RM lumbar puede representarse computacionalmente como una imagen médica con información espacial; sus estructuras anatómicas pueden delimitarse mediante segmentación; esas segmentaciones pueden compararse contra anotaciones de referencia mediante métricas objetivas; y, a partir de ellas, pueden derivarse mediciones geométricas revisables por un profesional, sin convertir el sistema en una herramienta de diagnóstico autónomo.

7.2 Resonancia magnética lumbar

7.2.1 Principio general de la resonancia magnética

La resonancia magnética (RM) es una modalidad de imagen médica no invasiva basada en el fenómeno de resonancia magnética nuclear. En términos generales, los protones de hidrógeno presentes en los tejidos son alineados por un campo magnético externo y excitados mediante pulsos de radiofrecuencia. La señal emitida durante el retorno al estado de equilibrio es captada por bobinas receptoras y procesada para construir imágenes con alto contraste de tejidos blandos [13, 14].

A diferencia de la tomografía computada y de la radiografía convencional, la RM no utiliza radiación ionizante. Esta característica resulta especialmente relevante en estudios muscu-

loesqueléticos y neurológicos, donde puede ser necesario repetir controles o analizar estructuras blandas con alto contraste. En el caso de la columna lumbar, la RM permite observar cuerpos vertebrales, discos intervertebrales, canal espinal, saco dural, raíces nerviosas y tejidos adyacentes con mayor detalle que otras modalidades para ciertas indicaciones clínicas [15, 16].

7.2.2 Secuencias T1 y T2 en columna lumbar

Las imágenes de RM se adquieren mediante secuencias de pulsos que modifican el contraste observado entre tejidos. En la evaluación lumbar, las secuencias ponderadas en T1 y T2 son particularmente relevantes:

- Secuencia T1 ponderada: proporciona buen contraste anatómico de estructuras óseas y médula ósea. Los tejidos con contenido graso tienden a presentar señal alta.
- Secuencia T2 ponderada: resalta líquidos y tejidos con mayor contenido de agua. El líquido cefalorraquídeo y el núcleo pulposo de discos sanos suelen observarse con señal alta, lo que facilita la evaluación de morfología discal y canal espinal [15].
- Secuencia STIR (Short Tau Inversion Recovery): suprime la señal grasa y resalta tejidos con edema. Se utiliza habitualmente como complemento a T1 y T2 para detectar cambios óseos activos (por ejemplo, Modic tipo 1) y procesos inflamatorios. El MVP no la incorpora porque ninguno de los dos datasets base se centra en STIR, pero su existencia se documenta como complemento clínico habitual.

El dataset SPIDER, definido como fuente principal del MVP, incluye series sagitales T1 y T2 de columna lumbar con segmentaciones de referencia para vértebras, discos intervertebrales y canal espinal [1]. Por ello, el marco teórico se concentra en estas secuencias y en este plano de adquisición.

7.2.3 Planos sagital y axial

El plano sagital divide el cuerpo en porciones izquierda y derecha. En columna lumbar, las imágenes sagitales permiten visualizar en una misma serie múltiples niveles vertebrales, la continuidad del canal espinal y la morfología de los discos intervertebrales. Este plano resulta adecuado para tareas de segmentación anatómica primaria porque muestra de forma simultánea las estructuras previstas en el alcance del prototipo.

Alcance operativo. El prototipo opera sobre RM lumbar con el plano sagital como base anatómica principal y un módulo axial complementario sobre los niveles discales inferiores. Esta decisión no implica que otros planos o modalidades carezcan de valor clínico, sino que acota el problema a un escenario compatible con los datasets públicos disponibles y con una validación técnica reproducible.

Incorporación del plano axial como módulo complementario. Si bien el alcance original

del prototipo se definió sobre RM lumbar sagital, el relevamiento del estado del arte identificó un dataset adicional (Sudirman et al., 2019) con anotaciones axiales nativas para los tres niveles discuales inferiores. La práctica clínica habitual combina sagital con axial T2 para evaluar canal espinal, forámenes neurales y compresión radicular en sección transversal. La incorporación de un módulo axial complementario, sobre los niveles L3/L4, L4/L5 y L5/S1, permite cubrir parcialmente este complemento sin modificar el núcleo sagital del MVP.

La verificación técnica de los headers DICOM del dataset Sudirman confirmó que sus secuencias T1 axial y T2 axial del mismo paciente comparten pixel spacing (0,6875 mm), slice thickness (4 mm) y posición espacial prácticamente idénticas, lo que evidencia un co-registro nativo entre ambas. Esta propiedad permite utilizar las máscaras anotadas sobre T1 para entrenamiento sobre T2, dado que la geometría volumétrica es coincidente. El plano axial se considera, en consecuencia, plano complementario de adquisición y no plano principal: la base anatómica del prototipo y la mayor parte de la validación técnica continúan apoyándose en SPIDER sagital.

7.3 Anatomía lumbar relevante para el prototipo

7.3.1 Organización general de la región lumbar

La columna vertebral se organiza en regiones cervical, torácica, lumbar, sacra y coccígea. La región lumbar está compuesta habitualmente por cinco vértebras, denominadas L1 a L5, aunque pueden existir variantes anatómicas como vértebras transicionales. Esta región soporta gran parte de la carga axial del cuerpo y participa en movimientos de flexión, extensión, inclinación lateral y rotación limitada [17].

La lumbalgia representa una de las principales causas de discapacidad a nivel mundial y se asocia a una carga sanitaria y socioeconómica considerable [18]. Sin embargo, el presente proyecto no busca diagnosticar causas de dolor lumbar, sino asistir el análisis estructural de RM lumbar mediante segmentación y mediciones geométricas revisables.

7.3.2 Estructuras anatómicas de interés

El MVP se concentra en tres estructuras anatómicas, seleccionadas por su presencia en SPIDER y por su utilidad para mediciones morfométricas básicas.

Cuerpos vertebrales

Los cuerpos vertebrales son las porciones anteriores y principales de las vértebras. En RM sagital pueden delimitarse como estructuras óseas de morfología relativamente regular. Su segmentación permite identificar niveles anatómicos y derivar mediciones geométricas como área proyectada, altura relativa o relaciones con estructuras adyacentes. Para el prototipo, estas mediciones se consideran descriptores geométricos, no indicadores diagnósticos autónomos.

Discos intervertebrales

Los discos intervertebrales se ubican entre cuerpos vertebrales consecutivos. Están compuestos por un núcleo pulposo central y un anillo fibroso periférico. En secuencias T2, los discos con mayor contenido hídrico suelen presentar señal alta, mientras que la degeneración discal puede asociarse a pérdida de señal y reducción de altura [15]. La segmentación de discos permite estimar alturas relativas, áreas proyectadas y relaciones entre niveles.

Canal espinal y saco dural

El canal espinal corresponde al espacio anatómico contenido dentro de la columna vertebral por el que transcurren el saco dural y las estructuras neurales. En la región lumbar inferior, estrictamente, no se observa médula espinal en todos los niveles, sino raíces de la cauda equina dentro del saco dural. Por ello, en el contexto del prototipo se utiliza la denominación canal espinal como región operativa segmentada según las anotaciones del dataset, evitando atribuirle significado diagnóstico por sí misma.

Estructuras adicionales contempladas en el módulo axial. El dataset Sudirman incluye en sus anotaciones axiales dos estructuras adicionales que no figuran en SPIDER: los elementos posteriores de la vértebra (apófisis articulares, láminas y procesos espinosos) y el área entre elementos anterior y posterior (AAP). Estas estructuras son particularmente relevantes para el módulo axial porque su hipertrofia es una causa frecuente de estenosis del canal en plano transversal, situación en la que el diámetro anteroposterior puede permanecer dentro de rangos normales mientras el área del canal se reduce significativamente. La cauda equina, conjunto de raíces nerviosas que ocupa el canal lumbar por debajo del cono medular, no se segmenta directamente en el MVP pero su evaluación visual queda implícita en la inspección del saco tecal.

Definición operativa de canal espinal. En este proyecto, el canal espinal se entiende como la región anatómica marcada en el dataset de referencia y visible en la serie sagital. Su segmentación permite derivar mediciones geométricas de apoyo, como área proyectada o dimensiones relativas, pero no constituye por sí sola diagnóstico de estenosis.

7.4 Representación computacional de imágenes médicas

7.4.1 Imagen médica como matriz con metadatos

Una imagen médica digital no equivale a una fotografía convencional. Además de una matriz de intensidades, incluye información espacial, orientación anatómica, resolución, espaciado entre píxeles o vóxeles (el vóxel es la unidad mínima de una imagen tridimensional: el equivalente al píxel pero con volumen, ya que representa un pequeño bloque del espacio en lugar de un punto en un plano), parámetros de adquisición y metadatos asociados al estudio. Esta información es necesaria para interpretar correctamente distancias, áreas y relaciones anatómicas.

En procesamiento de RM, dos imágenes con igual tamaño en píxeles pueden representar regiones físicas diferentes si su spacing no coincide. Por eso, cualquier medición derivada de una máscara debe convertir píxeles o vóxeles a unidades físicas cuando la información de espaciado está disponible.

7.4.2 Formatos DICOM y NifTI

DICOM es el estándar dominante en entornos clínicos para almacenar, transmitir y visualizar imágenes médicas [19]. Incluye tanto la imagen como metadatos de paciente, estudio, serie, modalidad y adquisición. En investigación, también es frecuente utilizar formatos como NifTI, que simplifican el manejo de volúmenes y máscaras segmentadas [20].

Para el PFI, estos conceptos justifican una etapa de carga y normalización antes de aplicar modelos de segmentación. Dicha etapa debe preservar orientación, espaciado e integridad espacial de las máscaras, ya que cualquier alteración puede afectar la validez de las mediciones geométricas.

7.4.3 Normalización y preprocesamiento

Las intensidades en RM no están estandarizadas de forma absoluta como ocurre en tomografía computada con unidades Hounsfield. Diferentes equipos, protocolos y centros pueden producir distribuciones de intensidad distintas. Por ello, los modelos de segmentación suelen requerir preprocesamiento, como normalización de intensidades, recorte de región de interés, remuestreo espacial, reorientación y aumento de datos [21, 4].

7.5 Segmentación de imágenes médicas

7.5.1 Definición

La segmentación es el proceso computacional mediante el cual se asigna una etiqueta a cada píxel o vóxel de una imagen para indicar la estructura o clase anatómica a la que pertenece [22]. En imágenes médicas, el resultado se representa habitualmente mediante una máscara binaria o multiclase.

En este proyecto, la segmentación permite transformar una RM lumbar en una representación estructurada: regiones correspondientes a vértebras, discos intervertebrales y canal espinal. Esa representación es el insumo para visualización superpuesta, validación técnica y mediciones geométricas.

7.5.2 Tipos de segmentación relevantes

- Segmentación semántica: asigna una clase a cada píxel o vóxel, por ejemplo vértebra, disco o canal. No distingue instancias individuales dentro de una misma clase.

- Segmentación de instancias: diferencia cada ocurrencia anatómica, por ejemplo L1, L2 o disco L4-L5. Es útil cuando las mediciones deben asociarse a un nivel específico.
- Segmentación multiclase: asigna distintas clases anatómicas dentro de una misma máscara o volumen de etiquetas. Es el caso más directamente vinculado al MVP.

La formulación que unifica la segmentación semántica con la de instancias se conoce en la literatura como segmentación panóptica [23].

Para el prototipo, resulta necesario identificar estructuras y, cuando sea posible, vincularlas a niveles anatómicos. La identificación por nivel puede resolverse como parte de la segmentación, mediante postprocesamiento o mediante reglas de ordenamiento anatómico, dependiendo de la implementación.

7.5.3 Desafíos en RM lumbar

La segmentación lumbar presenta dificultades específicas:

- Bordes difusos: los límites entre discos, cuerpos vertebrales y tejidos adyacentes pueden no ser nítidos, especialmente en degeneración avanzada.
- Variabilidad anatómica: variantes como vértebras transicionales, escoliosis o espondilolistesis dificultan reglas rígidas de localización.
- Variabilidad de adquisición: distintos centros, equipos, secuencias y parámetros generan cambios de contraste e intensidad.
- Diferencias de tamaño entre clases: estructuras grandes y pequeñas pueden estar desbalanceadas, afectando el entrenamiento y la evaluación.
- Calidad de imagen: artefactos de movimiento, cortes incompletos o ruido pueden degradar la precisión del modelo.

Estos desafíos explican por qué la segmentación médica requiere modelos robustos, validación por estructura y revisión profesional.

7.6 Aprendizaje supervisado y anotaciones de referencia

7.6.1 Concepto de ground truth

En aprendizaje supervisado, el modelo aprende a partir de pares de entrada y salida: una imagen y su correspondiente máscara de referencia. Esta máscara, generalmente elaborada o revisada por expertos, funciona como ground truth técnico. En el contexto del PFI, el ground truth permite entrenar o ajustar modelos y evaluar objetivamente el resultado mediante métricas cuantitativas.

SPIDER es central porque provee RM lumbares sagitales con segmentaciones de referencia de las estructuras previstas en el MVP [1]. Esto evita depender de datos clínicos privados

para la primera etapa de desarrollo y permite una validación reproducible.

7.6.2 Entrenamiento, validación y prueba

Un pipeline supervisado suele dividir los datos en subconjuntos de entrenamiento, validación y prueba. El entrenamiento ajusta los parámetros del modelo; la validación permite seleccionar hiperparámetros y evitar sobreajuste; y la prueba estima el desempeño sobre datos no vistos. Para una tesis de desarrollo, esta separación debe documentarse con claridad, especialmente si se realizan transformaciones o aumentos de datos.

7.7 Modelos de aprendizaje profundo para segmentación

7.7.1 Redes neuronales convolucionales

Las redes neuronales convolucionales (CNN) son modelos especialmente adecuados para imágenes porque utilizan filtros locales que detectan patrones espaciales en distintas escalas. En imágenes médicas, las CNN han demostrado utilidad en tareas de clasificación, detección y segmentación, especialmente cuando se dispone de anotaciones suficientes o de estrategias de aumento de datos [24, 21].

7.7.2 Arquitecturas encoder-decoder

La segmentación requiere una predicción densa: una etiqueta para cada píxel o vóxel. Las arquitecturas encoder-decoder resuelven este problema reduciendo primero la resolución para extraer contexto y reconstruyéndose luego para generar una máscara. Las conexiones de salto permiten recuperar detalles espaciales perdidos durante la codificación.

7.7.3 U-Net

U-Net es una arquitectura encoder-decoder propuesta para segmentación biomédica con conjuntos de datos relativamente pequeños [25]. Su estructura en forma de U y sus conexiones de salto la convirtieron en una arquitectura de referencia para segmentación médica. En el marco del PFI, U-Net representa una base conceptual clara para explicar cómo un modelo puede transformar una imagen de RM en una máscara anatómica.

7.7.4 nnU-Net

nnU-Net es un método auto-configurable que adapta preprocesamiento, arquitectura, configuración de entrenamiento y postprocesamiento a las propiedades de cada dataset [4]. Su importancia teórica radica en que no propone simplemente una nueva red, sino un pipeline completo de segmentación biomédica. Por eso resulta relevante como baseline metodológico para tareas como SPIDER.

7.7.5 Attention U-Net y modelos híbridos CNN-Transformer

Attention U-Net incorpora mecanismos de atención que permiten ponderar regiones relevantes durante la reconstrucción de la máscara [26]. Por otra parte, los modelos basados en Transformers y variantes híbridas CNN-Transformer buscan capturar relaciones globales de la imagen, complementando la capacidad local de las convoluciones [27]. Estas variantes amplían el marco conceptual, aunque el MVP no depende necesariamente de implementarlas.

7.7.6 Frameworks especializados en imagen médica

Frameworks como MONAI ofrecen componentes específicos para IA médica: transformaciones, funciones de pérdida, métricas, carga de datos, inferencia por ventanas y flujos reproducibles [28]. Su relevancia para el marco teórico no es solo técnica, sino metodológica: permiten construir pipelines más controlables que una implementación completamente manual.

Vinculación con el MVP. El proyecto no requiere crear una arquitectura nueva de segmentación para ser válido. Su aporte se ubica en integrar un modelo entrenable o ajustable con preprocesamiento, validación técnica, mediciones derivadas, visualización superpuesta y salida editable revisable.

7.8 Mediciones cuantitativas derivadas de máscaras

7.8.1 Máscaras como base geométrica

Una máscara de segmentación no es únicamente una salida visual. También constituye una representación geométrica de una estructura. A partir de ella pueden derivarse áreas, alturas, anchos, centroides, distancias o relaciones entre estructuras, siempre que se respete la información espacial de la imagen.

7.8.2 Mediciones posibles en RM lumbar

En el alcance del MVP, las mediciones deben ser simples, trazables y derivables directamente de las máscaras. Ejemplos adecuados son:

- Área proyectada de una estructura: cantidad de píxeles o vóxeles de una máscara convertida a unidades físicas.
- Altura relativa de discos intervertebrales: medida geométrica derivada de la extensión del disco en el plano sagital.
- Dimensiones relativas del canal espinal en el plano sagital: medidas de apoyo basadas en la máscara del canal, sin asumir diagnóstico de estenosis.
- Comparación entre niveles: relación entre valores obtenidos en distintos segmentos lumbares, útil como apoyo descriptivo.

- Área del saco tecal en sección transversal axial: medición derivada del módulo axial sobre los niveles L3/L4 a L5/S1, considerada en la literatura más sensible a estenosis que el diámetro anteroposterior aislado, especialmente cuando existen cambios degenerativos posteriores que reducen el diámetro transversal del canal sin afectar el AP [29].
- Anchos foraminales aproximados sobre cortes axiales: medición de apoyo derivada de la segmentación de elementos posteriores y del área entre elementos anterior y posterior, según el pipeline antecedente de Natalia et al. [8].

7.8.3 Límites clínicos de las mediciones

Es fundamental distinguir entre una medición geométrica y una conclusión clínica. Una medida calculada desde una máscara puede ser objetiva desde el punto de vista computacional, pero su interpretación clínica requiere revisión profesional, contexto del paciente y validación específica. Por ello, el prototipo presenta mediciones como información de apoyo, no como diagnóstico ni como recomendación terapéutica.

Corrección conceptual clave. En RM sagital, el área calculada de una región segmentada es una medida proyectada en el plano de la imagen. No debe confundirse automáticamente con un área transversal clínica del canal espinal, salvo que la adquisición y el método de medición estén definidos para ese fin.

7.9 Métricas de evaluación de segmentación

7.9.1 Necesidad de evaluación cuantitativa

La evaluación de un modelo de segmentación requiere comparar la máscara predicha con una máscara de referencia. Ninguna métrica aislada captura todos los errores posibles; por eso se recomienda combinar métricas de solapamiento con métricas de distancia o superficie [30, 31].

Sea P la máscara predicha y G la máscara de referencia.

7.9.2 Coeficiente Dice

El coeficiente Dice o Dice Similarity Coefficient (DSC) mide la superposición entre dos máscaras:

$$DSC(P, G) = \frac{2 \cdot |P \cap G|}{|P| + |G|} \quad (7.1)$$

Su valor se encuentra entre 0 y 1, donde 1 indica coincidencia perfecta. Es una métrica ampliamente utilizada en segmentación médica, aunque puede ser menos sensible a errores de borde en estructuras grandes.

7.9.3 Intersección sobre Unión

La Intersección sobre Unión, también conocida como índice de Jaccard, se define como:

$$IoU(P, G) = \frac{|P \cap G|}{|P \cup G|} \quad (7.2)$$

Penaliza con mayor severidad las discrepancias entre predicción y referencia. Dice e IoU están relacionados matemáticamente, pero no son idénticos.

7.9.4 Distancia de Hausdorff y HD95

La distancia de Hausdorff mide discrepancias entre los bordes de dos máscaras. En imágenes médicas suele utilizarse la versión percentil 95 (HD95), que reduce la sensibilidad a outliers extremos:

$$HD95(P, G) = \max(p95(d(P, G)), p95(d(G, P))) \quad (7.3)$$

donde $d(P, G)$ representa distancias mínimas desde puntos de borde de P hacia G , y $p95$ el percentil 95.

7.9.5 Normalized Surface Dice

La métrica Normalized Surface Dice (NSD) mide qué proporción de la superficie predicha se encuentra dentro de una tolerancia espacial respecto de la referencia. Resulta útil cuando la precisión del contorno es más importante que el volumen o área total [31].

7.9.6 Interpretación responsable de métricas

Valores altos de Dice no garantizan por sí solos utilidad clínica. Un modelo puede obtener buen solapamiento global y aun así fallar en una región anatómicamente crítica. Por eso, el PFI combina validación técnica cuantitativa con revisión cualitativa profesional de plausibilidad anatómica, legibilidad visual y utilidad de mediciones.

7.10 Visualización, interacción y salida estructurada

7.10.1 Visualización superpuesta

La utilidad de un sistema de segmentación no depende solo del desempeño algorítmico. El profesional debe poder revisar la imagen original y la máscara generada de forma clara. La visualización superpuesta permite detectar errores de contorno, estructuras omitidas, etiquetas incorrectas o segmentaciones anatómicamente improbables.

Para el prototipo, la interfaz debería permitir activar o desactivar estructuras, distinguir clases por color, revisar niveles lumbares y observar mediciones asociadas a cada máscara. Esta

capa de interacción es parte central del sistema, porque mantiene al usuario experto dentro del circuito de validación.

La centralidad de la revisión visual fue confirmada en el relevamiento profesional preliminar realizado para el proyecto: la mayoría del flujo del radiólogo se procesa por la vía visual, y una segmentación que no pueda contrastarse cómodamente contra la imagen original pierde valor operativo, independientemente de sus métricas técnicas. En particular, el módulo axial debe presentar las cuatro regiones de interés diferenciadas por color (disco, elemento posterior, saco tecal, AAP) sobre el corte axial original, permitiendo al profesional verificar visualmente la plausibilidad de la segmentación nivel por nivel.

7.10.2 Salida estructurada editable

La salida estructurada editable organiza los resultados del sistema en un formato revisable. Puede incluir estructura anatómica, nivel, medición, unidad, estado de revisión, advertencias de baja confianza y observaciones del profesional. No debe presentarse como informe clínico automático, sino como plantilla de apoyo.

La editabilidad es un requisito de seguridad y usabilidad: permite corregir errores, descartar mediciones, completar observaciones y evitar que el sistema imponga una interpretación automática.

El relevamiento preliminar con profesional del área confirmó que la posibilidad de aceptar o corregir manualmente cada estructura segmentada y cada medición derivada es un requisito de uso, no una funcionalidad opcional. La cita registrada en el relevamiento, «si se ve bonito no es lo que realmente importa», sintetiza este principio: una herramienta de apoyo se evalúa por su utilidad operativa y su capacidad de ser revisada, no por su estética.

7.10.3 Trazabilidad

La trazabilidad implica que cada resultado pueda vincularse con su origen: imagen, máscara, estructura, medición y eventual corrección profesional. En el PFI, esto significa que una medición no debería aparecer aislada, sino asociada a la máscara de la que proviene y al nivel anatómico correspondiente.

7.10.4 Generación de preinformes estructurados

Una salida estructurada puede presentarse como un conjunto de campos o como un texto redactado a partir de esos campos. La segunda forma, denominada preinforme, se construye mediante plantillas que combinan valores derivados de las máscaras con formulaciones fijas asociadas a cada estructura, nivel y medición. El texto resultante no proviene de un modelo de lenguaje ni de una inferencia clínica, sino de una transformación determinística de datos geométricos ya calculados y visibles. Esta distinción no impide que el producto incluya un chat

contextual como asistencia separada: dicho chat se apoya en una abstracción de proveedor LLM y, en Demo Mode, en un mock determinístico; no reemplaza el reporte estructurado ni genera diagnóstico.

Esta distinción es conceptualmente relevante. Un preinforme derivado de plantillas es reproducible y auditable: dado un mismo conjunto de máscaras y mediciones, produce siempre el mismo texto, y cada afirmación puede rastrearse hasta la estructura y el corte que la originan. Un informe generado por inferencia lingüística, en cambio, introduce una capa interpretativa que no es verificable estructura por estructura.

En el alcance del prototipo, el preinforme funciona como punto de partida editable para la revisión profesional, no como informe clínico. Su valor es operativo: reduce la transcripción manual de valores y organiza la información en un orden anatómico previsible, mientras la redacción final, la interpretación y la responsabilidad permanecen en el profesional.

7.11 Inteligencia artificial asistiva y rol profesional

7.11.1 Sistemas de apoyo a la decisión clínica

Un sistema de apoyo a la decisión clínica (Clinical Decision Support System, CDSS) es una herramienta informática que presenta información relevante para asistir al profesional en una tarea de salud [32]. En imágenes médicas, estos sistemas pueden ofrecer segmentaciones, mediciones, alertas o visualizaciones, pero su grado de autonomía determina sus implicancias clínicas y regulatorias.

7.11.2 Humano en el circuito

El prototipo se ubica en un enfoque human-in-the-loop: el sistema procesa la imagen y propone resultados, pero el profesional revisa, acepta, corrige o descarta dichos resultados. Esta decisión reduce el riesgo de automatización excesiva y es coherente con el alcance académico del proyecto.

7.11.3 Diferencia entre asistencia y diagnóstico autónomo

El PFI no emite diagnósticos autónomos, no recomienda tratamientos y no reemplaza la interpretación médica. Su función es automatizar tareas operativas de segmentación, medición, visualización y documentación. El producto puede generar un conjunto acotado de hallazgos degenerativos por nivel, siempre sujetos a revisión profesional y sin exponer probabilidades al usuario final; estos hallazgos se presentan como observaciones asistivas sobre estructuras segmentadas, no como una clasificación diagnóstica, y no sustituyen la gradación radiológica del profesional. Esta distinción es esencial para evitar sobreprometer capacidades clínicas y para mantener el prototipo dentro de un alcance técnicamente validable.

7.12 Privacidad, ética y límites normativos

Las imágenes médicas son datos sensibles. Aun cuando el MVP utilice datasets públicos anotados, cualquier trabajo futuro con estudios no públicos debería contemplar anonimización, minimización de datos, resguardo de metadatos y consentimiento cuando corresponda. En Argentina, este tratamiento debe considerar la Ley N.º 25.326 de Protección de Datos Personales y el artículo 53 del Código Civil y Comercial vinculado al derecho a la imagen [33, 34].

En el alcance actual, la principal medida ética es trabajar con datos públicos o debidamente anonimizados, no solicitar datos identificables de pacientes y comunicar con claridad que la herramienta no reemplaza al profesional.

7.13 Síntesis conceptual

La Tabla 7.1 resume los conceptos desarrollados y su vinculación con el prototipo.

TABLA 7.1: Síntesis del marco teórico y vinculación con el PFI.

Concepto	Papel dentro del proyecto	Componente asociado
RM lumbar sagital y axial	Modalidad y planos sobre los cuales opera el MVP.	Entrada del sistema
T1 / T2	Secuencias contempladas por el dataset principal.	Normalización de datos
Vértebras, discos y canal espinal	Estructuras anatómicas delimitadas por el modelo.	Segmentación
Imagen médica con metadatos	Justifica preservar orientación, espaciado y resolución.	Carga y preprocesamiento
Segmentación multiclase	Permite generar máscaras por estructura anatómica.	Modelo IA
Ground truth	Anotaciones de referencia usadas para entrenamiento y validación.	Dataset SPIDER
U-Net / nnU-Net	Bases metodológicas para segmentación biomédica.	Arquitectura / baseline
Dice, IoU, HD95, NSD	Métricas para evaluar solapamiento y precisión de bordes.	Validación técnica
Mediciones morfométricas	Valores geométricos derivados de máscaras.	Módulo cuantitativo

Concepto	Papel dentro del proyecto	Componente asociado
Visualización superpuesta	Permite revisión visual por el profesional.	Interfaz
Salida editable	Organiza resultados sin generar diagnóstico automático.	Plantilla revisable
IA asistiva	Define el rol del sistema como apoyo operativo.	Alcance clínico
Privacidad y anonimización	Enmarca el uso responsable de datos médicos.	Ética y normativa
Plano axial complementario	Cobertura transversal sobre niveles L3/L4-L5/S1.	Módulo axial sobre Sudirman
Co-registro DICOM T1-T2	Permite usar máscaras T1 para entrenamiento sobre T2.	Preprocesamiento axial

7.14 Conclusión del marco teórico

El marco teórico fundamenta la viabilidad conceptual del PFI. La RM lumbar proporciona imágenes adecuadas para observar vértebras, discos intervertebrales y canal espinal en el plano sagital, y para complementar ese análisis con la sección transversal de los niveles discales inferiores en el plano axial. La segmentación médica permite transformar esas imágenes en máscaras anatómicas evaluables, y los modelos de aprendizaje profundo ofrecen una vía técnica para automatizar esa tarea a partir de datos anotados. Las métricas de segmentación permiten validar objetivamente el desempeño del modelo, mientras que las mediciones morfométricas derivadas de las máscaras aportan una salida cuantitativa trazable.

Adicionalmente, en una primera instancia de relevamiento cualitativo con profesional especializado en neurorradiología, no se identificaron objeciones de fondo al planteo del proyecto. El enfoque «segmentación + mediciones simples + revisión humana» fue evaluado como clínicamente razonable. El relevamiento técnico complementario derivó en la incorporación del dataset Sudirman como base para un módulo axial complementario, que amplía la cobertura del prototipo a los niveles discales inferiores en sección transversal sin modificar el módulo sagital principal sobre SPIDER. Esta ampliación responde a un hallazgo legítimo del estado del arte y se mantiene dentro de la lógica acotada y reproducible del MVP original.

El valor del prototipo no reside en reemplazar al profesional ni en emitir diagnósticos, sino en integrar estos conceptos en un flujo revisable: imagen de entrada, segmentación, medición, visualización, salida editable y validación. Esta base conceptual sostiene el desarrollo de una herramienta académica, acotada, reproducible y alineada con el alcance definido para el Proyecto Final de Ingeniería.

8 User research, elicitación y análisis preliminar de requerimientos

8.1 Propósito del capítulo

Este capítulo interpreta el relevamiento realizado con profesionales de diagnóstico por imágenes y lo transforma en insumo de producto, siguiendo la cadena entrevistas, hallazgos, necesidades, requerimientos y épicas. El registro textual de las entrevistas se conserva en el Anexo D. No constituye una validación clínica: documenta una etapa exploratoria y justifica decisiones de alcance que el Capítulo 9 formaliza.

8.2 Diseño del relevamiento

El relevamiento se organizó mediante entrevistas semiestructuradas, técnica recomendada en las etapas exploratorias del diseño centrado en el usuario porque combina la comparabilidad de una guía común con la posibilidad de profundizar en aspectos no previstos [35]. Se utilizó una guía común de preguntas, pero se permitió repreguntar y profundizar según la experiencia de cada profesional. El objetivo no fue validar clínicamente un sistema terminado, sino identificar criterios tempranos de utilidad, confianza, alcance y riesgo para orientar el diseño del MVP.

Ejes de entrevista y objetivos:

- Flujo actual de trabajo. Comprender cómo se revisa una RM lumbar y cómo se llega al informe.
- Planos y secuencias. Identificar el rol del plano sagital, axial, coronal y de secuencias como T1, T2 o STIR.
- Hallazgos relevantes. Detectar estructuras, signos y mediciones consideradas útiles.
- Errores críticos. Comprender fallas clínicamente graves o inaceptables.
- Interfaz y confianza. Explorar qué debe mostrar el sistema para ser usable y confiable.
- Validación. Indagar contra qué debería validarse: expertos, segmentaciones manuales, métricas o uso profesional.
- Alcance defendible. Identificar qué incluir, excluir o diferir para evitar sobreprometer capacidades.
- Comparación temporal. Explorar el valor de relacionar estudios actuales y previos del mismo sujeto.

La muestra es intencional y exploratoria. No busca representatividad estadística de toda la comunidad radiológica. Su valor reside en contrastar perfiles con experiencia directa en RM, informe, segmentación, control de calidad y patología de columna.

8.3 Perfil de profesionales entrevistados

EN-01 — Dra. Susana Torres (Matrícula Nacional 179537). Médica radióloga con experiencia en resonancia magnética, segmentación y control de calidad. Referencias mencionadas: Sociedad Argentina de Radiología, FLENI y Prenuvo. Duración aproximada: 22 minutos.

EN-02 — Dr. Gonzalo Brito (Matrícula Provincial 96798). Médico radiólogo que informa resonancia magnética, tomografía y ecografía. Institución o referencia informada: Imágenes MDQ. Duración aproximada: 29 minutos.

EN-03 — Dra. Claudia Cejas. Médica radióloga, especialista en patología neuromuscular y de columna. Referencias mencionadas: FLENI y Sociedad Argentina de Radiología. Duración aproximada: 33 minutos.

EN-04 — Dr. Bruno Bregonzi. Profesional que informa un volumen elevado de resonancias, con práctica frecuente en columna lumbar y población deportiva. La institución y la duración no fueron especificadas en la transcripción provista. La entrevista fue realizada por Enzo Asplanatti y reconstruida a partir de una transcripción automática sin separación de hablantes.

EN-05 — Dr. Eduardo Luis Castiglione. Médico neurorradiólogo con un alto volumen de estudios de columna lumbar, mayoritariamente de patología degenerativa. Aporta una mirada centrada en el contexto clínico de cada hallazgo, en la exactitud del nivel anatómico como base del análisis y en el interés por una interpretación asistida por nivel.

La selección de perfiles permitió contrastar miradas vinculadas con informe de RM, práctica cotidiana en diagnóstico por imágenes, segmentación, control de calidad, patología de columna y adopción de herramientas asistidas por inteligencia artificial. EN-04 agrega una perspectiva de alto volumen de lectura cotidiana y refuerza el valor de una interfaz que funcione como alivio operativo; EN-05, con perfil de neurorradiólogo, aporta el foco en la exactitud del nivel anatómico y en el contexto clínico del hallazgo.

8.4 Criterio de tratamiento de las transcripciones

Las transcripciones completas se incorporan en un anexo independiente en formato de diálogo directo. Para el análisis de este capítulo se utilizan como fuentes primarias, codificadas como EN-01 a EN-05. El capítulo no reproduce las entrevistas completas ni reemplaza el anexo, sino que sintetiza patrones, divergencias y decisiones de producto derivadas del relevamiento.

La cuarta entrevista requiere una salvedad metodológica específica: el archivo de origen no incluía separación de hablantes. Su versión depurada fue reconstruida por contexto conversacional, normalizando términos técnicos evidentes y evitando agregar contenido no presente en la fuente. Por ello, se utiliza como evidencia cualitativa exploratoria y no como transcripción literal palabra por palabra.

8.5 Matriz de hallazgos

TABLA 8.1: Matriz de hallazgos

Hallazgo	Evidencia observada	Impacto en el proyecto
Hallazgo 1 — La IA debe asistir, no diagnosticar de forma autónoma.	EN-01 a EN-05 aceptan el valor de la IA como apoyo, pero mantienen la interpretación y la decisión final en el profesional.	conservar un enfoque human-in-the-loop, con resultados revisables, editables y explícitamente no diagnósticos.
Hallazgo 2 — El plano axial es necesario para una evaluación lumbar más completa.	EN-01 indicó que el sagital aislado deja incompleta la evaluación; EN-02 remarcó la importancia de revisar todos los planos; EN-03 recomendó considerar información axial; EN-04 señaló que el axial resulta especialmente importante para lateralidad y relación con raíces y neuroforámenes.	incorporar el plano axial como módulo complementario sin desplazar el núcleo sagital ni afirmar correspondencia tridimensional entre datasets independientes.
Hallazgo 3 — La revisión real se realiza sobre múltiples imágenes, secuencias y planos.	los profesionales describieron recorridos que combinan sagital T1, sagital T2, STIR, axial y, según el caso, coronal u otras secuencias. EN-04 aclaró además que en la práctica puede haber protocolos incompletos por movimiento, claustrofobia o tolerancia del paciente.	evitar reducir conceptualmente el estudio a una única imagen; identificar las secuencias disponibles y comunicar de forma explícita cuando falta un plano o una serie esperada.
Hallazgo 4 — La visualización superpuesta aumenta la confianza.	EN-01 pidió poder ver dónde el sistema identifica el hallazgo; EN-03 valoró una salida visual verificable; EN-04 indicó que lo importante es observar la segmentación ya realizada como guía.	priorizar imagen original, máscaras o contornos superpuestos, control de visibilidad y asociación con el resultado correspondiente.

TABLA 8.1: Matriz de hallazgos (continuación)

Hallazgo	Evidencia observada	Impacto en el proyecto
Hallazgo 5 — Las mediciones aportan valor cuando son trazables y no sobrecargan la interfaz.	se mencionaron canal, forámenes, discos, área, diámetros, volumen, alineación, ángulos y medidas en distintos ejes. EN-04 destacó las «mediciones puras» y la superposición de imágenes como funciones que podrían liberar trabajo.	asociar cada medición con imagen, estructura, máscara, plano, corte, unidad y estado de revisión, presentándola de manera progresiva y no invasiva.
Hallazgo 6 — La corrección o revisión manual es necesaria.	los profesionales plantearon aceptar, corregir, observar o descartar resultados automáticos. EN-04 reforzó que usaría el sistema como referencia inicial y luego revisaría el estudio personalmente.	exigir una acción profesional explícita antes de considerar revisado un resultado.
Hallazgo 7 — El falso negativo y la infravaloración son riesgos críticos.	EN-02 y EN-03 destacaron el peligro de omitir lesiones relevantes; EN-01 señaló el riesgo de sobredimensionar o infravalorar hallazgos. EN-04 ubicó la responsabilidad final en el profesional que informa.	combinar métricas técnicas, comunicación de incertidumbre y revisión obligatoria; no presentar el sistema como garantía de ausencia de patología.
Hallazgo 8 — El sistema no debe agregar fricción.	EN-02 advirtió sobre herramientas que agregan pasos o tiempo; EN-04 definió la utilidad en términos de un «alivianador» y pidió que no se muestre información de más.	priorizar simplicidad, tiempos razonables, revelado progresivo de información y mínima carga operativa.
Hallazgo 9 — El alcance debe acotarse.	EN-01 y EN-03 recomendaron concentrarse en estructuras o problemas prioritarios; EN-04 sugirió orientarse a un área y comenzar la prueba con un centro o grupo reducido.	mantener foco en región lumbar adulta, segmentación, mediciones, visualización y revisión, sin prometer diagnóstico diferencial amplio.
Hallazgo 10 — La comparación con estudios previos posee valor potencial alto.	La mayoría de los entrevistados valoró disponer de estudios anteriores. EN-04 la consideró útil especialmente para seguimiento; se mantiene como evolución de producto.	conservar una referencia de sujeto de-identificada y diseñar la evolución longitudinal como comparación descriptiva futura, sin afirmar porcentajes clínicos no validados.

TABLA 8.1: Matriz de hallazgos (continuación)

Hallazgo	Evidencia observada	Impacto en el proyecto
Hallazgo 11 — La identificación correcta del nivel anatómico condiciona la utilidad del resultado automático.	Señalado principalmente por EN-05 (neurorradiólogo): la utilidad del resultado depende de ubicar correctamente el nivel, y el contexto clínico condiciona su interpretación.	reforzar la localización por nivel, la trazabilidad del hallazgo hacia su nivel y corte de origen, y la revisión profesional obligatoria de la salida.

8.6 Lectura analítica de los hallazgos

Los hallazgos de la Tabla 8.1 admiten una lectura en cinco criterios de diseño, que el resto del documento retoma como decisiones.

Carácter asistivo. El valor esperado no está en reemplazar el criterio médico sino en delimitar, medir y mostrar elementos que luego puedan comprobarse. La revisión profesional no es una precaución agregada al final: forma parte del flujo, y un resultado automático debe conservar su estado, mostrar su origen y admitir una decisión explícita del usuario.

Incorporación del plano axial. El principal ajuste de alcance surge de la necesidad de correlacionar planos. El diseño original centrado en el sagital se mantiene como base por disponibilidad de datos, pero las entrevistas muestran que una evaluación lumbar representativa requiere información axial. El plano axial dejó así de ser una observación del estado del arte para constituir una necesidad funcional detectada en usuarios, y la respuesta técnica fue un módulo axial complementario entrenado y evaluado de forma independiente. Esa implementación no autoriza a interpretar ambos planos como una reconstrucción conjunta.

Trazabilidad verificable. Los profesionales no solicitaron una predicción sino una salida verificable: la confianza aumenta cuando el sistema muestra dónde detectó una estructura, cómo calculó una medición y qué parte puede revisarse. De ese hallazgo, junto con la comprobación de que los volúmenes contienen múltiples cortes, surgió el visor navegable de la serie completa.

Interfaz orientada a aliviar trabajo. EN-04 pide que el sistema funcione como referencia inicial, muestre la segmentación con claridad y evite información innecesaria; EN-02 advierte sobre la fricción operativa. La interfaz aplica revelado progresivo: la imagen y el resultado principal ocupan el centro, y las mediciones, la trazabilidad y los detalles técnicos quedan disponibles sin cubrir la imagen.

Validación en dos planos y contexto clínico. EN-01 destacó la calidad de las anotaciones de referencia y EN-04 señaló que la utilidad práctica debe contrastarse con profesionales que informan estudios, de modo que la validación separa la evaluación del modelo, la del artifact y el runtime, la de integración y la de usabilidad. Las entrevistas muestran además que la imagen

no se interpreta de forma aislada: EN-02 describió los estudios previos como fundamentales y EN-04 señaló que la comparación debe considerar si el dolor cambió. El prototipo persiste los estudios con una referencia de sujeto seudonimizada, conforme a la Ley N.º 25.326, para habilitar a futuro esa comparación, sin emitir conclusiones longitudinales automáticas.

8.7 Aspectos no consolidados o diferidos

La siguiente tabla resume los aspectos que, a partir del relevamiento, se decidieron diferir o acotar.

TABLA 8.2: Aspectos no consolidados o diferidos

Aspecto no consolidado o diferido	Lectura del relevamiento	Decisión
Diagnóstico diferencial automático	Aparece como posibilidad de valor, pero depende de clínica, antecedentes y datos no incluidos en el MVP.	Diferir; no forma parte del núcleo del producto.
Lesiones medulares, tumorales, infecciosas u oncológicas	Son relevantes y pueden ser críticas, pero requieren datasets, secuencias y validación específicos.	Documentar como riesgo y posible extensión; no prometer detección amplia.
Comparación con estudios previos	Fue valorada por varios de los entrevistados (EN-01 a EN-04).	Mantener como épica futura; comenzar por comparación descriptiva de mediciones y advertencias de comparabilidad, no por scoring clínico.
Ejecución en nube	Se considera compatible con el flujo y útil para evitar cómputo local pesado.	Evaluarla en arquitectura, privacidad, costos, disponibilidad y seguridad. Google Cloud se planteó inicialmente en esta etapa como arquitectura objetivo y fue luego implementada y validada (Capítulo 10).
Protocolos incompletos	EN-04 señaló que no siempre se dispone de todas las secuencias o planos.	Validar inputs, informar faltantes y evitar inventar resultados para datos ausentes.
Alcance degenerativo frente a alcance amplio	Se recomienda acotar a región lumbar adulta, patología discal, estructuras y mediciones prioritarias.	Mantener foco lumbar y separar hallazgos estructurales de conclusiones clínicas.

TABLA 8.2: Aspectos no consolidados o diferidos (continuación)

Aspecto no consolidado o diferido	Lectura del relevamiento	Decisión
Procesamiento de series o modalidades no soportadas	El relevamiento fundamenta la revisión del estudio completo; la compatibilidad de una serie con un modelo depende de su plano y ponderación.	No ejecutar inferencia automática fuera del alcance validado del modelo; mantener esas series disponibles para revisión visual (view-only). La segmentación full-series se aplica a las series y modalidades soportadas.

8.8 User persona preliminar

TABLA 8.3: User persona preliminar

Atributo	Detalle
Usuario principal	Médico/a radiólogo/a o profesional de diagnóstico por imágenes con práctica habitual en resonancia magnética lumbar.
Contexto de uso	Revisión de estudios de RM lumbar en centros de diagnóstico, instituciones hospitalarias o entornos especializados, con una carga de trabajo que puede incluir numerosos estudios por jornada.
Objetivos	Revisar estudios de manera eficiente; identificar estructuras y relaciones anatómicas relevantes; correlacionar planos y secuencias; apoyarse en mediciones trazables; comparar con estudios previos cuando estén disponibles; mantener control profesional sobre la salida.
Frustraciones	Alta carga de estudios; riesgo de omitir hallazgos; mediciones manuales repetitivas; protocolos incompletos; herramientas que agregan tiempo; resultados automáticos que no muestran su origen; pantallas sobrecargadas.
Necesidades	Visualización clara de la imagen original; navegación entre cortes y planos disponibles; máscaras o contornos superpuestos; corrección y revisión manual; mediciones asociadas a estructuras y cortes; advertencias ante datos faltantes; validación con expertos; salida estructurada editable.

TABLA 8.3: User persona preliminar (continuación)

Atributo	Detalle
Criterio de confianza	El sistema debe mostrar de dónde surge cada resultado, permitir contrastarlo con la imagen y habilitar su aceptación, observación, corrección o descarte.
Límite esperado	La herramienta no debe emitir diagnóstico autónomo ni reemplazar el criterio médico.

8.9 Necesidades detectadas

TABLA 8.4: Necesidades detectadas

ID	Necesidad detectada	Origen
N-01	Visualizar máscaras o contornos superpuestos sobre la RM original.	EN-01, EN-03, EN-04.
N-02	Permitir aceptar, observar, corregir o descartar resultados automáticos.	EN-01, EN-02, EN-03, EN-04.
N-03	Revisar conjuntamente la información del plano sagital y del axial de manera trazable, utilizando correspondencia geométrica únicamente cuando pueda verificarse.	EN-01, EN-02, EN-03, EN-04.
N-04	Obtener mediciones trazables por estructura, plano, corte y máscara.	EN-01, EN-02, EN-03, EN-04, EN-05.
N-05	Evitar diagnóstico autónomo y mantener revisión profesional.	EN-01, EN-02, EN-03, EN-04, EN-05.
N-06	Validar resultados con especialistas y no solo con métricas técnicas.	EN-01, EN-02, EN-03, EN-04, EN-05.
N-07	Mantener un flujo simple que no agregue tiempo innecesario.	EN-02, EN-04.
N-08	Registrar errores, discrepancias, correcciones u observaciones para mejorar el sistema.	EN-01, EN-02, EN-03.
N-09	Acotar el alcance a región lumbar adulta y hallazgos estructurales prioritarios.	EN-01, EN-03, EN-04.
N-10	Evaluar comparación con estudios previos como extensión futura.	EN-01, EN-02, EN-03, EN-04.

TABLA 8.4: Necesidades detectadas (continuación)

ID	Necesidad detectada	Origen
N-11	Informar de manera explícita la ausencia de secuencias, planos o resultados, sin completar artificialmente la información faltante.	EN-04 y criterio de seguridad derivado.
N-12	Navegar el conjunto de imágenes disponible y conservar la relación entre resultado y corte de origen.	síntesis EN-01–EN-05 y hallazgo de navegación.

8.10 Épicas iniciales y criterios de aceptación

El relevamiento se organizó en diez épicas académicas que estructuran el trabajo desde la perspectiva del producto y de la tesis: user research y evidencia, requerimientos y trazabilidad, gestión de conjuntos de datos, preprocesamiento, segmentación sagital, factibilidad axial, métricas y mediciones, visualización y revisión, salida estructurada editable, y validación y documentación.

Dos de ellas cambiaron de estado durante el desarrollo. La factibilidad axial dejó de ser una evaluación para convertirse en un módulo implementado y evaluado, con las limitaciones que documenta el Capítulo 13. La visualización se amplió con el visor navegable de la serie completa y la asociación de cada resultado con su corte de origen. La numeración de estas épicas es independiente de los bloques del roadmap y de los hitos experimentales del módulo de inteligencia artificial, según se detalla en la sección 12.2.

Los criterios de aceptación se definen en tres planos: la tesis exige que cada capítulo trace su contenido hasta una fuente; los repositorios exigen que cada incremento cuente con criterio de aceptación y evidencia localizable; y el tablero de trabajo exige que ningún elemento se declare terminado sin ambas condiciones.

8.11 Encuesta cuantitativa a profesionales

Para complementar las entrevistas con evidencia de mayor amplitud, se realizó una encuesta en línea (Google Forms) difundida entre profesionales vinculados al diagnóstico por imágenes y a la patología de columna. Se obtuvieron 167 respuestas.

8.11.1 Criterio de inclusión y dimensionamiento de la muestra

El universo de interés se definió como el conjunto de profesionales que informan o utilizan resonancias magnéticas de columna lumbar en su práctica: médicos radiólogos, neurorradiólogos, especialistas en diagnóstico por imágenes, traumatólogos y neurocirujanos. Se excluyeron las respuestas provenientes de perfiles ajenos a ese grupo, en coherencia con el alcance del proyecto,

que se limita al análisis estructural de RM lumbar y no contempla otras regiones anatómicas ni otras modalidades de imagen.

El tamaño muestral se evaluó mediante la expresión habitual para la estimación de una proporción poblacional [36]:

$$n = \frac{z^2 \cdot p \cdot (1 - p)}{e^2} \quad (8.1)$$

donde z es el valor crítico de la distribución normal asociado al nivel de confianza, p la proporción esperada y e el margen de error admitido. Se adoptó $p = 0,5$, valor que maximiza la varianza y produce por lo tanto la estimación más conservadora, y un nivel de confianza del 95

Bajo el supuesto de población infinita, las 167 respuestas obtenidas corresponden a un margen de error de $\pm 7,6$ puntos porcentuales con un nivel de confianza del 95

Cuando el universo es finito, el margen de error se corrige mediante el factor de población finita:

$$e = z \cdot \sqrt{\frac{p \cdot (1 - p)}{n}} \cdot \sqrt{\frac{N - n}{N - 1}} \quad (8.2)$$

No se identificó una estimación oficial única y suficientemente específica del universo definido (profesionales que informan o utilizan RM lumbar dentro de los perfiles incluidos) que permita establecer un valor N defendible para aplicar la corrección por población finita. Por este motivo se conserva, únicamente como referencia descriptiva, el cálculo bajo supuesto de población grande o infinita. Dado que la muestra es de conveniencia y no probabilística, el margen calculado no debe interpretarse como un intervalo de confianza poblacional estricto, sino como una referencia de precisión teórica bajo muestreo aleatorio simple. Corresponde señalar dos limitaciones metodológicas. La primera es que la muestra es de conveniencia y no probabilística: la encuesta se difundió por canales profesionales y la participación fue voluntaria, de modo que no puede descartarse un sesgo de autoselección hacia profesionales con mayor interés previo en herramientas informáticas de apoyo. La segunda es que el margen de error calculado describe la precisión estadística de las estimaciones bajo un muestreo aleatorio simple, supuesto que esta encuesta no satisface estrictamente. En consecuencia, los resultados se interpretan como una señal cuantitativa complementaria al análisis cualitativo de las entrevistas, con capacidad para confirmar tendencias, y no como una validación estadística poblacional.

8.11.2 Resultados

El perfil de los encuestados se concentra en roles clínicos vinculados a la RM lumbar: residentes o médicos en formación, diagnóstico por imágenes, traumatología de columna y neurocirugía. Casi tres de cada cuatro obtienen las mediciones de forma manual sobre el visor o

las estiman visualmente, y solo nueve utilizan un software que ya las calcula. El dato respalda la oportunidad detectada en las entrevistas: la cuantificación actual es predominantemente manual.




Figura 8.1: Perfil de los encuestados (pregunta 1) y obtención de mediciones en el flujo actual (pregunta 3). Fuente: elaboración propia sobre la encuesta.

La utilidad percibida de la segmentación automática es alta y se concentra en las estructuras que el prototipo segmenta: el 81

Las afirmaciones sobre transparencia obtuvieron los niveles de acuerdo más altos de la encuesta: el 86




Figura 8.2: Mediciones cuantitativas más valiosas (pregunta 9) y requisitos de confianza en la segmentación (pregunta 7). Fuente: elaboración propia sobre la encuesta.




Figura 8.3: Acuerdo sobre confianza y transparencia (pregunta 11), disposición a adoptarla (pregunta 12) y principales barreras (pregunta 13). Fuente: elaboración propia sobre la encuesta.

8.11.3 Síntesis de la encuesta

La encuesta refuerza cuantitativamente los hallazgos de las entrevistas. Confirma que la cuantificación actual es mayormente manual o visual, que la segmentación y las mediciones aportan valor percibido, y que la adopción depende de la edición humana, los indicadores de confianza, la transparencia y el carácter no diagnóstico de la herramienta. Las barreras señaladas (validación clínica e integración) coinciden con las exclusiones y los trabajos futuros ya documentados. Las 167 respuestas obtenidas constituyen el corte consolidado que acompaña la entrega del 50

8.12 Conclusión del capítulo

El relevamiento permitió validar la pertinencia del proyecto y ajustar su alcance. La incorporación del plano axial es el cambio más visible: dejó de ser una observación del estado del arte para constituir una necesidad funcional detectada en usuarios. La encuesta confirmó cuantitativamente los hallazgos cualitativos y aportó un dato que condiciona el diseño: el requisito más votado para confiar en una segmentación automática es poder corregirla manualmente.

Los hallazgos se formalizan en el Capítulo 9 como requerimientos con criterio de aceptación y trazabilidad hasta su origen. Ninguna de las dos instancias constituye validación clínica. Después de este relevamiento exploratorio, se realizaron dos sesiones de revisión cualitativa del producto sobre una versión funcional/intermedia del prototipo, con la Dra. Susana Torres y la Dra. Claudia Cejas, documentadas en la sección 13.11 y en el Anexo H. Esas sesiones tampoco constituyen validación clínica ni equivalen a la validación cruzada final, que continúa pendiente y requiere comparar lecturas profesionales independientes contra los resultados del sistema sobre los mismos estudios.

9 Requerimientos funcionales, no funcionales y trazabilidad

9.1 Propósito del capítulo

Este capítulo formaliza qué debe hacer el prototipo, bajo qué condiciones y cómo se verifica cada capacidad, mediante la cadena necesidad, historia de usuario, requerimiento, componente, criterio de aceptación y evidencia. Los identificadores RF, RNF y RV conservan el significado establecido en el Capítulo 8 y se amplían para cubrir autenticación, persistencia, trazabilidad distribuida y compatibilidad volumétrica.

9.2 Fuentes y criterios de formalización

La especificación adopta la distinción habitual entre requerimientos funcionales, que describen qué debe hacer el sistema, y no funcionales, que describen bajo qué condiciones de calidad debe hacerlo [37]. Se construye a partir de cuatro grupos de fuentes:

- User research: necesidades N-01 a N-12 y decisiones derivadas de las entrevistas EN-01 a EN-05.
- Alcance del producto: separación sagital–axial, revisión humana, salida no diagnóstica, ingesta de estudios DICOM completos (con MHA/NIfTI como compatibilidad técnica) y exclusiones clínicas.
- Implementación real: Frontend, Backend y AI Module, junto con PostgreSQL, assets durables, contratos y pruebas.
- Roadmap técnico: P9, P10, P10.5 y evolución posterior hacia Google Cloud y comparación longitudinal descriptiva.

No se incorporan requerimientos únicamente para completar una cantidad. Cada elemento debe estar vinculado con una necesidad, una capacidad comprobable o una decisión explícita de alcance. Cuando una función todavía no está implementada, se indica como «En curso» o «Futuro»; no se la presenta como terminada.

9.3 Actores y responsabilidades

TABLA 9.1: Actores y responsabilidades

Código	Actor	Responsabilidad principal
A1	Profesional revisor — roles DOCTOR o REVIEWER	Crear o consultar estudios, ejecutar análisis, inspeccionar imágenes y resultados, revisar mediciones y registrar una decisión profesional.

TABLA 9.1: Actores y responsabilidades (continuación)

Código	Actor	Responsabilidad principal
A2	Administrador — rol ADMIN	Gestionar usuarios y permisos, consultar diagnósticos técnicos y supervisar la disponibilidad operativa del sistema.
A3	Backend de producto	Validar autenticación y autorización, aplicar reglas de negocio, persistir estudios y corridas, publicar assets autorizados y orquestar la comunicación con el AI Module.
A4	AI Module	Validar modelos y artifacts, preprocesar volúmenes, ejecutar inferencia, generar máscaras, overlays, mediciones, metadata y artifacts técnicos.
A5	Equipo de desarrollo e investigación	Mantener datasets, modelos, manifests, contratos, pruebas, evidencia y documentación reproducible.

El profesional es el actor humano principal. El Backend y el AI Module se documentan como actores de sistema para hacer explícitas las responsabilidades distribuidas y evitar atribuir al Frontend capacidades que dependen de otras capas.

9.4 Estados de requerimiento y criterio de prioridad

TABLA 9.2: Estados de requerimiento y criterio de prioridad

Estado	Definición
Implementado	La capacidad existe en el producto y dispone de evidencia técnica o funcional.
Parcial	Existe una parte funcional, pero falta completar el alcance definido o su validación end-to-end.
En curso	El contrato o desarrollo está iniciado y posee tareas bloqueantes identificadas.
Futuro	La capacidad se conserva como evolución y no integra el alcance inmediato.

La prioridad se clasifica como alta, media o baja. Una prioridad alta corresponde a seguridad, flujo principal, revisión humana, trazabilidad o funciones que bloquean otras capas. Una prioridad media identifica capacidades relevantes que no bloquean el recorrido principal. Una

prioridad baja corresponde a evoluciones posteriores, como comparación longitudinal avanzada.

9.5 Flujos alternativos y excepciones

FA-01 — AI Module no disponible. El Backend conserva su disponibilidad, devuelve un estado degradado explícito y evita presentar una respuesta contractual como inferencia real. Los estudios persistidos continúan siendo consultables dentro del alcance de los assets ya almacenados.

FA-02 — Archivo inválido o incompatible. La carga se rechaza con un mensaje comprensible y no se crea una corrida parcial presentada como válida.

FA-03 — Plano axial ausente. El sistema debe informar la ausencia y permitir un flujo sagital cuando el contrato lo admita, sin fabricar resultados axiales.

FA-04 — Modelo o artifact no disponible. La corrida no se marca como inferencia real. El diagnóstico técnico debe indicar qué modelo o artifact falta.

FA-05 — Usuario sin permisos. El Backend rechaza la operación y el Frontend no expone acciones para las que el rol no está autorizado.

FA-06 — Corrida histórica. Si el estudio solo conserva input.png y overlay.png, debe poder abrirse en modo compatible, sin inventar un catálogo de slices inexistente.

FA-07 — Corte sin resultados. El visor muestra la imagen base y el estado «Sin resultados automáticos en este corte».

FA-08 — Asset faltante o corrupto. El sistema informa la ausencia, conserva la trazabilidad del error y evita reemplazarlo por un contenido engañoso.

9.6 Historias de usuario priorizadas

TABLA 9.3: Historias de usuario priorizadas

ID	Historia de usuario	Prioridad	Estado
HU-01	Como usuario autorizado, quiero iniciar y cerrar sesión para acceder únicamente a las funciones permitidas por mi cuenta.	Alta	Implementado
HU-02	Como profesional, quiero consultar una worklist de estudios para identificar casos disponibles, pendientes y revisados.	Alta	Implementado
HU-03	Como profesional, quiero crear o seleccionar un Patient de-identificado y asociar el Study correspondiente para organizar longitudinalmente los casos sin almacenar identificadores clínicos directos innecesarios.	Alta	Implementado

TABLA 9.3: Historias de usuario priorizadas (continuación)

ID	Historia de usuario	Prioridad	Estado
HU-04	Como profesional, quiero cargar un estudio DICOM completo y utilizar las series compatibles identificadas por el sistema para ejecutar el análisis.	Alta	Implementado
HU-05	Como profesional, quiero ejecutar el análisis y conocer el estado de la corrida para distinguir procesamiento, resultado, degradación y error.	Alta	Implementado
HU-06	Como profesional, quiero observar la imagen original con el overlay automático para comprobar visualmente la segmentación.	Alta	Implementado
HU-07	Como profesional, quiero recorrer todos los cortes del volumen para analizar el contexto alrededor del corte inferido.	Alta	Implementado; P10.9 integrado en Frontend. El E2E local/containerizado del producto está validado (sección 13.8); el recorrido completo en Cloud desde el navegador es parcial (sección 13.9).
HU-08	Como profesional, quiero consultar mediciones vinculadas con estructura, plano y corte para entender de dónde surge cada valor.	Alta	Implementado
HU-09	Como profesional, quiero aceptar, observar, corregir o descartar resultados para mantener la revisión humana obligatoria.	Alta	Implementado
HU-10	Como profesional, quiero reabrir un estudio ya procesado sin repetir la inferencia para conservar continuidad y evitar cómputo innecesario.	Alta	Implementado; reapertura integrada en Frontend. El E2E local/containerizado del producto está validado (sección 13.8); el recorrido completo en Cloud desde el navegador es parcial (sección 13.9).
HU-11	Como usuario, quiero recibir mensajes claros cuando la IA no está disponible o falta información para no confundir una degradación con un resultado válido.	Alta	Parcial

TABLA 9.3: Historias de usuario priorizadas (continuación)

ID	Historia de usuario	Prioridad	Estado
HU-12	Como administrador, quiero consultar salud, modelos y configuración operativa para diagnosticar fallas del sistema.	Media	Implementado
HU-13	Como administrador, quiero gestionar activación y roles de usuarios para controlar el acceso al producto.	Alta	Implementado
HU-14	Como profesional, quiero comparar mediciones de estudios previos del mismo paciente de-identificado para observar cambios descriptivos en el tiempo.	Baja	Futuro

9.7 Requerimientos funcionales

TABLA 9.4: Requerimientos funcionales

ID	Requerimiento	Criterio de aceptación	Prioridad / estado / fuente
RF-01	Ingerir un estudio de RM lumbar en formato DICOM (empaquetado en ZIP), identificar sus series, clasificar plano y ponderación, y registrar los inputs compatibles para el análisis.	El sistema recibe un estudio DICOM completo, identifica las series (por ejemplo Sagital T1, Sagital T2/STIR y Axial T2), registra los inputs compatibles y presenta al menos el corte seleccionado por serie. Se mantiene compatibilidad secundaria con inputs individuales MHA/NIfTI para investigación.	Prioridad: Alta Estado: Implementado Fuente: N-03, N-07
RF-02	Mostrar máscaras o contornos superpuestos sobre la imagen original.	El usuario puede activar y desactivar el overlay y comprobar que corresponde al plano y corte informado.	Prioridad: Alta Estado: Implementado Fuente: N-01; HU-06
RF-03	Permitir revisión explícita de resultados automáticos.	Cada resultado puede quedar aceptado, observado, corregido o descartado mediante una acción autenticada.	Prioridad: Alta Estado: Implementado Fuente: N-02, N-05; HU-09
RF-04	Generar mediciones geométricas trazables por estructura, plano, máscara y corte.	Cada medición conserva valor, unidad, estructura o label, plano, sliceIndex y referencia al resultado que la originó.	Prioridad: Alta Estado: Implementado Fuente: N-04; HU-08
RF-05	Generar una salida estructurada editable y no diagnóstica.	La salida reúne estructuras, mediciones, observaciones, advertencias y revisión, sin cerrar diagnóstico ni recomendar tratamiento.	Prioridad: Alta Estado: Implementado Fuente: N-05, N-07; HU-08, HU-09
RF-06	Registrar discrepancias, correcciones u observaciones del usuario.	El sistema persiste al menos el estado de revisión, comentario y usuario responsable vinculados con la corrida.	Prioridad: Media Estado: Implementado Fuente: N-08; HU-09
RF-07	Incorporar un módulo axial complementario sin fusionar artificialmente las taxonomías de los datasets.	La corrida multiplanar ejecuta o registra un resultado axial diferenciado, con modelo, clases y limitaciones propias.	Prioridad: Alta Estado: Implementado Fuente: N-03; HU-04, HU-05
RF-08	Documentar y habilitar progresivamente la comparación con estudios previos asociados al mismo Patient de-identificado.	La evolución longitudinal se mantiene separada del MVP inmediato y define datos, comparabilidad, deltas descriptivos y revisión profesional.	Prioridad: Baja Estado: Futuro Fuente: N-10; HU-14

TABLA 9.4: Requerimientos funcionales (continuación)

ID	Requerimiento	Criterio de aceptación	Prioridad / estado / fuente
RF-09	Permitir la navegación ordenada de todos los cortes del estudio o volumen procesado.	El usuario puede recorrer series y cortes del estudio mediante scroll, teclado y modo cine, con controles de imagen (window/level, zoom) e indicador de corte actual/total; los cortes sin inferencia se muestran como imagen base.	Prioridad: Alta Estado: Implementado (Backend + AI en full-series; P10.9 integrado y visor navegable en Frontend). El E2E local/containerizado del producto está validado (sección 13.8); el recorrido completo en Cloud desde el navegador es parcial (sección 13.9). Fuente: N-12
RF-10	Comunicar planos, cortes, modelos, assets o resultados ausentes sin completar artificialmente la información.	El Frontend muestra un estado explícito y el contrato diferencia ausencia, degradación y error.	Prioridad: Alta Estado: Parcial Fuente: N-11; HU-11
RF-11	Autenticar usuarios y administrar una sesión renovable.	Los endpoints protegidos requieren credenciales válidas, la sesión puede renovarse y el cierre de sesión invalida el acceso desde la interfaz.	Prioridad: Alta Estado: Implementado Fuente: Alcance de seguridad; HU-01
RF-12	Aplicar autorización por rol y estado de cuenta.	Las acciones de administración, revisión y consulta se habilitan o rechazan según ADMIN, DOCTOR, REVIEWER y estado de aprobación.	Prioridad: Alta Estado: Implementado Fuente: Alcance de seguridad; HU-01, HU-13
RF-13	Proveer una worklist de estudios y corridas.	El usuario autorizado puede listar estudios, abrir un caso y distinguir estados relevantes del flujo.	Prioridad: Alta Estado: Implementado Fuente: HU-02
RF-14	Asociar explícitamente cada Study, identificado mediante caseld o studyId según corresponda, con un Patient de-identificado.	La creación, consulta y eventual reasignación conservan identificadores estables y una relación explícita <code>Study.patientId → Patient.id</code> , sin exigir nombre, DNI u otro identificador clínico directo. La asociación se audita y no se infiere automáticamente desde <code>subjectRef</code> .	Prioridad: Alta Estado: Implementado Fuente: N-10; HU-03
RF-15	Orquestar una corrida multiplanar reconociendo entradas independientes: Sagital T1, Sagital T2 y Axial.	Cada entrada (sagittalT1, sagittalT2, axial) conserva su propio <code>inputId</code> y <code>segmentationRunId</code> ; T1 y T2 se procesan de forma independiente y ambas pueden alimentar la línea de hallazgos P10.7. Los resultados se agrupan bajo un identificador común sin asumir correspondencia espacial automática entre planos.	Prioridad: Alta Estado: Implementado Fuente: N-03
RF-16	Conservar trazabilidad de modelo, artifact y modo de inferencia.	La corrida registra <code>modelKey</code> , versión, hash del artifact, <code>requestedInferenceMode</code> , <code>effectiveInferenceMode</code> y <code>traceId</code> cuando corresponda.	Prioridad: Alta Estado: Implementado Fuente: N-04, N-06, N-08
RF-17	Persistir resultados, mediciones, revisión y referencias a assets.	El estudio puede recuperarse desde PostgreSQL y storage durable sin depender de la memoria de una sesión del navegador.	Prioridad: Alta Estado: Implementado Fuente: HU-10

TABLA 9.4: Requerimientos funcionales (continuación)

ID	Requerimiento	Criterio de aceptación	Prioridad / estado / fuente
RF-18	Reabrir estudios persistidos cuando el AI Module no está disponible.	El resultado de una corrida se persiste en PostgreSQL y puede reabrirse extremo a extremo, incluyendo mediciones, correcciones profesionales y estado de revisión.	Prioridad: Alta Estado: Implementado; reapertura integrada en Frontend. El E2E local/containerizado del producto está validado (sección 13.8); el recorrido completo en Cloud desde el navegador es parcial (sección 13.9). Fuente: HU-10
RF-19	Exponer diagnóstico técnico de salud y modelos.	Un usuario autorizado puede consultar disponibilidad del Backend, AI Module, modelos registrados y estado degradado sin revelar secretos.	Prioridad: Media Estado: Implementado Fuente: HU-12
RF-20	Servir assets mediante URLs controladas y autorización del Backend.	El navegador no recibe paths internos del AI Module y los assets protegidos requieren una sesión válida.	Prioridad: Alta Estado: Implementado Fuente: RNF-06, RNF-07
RF-21	Mantener compatibilidad con corridas históricas y contratos versionados.	Un estudio legacy con assets limitados puede abrirse sin inventar slices; los consumidores diferencian versiones y campos opcionales.	Prioridad: Media Estado: En curso Fuente: Contrato P10.5-A; FA-06
RF-22	Generar hallazgos degenerativos asistivos por nivel (línea P10.7).	El sistema puede generar los ocho tipos de hallazgo definidos por contrato (pfirrmann_grade, modic_change, upper_endplate_change, lower_endplate_change, spondylolisthesis, disc_herniation, disc_narrowing, disc_bulging), asociados al nivel correspondiente, con classification.label y deploymentStatus. No constituye diagnóstico autónomo, requiere revisión profesional y no expone probabilidades al usuario.	Prioridad: Alta Estado: Implementado (Backend + AI) Fuente: estado del arte; P10.7
RF-23	Gestionar Sagital T1 y Sagital T2 como modalidades independientes.	Cada modalidad conserva inputId y segmentationRunId propios; no se asume correspondencia espacial implícita entre T1 y T2; ambas pueden participar de la línea de hallazgos P10.7. No existe registro automático T1↔T2 validado.	Prioridad: Alta Estado: Implementado Fuente: pipeline P10.9
RF-24	Exponer el resultado de IA de forma segura en el contrato público.	El contrato público no expone probabilidades, logits, salidas crudas, mapas de confianza ni rutas internas del modelo; preserva los campos necesarios para la revisión (classification.label, level, provenance, deploymentStatus y estado de revisión).	Prioridad: Alta Estado: Implementado Fuente: contrato P10.9
RF-25	Generar un preinforme automático revisable a partir de las estructuras segmentadas y de las mediciones derivadas, editable por el profesional antes de su uso.	El sistema produce un texto estructurado por estructura y nivel, con las mediciones y sus unidades, que el profesional puede modificar, completar o descartar. El preinforme indica de forma explícita que no constituye un informe clínico y conserva el estado de revisión asociado.	Prioridad: Alta Estado: Implementado Fuente: N-04, N-08; HU-09

9.8 Requerimientos no funcionales

TABLA 9.5: Requerimientos no funcionales

ID	Requerimiento	Criterio de aceptación	Prioridad / estado
RNF-01	El sistema no debe emitir diagnóstico autónomo ni recomendar tratamiento.	Textos, contratos e interfaces presentan resultados como apoyo revisable e incluyen advertencias de uso no diagnóstico.	Prioridad: Alta Estado: Implementado de forma transversal
RNF-02	El flujo debe ser simple y no agregar pasos innecesarios.	El recorrido principal puede completarse mediante una secuencia comprensible de autenticación, estudio, carga, análisis, visualización y revisión.	Prioridad: Alta Estado: Parcial; requiere validación de usabilidad
RNF-03	El desarrollo debe ser reproducible sobre datos públicos o documentados.	Se registran dataset, versión, configuración, checkpoints, manifests, hashes, scripts, commits y evidencia de ejecución.	Prioridad: Alta Estado: Implementado con revisión continua
RNF-04	El sistema debe preservar trazabilidad y auditabilidad.	Una salida puede vincularse con estudio, plano, corrida, modelo, artifact, input, corte, medición, asset y revisión.	Prioridad: Alta Estado: Implementado
RNF-05	El sistema debe degradarse de forma explícita ante indisponibilidad del AI Module.	La interfaz y la API distinguen servicio disponible, degradado y error; no presentan fallback contractual como inferencia real.	Prioridad: Alta Estado: Parcial
RNF-06	La comunicación y el acceso deben aplicar controles de seguridad.	Las APIs protegidas exigen autenticación, autorización por rol y manejo seguro de secretos y variables de entorno.	Prioridad: Alta Estado: Consolidado para el checkpoint P10.9; hardening productivo posterior.
RNF-07	Los datos personales del paciente deben protegerse conforme a la Ley N.º 25.326.	La identidad longitudinal utilizada por el producto es un Patient de-identificado. Los Studies se asocian mediante <code>Study.patientId</code> → <code>Patient.id</code> ; <code>patientReference</code> funciona como referencia seudónima de trabajo y <code>subjectRef</code> permanece únicamente como atributo opcional de compatibilidad.	Prioridad: Alta Estado: Implementado como criterio de diseño
RNF-08	La solución debe ser modular y mantenible.	Frontend, Backend y AI Module conservan responsabilidades separadas, contratos explícitos y pruebas por repositorio.	Prioridad: Alta Estado: Implementado
RNF-09	Los contratos deben ser interoperables y versionados.	Los cambios incompatibles se identifican mediante versión, fixtures y estrategia legacy; no se dependen de paths internos.	Prioridad: Alta Estado: En curso
RNF-10	El rendimiento debe ser compatible con un flujo interactivo y con límites controlados.	Las cargas, timeouts y tamaños máximos se configuran; el usuario recibe estado de procesamiento y no queda ante una espera silenciosa.	Prioridad: Media Estado: Parcial
RNF-11	Los resultados persistidos deben ser durables y recuperables.	Una reapertura recupera contratos y assets almacenados; la pérdida temporal del AI Module no elimina resultados existentes.	Prioridad: Alta Estado: Implementado para assets actuales
RNF-12	La solución debe ofrecer observabilidad suficiente para diagnosticar fallas.	Logs, traceId, health, models, estados de ejecución y errores permiten localizar el componente responsable sin exponer datos sensibles.	Prioridad: Alta Estado: Consolidado para el checkpoint P10.9; observabilidad productiva posterior.

9.9 Requerimientos de validación

TABLA 9.6: Requerimientos de validación

ID	Requerimiento	Criterio de aceptación	Estado
RV-01	Evaluar segmentación con métricas técnicas.	Se calculan Dice, IoU y métricas por clase o equivalentes sobre conjuntos de prueba documentados.	Implementado experimentalmente; requiere consolidación final
RV-02	Complementar métricas con revisión cualitativa profesional.	Profesionales revisan ejemplos, flujo, overlays, mediciones y limitaciones; sus observaciones quedan documentadas.	En curso
RV-03	Validar usabilidad y recorrido end-to-end del producto actualizado.	Se ejecuta un protocolo que cubre login, carga, análisis, persistencia, reapertura, degradación y revisión, registrando incidencias y evidencia.	En curso

9.10 Matriz de trazabilidad resumida

TABLA 9.7: Matriz de trazabilidad resumida

Historia	Necesidad	Requerimientos asociados	Componentes	Evidencia esperada
HU-01	N-05, seguridad	RF-11, RF-12; RNF-06	Frontend + Backend	Tests de autenticación, renovación, logout y autorización
HU-02	N-07	RF-13, RF-17	Frontend + Backend + PostgreSQL	Captura de worklist y prueba de consulta persistente
HU-03	N-10, privacidad	RF-14; RNF-07	Frontend + Backend + PostgreSQL	Patient de-identificado creado o seleccionado y Study asociado explícitamente, sin identificadores clínicos directos obligatorios
HU-04	N-03	RF-01, RF-07, RF-15	Frontend + Backend + AI Module	Carga de estudio DICOM completo, identificación/registro de series compatibles y corrida multiplanar registrada.
HU-05	N-03, N-06	RF-15, RF-16; RNF-03, RNF-04	Backend + AI Module	Contrato con runId, traceId, modelo, hash y modo efectivo
HU-06	N-01	RF-02, RF-20	Frontend + Backend + AI Module	Overlay autorizado sobre la imagen correspondiente
HU-07	N-12	RF-09, RF-18, RF-21; RNF-09, RNF-11	Tres repositorios	Catálogo de cortes full-series y visor navegable integrado en Frontend mediante P10.9; cierre E2E global pendiente.
HU-08	N-04	RF-04, RF-05, RF-16	Frontend + Backend + AI Module	Medición vinculada con estructura, plano, corte y asset
HU-09	N-02, N-05, N-08	RF-03, RF-06; RNF-01, RNF-04	Frontend + Backend	Revisión persistente con usuario, estado y observación

TABLA 9.7: Matriz de trazabilidad resumida (continuación)

Historia	Necesidad	Requerimientos asociados	Componentes	Evidencia esperada
HU-10	N-07	RF-17, RF-18; RNF-11	Frontend + Backend + storage	Reapertura del estudio con mediciones, correcciones y estado de revisión, validada sobre assets persistidos.
HU-11	N-11	RF-10, RF-18, RF-19; RNF-05, RNF-12	Tres repositorios	Estado degradado comprensible y logs correlacionables
HU-12	Operación técnica	RF-19; RNF-12	Frontend + Backend + AI Module	Pantalla o endpoint protegido de salud y modelos
HU-13	Seguridad	RF-12; RNF-06	Frontend + Backend	Activación de cuenta y control de roles
HU-14	N-10	RF-08, RF-14; RNF-07, RNF-09	Backend + datos + futura IA	Especificación longitudinal sobre Studies asociados al mismo Patient y deltas descriptivos revisables

9.11 Control de alcance y requerimientos diferidos

Las siguientes capacidades no se consideran requerimientos terminados del MVP inmediato:

- diagnóstico diferencial automático;
- probabilidad clínica de lesión o degradación;
- inferencia automática sobre series o modalidades no soportadas (los cortes correspondientes se muestran como imagen base);
- crosshair sagital–axial sin geometría compatible;
- edición avanzada de máscaras comparable con un visor clínico certificado;
- integración productiva con PACS, RIS o historia clínica;
- comparación longitudinal con scoring clínico no calibrado;
- uso asistencial real o certificación regulatoria.

Una función propuesta que no pueda relacionarse con necesidad, historia, criterio y evidencia debe considerarse candidata a postergación. Esta regla evita que capacidades visualmente atractivas desplacen el cierre de seguridad, persistencia, navegación volumétrica y validación.

9.12 Actualización técnica de alcance final

El cierre técnico agrega capacidades que no modifican el principio de no diagnóstico, pero sí amplían la trazabilidad del prototipo: exportación PDF/JSON, historial por subjectRef, comparación longitudinal descriptiva en Demo Mode, concordance descriptiva, review analytics, feedback curation, Grad-CAM experimental, chat contextual con proveedor mock y despliegue Cloud DEV con AI privado y persistencia gestionada. Estas capacidades se interpretan con estados diferenciados: validadas técnicamente, parciales, experimentales, demo-only, bloquea-

das o planificadas. En particular, Patient queda parcial por la diferencia entre Backend/API y Frontend visible; Cloud queda validado técnicamente de punta a punta en DEV (autenticación privada, persistencia y reproceso sin re-subida), aunque el recorrido browser completo en Cloud permanece parcial por una limitación de tooling de automatización; y las capacidades 67B2, 67C y P10.7 quedan sujetas a sus gates de paridad y validación.

9.13 Conclusión del capítulo

La especificación conecta cada requerimiento con una necesidad del relevamiento, un componente responsable, un criterio de aceptación y su evidencia. Los requerimientos declarados como parciales o futuros se identifican como tales, de modo que la matriz de trazabilidad describe el estado real del producto y no su estado deseado.

10 Diseño de la solución, arquitectura y selección tecnológica

10.1 Propósito y enfoque arquitectónico

Este capítulo traduce los requerimientos del capítulo anterior en una arquitectura concreta, organizada en tres repositorios desacoplados que colaboran mediante contratos HTTP explícitos, persistencia, trazabilidad distribuida y revisión profesional obligatoria. La separación entre experiencia de usuario, lógica de producto y procesamiento especializado es estricta por diseño, y el sistema no emite diagnóstico autónomo ni considera aceptada una salida sin revisión humana.

La documentación sigue el modelo de vistas «4+1» de Kruchten [38], que organiza la descripción en cinco vistas complementarias: lógica, de procesos, de desarrollo, física y de escenarios. Cada una atiende las inquietudes de distintos interesados y, en conjunto, permite verificar que la arquitectura satisface los requerimientos sin repetir la misma información desde perspectivas superpuestas.



Figura 10.1: Diagrama de contexto del sistema. Fuente: elaboración propia.

El prototipo recibe un estudio de resonancia magnética lumbar que puede incluir el plano sagital, el axial o ambos, y lo recorre en seis etapas. La entrada se carga y se prepara mediante normalización de intensidades y ajuste de formato. La segmentación genera máscaras para las

estructuras contempladas en cada plano. El postprocesamiento organiza esas máscaras, las asocia a un nivel anatómico cuando resulta posible y calcula los valores geométricos. La visualización superpone las máscaras sobre la imagen original. La revisión profesional permite aceptar, corregir, observar o descartar cada resultado. La salida editable reúne estructuras, mediciones, unidades, observaciones y estado de revisión, e incluye un preinforme automático revisable.

TABLA 10.1: Componentes funcionales del prototipo

Componente	Función principal
Entrada y preprocesamiento	Cargar el estudio, preservar su información espacial y prepararlo para la inferencia
Segmentación	Delimitar las estructuras anatómicas contempladas en cada plano mediante modelos de aprendizaje profundo
Mediciones	Calcular valores geométricos derivados de máscaras visibles y trazables
Visualización	Mostrar la imagen original con las máscaras superpuestas y sus resultados asociados
Salida editable	Organizar los resultados en una plantilla revisable y un preinforme modificable y no diagnóstico
Validación	Comparar máscaras contra anotaciones de referencia y complementar con revisión profesional

El prototipo opera bajo un enfoque de humano en el circuito: el sistema propone segmentaciones y mediciones, y el profesional conserva la revisión final. Esa condición es necesaria porque las máscaras pueden contener errores, las mediciones requieren contexto y el alcance del proyecto no contempla diagnóstico autónomo. El resultado esperado no se mide únicamente por una métrica de segmentación sino por la coherencia del flujo completo, desde la imagen de entrada hasta la salida revisada. El fundamento conceptual de este enfoque se desarrolla en la sección 7.11 y su implementación en la sección 11.8.

10.2 Decisiones arquitectónicas derivadas de los requerimientos

Las decisiones principales se derivan de las necesidades de carga, segmentación, visualización, corrección, trazabilidad, seguridad y control profesional. El diseño evita concentrar todas las responsabilidades en una aplicación monolítica y asigna cada capacidad a la capa tecnológica más adecuada.

Requerimiento o necesidad	Implicancia técnica	Respuesta arquitectónica
Carga de estudios de-identificados	El caso debe conservar identidad, plano y metadata sin almacenar datos personales innecesarios	Backend para registrar el estudio y Frontend para seleccionar los volúmenes.
Segmentación sagital y axial	Coexisten modelos con datasets, clases y artifacts diferentes	Registro por modelKey, ejecución por plano y agrupación bajo multiplanarRunId.
Revisión profesional	La salida automática no puede considerarse definitiva	Estados pendiente, aceptado, observado y descartado, con notas y auditoría.
Trazabilidad	Cada corrida debe poder explicarse y reproducirse	caseId, runId, multiplanarRunId, traceId, modelVersion, artifactHash y modos de inferencia.
Reapertura sin AI Module	Los resultados deben permanecer disponibles aunque el motor de IA esté apagado	Persistencia durable de contratos, mediciones y assets servidos por el Backend.
Navegación volumétrica	Un archivo MHA contiene múltiples cortes y el usuario debe poder recorrerlos	Catálogo de slices, previews persistidos, índice seleccionado y visor navegable.
No diagnóstico autónomo	El sistema debe asistir sin reemplazar el juicio profesional	humanReviewRequired, notClinicalDiagnosis y ausencia de conclusiones clínicas automáticas.
Actualización de modelos	Los checkpoints pueden evolucionar y exceder los límites de GitHub	Código en repositorios; artifacts y manifests en storage externo verificable.
Despliegue controlado	La infraestructura debe ser reproducible y limitar costos	Contenedores, variables de entorno, servicios separados y arquitectura objetivo en Google Cloud.

10.3 Vista lógica

La vista lógica describe la estructura funcional del sistema: sus componentes principales, el modelo de datos y las clases del dominio.

10.3.1 Arquitectura lógica consolidada

La arquitectura se organiza en capas desacopladas. El navegador consume el Frontend; el Frontend se comunica exclusivamente con el Backend de producto; el Backend centraliza autenticación, autorización, persistencia, auditoría, serving de assets y comunicación con el AI Module; y el AI Module encapsula la lógica Python, la gestión de modelos, el runtime PyTorch y la orquestación de inferencia.

Capa	Tecnología	Responsabilidad principal
Frontend	React, TypeScript y Vite	Autenticación visual, worklist, alta y consulta de estudios, workspace sagital-axial, visor de cortes, revisión, historial, longitudinal y diagnósticos técnicos.
Backend	Spring Boot y Java 21	Frontera de producto, seguridad, persistencia y orquestación: autenticación, reglas de negocio, auditoría, proxy hacia IA, contratos canónicos, serving de assets, reportes, chat y reapertura.
AI Module	Python, FastAPI y PyTorch	Servicio especializado de IA: registry de modelos, manifests, hashing, preprocesamiento, inferencia, catálogo volumétrico, overlays, Grad-CAM experimental y generación de previews.
Runtime de inferencia	PyTorch	Reconstrucción de arquitecturas, carga de state_dict, model.eval(), torch.inference_mode() y predicción.
Persistencia	PostgreSQL	Usuarios, roles, pacientes, estudios, corridas, revisiones, mediciones, evidencia, chat, feedback, artifacts y eventos de auditoría.
Storage de modelos y archivos	Storage externo controlado	Checkpoints, manifests, datasets y, en la arquitectura objetivo, volúmenes y assets durables.
Entorno experimental	Google Colab, Drive y notebooks	Entrenamiento, evaluación, generación de checkpoints y evidencia reproducible.

Esta separación permite desplegar, probar y evolucionar cada módulo con su tecnología natural. También reduce el riesgo de que una modificación del modelo obligue a recompilar la interfaz o que la lógica clínica-asistiva quede mezclada con detalles internos de PyTorch.

La Figura 10.2 muestra la separación entre Frontend, Backend, AI Module, runtime PyTorch, persistencia y almacenamiento de artifacts.

El sistema ingesta el estudio como DICOM completo, identifica las series y las clasifica por plano y ponderación; los formatos MHA y NIfTI se conservan como compatibilidad técnica. El contrato volumétrico define por serie el plano, el identificador, la cantidad de cortes, el corte seleccionado, el eje, las dimensiones nativa y normalizada, el espaciado y un catálogo en el que cada corte puede asociarse con una vista previa, un indicador de resultados y, cuando corresponda, superposición, puntos de referencia y mediciones.

La responsabilidad se distribuye entre las tres capas: el módulo de inteligencia artificial lee el volumen completo, genera una vista previa por corte y marca los cortes con resultados; el backend persiste volumen, catálogo y vistas previas, y publica los accesos autorizados, de modo que la reapertura funciona con el módulo de inferencia apagado; el frontend presenta el recorrido por cortes con teclado, miniaturas, ajuste visual y navegación desde un resultado hacia su corte de origen.




Figura 10.2: Arquitectura general por componentes. Fuente: elaboración propia.

La superposición automática no se presupone para todos los cortes de todas las series. Se ejecuta segmentación de la serie completa en las modalidades soportadas, y las series no soportadas permanecen disponibles como imagen base, informando que no poseen inferencia automática. El visor no simula una correspondencia espacial entre el plano sagital y el axial cuando la metadata geométrica no permite demostrarla.

10.3.2 Modelo de datos

La persistencia se apoya en un modelo relacional en PostgreSQL organizado alrededor de tres ejes: la identidad y el control de acceso (usuarios y roles), la evidencia de cada análisis (corridas, mediciones, revisiones, assets y catálogo de cortes), y el dominio Patient de-identificado del Backend. Este último existe como entidad persistida y API, pero su adopción por la interfaz final es parcial: el historial y la comparación longitudinal que consume el Frontend siguen operando principalmente con `subjectRef`. La Figura 10.4 presenta el diagrama entidad-relación con sus claves primarias, foráneas y cardinalidades.

El modelo separa la identidad técnica de cada estudio de la identidad longitudinal de-identificada cuando esta se encuentra disponible. En Backend, `Patient` posee un identificador interno `UUID` y una `patientReference` seudónima; `Study` conserva su identificador, `caseId`, `subjectRef` y una asociación opcional mediante `patientId`. La asociación `Patient-Study` está implementada, persistida y validada a nivel API. Sin embargo, en el producto visible




Figura 10.3: Arquitectura del visor volumétrico. Fuente: elaboración propia.

final la navegación histórica y longitudinal del Frontend continúa basada en subjectRef; las pantallas de historial consumen endpoints de /api/subjects y no un flujo browser completo de alta o selección de entidades Patient. Por este motivo, el dominio Patient se clasifica como implementación parcial y no como gestión integral de pacientes end-to-end en interfaz. Cada corrida conserva su linaje técnico; las mediciones y los assets permanecen vinculados a la corrida y al corte de origen; y la revisión profesional se registra sin sobrescribir el resultado automático original, preservando trazabilidad y auditabilidad.




Figura 10.4: Modelo de datos relacional (PostgreSQL). Fuente: elaboración propia.

Entidades principales

Entidad	Descripción y atributos clave
usuario	Cuenta del sistema. Atributos: id (PK), email, password_hash, estado_aprobacion, fecha_registro.
rol / usuario_rol	Roles ADMIN, DOCTOR y REVIEWER, asociados a usuarios mediante una tabla intermedia (relación muchos a muchos).
patient	Identidad longitudinal de-identificada del paciente. Atributos principales: id (PK, UUID), patient_reference (única), created_at y updated_at. No almacena identificadores directos del paciente.
estudio (Study)	Contenedor lógico de un caso. Atributos principales: id (PK), case_id, patient_id (FK nullable a Patient), subject_ref (opcional), estado, fecha del estudio, modalidad, descripción, prioridad de revisión y timestamps.

Entidad	Descripción y atributos clave
corrida (run)	Ejecución de análisis por plano. Atributos: run_id (PK), study_id (FK), model_key (FK), plano, multiplanar_run_id, artifact_hash, requested/effective_inference_mode, trace_id, estado.
modelo / artifact	Modelo registrado y su artifact verificable. Atributos: model_key (PK), plano, version, artifact_hash, manifest_uri, arquitectura.
medicion	Valor geométrico derivado de una máscara. Atributos: id (PK), run_id (FK), estructura/label, plano, slice_index, valor, unidad, confidence, estado_revision.
revision	Decisión profesional sobre una corrida. Atributos: id (PK), run_id (FK), usuario_id (FK), estado (pendiente/aceptado/observado/rechazado/corregido), comentario, fecha.
asset	Archivo derivado servido bajo autorización. Atributos: id (PK), run_id (FK), rol (input/mask/overlay/...), content_type, hash, size, url.
slice_catálogo (P10.5)	Catálogo de cortes del volumen para el visor. Atributos: id (PK), run_id (FK), index, preview_asset, has_results.
evento_auditoria	Registro de trazabilidad. Atributos: id (PK), usuario_id (FK), entidad, accion, trace_id, timestamp.

Relaciones principales

- Un Patient puede asociarse con cero o múltiples Studies; cada Study puede referenciar opcionalmente un Patient mediante patientId. Un Study puede permanecer sin Patient asociado, especialmente en registros históricos o durante etapas intermedias del flujo. Cada Study contiene una o múltiples corridas.
- La asociación Study–Patient es explícita y auditable. La primera asociación y una eventual corrección se realizan como operaciones diferenciadas; subjectRef no se utiliza para inferir automáticamente esta relación.
- Cada corrida referencia el modelo/artifact ejecutado y genera múltiples mediciones, assets y entradas del catálogo de cortes.
- Una corrida acumula una o varias revisiones profesionales sin eliminar el resultado automático original.
- Los usuarios se asocian con roles (muchos a muchos) y quedan registrados como autores de estudios, revisiones y eventos de auditoría.

10.3.3 Diagrama de clases

El diagrama de clases presenta las entidades del dominio y los servicios principales, con sus atributos, operaciones y relaciones. La Figura 10.5 lo resume.

La vista de procesos describe el comportamiento en ejecución: la secuencia de una corrida, la persistencia y reapertura, y la comunicación entre servicios.




Figura 10.5: Diagrama de clases del dominio y servicios. Fuente: elaboración propia.

10.4 Vista de procesos

La vista de procesos describe el comportamiento en ejecución: la secuencia de una corrida, la comunicación entre servicios y el tratamiento de los estados de error.

10.4.1 Flujo end-to-end de una corrida

Desde la perspectiva arquitectónica, el recorrido funcional final es: sujeto o referenciaseudónima, Study, DICOM, identificación de series, análisis sagital y axial cuando corresponde, mediciones, evidencia visual, revisión profesional, reporte, historial y comparación longitudinal. El Backend actúa como frontera de producto, seguridad, persistencia y orquestación: valida la solicitud, coordina la ingesta con el AI Module, persiste los contratos resultantes en PostgreSQL, sirve assets autorizados, compone reportes y media el acceso al proveedor LLM. El AI Module permanece como servicio especializado: identifica y clasifica series, registra inputs, ejecuta modelos PyTorch, genera máscaras, overlays y salidas experimentales. La línea P10.7 no debe describirse como inferencia productiva automática: su endpoint existe, pero permanece bloqueado por blocked_preprocessing_parity y automaticInferenceEnabled=false. El Frontend presenta posteriormente el estudio en el espacio de revisión profesional, desde donde pueden consultarse resultados persistidos y reabrirse el caso sin repetir necesariamente la inferencia. Los formatos MHA/NIFTI se mantienen como compatibilidad técnica y fixtures de investigación, no como flujo principal de producto.

La arquitectura diferencia requestedInferenceMode de effectiveInferenceMode. Una

solicitud `real_baseline` solo se informa como efectiva cuando el artifact fue verificado y la ejecución PyTorch finalizó correctamente. Si la ejecución falla, el sistema debe informar error o degradación según la configuración; no debe presentar una respuesta de contrato como inferencia real.

La Figura 10.6 resume la secuencia completa desde la autenticación y la selección del Patient hasta la persistencia, la asociación del Study y la revisión profesional.




Figura 10.6: Flujo de interacción end-to-end. Fuente: elaboración propia.

La persistencia se diseña alrededor de la corrida de análisis. Cada estudio conserva contratos canónicos, mediciones, estados de revisión, referencias a assets y datos de auditoría. Los paths internos del AI Module (por ejemplo rutas temporales de contenedor) no forman parte del contrato público.

Los assets se describen mediante nombre, rol, tipo de contenido, hash, tamaño y URL autorizada del Backend. Esta estrategia desacopla el navegador de la ubicación física del archivo y permite mover el almacenamiento sin alterar la interfaz.

La reapertura es un requisito arquitectónico central. Una corrida persistida debe poder visualizarse aunque el AI Module esté detenido. Por esa razón, los previews del stack no se generan bajo demanda desde el motor de IA: deben producirse durante la corrida y persistirse junto con el resto de la evidencia.

10.4.2 Arquitectura de red, protocolos y seguridad

La comunicación entre capas utiliza HTTP(S), contratos JSON versionables y trazabilidad por headers. El navegador se autentica contra el Backend; el Backend propaga el traceId hacia el AI Module; y el AI Module materializa artifacts desde storage externo mediante credenciales administradas fuera del código.

Origen	Destino	Mecanismo	Propósito
Navegador	Frontend	HTTPS	Acceso a la interfaz.
Frontend	Backend	REST, JSON, JWT y X-Trace-Id	Operaciones de producto y trazabilidad.
Backend	AI Module	REST, JSON y X-Trace-Id	Inferencia, readiness, modelos y orquestación.
Backend	PostgreSQL	SQL/TLS según entorno	Persistencia transaccional.
AI Module	Storage	HTTPS o SDK autenticado	Descarga y verificación de models y manifests.

Las credenciales, URLs sensibles y secretos se administran mediante variables de entorno y, en la arquitectura objetivo, Secret Manager. El Frontend no recibe secretos del Backend ni rutas internas del AI Module. La autorización se aplica también al acceso a assets y estudios persistentes.

Los criterios de seguridad requeridos para el checkpoint P10.9 fueron consolidados y el Backend y el AI Module quedaron congelados para el traspaso al Frontend. El hardening productivo definitivo (incluida la observabilidad de producción) continúa como evolución posterior y no forma parte del alcance del checkpoint actual.

10.5 Vista de desarrollo

La vista de desarrollo describe la organización del código en repositorios, el ciclo de vida de los artifacts y las tecnologías seleccionadas.

10.5.1 Distribución por repositorios y responsabilidades

La solución se mantiene en tres repositorios independientes, cada uno con su suite de pruebas, su configuración y su ciclo de despliegue. El frontend concentra el acceso, la worklist, la carga, el espacio de trabajo, el historial, la revisión y el visor de cortes. El backend concentra autenticación, roles, persistencia, validaciones, trazabilidad, serving de assets y la comunicación con el módulo de inferencia. El módulo de inteligencia artificial concentra el registro de modelos, los artifacts, los manifests, el runtime y la generación de salidas.

El frontend no consume directamente el módulo de inteligencia artificial: todas las operaciones de producto pasan por el backend. Esa frontera permite aplicar autorización, evitar

la exposición de rutas internas y conservar el resultado aunque el servicio de inferencia no esté disponible. La distribución de responsabilidades entre los integrantes del equipo se describe en la sección 12.1.

Esta distribución no responde únicamente a una organización del código, sino a una decisión arquitectónica orientada a separar responsabilidades y ciclos de evolución diferentes. La decisión, las alternativas consideradas y sus principales consecuencias se formalizan mediante registros de decisión arquitectónica (Architecture Decision Records, ADR), incluidos en el Anexo G.

10.5.2 Estrategia de datos, modelos y ciclo de vida de artifacts

Los modelos finales provienen de pipelines experimentales separados. El sagital utiliza SPIDER y el axial utiliza Sudirman/Al-Kafri. Sus datasets, clases y procedencias no se fusionan artificialmente.

Plano	Artifact principal	Función
Sagital	sagittal_spider_multiclass_final_best.pt	Segmentación multiclase de estructuras sagitales.
Axial	axial_t2_alkafri_final_best.pt	Segmentación axial según la codificación del dataset complementario.

Los checkpoints pesados no se consideran código fuente. GitHub conserva el runtime, los manifests, la configuración y los tests; el storage externo conserva los artifacts. Al materializar un modelo, el AI Module verifica integridad, compatibilidad de arquitectura, metadata y estado del manifest.

El sistema diferencia contract, real_baseline y una posible evolución real_validated. Contract permite probar contratos y UI sin afirmar ejecución clínica. Real_baseline exige artifact verificado y ejecución PyTorch exitosa. Real_validated queda reservado para una validación más amplia y no describe el estado actual.

10.5.3 Selección tecnológica y justificación

La selección tecnológica se realizó considerando la responsabilidad de cada componente, su compatibilidad con el desarrollo ya realizado, la mantenibilidad, la interoperabilidad mediante contratos explícitos, la reproducibilidad y la posibilidad de desplegar los servicios de forma independiente. El criterio no fue homogeneizar el lenguaje de implementación, sino asignar a cada componente un stack coherente con su función y con las dependencias que necesita ejecutar. Las decisiones de mayor impacto arquitectónico y las alternativas descartadas se desarrollan en los ADR del Anexo G.

Tecnología	Rol	Justificación
Spring Boot / Java 21	Backend de producto	Se utiliza como frontera de producto para concentrar autenticación, autorización, reglas de negocio, persistencia, auditoría, reportes, chat y contratos públicos en un servicio independiente del runtime científico. Esta separación evita trasladar al Backend las dependencias propias del procesamiento y de los modelos de inteligencia artificial.
Python + FastAPI	Servicio IA	Se utiliza en el AI Module por su integración directa con PyTorch, SimpleITK y el código de preprocesamiento e inferencia. FastAPI permite exponer estas capacidades mediante una API HTTP interna consumida por el Backend, manteniendo desacoplado el runtime científico del resto del producto.
PyTorch	Entrenamiento e inferencia	Se mantiene como runtime porque los modelos y checkpoints del proyecto fueron entrenados, evaluados y registrados dentro de este ecosistema. Sustituirlo requeriría validar previamente la equivalencia de las salidas del nuevo runtime.
React + Vite + TypeScript	Frontend	Se utiliza para construir una interfaz web interactiva y modular. TypeScript aporta contratos tipados y React facilita la composición del visor, la worklist y los flujos de revisión. El Frontend consume exclusivamente el contrato público expuesto por el Backend.
PostgreSQL	Persistencia	Se utiliza por la necesidad de mantener integridad transaccional y relaciones consistentes entre usuarios, estudios, corridas, mediciones, revisiones y eventos de auditoría.
Docker	Portabilidad	Permite encapsular las dependencias y configuraciones de cada servicio, reproducir los entornos de ejecución y desplegar Backend y AI Module de manera desacoplada.
Google Colab + Drive	Experimentación	Se utilizan para entrenamiento, evaluación y conservación de la evidencia experimental y académica. No forman parte del runtime operativo del producto.

Tecnología	Rol	Justificación
Google Cloud	Arquitectura objetivo y despliegue parcial DEV	Se definió como plataforma objetivo por disponer de servicios administrados para cómputo, persistencia, almacenamiento y gestión operativa. Al cierre técnico sólo están desplegados/validados Artifact Registry/WIF, Backend Cloud Run DEV y Frontend Cloud Run DEV; AI Cloud Run privado, Cloud SQL, Secret Manager, storage productivo, DEMO environment y monitoreo/alerting live permanecen no desplegados.

La diversidad tecnológica es deliberada. Java se utiliza para la lógica transaccional, Python para IA y TypeScript para la experiencia web. La arquitectura evita forzar toda la solución dentro de una única plataforma cuando eso reduciría compatibilidad o mantenibilidad.

10.5.4 Alternativas evaluadas

Las alternativas se evaluaron considerando no solo la posibilidad técnica de implementarlas, sino también su impacto sobre la separación de responsabilidades, las dependencias existentes, la mantenibilidad y la necesidad de validar nuevamente componentes ya consolidados.

Alternativa	Ventaja principal	Limitación o costo para el PFI	Decisión
Python + FastAPI para Backend y AI Module	Reduce la heterogeneidad tecnológica y permite utilizar un único lenguaje en los servicios del lado servidor.	No elimina la necesidad de separar las responsabilidades de producto del runtime científico y requeriría trasladar o reimplementar capacidades de autenticación, autorización, persistencia, auditoría y reglas de negocio ya establecidas en el Backend.	No adoptada. FastAPI se mantiene como servicio especializado de IA.
Java para Backend e inferencia	Unifica el stack del lado servidor y reduce la cantidad de lenguajes utilizados.	El pipeline de entrenamiento e inferencia, los checkpoints y las dependencias de procesamiento científico del proyecto se encuentran integrados con el ecosistema Python, PyTorch y SimpleITK. Migrarlos introduciría complejidad sin aportar una ventaja funcional al alcance actual.	No adoptada. Java se mantiene en el Backend de producto.
Spring Boot para Backend y Python + FastAPI para AI Module	Permite utilizar en cada componente el ecosistema más adecuado a su responsabilidad y mantener una frontera explícita entre producto e inteligencia artificial.	Obliga a mantener dos stacks tecnológicos y contratos de integración entre ambos servicios.	Adoptada.
ONNX Runtime para inferencia	Podría desacoplar la ejecución de los modelos del runtime original de PyTorch y facilitar alternativas de despliegue.	Requiere convertir los modelos y verificar que las salidas sean equivalentes a las obtenidas con los checkpoints actualmente evaluados. Esa equivalencia no fue validada en esta etapa.	Diferida.

La alternativa adoptada prioriza la separación de responsabilidades por encima de la homogeneidad del lenguaje de implementación. Spring Boot funciona como frontera de producto,

seguridad y persistencia, mientras que Python y FastAPI encapsulan el procesamiento científico y la inferencia. De esta forma, los modelos pueden evolucionar sin trasladar sus dependencias al Frontend ni convertir al servicio de IA en la API pública del sistema. El fundamento detallado de esta decisión se registra en los ADR-002 y ADR-003 del Anexo G.

MONAI o nnU-Net — Referencias metodológicas y posibles evoluciones, no reemplazo obligatorio del baseline.

OHIF, Cornerstone o 3D Slicer — Referencias para navegación y herramientas de imagen; el MVP mantiene un visor propio alineado con sus contratos.

Integración PACS/RIS — Fuera del alcance académico actual.

10.6 Vista física (despliegue)

La vista física describe el mapeo del sistema a la infraestructura: el entorno actual de validación y la arquitectura objetivo de despliegue.

10.6.1 Arquitectura actual de validación

Durante la integración final se utilizaron dos niveles de infraestructura. El primero fue el stack local containerizado para validar el producto completo con PostgreSQL, AI Module, mock LLM, Backend y Frontend. El segundo fue el despliegue DEV parcial en Google Cloud, donde quedaron corroborados Artifact Registry/WIF y servicios Cloud Run para Backend y Frontend. Esta evidencia no equivale a un despliegue productivo completo: el AI Module privado en Cloud Run, Cloud SQL, Secret Manager, storage productivo, DEMO environment y monitoreo/alerting live permanecen no desplegados.

10.6.2 Arquitectura objetivo en Google Cloud

La plataforma objetivo del sistema es Google Cloud, con una migración organizada por fases para no crear recursos cuyo costo o necesidad no estén justificados. La arquitectura objetivo conecta GitHub Actions con Workload Identity Federation, Artifact Registry, Cloud Run Frontend, Cloud Run Backend y, para una etapa posterior, Cloud Run AI privado protegido con Google ID Token. El Backend se conectaría a Cloud SQL y utilizaría Secret Manager, Cloud Storage y Cloud Monitoring/Logging como servicios gestionados. Al cierre técnico, sólo Artifact Registry/WIF y Cloud Run DEV para Backend y Frontend cuentan con evidencia de despliegue; el resto debe leerse como arquitectura objetivo.

El dimensionamiento de la infraestructura objetivo se definirá a partir del consumo observado de los componentes ejecutados en contenedores, en lugar de asignar recursos únicamente a partir de estimaciones teóricas. Para ello se consideran por separado el Backend, el AI Module y la base de datos, registrando consumo de memoria y CPU tanto en reposo como durante un recorrido representativo de procesamiento. En el caso del AI Module resulta especialmente relevante

registrar el consumo con los modelos cargados y durante la inferencia, dado que constituye el componente de mayor demanda computacional. La necesidad de aceleración mediante GPU se evaluará únicamente si las mediciones sobre CPU muestran tiempos incompatibles con el flujo previsto.

Componente	Escenario medido	CPU observada	RAM observada	GPU/VRAM	Criterio preliminar para despliegue
Frontend	Navegación y serving containerizado	p95: 1,98 %; pico: 2,69 %	p95: 14,68 MiB; pico: 14,80 MiB	No aplica	Componente de baja demanda computacional; apto para hosting estático o un contenedor de recursos mínimos.
Backend	Reposo y recorrido E2E	p95: 7,67 %; pico: 33,40 %	p95: 267,50 MiB; pico: 306,60 MiB	No aplica	La medición muestra una demanda moderada y ampliamente inferior a una vCPU durante el recorrido evaluado; se debe conservar margen de memoria para el runtime Java y variaciones de carga.
AI Module	Modelos cargados e inferencia real	p95: 346,62 %; pico: 405,09 %	p95: 801,20 MiB; pico: 940,80 MiB	GPU no utilizada	Es el principal consumidor de cómputo. El p95 equivale aproximadamente al uso concurrente de 3,47 vCPU y el pico a 4,05 vCPU en el entorno medido, por lo que el dimensionamiento inicial debe priorizar capacidad de CPU y margen de memoria.
PostgreSQL	Persistencia durante recorrido E2E	p95: 4,13 %; pico: 30,81 %	p95: 37,19 MiB; pico: 37,37 MiB	No aplica	La carga observada fue baja para un único recorrido E2E; corresponde utilizar una instancia administrada básica para el prototipo y reevaluarla bajo carga concurrente.

Las mediciones corresponden a una ejecución local containerizada del prototipo sobre Docker Desktop, con 16 procesadores lógicos visibles para Docker y 7,39 GiB de memoria disponible en dicho entorno. Durante la prueba se ejecutó un recorrido E2E local de 77,24 segundos que incluyó ingestión DICOM, clasificación de series, segmentación sagital y axial,

procesamiento full-series, persistencia y revisión profesional; no debe interpretarse como habilitación productiva de P10.7, que permanece bloqueado por paridad de preprocesamiento. El AI Module fue el componente de mayor demanda, con un percentil 95 de CPU de 346,62 % y un pico de 405,09 %, equivalentes aproximadamente al uso concurrente de 3,47 y 4,05 núcleos de CPU respectivamente. La utilización máxima de memoria del mismo componente fue de 940,80 MiB. La GPU disponible en el host no fue utilizada por el contenedor durante esta prueba, por lo que no se considera necesaria para la configuración inicial evaluada. Estos resultados constituyen una línea base para el dimensionamiento preliminar del prototipo y deberán contrastar posteriormente con mediciones realizadas sobre la infraestructura desplegada en Google Cloud.




Figura 10.7: Arquitectura objetivo de despliegue en Google Cloud. Fuente: elaboración propia.

El principio financiero adoptado es no crear un recurso cuyo costo máximo no pueda estimarse de antemano. Esta arquitectura debe leerse por estado de madurez: Artifact Registry/WIF, Backend Cloud Run DEV (legacy y Green), Frontend Cloud Run DEV, AI Cloud Run privado, Cloud SQL, Secret Manager y storage durable están desplegados y validados de punta a punta (Capítulo 13, Sección 13.8); DEMO environment y monitoreo/alerting live no están desplegados y no deben presentarse como parte del estado operativo actual. El entorno Cloud se encuentra además pausado intencionalmente al cierre de este documento para minimizar consumo de crédito mien-

tras continúa el trabajo de documentación; el procedimiento de pausa y el de restauración están documentados en el repositorio Backend (docs/cloud/CLOUD_PAUSE_RESTORE_COMMANDS.md).

10.6.3 Estado real del despliegue Cloud

El estado Cloud final se documenta por recurso en la Tabla 10.10. Esta tabla resume el estado de despliegue de cada recurso; la evidencia técnica completa de extremo a extremo (autenticación privada, persistencia durable, resiliencia ante reinicio, reproceso sin re-subida, costo y performance reales) se desarrolla en el Capítulo 13, Sección 13.9.

TABLA 10.10: Estado final de despliegue Cloud por recurso.

Recurso	Estado	Lectura para la tesis
Artifact Registry y Workload Identity Federation	Desplegado / validado	Existe evidencia de publicacion de imagenes y federacion CI hacia Google Cloud.
Backend Cloud Run DEV (legacy y Green)	Desplegado / validado	Dos servicios: legacy (pfi-backend-dev) y Green (pfi-backend-v2-dev); el Frontend fue conmutado a Green (Capítulo 13). No implica ambiente productivo ni DEMO final.
Frontend Cloud Run DEV	Desplegado / validado	Servicio DEV corroborado, apuntando en runtime a Backend Green; no implica ambiente productivo ni DEMO final.
AI Cloud Run privado	Desplegado / validado	Autenticacion con Google ID Token ejercitada de punta a punta contra el servicio AI privado real; acceso no autenticado verificado en 403.
Cloud SQL	Desplegado / validado	Utilizada como persistencia gestionada real (Postgres) para el Backend Green, con durabilidad verificada ante reinicio.
Secret Manager	Desplegado / validado	DATABASE_URL y el secreto JWT del Backend Green se sirven desde Secret Manager, no desde variables en texto plano.
Storage durable (GCS)	Desplegado / validado	Dos buckets en uso real: assets durables del producto y checkpoint del modelo, con integridad verificada por tamaño tras materializacion.
DEMO environment	No desplegado	No existe promocion DEV-DEMO ejecutada.
Monitoring/alerting live	No desplegado	La observabilidad esta disenada, pero no operada con trafico real ni alertas live.

10.7 Vista de escenarios (+1)

Los escenarios articulan las cuatro vistas anteriores mediante casos de uso concretos. El escenario principal (autenticación, carga del estudio, ejecución multiplanar, persistencia, visualización y revisión profesional) recorre la vista de procesos (sección 10.4.1), se apoya en los componentes de la vista lógica y en la organización de la vista de desarrollo, y se ejecuta sobre la infraestructura de la vista física. Las historias de usuario del Capítulo 9 formalizan estos escenarios y permiten validar que la arquitectura satisface los requerimientos.

10.8 Diseño de interfaz: wireframes y decisiones de diseño

Antes de implementar el frontend se elaboraron esquemas de interfaz que traducen las necesidades detectadas en el relevamiento a una disposición concreta de pantallas y componentes.

Estos wireframes cumplen dos funciones dentro del proyecto: fijar el recorrido del profesional antes de escribir código y dejar explícita la relación entre cada zona de la interfaz y la necesidad que la origina. El diseño no persigue elaboración estética, sino legibilidad de resultados y disponibilidad permanente de la acción de revisión.

10.8.1 Criterios de diseño derivados del user research

El relevamiento estableció cuatro condiciones que la interfaz debe cumplir con independencia de su apariencia final.

- La imagen original y la máscara superpuesta deben poder compararse sin cambiar de pantalla, y la superposición debe poder activarse y desactivarse (N-01).
- Toda estructura y toda medición deben ofrecer, en el mismo lugar donde se muestran, la posibilidad de aceptar, observar, corregir o descartar el resultado (N-02, N-05).
- Cada valor presentado debe indicar la estructura, el plano y el corte del que proviene, de modo que el profesional pueda verificar su origen (N-04, N-12).
- La ausencia de una secuencia, de un plano o de un resultado debe informarse de manera explícita, sin completar el espacio con información aproximada (N-11).

A estas condiciones se suma un criterio de eficiencia señalado en las entrevistas: el flujo no debe agregar tiempo innecesario respecto de la práctica actual (N-07). En consecuencia, el recorrido principal se diseñó con la menor cantidad posible de pantallas intermedias entre la carga del estudio y la visualización de resultados.

10.8.2 Esquemas de las pantallas principales

TABLA 10.11: Relación entre zonas de la interfaz, necesidades del relevamiento y requerimientos

Zona de la interfaz	Función	Necesidad	Requerimiento
Worklist de estudios	Identificar casos disponibles, pendientes y revisados sin abrir cada uno.	N-07	HU-02
Alta de estudio y carga	Asociar el volumen a una referencia de sujeto seudonimizada e informar las series compatibles detectadas.	N-09, N-11	HU-03, HU-04
Visor con superposición conmutable	Comparar imagen original y máscara en el mismo encuadre.	N-01	HU-06
Selector de plano y navegación por cortes	Recorrer el volumen conservando la relación entre resultado y corte de origen.	N-03, N-12	HU-07
Panel de mediciones	Presentar cada valor junto con su estructura, plano y corte.	N-04	HU-08
Controles de revisión	Aceptar, observar, corregir o descartar cada resultado desde el punto en que se muestra.	N-02, N-05	HU-09

TABLA 10.11: Relación entre zonas de la interfaz, necesidades del relevamiento y requerimientos (continuación)

Zona de la interfaz	Función	Necesidad	Requerimiento
Preinforme editable	Reunir estructuras, mediciones, observaciones y estado de revisión en una salida modificable.	N-04, N-08	HU-09
Estados vacíos y degradados	Informar la ausencia de plano, secuencia o resultado sin completar la información faltante.	N-11	HU-11
Historial de corridas	Reabrir un estudio ya procesado sin repetir la inferencia.	N-08, N-10	HU-10

10.8.3 Decisiones de diseño y alternativas descartadas

Tres decisiones merecen registro porque condicionaron la implementación posterior.

La primera es la disposición del panel de revisión junto al visor y no en una pantalla posterior. El relevamiento indicó que la corrección forma parte de la lectura y no de una etapa separada, de modo que separar ambas acciones habría agregado un paso sin valor clínico.

La segunda es la decisión de no mostrar probabilidades ni puntajes de confianza numéricos al usuario final. Las entrevistas señalaron que un valor de confianza sin validación clínica puede inducir una interpretación indebida, por lo que la interfaz comunica el estado del resultado en términos operativos y no probabilísticos.

La tercera es la presentación del plano axial como vista complementaria y no como pestaña equivalente al sagital. Esta decisión refleja el alcance real del prototipo, en el que la base anatómica y la mayor parte de la validación técnica se apoyan en el plano sagital, y evita sugerir una paridad de madurez entre ambos módulos.

Workspace multiplanar - wireframe UX low-fidelity

Arquitectura de información para lectura asistida por IA. Placeholder abstracto, sin imágenes reales.




Figura 10.8: Wireframe de baja fidelidad del workspace multiplanar propuesto, incluyendo visualización sagital y axial, navegación full-series, superposición de resultados y panel de mediciones vinculadas al nivel anatómico. Fuente: elaboración propia.

Revisión profesional y preinforme - wireframe UX low-fidelity

Human-in-the-loop: resultado automático, corrección, revisión y salida estructurada revisable.




Figura 10.9: Wireframe de baja fidelidad del flujo de revisión profesional y preinforme, mostrando la trazabilidad entre el resultado automático, la corrección del profesional, el estado de revisión y la salida estructurada revisable. Fuente: elaboración propia.

11 Capacidades del prototipo

11.1 Cómo leer este capítulo

Este capítulo describe qué hace el prototipo, capacidad por capacidad. Cada sección responde cuatro preguntas en el mismo orden: qué hace la capacidad, cómo funciona, qué evidencia la respalda y qué límites tiene. La decisión de organizarlo así, y no por la secuencia en que cada componente se construyó, responde a que el lector necesita saber de qué es capaz el sistema antes que cuándo se implementó cada parte. La evolución técnica del desarrollo se documenta en el Anexo F.

Las capacidades se presentan en el orden del recorrido del usuario. El estudio ingresa al sistema, se prepara, se segmenta en ambos planos, se derivan mediciones que se asocian a un nivel anatómico, el resultado se visualiza y se navega, el profesional lo revisa y el conjunto se persiste con su trazabilidad. Las dos últimas secciones reúnen las capacidades desarrolladas que no se exponen en el producto y el estado consolidado de todas ellas.

Una advertencia de lectura vale para todo el capítulo: capacidad implementada no significa capacidad validada clínicamente. El prototipo produce salidas técnicas verificables contra anotaciones de referencia. Su utilidad clínica no fue evaluada y queda declarada como fuera del alcance en el Capítulo 5.

11.2 Ingesta y preparación del estudio

Qué hace. Recibe un estudio de resonancia magnética lumbar completo, identifica las series que contiene, las clasifica por plano y ponderación, y las prepara para el procesamiento.

Cómo funciona. Antes de iniciar un nuevo análisis, el profesional define el `caseId` y una referencia seudónima de sujeto para el Study. En Backend existe además el dominio Patient: entidad persistida, endpoint `/api/patients`, campo `Study.patientId` y asociación Patient–Study validada a nivel API. Sin embargo, la interfaz final de historial y longitudinal continúa operando principalmente con `subjectRef`; no existe todavía un flujo browser completo de alta o selección de entidades Patient persistidas. Por eso la capacidad se describe como implementación parcial del dominio Patient. La vía principal de ingesta continúa siendo un estudio en formato DICOM empaquetado, del que el sistema extrae las series y determina automáticamente cuáles son compatibles con los modelos disponibles. El usuario no selecciona imágenes de a una: la cantidad de cortes se obtiene del propio volumen. Se conserva compatibilidad con otros formatos, empleados como fixtures de prueba y en flujos de investigación.

TABLA 11.1: Formatos admitidos y uso previsto.

Formato	Uso en el proyecto	Metadata aprovechada
DICOM	Vía principal de ingesta; estudio completo con sus series registradas	Espaciado de píxel, posición y orientación de la imagen, y demás metadata de serie e instancia
MHA y MHD	Compatibilidad técnica, fixtures y flujos de investigación	Dimensiones, espaciado, origen y dirección cuando están disponibles
NPY	Pruebas automatizadas y volúmenes controlados	Dimensiones y eje de selección
PNG, JPG y otros formatos de imagen	Pruebas mínimas y entradas bidimensionales simples	Sin geometría física confiable

La preparación normaliza la intensidad recortando por los percentiles 1 y 99 y escalándola al intervalo unitario, y redimensiona la imagen a la dimensión que el modelo espera. Ese redimensionado obliga a una corrección que resulta determinante para las mediciones posteriores: el sistema mantiene tres representaciones geométricas simultáneas, la grilla nativa de la imagen, la grilla del modelo y el espacio del paciente en milímetros, y ajusta el espaciado al pasar de la segunda a la tercera. La corrección se aplica sobre el espaciado y no sobre la medición, porque el error no reside en el recuento de píxeles sino en cuánto mide cada píxel de esa grilla. Sin ella, un corte redimensionado devolvía valores un tercio menores que los reales y áreas afectadas en mayor proporción, dado que el factor interviene al cuadrado.

Antes de ejecutar, el sistema valida el formato y los límites aceptados. La ausencia del plano axial no invalida una corrida sagital.

Qué evidencia lo respalda. Pruebas automatizadas de lectura de volúmenes, de preprocesamiento y de selección de corte, y regresión sobre fixtures de-identificados. El acceso requiere autenticación y una cuenta nueva permanece pendiente de aprobación hasta que un administrador la habilite.

Qué límites tiene. Cuando la fuente no aporta espaciado válido, las mediciones derivadas se expresan en píxeles y la unidad lo declara: el sistema no infiere geometría física ausente. Las series y modalidades no soportadas quedan disponibles como imagen base e informan que no poseen inferencia automática.

11.3 Segmentación sagital

Qué hace. Delimita, sobre cortes sagitales, tres tipos de estructura: cuerpos vertebrales, canal espinal y discos intervertebrales.

Cómo funciona. Una red convolucional bidimensional de tipo U-Net, entrenada sobre el conjunto SPIDER, que produce una máscara de cuatro clases: fondo, vértebras, canal y discos. Las vértebras y los discos se segmentan como clase agrupada, no como instancias individuales; la separación por espacio discal se resuelve en el postprocesamiento, según se describe en la sección 11.6. El procesamiento se aplica a la serie completa y no únicamente al corte de referencia.

Cada corrida resuelve el artifact correspondiente al plano solicitado, verifica que su manifest y su arquitectura sean compatibles y ejecuta la inferencia. La carga es estricta: si los nombres de capa del artifact no coinciden con los de la arquitectura declarada, la carga falla de forma explícita en lugar de completar los pesos faltantes.

Qué evidencia lo respalda. Coeficiente Dice macro de 0,893 sobre una partición retenida separada a nivel de paciente, con 152 pacientes de entrenamiento, 33 de validación y 33 de prueba. El artifact supera el umbral de calidad del proyecto y está registrado como baseline técnico validado. El protocolo completo, las particiones y el criterio del umbral se desarrollan en el Capítulo 13; la configuración de entrenamiento, en el Anexo E.

Qué límites tiene. El modelo produce clases agrupadas: no distingue una vértebra de otra ni un disco de otro. Toda afirmación sobre niveles anatómicos individuales depende del mecanismo descrito en la sección 11.6 y no del modelo. La evaluación mide coincidencia con las anotaciones del conjunto, de modo que reproduce también los criterios de quien anotó. No se informan métricas de distancia, que aportarían información sobre la precisión del contorno que el coeficiente Dice no captura en estructuras de tamaño considerable.

11.4 Segmentación axial

Qué hace. Delimita, sobre cortes axiales de los tres niveles discales inferiores, cuatro estructuras: disco intervertebral, elemento posterior, saco tecal y región anteroposterior.

Cómo funciona. Una red convolucional bidimensional entrenada sobre el conjunto de Sudirman y Al-Kafri. Las máscaras de referencia de ese conjunto no codifican las estructuras como índices consecutivos sino como valores de gris, de modo que el entrenamiento las remapea a seis clases conservando la nomenclatura de origen: las cuatro anatómicas y dos de fondo.

TABLA 11.2: Correspondencia entre clases del modelo axial y estructuras anatómicas.

Índice	Clase	Valor de origen	Estructura anatómica
0	background_250	250	Fondo del remapeo de entrenamiento
1	raw_0	0	Fondo del conjunto de origen, correspondiente a la región que rodea al paciente

Índice	Clase	Valor de origen	Estructura anatómica
2	raw_50	50	Disco intervertebral
3	raw_100	100	Elemento posterior
4	raw_150	150	Saco tecal
5	raw_200	200	Región anteroposterior

La presencia de dos clases de fondo responde a que el remapeo de entrenamiento reserva el índice cero para su propio valor de fondo, mientras que el valor cero del conjunto de origen designa la región exterior al paciente. Ambas se excluyen de la representación visual. La nomenclatura de origen se conserva de forma deliberada, porque los nombres corresponden a valores de intensidad y no a términos clínicos: traducirlos a una terminología normalizada supondría atribuir una equivalencia que el conjunto de datos no declara.

La correspondencia queda congelada en el manifest del artifact y replicada en la configuración del runtime, con un validador que compara ambas fuentes. Renombrar una clase en el código invalida el manifest y deshabilita el modelo, restricción intencional para que el código y el artifact coincidan respecto de qué se entrenó.

Qué evidencia lo respalda. El gate oficial del artifact axial registra `qualityGatePassed=false`. La métrica oficial de primer plano es Dice macro 0,679348283374592 e IoU macro 0,5699727598420694, con razón `dice_macro_foreground_below_threshold`. Como análisis secundario, excluyendo la clase `raw_0`, el Dice es 0,8105661875685084 y el IoU 0,6915400877715925. Esta segunda lectura ayuda a interpretar el comportamiento sobre estructuras anatómicas, pero no reemplaza la métrica oficial del gate.

Qué límites tiene. El artifact no alcanzó el umbral de calidad de 0,70 en la métrica que lo evalúa, que incluye las clases de fondo, y permanece registrado como candidato sin promoverse a baseline técnico. El umbral no se modificó para acomodar el resultado. La partición de prueba había sido evaluada previamente para una versión anterior del mismo modelo, de modo que el resultado es comparativo y no una validación sobre datos enteramente no observados. Los conteos de la partición de entrenamiento no fueron publicados en el manifest y su recuperación permanece pendiente. El capítulo 13 desarrolla estos tres puntos.

Corresponde además señalar que las anotaciones del conjunto de origen se realizaron sobre la ponderación T1 y la inferencia se ejecuta sobre T2, apoyándose en el co-registro nativo verificado entre ambas secuencias. Esa verificación se realizó sobre una muestra de los estudios y no sobre la totalidad del conjunto.

11.5 Mediciones geométricas

Qué hace. Deriva de las máscaras un conjunto acotado de magnitudes geométricas, cada una asociada a la estructura, el plano y el corte del que proviene.

Cómo funciona. Cada medición se emite con su valor, su unidad, el nivel anatómico cuando corresponde, el índice del corte, la confianza media del modelo sobre su propia máscara, el estado de revisión y el segmento de puntos del que se derivó el número. El valor automático y el valor corregido por el profesional se conservan en campos separados, de modo que una corrección no elimina el dato original. El conjunto de puntos viaja junto al valor y no se recalcula en la interfaz, para evitar que la representación gráfica y la tabla numérica discrepen.

TABLA 11.3: Catálogo de mediciones derivadas de las máscaras.

Medición	Estructura	Método de cálculo	Unidad	Nivel
Área, ancho y alto de disco	Disco intervertebral, una instancia por espacio discal	Área por recuento de píxeles convertido con el espaciado; ancho y alto sobre los ejes propios de la estructura	mm y mm ²	Sí
Área, ancho y alto de cuerpo vertebral	Cuerpo vertebral, separado del arco posterior	Idéntico al anterior	mm y mm ²	Sí
Área del canal	Canal completo visible en la serie	Recuento de píxeles convertido con el espaciado	mm ²	No, corresponde al estudio
Diámetro anteroposterior del canal	Canal, acotado a la banda del disco correspondiente	Medición fila por fila dentro de la banda del nivel	mm	Sí
Ángulo segmentario	Dos cuerpos vertebrales contiguos	Ángulo entre los ejes de ancho de ambos cuerpos	Grados	Sí, con carácter experimental
Área, ancho y alto de estructuras axiales	Clases del módulo axial	Idéntico al de disco y cuerpo vertebral	mm y mm ²	No

Tres decisiones de método requieren justificación explícita, y las tres surgieron de errores detectados durante el desarrollo.

Los ejes de medición son los de la estructura, no los de la imagen. El ancho y el alto se calculan sobre los ejes propios de cada estructura, obtenidos de los autovectores de la covarianza de la nube de píxeles y computados en milímetros para que un espaciado anisotrópico no incline los ejes por sí solo. La alternativa, una caja delimitadora alineada con la imagen, sobreestima toda estructura inclinada: en el espacio discal más angulado devolvía 25 milímetros de alto para un disco cuya dimensión habitual se sitúa entre 8 y 12. De los dos ejes resultantes, el más próximo a la horizontal se informa como ancho; ordenarlos por magnitud los intercambiaría en cualquier estructura más alta que ancha.

El área no requiere esa corrección, porque el recuento de píxeles no depende de la orientación.

El diámetro anteroposterior del canal se mide fila por fila. La primera implementación empleaba la caja delimitadora y devolvía 47 milímetros, valor incompatible con un canal lumbar: ese número correspondía al recorrido de la lordosis, dado que el centro del canal se desplaza

alrededor de 35 milímetros entre los extremos de la serie. La medición fila por fila, acotada a la banda del disco, devuelve una componente conexa de 230 milímetros de extensión y entre 10 y 15 de ancho, con mediana de 13,1.

Qué evidencia lo respalda. Una verificación por contraste contra rangos conocidos, desarrollada en el Capítulo 13. El diámetro anteroposterior del canal arroja una mediana compatible con el saco tecal lumbar, y la suma de ángulos segmentarios entre la primera y la quinta vértebra lumbar da 36 grados frente a una lordosis habitual de entre 40 y 60.

Qué límites tiene. Esa verificación no equivale a una validación. Un contraste con rangos poblacionales permite descartar valores manifiestamente incompatibles, pero no establece la exactitud de una medición individual. No existe comparación contra mediciones realizadas por profesionales sobre los mismos estudios, que requeriría un conjunto anotado específicamente para ese fin.

Dos límites adicionales se declaran de forma explícita. El primero es que el conjunto de datos denomina canal espinal a la clase segmentada sin precisar si delimita el canal óseo o su contenido dural, y el proyecto no atribuye una lectura que la fuente no declara. El segundo es que las mediciones son descriptores geométricos y no constituyen, por sí mismas, una clasificación clínica.

11.6 Asignación de nivel anatómico

Qué hace. Determina a qué espacio discal corresponde cada corte axial y cada medición, de modo que un valor pueda informarse como perteneciente a un nivel concreto y no de forma aislada.

Cómo funciona. Ninguna de las estructuras que el módulo axial segmenta es numerable por sí misma: para afirmar que una medición corresponde a un espacio discal determinado hay que contar espacios desde la unión lumbosacra, y un corte axial muestra uno solo. Antes de incorporar este mecanismo, la totalidad de las mediciones axiales se presentaba sin nivel asignado, lo que la interfaz mostraba como una falla cuando en realidad la ubicación nunca se había intentado.

El procedimiento resuelve la asignación en dos etapas, en coordenadas del paciente y no en índices de corte.

Sobre el plano sagital, por cada disco segmentado se publica su casco convexo expresado en coordenadas del paciente. La elección del casco convexo, en lugar de una caja delimitadora o de un centroide, responde a una propiedad del cálculo posterior: la pregunta que se formulará es entre qué dos valores queda comprendido el disco al proyectarlo sobre la normal del corte axial, y esa proyección es una función lineal, que sobre un conjunto acotado alcanza su mínimo y su máximo en un vértice del casco. El intervalo resultante es exacto para cualquier angulación, sin conservar la máscara completa. Una caja delimitadora produciría un intervalo mayor que el real,

con lo que dos discos contiguos reclamarían el mismo corte; un centroide produciría uno menor, que es peor. La numeración se establece desde la unión lumbosacra hacia arriba.

Sobre el plano axial, para cada corte se calcula su normal a partir de los vectores de orientación registrados en la metadata y se proyecta sobre ella el casco convexo de cada disco. Si el desplazamiento del plano no queda comprendido entre los valores extremos de esa proyección, el disco no cruza ese corte. La resolución se realiza corte por corte y no una vez por serie, porque una serie axial lumbar habitualmente se adquiere en bloques angulados, uno por espacio discal: en el estudio de referencia empleado durante el desarrollo, los primeros cinco cortes presentan una angulación de 3,5 grados, los cinco siguientes de 5,9 y los últimos de 23. Propagar el nivel del corte analizado al resto de la serie situaría cerca de dos tercios de las mediciones bajo un nivel que no les corresponde.

Cuando un plano angulado cruza más de un espacio discal, se adjudica aquel al que atraviesa más cerca de su punto medio, que es el espacio sobre el cual la serie fue planificada, y la distancia se normaliza por la extensión del propio disco para que un espacio de mayor altura no resulte favorecido por su tamaño.

Qué evidencia lo respalda. El mecanismo está implementado y su salida expone el nivel de cada corte identificado por su índice, que el visor consume para presentar cada medición junto con su ubicación anatómica. No se dispone de una métrica de acierto de la asignación, es decir, de la proporción de cortes cuyo nivel se determina correctamente frente a una referencia. Es la principal evidencia faltante de esta capacidad y se declara como tal.

Qué límites tiene. Dos reglas de abstención acotan la capacidad de forma deliberada. Si el estudio muestra menos de cinco espacios discales, ninguna medición recibe nivel, antes que desplazar la numeración completa y adjudicar identificaciones incorrectas. Y si un corte no atraviesa ningún espacio discal, no se le asigna nivel: un corte axial puede haberse adquirido a la altura de un cuerpo vertebral, y adjudicarle el espacio más próximo situaría una medición bajo un nivel que no le corresponde, lo que resulta menos aceptable que no informarlo.

11.7 Visualización y navegación por cortes

Qué hace. Presenta la imagen original con la máscara superpuesta y permite recorrer la serie completa, conservando la relación entre cada resultado y el corte del que proviene.

Cómo funciona. El contrato volumétrico define, por serie, el plano, la cantidad de cortes, el corte de referencia, el eje de la secuencia, las dimensiones y el espaciado, junto con un catálogo en el que cada corte puede asociarse con una vista previa, un indicador de resultados y, cuando corresponda, superposición, puntos de referencia y mediciones. La responsabilidad se distribuye entre las tres capas: el módulo de inteligencia artificial genera una vista previa por corte y marca los que tienen resultado; el backend persiste el catálogo y publica los accesos autorizados, de modo que la navegación funciona con el módulo de inferencia apagado; el frontend presenta

el recorrido con teclado o desplazamiento, indicador de corte actual y total, miniaturas, ajuste visual, control de opacidad y navegación desde una medición hacia su corte de origen.

Qué evidencia lo respalda. El procesamiento de la serie completa está implementado y los assets se persisten y se sirven por corte. El frontend consume la integración contractual P10.9 y presenta el catálogo full-series en un visor navegable. Las pruebas verifican la cantidad y el orden de los cortes, el eje, el índice computacional y la numeración mostrada, con índice interno desde cero y numeración de interfaz desde uno.

Qué límites tiene. La superposición automática no se presupone para todos los cortes de todas las series: solo se muestra donde hay resultado, y los cortes sin inferencia lo declaran en lugar de presentarse vacíos. El visor no simula una correspondencia espacial entre el plano sagital y el axial cuando la metadata geométrica no permite demostrarla; la relación entre planos se establece por la asignación de nivel de la sección 11.6 y no por una superposición supuesta. La integración de los contratos congelados en el frontend está implementada. El recorrido browser E2E final obtuvo 11/11 en Playwright sobre el stack final, pero ese resultado valida el flujo funcional del prototipo y Demo Mode; no convierte a Patient en una entidad browser-level completa ni habilita inferencia clínica.

11.8 Revisión profesional y salida editable

Qué hace. Permite que el profesional acepte, observe, corrija o descarte cada resultado, y reúne las estructuras, las mediciones y las observaciones en una salida editable que incluye un preinforme automático revisable.

Cómo funciona. La revisión no es una etapa posterior sino parte del flujo: los controles se ubican junto al resultado que califican, y cada decisión queda registrada con su autor y su estado. El valor automático y el corregido se conservan por separado, de modo que la corrección no borra la evidencia original.

El preinforme se construye mediante plantillas que combinan los valores derivados de las máscaras con formulaciones fijas asociadas a cada estructura, nivel y medición. No proviene de un modelo de lenguaje ni de una inferencia clínica, sino de una transformación determinística de datos geométricos ya calculados y visibles. Esa distinción importa: dado un mismo conjunto de máscaras y mediciones, produce siempre el mismo texto, y cada afirmación puede rastrearse hasta la estructura y el corte que la originan.

Qué evidencia lo respalda. El flujo de revisión está implementado y persistido, y la reapertura de un estudio recupera el estado de revisión junto con los resultados. El relevamiento con profesionales identificó la posibilidad de corregir manualmente cada resultado como el requisito más votado para confiar en una segmentación automática, según se informa en la sección 8.12.

Qué límites tiene. El preinforme es un punto de partida editable y no un informe clínico:

su función es reducir la transcripción manual de valores y organizarlos en un orden anatómico previsible, mientras la redacción final, la interpretación y la responsabilidad permanecen en el profesional. La utilidad del flujo de revisión sobre el producto integrado se observó en las dos sesiones de revisión cualitativa documentadas en la sección 13.11; esas sesiones no equivalen a validación clínica, y la validación cruzada final, con lectura profesional independiente sobre los mismos estudios, continúa pendiente.

11.9 Persistencia, reapertura y trazabilidad

Qué hace. Conserva cada corrida con su modelo, su artifact, sus resultados, sus mediciones y su estado de revisión, de modo que un estudio pueda recuperarse más tarde sin volver a ejecutar la inferencia.

Cómo funciona. Un estudio actúa como contenedor lógico y una corrida representa una ejecución concreta, de manera que ejecutar de nuevo no sobrescribe la evidencia anterior. Backend permite vincular Studies con una entidad Patient mediante `patientId`, y esa asociación se persiste y se valida por API. En la interfaz final, sin embargo, el historial y la comparación longitudinal siguen recorriendo principalmente la identidad `subjectRef`. Por lo tanto, `patientId` debe leerse como dominio de Backend implementado, no como flujo visual completo de gestión de pacientes. Cada corrida genera identificadores que permiten seguirla: el del caso, el de la ejecución, el que agrupa ambos planos y el que correlaciona solicitudes y registros técnicos.

Qué evidencia lo respalda. La prueba de aceptación de esta capacidad consiste en abrir un estudio persistido con el módulo de inferencia apagado y comprobar que recupera resultados, mediciones y estado de revisión. Esa prueba está incorporada al repositorio y se ejecuta como regresión.

Qué límites tiene. Las corridas anteriores a la incorporación del catálogo de cortes conservan únicamente los assets que existían en su momento y se abren en modo de compatibilidad, sin fabricar un catálogo que no se generó. Los registros históricos pueden no tener un Patient asociado, porque `patientId` es nullable y no se infiere retroactivamente desde `subjectRef`. Cuando la evidencia ya existe, la reapertura utiliza los datos persistidos y no requiere repetir la inferencia.

11.10 Seguridad y estados degradados

Qué hace. Restringe las operaciones según el rol del usuario y comunica de forma explícita cuándo un componente no está disponible, en lugar de presentar la indisponibilidad como un resultado del análisis.

Cómo funciona. Las operaciones protegidas requieren autenticación y autorización, las cuentas nuevas permanecen pendientes de aprobación, los assets no se sirven mediante rutas internas y los secretos se mantienen fuera del código. El frontend no se comunica directamente

con el módulo de inferencia: todas las operaciones pasan por el backend, lo que permite aplicar autorización y conservar el resultado aunque el servicio de inferencia esté caído.

El sistema distingue el modo de ejecución solicitado del modo efectivamente aplicado. Una corrida solo se informa como inferencia real cuando existieron un artifact identificable, un manifest coherente, una arquitectura compatible, una entrada procesable y una ejecución exitosa. Si alguna de esas condiciones falta, la respuesta declara el estado degradado y no se registra como resultado válido.

Qué evidencia lo respalda. Pruebas de autenticación, autorización, contratos, auditoría y comportamiento ante archivo inválido, artifact ausente, rol insuficiente y asset faltante. El contrato público no expone probabilidades, salidas crudas, mapas de confianza ni rutas internas.

Qué límites tiene. El endurecimiento de la configuración de seguridad para un entorno productivo permanece como evolución posterior. Las medidas descritas corresponden a un prototipo académico y no constituyen una evaluación formal de cumplimiento normativo.

11.11 Capacidades desarrolladas y no expuestas

Dos líneas de trabajo produjeron modelos entrenados y congelados que no forman parte de las capacidades del producto. Se documentan aquí porque constituyen trabajo realizado y porque su exclusión es una decisión de alcance que conviene justificar, no una omisión.

11.11.1 Estimación de hallazgos estructurales por nivel

Se entrenó y congeló un modelo multitarea que, a partir de las series sagitales, produce ocho estimaciones estructurales por nivel discal: grado de degeneración discal, cambio de señal de platillo, cambios de platillo vertebral superior e inferior, desplazamiento vertebral, hernia, reducción de altura y protrusión.

El modelo se entrenó sobre 992 muestras y se seleccionó sobre 248 de validación. La evaluación final se realizó una única vez sobre una partición sellada de 278 niveles discales correspondientes a 39 pacientes, sin solapamiento de pacientes con el conjunto de desarrollo y sin inspeccionarla durante la selección del modelo. El grado de degeneración y el cambio de señal de platillo son tareas multiclase, de cinco y cuatro categorías respectivamente, y se evalúan mediante F1 macro y exactitud balanceada; las seis restantes son binarias y se evalúan mediante F1, área bajo la curva ROC y precisión promedio.

TABLA 11.4: Desempeño de la estimación estructural sobre la partición sellada.

Estimación	Tipo	F1	Exactitud balanceada	ROC-AUC	Precisión promedio	Línea base
Protrusión discal	Binaria	0,846	—	0,899	0,903	—
Reducción de altura discal	Binaria	0,733	—	0,890	0,823	—
Cambio de platillo inferior	Binaria	0,751	—	0,787	0,794	—

Estimación	Tipo	F1	Exactitud balanceada	ROC-AUC	Precisión promedio	Línea base
Cambio de platillo superior	Binaria	0,730	—	0,771	0,770	—
Grado de degeneración discal	5 clases	0,492	0,521	—	—	0,200
Cambio de señal de platillo	4 clases	0,315	0,422	—	—	0,250
Hernia discal	Binaria	0,189	—	0,669	0,085	0,036
Desplazamiento vertebral	Binaria	0,125	—	0,788	0,089	0,032

La línea base indica el valor que alcanzaría un clasificador aleatorio: en las tareas multiclase corresponde al azar uniforme y en las binarias a la prevalencia de la clase positiva, que es la referencia adecuada para la precisión promedio cuando las clases están desbalanceadas.

El desempeño es marcadamente heterogéneo y las ocho estimaciones no admiten la misma lectura. La protrusión y la reducción de altura alcanzan valores consistentes en las tres métricas. Los cambios de platillo se sitúan en un rango intermedio. Las dos tareas multiclase superan con claridad el azar uniforme, en 32 y 17 puntos porcentuales respectivamente, pero permanecen lejos de un valor utilizable en un flujo asistido.

Las dos últimas requieren una lectura más cuidadosa. El desplazamiento vertebral aparece en 9 de las 278 muestras y la hernia en 10, es decir, con prevalencias en torno al 3 %. Con ese desbalance, su precisión promedio de 0,089 y 0,085 equivale a 2,75 y 2,36 veces la línea base, de modo que no es correcto describirlas como indistinguibles del azar. El área bajo la curva del desplazamiento vertebral, de 0,788, indica además una capacidad de ordenamiento razonable. Sin embargo, sus F1 de 0,125 y 0,189 muestran que, con el umbral operativo empleado, la clasificación positiva sigue siendo débil: el modelo ordena mejor de lo que decide.

Esa heterogeneidad está registrada en el propio contrato del sistema. El desplazamiento vertebral y la hernia se encuentran marcados como no soportados para producto, de modo que la distinción entre estimaciones utilizables y no utilizables no es una lectura posterior del documento sino una propiedad del artifact congelado.

Ninguna de las ocho estimaciones se expone en el producto. La razón no es únicamente el desempeño de las tareas más débiles, sino que el prototipo no dispone de un mecanismo para comunicar al profesional que dos estimaciones presentadas con la misma jerarquía visual difieren en confiabilidad en un orden de magnitud. Exponer probabilidades queda excluido por diseño, y presentar las ocho como equivalentes induciría a confiar por igual en resultados que no lo son. La decisión responde al mismo criterio que la sección 13.7 desarrolla con otro caso: una salida se publica cuando puede verificarse y comunicarse junto con su incertidumbre, no cuando puede calcularse.

El entrenamiento continúa sobre un conjunto de datos de mayor tamaño, de modo que las cifras informadas corresponden al estado congelado en esta instancia y no al desempeño final de la línea. Su promoción a capacidad del producto requeriría, como mínimo, ampliar el conjunto

en las tareas de baja prevalencia y resolver cómo comunicar la diferencia de confiabilidad entre estimaciones.

11.11.2 Clasificación de estenosis subarticular

Se entrenó y evaluó internamente un modelo de estenosis subarticular sobre cortes axiales, empleando el conjunto RSNA y LumbarDISC, y su checkpoint fue congelado. La capacidad permanece bloqueada porque el clasificador requiere como entrada una región de interés anatómica que el sistema no genera de forma automática: el modelo axial disponible no incluye una clase de vértebra, de modo que no existe una referencia anatómica desde la cual derivar esa región. Los sustitutos evaluados se descartaron por razones metodológicas.

Se trata de un bloqueo de capacidad y no de un trabajo pendiente de ejecución. Su resolución depende de una etapa de localización anatómica que no está disponible.

11.12 Demo Mode y validación funcional reproducible

Demo Mode es un recorrido determinístico, no clínico, construido para defensa académica, testing E2E y validación funcional del producto. Utiliza datos sintéticos o fixtures controlados y no debe presentarse como sustituto de inferencia clínica real. La configuración final contiene cuatro studies y dos subjects de demostración; cuando el localizador real no puede habilitarse, el flujo usa `localizationStatus=demo_fixture`, `source=DEMO_FIXTURE`, `validated=false` y una advertencia explícita de no inferencia real.

El valor de Demo Mode es que permite recorrer de punta a punta el producto sin fabricar un nivel anatómico no validado. En ese recorrido se ejercitan ingesta, corrida AI, mediciones, evidencia visual, revisión profesional, reporte, exportación PDF/JSON, chat contextual contra proveedor mock y comparación longitudinal determinística. La comparación longitudinal usa valores controlados por `caseId`; por ejemplo, el flujo final valida una variación absoluta de 0,6 mm luego de una corrección profesional. El resultado browser E2E final fue Playwright 11/11 PASS, interpretado como validación funcional del prototipo y no como validación clínica.

11.13 Disponibilidad productiva de modelos y extensiones

La Tabla 11.5 resume la diferencia entre evaluación offline, disponibilidad runtime y exposición de producto. Esta distinción evita presentar una métrica experimental como si habilitara automáticamente una capacidad clínica o productiva.

TABLA 11.5: Estado final de modelos y extensiones.

Capacidad	Evidencia	Estado	Limitación principal
Sagital SPIDER U-Net2D	Test Dice macro 0,8934 e IoU 0,8080; quality gate aprobado	Validada técnicamente	Dataset académico, sin validación clínica.

Capacidad	Evidencia	Estado	Limitación principal
Axial Sudirman/Al-Kafri U-Net2D	Dice oficial 0,679348283374592; IoU 0,5699727598420694	Experimental	qualityGatePassed=false; la lectura excluyendo raw_0 no reemplaza el gate.
67B2 localización lumbar absoluta	DEV top1 0,9343629343629344; top2 0,972972972972973; MRR 0,9617117117117117; n=259. Locked Top1 0,9049295774647887; Top2 0,9612676056338029; MRR 0,9448356807511736; pipeline accuracy given emit 0,9909502262443439	Parcial/offline	67B2_RUNTIME_PARITY_NOT_PROVEN; productEnabled=false; parityVerified=false.
67C pairing sagital-axial	Algoritmo geométrico determinístico con flags de contrato	Experimental	experimental=true, validated=false, reviewRequired=true; depende de 67B2.
P10.7 hallazgos degenerativos	Checkpoints y contratos existen	Bloqueada	blocked_preprocessing_parity; automaticInferenceEnabled=false.
Grad-CAM	Tests AI específicos PASS, contrato API validado, wiring Frontend presente	Experimental	No fue ejercitado explícitamente en el browser E2E final; no es validación clínica.

11.14 Capacidades extendidas de revisión y análisis

Además del flujo principal de segmentación, medición y reporte, el producto final incorpora extensiones de revisión con alcance controlado. Concordance compara evidencia del mismo fenómeno, nivel y lado como regla descriptiva, no clínica. Review analytics agrega telemetría de revisión para observar tiempos y estados, sin medir exactitud médica. Feedback curation registra candidatos de curación profesional, pero no activa reentrenamiento automático ni aprendizaje online. Grad-CAM expone mapas experimentales para el clasificador subarticular, siempre con experimental=true. Product-analysis integra resultados del flujo de producto: en Demo Mode puede completar un nivel determinístico, mientras que en entradas reales conserva el fallo seguro cuando 67B2 no prueba paridad runtime.

El chat contextual usa una abstracción de proveedor LLM. En el recorrido demo se valida contra un mock determinístico; Qwen/self-hosted se documenta como target soportado, no como despliegue productivo ejercitado. Esta capacidad acompaña la lectura del caso, pero no genera diagnóstico, tratamiento ni decisión automática.

11.15 Estado consolidado de las capacidades

TABLA 11.6: Estado de las capacidades al cierre de esta entrega.

Capacidad	Sección	Estado
Ingesta DICOM con identificación de series	11.2	Implementada

Capacidad	Sección	Estado
Preparación y corrección geométrica	11.2	Implementada
Segmentación sagital	11.3	Implementada y evaluada; baseline técnico
Segmentación axial	11.4	Implementada y evaluada; artifact por debajo del umbral
Mediciones geométricas	11.5	Implementadas y persistidas; verificadas por contraste, sin validación
Asignación de nivel anatómico	11.6	Implementada; sin métrica de acierto
Visualización y navegación por cortes	11.7	Implementada; P10.9 integrado en frontend con catálogo full-series y visor navegable; Playwright final 11/11 PASS en recorrido funcional del prototipo
Revisión profesional	11.8	Implementada en su flujo principal
Preinforme automático revisable	11.8	Implementado; editable y no diagnóstico
Persistencia, reapertura y trazabilidad	11.9	Implementadas; Patient/API/persistencia validado en Backend, con UI longitudinal todavía basada principalmente en <code>subjectRef</code>
Seguridad, roles y estados degradados	11.10	Implementados; endurecimiento productivo posterior
Estimación de hallazgos estructurales	11.11.1	Desarrollada y evaluada sobre partición sellada; no expuesta por desempeño heterogéneo
Clasificación de estenosis subarticular	11.11.2	Bloqueada
Recorrido extremo a extremo local/containerizado	—	Validado según la evidencia de la sección 13.8 (Playwright 11/11 sobre Demo Mode y recorrido de producto); no equivale a validación clínica
Recorrido extremo a extremo en Cloud desde navegador	—	Parcial, no cerrado, según la evidencia de la sección 13.9
Validación profesional sobre el producto	—	Revisión cualitativa realizada (Dra. Susana Torres y Dra. Claudia Cejas, sección 13.11); no es validación clínica; la validación cruzada final continúa pendiente
Comparación longitudinal	—	Parcial: disponible en el alcance Demo/ <code>subjectRef</code> según la evidencia existente; no constituye validación clínica de progresión
Despliegue en Google Cloud	—	Entorno DEV desplegado y validado (Backend, Frontend, AI privado, Cloud SQL, Secret Manager y storage durable); DEMO environment separado y monitoreo/alerting en vivo no desplegados

Esta tabla describe el estado del producto y no sustituye el backlog técnico. Una capacidad solo se declara implementada cuando existe en el flujo, cuenta con pruebas y su evidencia puede localizarse. Las tres capacidades cuya evidencia visual todavía no se incorporó al documento se identifican mediante los espacios reservados de las figuras correspondientes.

12 Metodología de desarrollo y validación técnica

12.1 Enfoque de trabajo

Este capítulo describe cómo se construyó, integró y validó el prototipo: de qué manera las necesidades identificadas, los requerimientos, los componentes técnicos, las pruebas y la evidencia se transforman en incrementos verificables.

El proyecto adopta un enfoque aplicado, iterativo e incremental, en la línea de los métodos que construyen el sistema mediante incrementos sucesivos verificables en lugar de una única fase de implementación [39]. No se emplea Scrum de forma estricta ni se reproducen ceremonias que no aporten valor a un equipo de dos integrantes. Se combinan un backlog priorizado, checkpoints técnicos, contratos compartidos, ramas de corta duración, revisión cruzada y validación por capas. Una capacidad no se considera terminada por compilar, renderizar una pantalla o existir en un único repositorio.

La división del trabajo se realiza por módulos y no mediante una rama permanente por persona. Un integrante asume como responsabilidad primaria el módulo de inteligencia artificial, el backend, los contratos y la infraestructura; el otro, el frontend, el visor, la interacción y la accesibilidad. Ambos revisan los cambios del otro cuando atraviesan un contrato compartido.

12.2 Sistemas de identificación

La nomenclatura de trabajo no fue uniforme a lo largo del proyecto y el documento emplea tres sistemas principales de identificación de distinta naturaleza, además de convenciones auxiliares utilizadas en etapas específicas. Estos identificadores no deben interpretarse como una única secuencia.

- Las épicas académicas, identificadas como E1 a E10, derivan del user research y de los requerimientos, y organizan el trabajo desde la perspectiva del producto y de la tesis.
- Los backlogs técnicos internos de cada repositorio, con prefijos propios: AI- en el módulo de inteligencia artificial, BE- en el backend, FE- y FE-RD- en el frontend, y DEV- para contenedorización y orquestación.
- Los checkpoints coordinados de producto, identificados como P8, P9, P10 y la secuencia P10.5 a P10.9, en los que un mismo objetivo se distribuye entre repositorios y cada uno asume el subbloque correspondiente.

Algunos checkpoints coordinados se subdividen en bloques de implementación —por ejemplo, P10.5-A a P10.5-F— sin constituir por ello una nueva secuencia global del proyecto.




Figura 12.1: Sistemas de identificación utilizados en el proyecto

La Figura 12.1 resume estas nomenclaturas y sus ámbitos de aplicación.

De esta distinción se siguen dos consecuencias para la lectura. La primera es que no existió una secuencia global de P1 a P7 compartida por los tres repositorios: la coordinación mediante checkpoints comunes comenzó con P8, y las etapas anteriores son líneas paralelas de backlog. La segunda es que los identificadores FE-P1 a FE-P8, de una épica de pulido del frontend, son internos de ese repositorio: FE-P8 designa un documento de control de calidad de la interfaz, mientras que P8 designa el checkpoint de persistencia descrito en el Anexo F.

Los hitos experimentales del módulo de inteligencia artificial, numerados también con la letra E en la etapa de notebooks, pertenecen a una numeración técnica propia y no guardan relación con las épicas académicas. Los profesionales entrevistados se identifican con el prefijo EN, de EN-01 a EN-05, precisamente para evitar la confusión con cualquiera de esas dos numeraciones.

Un checkpoint es un estado compatible y reproducible del sistema, identificado mediante commits concretos en los tres repositorios. Su función es congelar una frontera común desde la cual el otro integrante pueda continuar sin depender de cambios locales no publicados, e indica alcance, identificadores de commit, variables necesarias, forma de ejecución, pruebas realizadas y limitaciones. El estado global no se deriva del avance de una sola capa: el cierre de seguridad del frontend no implica que P10 esté terminado si el módulo de inteligencia artificial conserva criterios pendientes.

12.3 Ciclo de trabajo y coordinación

Cada incremento responde a una necesidad, un requerimiento o una deuda técnica explícita. Antes de implementarlo se define su alcance, dependencia, responsable, criterio de aceptación y evidencia esperada; se delimita el repositorio responsable y, cuando hay comunicación entre

servicios, se define o actualiza el contrato compartido junto con sus fixtures. La implementación ocurre en una rama de corta duración. Después se ejecutan las pruebas que correspondan, se recolecta evidencia sanitizada, se realiza revisión cruzada y se integra o se congela en una rama de checkpoint identificable. Cuando el incremento atraviesa más de un repositorio, la validación es conjunta.

El ciclo se repite cuando una prueba revela incompatibilidades o cuando el resultado no satisface el criterio original. La iteración no se interpreta como falta de planificación sino como reducción progresiva de incertidumbre.

La coordinación entre repositorios se apoya en contratos antes que en acuerdos informales. Un cambio que modifica campos, estados, assets o errores debe actualizar el contrato compartido, los fixtures, los tipos del consumidor y las pruebas correspondientes. Los fixtures permiten que una capa consumidora avance mientras la productora todavía se implementa.

Los cambios de alcance se aceptan cuando tienen evidencia de origen y análisis de impacto. La incorporación del plano axial surgió del user research y de la disponibilidad de datos; el visor volumétrico, de la necesidad de revisar múltiples cortes. Cada ampliación debe actualizar requerimientos, roadmap, arquitectura, contratos, pruebas y documentación.

12.3.1 Automatización de integración y publicación

Como extensión del ciclo de desarrollo se incorporó una ruta de automatización para la publicación de artifacts de software hacia Google Cloud. GitHub Actions se integra con Google Cloud mediante Workload Identity Federation, evitando almacenar claves JSON permanentes de cuentas de servicio en los repositorios. Las imágenes de los servicios se construyen como contenedores versionados y se publican en Artifact Registry, desde donde pueden ser utilizadas por Cloud Run.

Esta automatización reduce la dependencia de credenciales locales, mejora la reproducibilidad del proceso de publicación y mantiene separadas las responsabilidades entre código, artifact de contenedor y configuración de infraestructura. Durante el PFI, la promoción de revisiones y los cambios de configuración de Cloud se realizaron de manera controlada y por etapas; por lo tanto, no se presenta este mecanismo como una canalización de despliegue productivo completamente autónoma, sino como una automatización de integración y publicación validada para el entorno académico.

Las imágenes se publican de forma versionada utilizando el identificador del commit Git como tag, evitando depender de una etiqueta mutable latest. De esta manera, una imagen almacenada en Artifact Registry puede vincularse con el estado exacto del código fuente que la generó. La automatización implementada cubre la autenticación federada, la construcción y la publicación de contenedores; la promoción de una imagen hacia un servicio Cloud Run se mantiene como una acción controlada.




Figura 12.2: Flujo automatizado de construcción y publicación de imágenes de contenedor mediante GitHub Actions, Workload Identity Federation y Artifact Registry. La promoción hacia Cloud Run se mantiene como una acción controlada. Fuente: elaboración propia.

La Figura 12.2 resume este mecanismo. GitHub no almacena una clave JSON permanente de cuenta de servicio: cada ejecución de `cloud-03-publish-image.yml` obtiene de GitHub un token OIDC de corta duración, que Workload Identity Federation vincula con una identidad acotada en Google Cloud sin exponer credenciales estáticas. Con esa identidad temporal, el workflow construye la imagen del servicio correspondiente y la publica en Artifact Registry identificada por el hash del commit que la originó. Artifact Registry desacopla así la construcción del despliegue: Cloud Run no reconstruye ni recibe la imagen de forma directa, sino que consume una imagen ya publicada cuando dicha promoción se ejecuta de manera controlada. Backend y Frontend habilitan esta publicación sobre sus ramas Cloud aisladas o mediante `workflow_dispatch`, mientras que el módulo de inteligencia artificial la ejecuta exclusivamente mediante `workflow_dispatch manual`.

12.4 Criterios de listo, terminado y evidencia

Una tarea está lista para comenzar cuando cuenta con objetivo concreto, necesidad o requerimiento de origen, responsable, repositorio, dependencias identificadas, entrada real o fixture, criterio de aceptación, plan de prueba y consideraciones de privacidad.

Se considera terminada, para su alcance, cuando el código, contrato o documento está completo, el criterio de aceptación fue ejecutado, los casos de error relevantes fueron probados, la evidencia puede localizarse y el estado real quedó reflejado en la documentación. Una capacidad parcial se declara como tal en lugar de presentarse como cerrada.

La evidencia técnica puede incluir commits, solicitudes de integración, comandos de prueba, respuestas sanitizadas, registros sin datos sensibles, capturas, manifests y hashes. Los checkpoints de modelos se administran como artifacts versionados y no como archivos anónimos: cada uno conserva dataset, clases, preprocesamiento, arquitectura, versión, métricas, hash y manifest, y la ejecución registra qué artifact utilizó.

12.5 Validación por capas y pruebas

La evaluación se estructura en capas para localizar fallas y evitar conclusiones excesivas: datos y fixtures; modelo experimental; artifact y runtime; módulo de inteligencia artificial; backend; frontend; integración extremo a extremo; evaluación profesional; y despliegue con observabilidad.

Una falla en una capa inferior limita las afirmaciones posibles en las superiores. Un buen coeficiente Dice no demuestra que el estudio pueda reabrirse; una pantalla correcta con fixtures no demuestra que las vistas previas reales estén persistidas; y una opinión favorable en una entrevista no constituye validación clínica.

En el módulo de inteligencia artificial se prueban lectura de volúmenes, preprocesamiento, selección de corte, reconstrucción de arquitecturas, verificación de manifests y hashes, inferencia

y regresión sobre fixtures de-identificados. En el backend, autenticación, autorización, validaciones, contratos, persistencia, auditoría, serving de assets y reapertura, con un criterio relevante: abrir un estudio persistido con el módulo de inteligencia artificial apagado. En el frontend, tipos y adaptadores, navegación, estados de carga y error, ausencia de superposición y accesibilidad.

La validación del visor volumétrico comprueba cantidad y orden de los cortes, eje, índice computacional y numeración mostrada, con índice interno desde cero y numeración de interfaz desde uno. Verifica también que la reapertura funcione sin volver a ejecutar la inferencia y que no se simule una correspondencia sagital-axial cuando la geometría no permite establecerla. Las series no soportadas permanecen disponibles como imagen base e informan que no poseen inferencia automática.

La seguridad se integra desde el diseño: las operaciones protegidas requieren autenticación y autorización, las cuentas nuevas quedan pendientes de aprobación, los assets no se sirven mediante rutas internas y los secretos se mantienen fuera del código.

12.6 Diferencia entre instancias de validación

El proyecto distingue cuatro instancias que cumplen objetivos distintos y no deben mezclarse. Las entrevistas EN-01 a EN-05 constituyen user research exploratorio: identificaron necesidades, riesgos, lenguaje de dominio y criterios iniciales de alcance. Las sesiones posteriores con la Dra. Susana Torres y la Dra. Claudia Cejas se clasifican como validación profesional cualitativa del prototipo: profesionales observaron y comentaron una versión funcional/intermedia del producto, con foco en utilidad, flujo, comprensión, priorización funcional y confianza. La validación técnica automatizada corresponde a pruebas de software, modelos, contratos, persistencia, seguridad, recorridos browser y despliegue. Finalmente, la validación cruzada profesional queda pendiente como etapa superior: requiere comparar la lectura independiente del profesional con el resultado del sistema sobre los mismos estudios.

La validación profesional cualitativa no se interpreta como validación clínica, diagnóstica, ensayo clínico, evaluación de performance clínica ni validación contra ground truth. Su muestra es pequeña e intencional, y sus resultados se analizan de forma narrativa. Sirve para orientar decisiones de producto y priorizar trabajo futuro; no permite estimar sensibilidad, especificidad, exactitud diagnóstica ni seguridad clínica.

12.6.1 Validación profesional final pendiente

La siguiente etapa de validación profesional debe realizarse con un protocolo cruzado. En primer lugar, el profesional analiza uno o más estudios de forma independiente y registra interpretación, mediciones y hallazgos relevantes. En segundo lugar, el sistema procesa los mismos estudios bajo configuración controlada. Luego se comparan niveles, segmentaciones, mediciones, hallazgos, omisiones y falsos positivos. Finalmente, el profesional revisa las diferencias,

explica concordancias y discrepancias, y se documenta que parte del desacuerdo corresponde a limitaciones del sistema, variabilidad de criterio o ausencia de información clínica. Esta etapa no se realizó todavía y se presenta como el siguiente nivel de validación, no como evidencia ya obtenida.

12.7 Limitaciones metodológicas

La metodología se desarrolla bajo restricciones propias de un proyecto final: equipo reducido, tiempo académico, hardware limitado, conjuntos de datos públicos con taxonomías diferentes, infraestructura temporal y ausencia de validación clínica multicéntrica. Estas condiciones limitan el alcance de las conclusiones, pero no invalidan la evaluación de ingeniería, la reproducibilidad ni el aporte de integración.

Las entrevistas EN-01 a EN-05 constituyen user research exploratorio y las sesiones posteriores de producto constituyen validación profesional cualitativa sobre una versión intermedia del prototipo. Ninguna de esas instancias reemplaza una validación clínica ni una prueba de performance diagnóstica. Sus resultados se analizan de forma cualitativa y no se generalizan a toda la población profesional ni se utilizan para afirmar eficacia diagnóstica.

Existe además el riesgo de que la documentación quede desactualizada frente a un desarrollo rápido. Para mitigarlo se emplean checkpoints, estados explícitos y una revisión editorial antes de continuar con nuevos capítulos.

13 Resultados de la evaluación técnica

13.1 Propósito y alcance de la evaluación

Este capítulo reúne los resultados obtenidos al evaluar los modelos de segmentación contra las anotaciones de referencia de sus conjuntos de origen. Su función es responder, con valores concretos, al objetivo específico que compromete la evaluación técnica del prototipo mediante métricas de segmentación.

El alcance de lo que aquí se informa está acotado y conviene delimitarlo antes de presentar cifra alguna. Se evalúa la coincidencia entre las máscaras que produce cada modelo y las anotaciones de referencia del conjunto correspondiente. No se evalúa la exactitud clínica de las mediciones derivadas, para lo cual sería necesario un conjunto de mediciones realizadas por profesionales sobre los mismos estudios, ni la utilidad del prototipo en un flujo de trabajo real, que corresponde a la validación cualitativa prevista para la instancia siguiente.

La distinción importa porque una segmentación con buen desempeño métrico no garantiza que las mediciones derivadas de ella sean correctas, del mismo modo que una medición correcta no implica que la interpretación clínica que se haga de ella lo sea. El Capítulo 7 desarrolla esta separación en términos conceptuales; aquí se sostiene en la presentación de los resultados.

13.2 Protocolo de evaluación

La evaluación se realiza sobre una partición retenida que no interviene en el entrenamiento ni en la selección del modelo. La separación se establece a nivel de paciente y no de corte ni de serie, de modo que ninguna imagen de un paciente presente en el conjunto de entrenamiento aparezca en el de prueba. Esta condición es determinante en imagen médica: cortes contiguos de un mismo volumen guardan una similitud muy alta, y una separación por corte produciría una estimación optimista que no describe el comportamiento sobre pacientes nuevos.

TABLA 13.1: Partición de los conjuntos de datos empleados en el entrenamiento y la evaluación.

Conjunto	Unidad de separación	Entrenamiento	Validación	Prueba
SPIDER, plano sagital	Paciente	152 pacientes, 5.271 cortes	33 pacientes, 1.174 cortes	33 pacientes, 1.218 cortes
Sudirman y Al-Kafri, plano axial	Paciente	Pendiente de recuperación	81 casos evaluables	102 casos evaluables

La selección de cortes del conjunto sagital se realiza mediante una distribución lineal de hasta dieciséis cortes por volumen, conservando una proporción de cortes sin estructura anotada del veinte por ciento y un máximo de cuatro cuando el volumen no contiene ninguna. El criterio evita que el modelo se entrene únicamente sobre cortes centrales, donde las estructuras son más

nítidas.

La trazabilidad del entrenamiento sagital se conserva mediante identificadores criptográficos del índice de entrenamiento, del código de la arquitectura y del commit del repositorio, junto con la referencia al cuaderno que produjo el artifact.

En el caso axial, la separación a nivel de paciente está confirmada en el manifest del artifact, pero los conteos de la partición de entrenamiento no fueron publicados en él. El proyecto conserva dos particiones axiales que no coinciden: la congelada en una etapa anterior y la derivada por el cuaderno que produjo el artifact en uso. La recuperación de los conteos definitivos permanece como tarea pendiente y se declara como tal, en lugar de informar cifras de una partición que no corresponde al modelo evaluado.

13.3 Resultados de segmentación

TABLA 13.2: Coeficiente Dice sobre la partición retenida, por modelo.

Modelo	Clases evaluadas	Dice macro	Umbral del proyecto	Resultado
Sagital, SPIDER	Vértebras, canal y discos, sin fondo	0,893	0,70	Supera el umbral
Axial, Sudirman y Al-Kafri	Primer plano oficial, incluyendo <code>raw_0</code>	0,679348283374590 (IoU 0,5699727598420694)	0,70	No alcanza el umbral
Axial, excluyendo <code>raw_0</code>	Análisis secundario de estructuras	0,8105661875685084 (IoU 0,6915400877715925)	0,70	Lectura secundaria; no reemplaza el gate

El valor informado corresponde al promedio macro del coeficiente Dice, es decir al promedio de los coeficientes por clase, que otorga el mismo peso a cada estructura con independencia de su tamaño. El criterio es más exigente que un promedio ponderado por número de píxeles, bajo el cual las estructuras pequeñas quedarían enmascaradas por las grandes.

La diferencia entre las dos lecturas del modelo axial requiere explicación, porque es de una magnitud considerable y no responde a un cambio en el modelo sino en el conjunto de clases sobre el que se promedia. Según establece la Tabla 11.2, el modelo axial distingue seis clases, de las cuales dos corresponden a fondo. Una de ellas, la que designa la región exterior al paciente en el conjunto de origen, obtiene un coeficiente Dice de 0,15 y arrastra el promedio macro cuando se la incluye entre las clases de primer plano.

El desempeño secundario excluyendo `raw_0` es de 0,8105661875685084 para Dice y 0,6915400877715925 para IoU. Esa lectura ayuda a describir la segmentación de las estructuras de interés, pero no sustituye la métrica oficial del artifact: `qualityGatePassed=false`, con razón `dice_macro_foreground_below_threshold`.

13.4 Umbral de calidad y estado del artifact axial

El proyecto estableció un umbral de 0,70 sobre el coeficiente Dice macro de primer plano como condición para promover un artifact a la categoría de baseline técnico. El umbral se acompaña de tres condiciones adicionales no configurables: la partición retenida debe estar separada a nivel de paciente, el informe debe reportar de forma explícita el desempeño sobre la clase de fondo del conjunto de origen, y debe incluir la intersección sobre unión además del coeficiente Dice. La generación de una partición nueva requiere además una habilitación manual.

Aplicado al modelo axial, el umbral no se alcanzó en su lectura de primer plano completo. El artifact quedó registrado como candidato por debajo del umbral de calidad y no fue promovido a baseline técnico. El valor del umbral no se modificó para acomodar el resultado.

Esta decisión merece explicitarse porque describe el papel que el control cumple en el proyecto. Un umbral que se ajusta cuando un modelo no lo alcanza no ejerce ninguna función de control; su utilidad reside precisamente en registrar los casos en que no se supera. El módulo axial, en consecuencia, se documenta como componente complementario evaluado y no como baseline consolidado, y esa condición se refleja en el estado de las capacidades del Capítulo 11.

Corresponde señalar que el criterio del umbral es discutible en un aspecto concreto: promediar una clase de fondo junto con las estructuras anatómicas penaliza al modelo por una clase que ninguna medición utiliza. La revisión de ese criterio, o su sustitución por el promedio sobre estructuras anatómicas exclusivamente, es una de las tareas previstas para la instancia siguiente.

13.5 Advertencia sobre la partición de prueba axial

La partición de prueba del conjunto axial había sido evaluada previamente durante el desarrollo de una versión anterior del mismo modelo. La evaluación que aquí se informa es, por lo tanto, comparativa respecto de esa versión y no constituye una validación sobre datos enteramente no observados.

La advertencia se registra en el manifest del artifact y el cuaderno de entrenamiento incorpora una restricción en tiempo de ejecución que impide reevaluar la partición retenida sin una confirmación explícita. Se declara aquí porque omitirla presentaría el resultado como más independiente de lo que es.

13.6 Verificación por contraste de las mediciones derivadas

Las mediciones derivadas de las máscaras no cuentan con una validación formal contra mediciones realizadas por profesionales, que requeriría un conjunto anotado específicamente para ese fin y forma parte del trabajo previsto. Durante el desarrollo se aplicó, en cambio, una verificación por contraste con rangos conocidos, cuyo alcance es más limitado pero permitió

detectar errores de método que las métricas de segmentación no revelan.

TABLA 13.3: Verificación por contraste de las mediciones sobre el estudio de referencia.

Medición	Valor obtenido	Referencia de contraste	Lectura
Diámetro anteroposterior del canal, mediana	13,1 mm	Rango compatible con el saco tecal lumbar	Consistente
Diámetro anteroposterior por nivel, de T11-T12 a L4-L5	13,1 · 14,2 · 13,1 · 12,0 · 9,8 · 12,0 mm	Descenso esperable con un valor menor aislado	Consistente, con un valor menor en L3-L4
Suma de ángulos segmentarios de L1 a L5	36 grados	Lordosis lumbar habitual entre 40 y 60 grados	Del mismo orden, por debajo del rango

Este procedimiento no equivale a una validación. Un contraste con rangos poblacionales permite descartar valores manifiestamente incompatibles, pero no establece la exactitud de una medición individual. Su utilidad durante el desarrollo fue detectar tres errores de método cuya magnitud se documenta en la sección 11.5, que las métricas de segmentación no habrían señalado, dado que la máscara era correcta y el error residía en cómo se medía sobre ella.

13.7 Una medición implementada y no publicada

El sistema calcula el desplazamiento entre cuerpos vertebrales contiguos, hallazgo estructural frecuente en la evaluación lumbar. Esa medición está implementada y se decidió no exponerla al usuario. El fundamento de la decisión es metodológico y se sostiene en valores medidos.

La medición depende en su totalidad de la ubicación de un único punto, la esquina posterior del platillo vertebral, que es precisamente la región donde la segmentación presenta menor precisión. Dos procedimientos igualmente razonables para derivar ese punto, uno a partir del eje de ancho del cuerpo vertebral y otro a partir del borde de la máscara, producen resultados que difieren hasta en 17 milímetros sobre el mismo nivel: 7,30 frente a 24,06 milímetros entre la primera y la segunda vértebra lumbar, y 6,64 frente a 20,78 entre la segunda y la tercera. Con una dispersión de ese orden, cualquiera de los dos valores resulta arbitrario.

El contraste con el ángulo segmentario, que sí se publica con carácter experimental, no reside en el método sino en la posibilidad de verificación. El ángulo pudo contrastarse contra un rango poblacional conocido, según se indica en la sección anterior. Para el desplazamiento vertebral no existe un contraste equivalente sin un conjunto de estudios con el desplazamiento medido por un profesional.

La decisión se documenta porque describe un criterio que el proyecto aplica de forma general: una medición se publica cuando puede verificarse, y no cuando puede calcularse.

13.8 Resultados finales de validación técnica por capa

Además de la evaluación offline de modelos, el cierre técnico del producto incluyó verificaciones de software, integración y recorrido browser. Estas pruebas validan el comportamiento funcional del prototipo bajo condiciones controladas; no constituyen validación clínica.

TABLA 13.4: Validación técnica final del prototipo.

Validación	Resultado	Interpretación
Backend Java 21, suite reconciliada	1053 tests, 0 failures, 0 errors, 78 skipped	Suite final verde para el alcance ejecutado; los skipped corresponden a tests condicionados por Postgres/Testcontainers. No mezclar con conteos baseline previos.
Backend focal	67/67 PASS	Cubre Patient API, controlador AI, seguridad, validadores y asociación Study–Patient a nivel Backend.
Frontend	lint PASS, typecheck PASS, build PASS, unit tests PASS	Valida calidad estática y construcción de la interfaz final.
AI focal/product regressions	PASS; 67 passed y 1 skipped en el recorte focal	Valida product orchestration, multiplanar, real baseline, Grad-CAM y subarticular en el alcance focal.
AI full suite	479 passed / 40 failed	No se presenta como suite totalmente verde: los fallos son brechas ambientales preexistentes asociadas a highdicom y resolución de subprocess.
Docker full stack	PASS	Construcción del stack completo con imágenes requeridas.
Browser E2E	Playwright 11/11 PASS	Validación funcional del producto en recorrido demo/final; no equivale a validación clínica ni a Patient entity browser-level completo.
Patient API smoke	8/8 PASS	Valida create/associate/list/detail/longitudinal/report/reload/persist-after-restart a nivel API/Backend.
Persistencia	PASS	Resultados, asociaciones y series sobreviven reinicio del Backend.
Product-analysis	PASS en demo path; bloqueado en path real sin 67B2 parity	El producto no fabrica nivel anatómico cuando la paridad runtime no está probada.
Longitudinal	PASS	Comparación determinística en Demo Mode y flujo subjectRef .
Reporte / PDF / JSON	PASS	Reporte estructurado pfi.study-report.v1 ; exportaciones PDF y JSON verificadas.
Chat contextual	PASS en mock LLM	Valida integración funcional con proveedor determinístico; no despliegue productivo de Qwen.
Evidencia visual	PASS	Overlays/assets servidos por Backend; limitados por registro AI efímero tras reinicio.
DICOM inválido	422 UNSUPPORTED_INPUT PASS	El sistema falla de forma controlada ante input no procesable.
Secret scan	Sin credenciales reales	Hallazgos revisados como falsos positivos; no se detectaron secretos productivos.

13.9 Validación técnica en Google Cloud

La tabla anterior valida el prototipo en un entorno local/contenedorizado. Por separado, se ejecutó una validación técnica de extremo a extremo sobre el proyecto real de Google Cloud `pfi-asplanatti-fabrello-v1` (Backend Green `pfi-backend-v2-dev`, IA privada `pfi-ai-module`, Frontend `pfi-frontend-dev`, Cloud SQL `pfi-postgres-dev`, bucket durable `gs://pfi-backend-durable-dev` y bucket de checkpoint `gs://pfi-rm-lumbar-artifacts-2026-ef` documentada en el repositorio Backend (`docs/cloud/CLOUD_STAGE_6` a 10B). La prueba se ejecutó con una fixture DICOM sintética, válida y no identificable, compuesta por cinco series y treinta cortes. Esta evidencia es técnica de infraestructura, no clínica.

TABLA 13.5: Validación técnica de Cloud, extremo a extremo (Etapas 6–10B).

Verificación	Resultado	Interpretación
Autenticación privada Backend–IA	PASS	Google ID Token real, audiencia validada; acceso directo no autenticado a la IA responde 403.
Cloud DICOM E2E sobre fixture sintética	PASS	Carga, procesamiento y persistencia de la fixture DICOM sintética de punta a punta sobre los servicios Cloud.
Durabilidad tras reinicio	PASS	Assets e índices recuperables tras reiniciar Backend/IA, con verificación de tamaño/checksum.
Reproceso sin re-subida	PASS	<code>POST /studies/{id}/reprocess</code> reutiliza el ZIP durable ya almacenado; sin duplicar objetos en 16+ ejecuciones acumuladas.
Persistencia final estable	Sí	Estable bajo reinicio y bajo concurrencia moderada, con evidencia cruzada (bytes en GCS, filas en SQL, checksums).
Conmutación Frontend a Backend Green	PASS	<code>env.js</code> en runtime confirmado apuntando a <code>pfi-backend-v2-dev</code> .
Recorrido browser completo en Cloud	Parcial	Verificado por capas (red, runtime config, autenticación); el click-through completo de subida de archivo quedó limitado por el tooling de automatización de navegador de la sesión, no por un defecto del producto.
Modelo de costo observado en el escenario sintético	Listo	Construido sobre mediciones reales tomadas sobre la fixture sintética (ver Tabla 13.6), no sobre estimaciones teóricas ni sobre costo de operación clínica.
Cierre técnico de la etapa Cloud	Completo	Las siete verificaciones anteriores cubren el alcance técnico definido para esta etapa.

TABLA 13.6: Costo y performance Cloud medidos (Etapa 10/10B).

Lote	Éxito	p50	p95	Nota
10 estudios	10/10	19,465 s	20,814 s	Fixture DICOM sintética, no identificable.
25 estudios	25/25	18,794 s	21,812 s	Métricas convergentes respecto del lote de 10.
50 estudios	No ejecutado	—	—	No fue necesario: las métricas ya habían convergido entre los lotes de 10 y 25.

El costo variable observado fue de aproximadamente USD 0,00236 por estudio (Backend + IA + almacenamiento), sobre una *fixture* sintética de menor resolución que un estudio clínico

real; se trata de un piso empírico de referencia, no del costo de operación clínica productiva. El desarrollo completo de este costo, su traducción a escenarios financieros (Optimista/Base/Pesimista) y su papel en el análisis de sensibilidad se presentan en el Capítulo 14, que reutiliza esta misma evidencia sin remedirla.

Al cierre de este documento, el entorno Cloud fue pausado intencionalmente para minimizar consumo de crédito mientras continúa el trabajo de documentación (ningún recurso fue eliminado; Cloud SQL detenido, Cloud Run en su estado de costo cero por inactividad). El procedimiento de pausa y los comandos de restauración están documentados en el repositorio Backend (docs/cloud/CLOUD_PAUSE_RESTORE_COMMANDS.md).

13.10 Niveles de validación y alcance

El cierre distingue seis niveles. La validación de modelo offline mide desempeño contra anotaciones o particiones congeladas. La validación técnica de software verifica contratos, persistencia, seguridad y errores controlados. La validación E2E recorre el producto integrado en browser y stack containerizado. La validación profesional cualitativa recoge observaciones de profesionales sobre una versión funcional/intermedia del prototipo y se informa en la sección siguiente. La validación cruzada profesional, todavía pendiente, requiere comparar lecturas independientes de profesionales contra resultados del sistema sobre los mismos estudios. La validación clínica requeriría un protocolo específico con datos, comparadores y criterios clínicos; no fue realizada y no se afirma.

Esta separación es central para interpretar las métricas. Por ejemplo, 67B2 tiene resultados offline altos, pero conserva 67B2_RUNTIME_PARITY_NOT_PROVEN, productEnabled=false y parityVerified=false; por lo tanto no habilita inferencia productiva real. Del mismo modo, Playwright 11/11 valida el recorrido funcional del prototipo, no la exactitud clínica de sus salidas.

13.11 Resultados de la validación profesional cualitativa

Se realizaron dos sesiones de validación profesional del prototipo, una con la Dra. Susana Torres y otra con la Dra. Claudia Cejas. Estas sesiones no fueron entrevistas exploratorias iniciales: ocurrieron sobre una versión funcional/intermedia del producto y se orientaron a observar utilidad, flujo, comprensión, priorización funcional y confianza. Tampoco constituyen validación clínica, diagnóstica, ensayo clínico ni comparación contra ground truth.

Las funcionalidades observadas o discutidas incluyeron segmentación visual, overlays, posibilidad de activar o desactivar máscaras, corrección manual de mediciones, evidencia visual, revisión de múltiples cortes, correlación sagital-axial, mediciones priorizadas, comparación longitudinal y salida estructurada editable. La muestra es pequeña e intencional, por lo que se informa narrativamente y no mediante porcentajes.

13.11.1 Ficha de la sesión con la Dra. Susana Torres

La sesión con la Dra. Susana Torres registró interés en la comparación con resonancias previas y en el historial longitudinal como apoyo para observar evolución de cambios degenerativos. La segmentación fue valorada como apoyo visual, siempre que el profesional pueda revisar la imagen original, activar la asistencia luego de una primera lectura y apagar máscaras para evitar sesgo o confusión visual. También surgió la necesidad de corregir manualmente mediciones, mantener colores consistentes entre estructuras y evitar superposiciones que dificulten la interpretación.

En cuanto a contenido anatómico y funcional, la profesional remarcó la relevancia del diámetro anteroposterior y transversal del saco o canal, la diferenciación de neuroforámenes, la grasa alrededor de raíces, la utilidad para valorar estenosis y la importancia de revisar múltiples cortes en lugar de limitarse al corte central. También mencionó cambios degenerativos, hipertrofia del ligamento amarillo como posible futuro, cambios Modic, pérdida de altura discal, correlación sagital-axial y respeto de la inclinación del disco en esa correlación. La valoración general fue favorable al uso como asistencia revisable, con revisión profesional obligatoria. Como limitación, varias sugerencias corresponden a capacidades futuras o parciales y no deben presentarse como implementadas por el solo hecho de haber sido propuestas.

13.11.2 Ficha de la sesión con la Dra. Claudia Cejas

La sesión con la Dra. Claudia Cejas destacó el contador o identificación de nivel como apoyo práctico, la utilidad de la segmentación visual, la corrección manual de mediciones y la prioridad del diámetro del canal. También surgió la recomendación de medir perpendicular al eje del canal y la necesidad de verificar bibliográficamente cualquier número o rango verbal antes de transformarlo en umbral del sistema.

En cuanto a estructuras y hallazgos, la profesional remarcó la importancia del neuroforamen, la estenosis foraminal, el receso subarticular o canal lateral, la distinción entre canal central, canal lateral y neuroforamen, la revisión de múltiples cortes, la detección de protrusiones focales o laterales, los cambios Modic, la degeneración discal y la pérdida de altura. En términos operativos, vinculó la utilidad de colores y asistencia visual con la reducción de omisiones en contextos de carga laboral y fatiga. También consideró aceptable cierta sobredetección si el profesional conserva la posibilidad de revisar, corregir o descartar. La preferencia expresada fue detección y asistencia antes que diagnóstico automático, con valor potencial para comparación longitudinal e informe estructurado editable.

13.11.3 Síntesis transversal

Los hallazgos comunes se agrupan en cinco categorías. En usabilidad, ambas sesiones respaldan overlays útiles, máscaras activables o desactivables, edición manual, precisión visual y colores consistentes. En valor clínico-operativo, aparecen detección asistida, reducción de omisiones, apoyo ante carga elevada, seguimiento longitudinal y correlación sagital-axial. En mediciones priorizadas, se destacan canal central, neuroforamen, receso lateral o subarticular y altura discal; otras medidas deben incorporarse solo si aportan valor real y pueden verificarse. En hallazgos relevantes, se repiten protrusión o herniación, estenosis, pérdida de altura, cambios degenerativos o Modic, forámenes y raíces. En confianza, las dos sesiones refuerzan revisión profesional obligatoria, posibilidad de corregir, comunicación de confianza cuando corresponda y rechazo de la IA como diagnóstico autónomo.

La diferencia principal entre las sesiones está en el énfasis. La Dra. Torres profundizó en comparación longitudinal, control visual de máscaras, correlación sagital-axial e inclinación discal. La Dra. Cejas enfatizó la protocolización de mediciones, la distinción entre canal central/lateral/neuroforamen, la carga laboral y la aceptabilidad de sobredetección bajo revisión profesional.

TABLA 13.7: Cambios de producto derivados de la validación profesional cualitativa.

Observación profesional	Profesional	Decisión de producto	Estado actual
Activar/desactivar máscaras y evitar confusión visual	Torres	Mantener overlays revisables y controles de visibilidad por estructura.	PARTIAL: overlays implementados; controles finos por estructura quedan como mejora de interfaz.
Corrección manual de mediciones	Torres/Cejas	Permitir que el profesional corrija valores y conserve trazabilidad.	IMPLEMENTED: mediciones editables y revisión profesional implementadas.
Evidencia visual verificable	Torres/Cejas	Mostrar máscaras, assets y regiones de evidencia asociadas al resultado.	IMPLEMENTED: overlays y evidencia visual servidos por Backend; limitados por registro AI efímero.
Comparación con estudios previos	Torres/Cejas	Mantener historial y comparación longitudinal descriptiva.	PARTIAL: implementado en Demo Mode/subjectRef; no es evaluación clínica de progresión.
Correlación sagital-axial y múltiples cortes	Torres/Cejas	Priorizar visor volumétrico, revisión por corte y no solo corte central.	PARTIAL: visor y catálogo full-series implementados; pairing sagital-axial 67C sigue experimental.
Medición de neuroforamen	Torres/Cejas	Registrar como medición prioritaria futura si se valida técnica y bibliográficamente.	PLANNED: no debe presentarse como medición productiva validada.
Receso lateral/subarticular	Cejas	Mantener línea subarticular como capacidad asistiva bajo gates.	PARTIAL: clasificador subarticular existe, pero P10.7/product path sigue bloqueado.

Observación profesional	Profesional	Decisión de producto	Estado actual
Transparencia Demo/IA y revisión humana	Torres/Cejas	Declarar modo demo/no clínico y mantener revisión obligatoria.	PARTIAL: flags técnicos existen; indicador persistente de Demo Mode en UI queda pendiente.
Informe estructurado editable	Cejas	Generar salida estructurada revisable y exportable.	IMPLEMENTED: reporte <code>pfi.study-report.v1</code> , PDF/JSON y revisión profesional.
Mostrar confianza cuando corresponda	Cejas	Comunicar confianza/estado solo cuando el modelo lo respalde.	PARTIAL: existen estados y gates; visualización sistemática de confianza queda pendiente.
Cambios Modic	Torres/Cejas	Documentar como hallazgo relevante, sin exponerlo productivamente sin validación.	PLANNED: P10.7 contiene tarea relacionada pero no está habilitada productivamente.
Hipertrofia del ligamento amarillo	Torres	Registrar como posible extensión futura.	PLANNED: no implementado en producto.
Diagnóstico automático	Torres/Cejas	Mantener enfoque asistivo, no diagnóstico.	OUT_OF_SCOPE: el sistema no diagnostica ni recomienda tratamiento.

13.11.4 Validación profesional final pendiente

La validación cruzada profesional sigue pendiente. Para realizarla, un profesional debe analizar estudios de manera independiente; luego el sistema debe procesar esos mismos estudios; después deben compararse niveles, segmentaciones, mediciones, hallazgos, omisiones y falsos positivos; finalmente el profesional debe revisar discrepancias y documentar concordancias. Esa evidencia permitirá evaluar utilidad y errores sobre casos concretos, pero todavía no fue obtenida.

El detalle ampliado de las sesiones VP-01 y VP-02, su metodología, la trazabilidad hacia decisiones de producto y las limitaciones de esta instancia se documentan en el Anexo H.

13.12 Limitaciones de la evaluación

La evaluación final permite afirmar la consistencia funcional y técnica del prototipo académico, pero no habilita conclusiones clínicas ni productivas fuera del alcance declarado. Las limitaciones principales son:

1. No se realizó validación clínica prospectiva ni retrospectiva con profesionales sobre una cohorte independiente.
2. Las dos sesiones profesionales incorporadas son cualitativas, con muestra pequeña e intencional, y se realizaron sobre una versión intermedia del producto.
3. Las sesiones de producto no compararon resultados del sistema contra ground truth, sensibilidad, especificidad ni lectura independiente de profesionales.
4. El recorrido Playwright 11/11 valida comportamiento funcional de interfaz, no desempeño clínico.
5. El modo demo usa fixtures determinísticos y no debe interpretarse como inferencia médica real.

6. La integración Patient está implementada en Backend/API/persistencia, pero la interfaz conserva flujos basados en subjectRef y no ofrece creación/selección completa de Patient en navegador.
7. La prueba Patient E2E 8/8 corresponde a validación API-level/smoke, no a recorrido browser-level completo.
8. El modelo axial oficial no supera el umbral de calidad definido, por lo que queda como capacidad experimental o complementaria.
9. La mejora axial secundaria que excluye raw_0 es evidencia exploratoria y no reemplaza la métrica oficial de gate.
10. El modelo 67B2 tiene métricas offline verificadas, pero no se probó paridad runtime productiva y permanece con productEnabled=false.
11. P10.7 mantiene automaticInferenceEnabled=false por blocked_preprocessing_parity.
12. 67C no se declara validado productivamente.
13. Grad-CAM cuenta con pruebas AI específicas, contrato API y wiring Frontend, pero permanece experimental y no fue ejercitado explícitamente en el recorrido browser E2E final.
14. El chat contextual se validó con mock determinístico; el uso de Qwen queda como ruta objetivo, no como disponibilidad productiva demostrada.
15. El despliegue Cloud DEV (Backend, Frontend, AI Cloud Run privado, Cloud SQL, Secret Manager y storage durable) está desplegado y validado según la evidencia de la sección 13.9; el entorno DEMO separado y el monitoreo/alerting en vivo no fueron desplegados.
16. El escaneo de secretos no encontró credenciales reales, pero no reemplaza una auditoría de seguridad formal.
17. El sistema no aprende automáticamente de correcciones profesionales; la curación de feedback queda como insumo controlado para entrenamiento offline futuro.

13.13 Conclusión del capítulo

El módulo sagital alcanza un coeficiente Dice macro de 0,893 sobre una partición retenida separada a nivel de paciente, supera el umbral establecido y se documenta como baseline técnico del prototipo. El módulo axial registra una métrica oficial Dice 0,679348283374592 e IoU 0,5699727598420694, por debajo del umbral; la lectura secundaria que excluye raw_0 alcanza Dice 0,8105661875685084 e IoU 0,6915400877715925, pero no reemplaza el gate oficial.

Los resultados sostienen que la segmentación de estructuras lumbares en el plano sagital es viable con los datos y la arquitectura empleados, y que el módulo axial requiere trabajo

adicional antes de considerarse consolidado. Ninguno de los dos resultados autoriza afirmaciones sobre desempeño clínico, que dependen de una validación que este trabajo no realiza y declara como fuera de su alcance.

El aporte de este capítulo no reside únicamente en las cifras. Reside también en documentar un control de calidad que se aplicó y no se superó, una partición de prueba cuya independencia es parcial, una verificación de mediciones que no equivale a validación y una medición que se decidió no publicar. Un prototipo académico se evalúa por la correspondencia entre lo que afirma y lo que puede demostrar, y esa correspondencia exige informar también lo que no funcionó como se esperaba.

14 Modelo de negocio y viabilidad económica

14.1 Alcance y política de evidencia

Este capítulo evalúa la viabilidad económica del producto como complemento a la evaluación técnica del Capítulo 13. Responde preguntas distintas: no si el prototipo segmenta correctamente, sino si un modelo comercial construido sobre él podría sostenerse financieramente bajo supuestos explícitos.

Toda cifra que seguirá se clasifica en una de cuatro categorías, y esa clasificación se mantiene visible a lo largo del capítulo:

- **Evidencia técnica medida:** proviene de la infraestructura Cloud desplegada y validada en el Capítulo 13 y su documentación asociada, mediante cargas de trabajo reales ejecutadas sobre Google Cloud.
- **Supuesto de negocio:** una elección de modelado –precio, adquisición de clientes, *churn*, costos de soporte y mantenimiento– necesaria para construir el flujo de fondos, sin respaldo en ventas reales.
- **Escenario proyectado:** un resultado posible derivado de aplicar los supuestos anteriores a 36 meses.
- **Propuesta comercial pendiente de validación:** un ajuste de *pricing* derivado del modelo financiero, que todavía no fue contrastado con entrevistas de *willingness-to-pay* ni con procesos reales de adquisición institucional.

La evidencia técnica medida de la primera categoría proviene, concretamente, de los estudios sintéticos utilizados en el Capítulo 13 para medir el costo real de Google Cloud; esa aclaración no constituye una categoría adicional, sino la fuente de la primera.

Este capítulo no afirma que los precios propuestos estén validados por el mercado, que existan hospitales dispuestos a pagarlos, que exista demanda institucional demostrada, ni que un valor actual neto positivo garantice éxito comercial. Tampoco afirma que el costo de infraestructura observado corresponda a un volumen de estudios clínicos reales de resolución productiva: los estudios medidos fueron sintéticos, no identificables y de menor resolución que una resonancia lumbar clínica real, por lo que ese costo debe leerse como piso empírico de referencia, no como costo definitivo de operación clínica.

La fuente primaria de las cifras de este capítulo es el modelo financiero editable PFI_RM_LUMBAR_FINAN un libro de cálculo de 36 meses con hojas separadas de supuestos, *pricing*, flujo de fondos, indicadores, escenarios, punto de equilibrio, sensibilidad, evidencia Cloud y propuesta comercial. El libro no fue modificado como parte de la redacción de este capítulo; se lo utilizó exclusivamente como fuente de lectura.

14.2 Modelo de negocio

El producto se dirige a instituciones, no a pacientes individuales. El usuario que interactúa con el sistema –segmentación, mediciones, evidencia visual, comparación longitudinal y reporte estructurado– es el profesional de diagnóstico por imágenes; quien contrata y paga el servicio es la institución de la que ese profesional forma parte.

TABLA 14.1: Roles económicos distinguidos en el modelo de negocio.

Rol	Descripción	Relación con el producto
Usuario	Radiólogo o profesional de diagnóstico por imágenes	Revisa, edita, valida y exporta resultados; conserva la responsabilidad de interpretación.
Comprador económico	Centro de diagnóstico por imágenes, clínica u hospital	Contrata y paga la suscripción, integración y soporte.
Referente técnico	Equipo de TI o infraestructura institucional	Evalúa despliegue, seguridad, integración y gobierno de datos.
Beneficiario indirecto	Paciente y equipo médico referente	Se beneficia únicamente a través de un flujo mediado por el profesional.

La propuesta de valor es asistiva y no diagnóstica: organiza segmentación, mediciones, evidencia visual, contexto longitudinal y reporte estructurado en un flujo trazable donde el radiólogo conserva la responsabilidad de interpretación y validación final. El sistema no realiza diagnóstico autónomo ni reemplaza el criterio profesional, condición que se mantiene como restricción de producto en todos los planes comerciales.

14.3 Justificación del modelo SaaS B2B

Se adopta un modelo de suscripción *business-to-business* (B2B) tipo *Software as a Service* (SaaS), por sobre alternativas como licencia perpetua, venta *on-premise* o cobro exclusivamente por estudio sin suscripción base. La justificación es doble.

Primero, la infraestructura del producto ya está construida sobre un patrón de servicio gestionado –Backend, IA privada, base de datos y almacenamiento durable desplegados en Google Cloud, según el Capítulo 13– por lo que un modelo de suscripción con actualizaciones continuas y sin instalación local en la institución compradora es coherente con la arquitectura ya validada, y evita trasladar a cada cliente la complejidad de operar su propia instancia.

Segundo, el costo de infraestructura mostró dos características relevantes para la elección de modelo: es mayormente variable por estudio procesado, con un componente fijo de base de datos que no depende del volumen (Sección 14.7), lo que favorece un esquema de suscripción con volumen incluido y sobreconsumo cobrado aparte, en lugar de un precio plano independiente del uso o un cobro puramente transaccional sin previsibilidad de ingresos.

Cada plan incluye revisión profesional obligatoria como condición no negociable, no como característica opcional: el modelo de negocio no ofrece, en ningún nivel, un modo de uso

sin profesional a cargo.

14.4 Segmentación de clientes: Starter, Professional y Enterprise

Se definen tres segmentos de cliente institucional, diferenciados por volumen mensual de estudios y complejidad organizacional, no por funcionalidad restringida de forma artificial:

- **Starter:** centros pequeños o pilotos institucionales, con volumen mensual bajo y necesidad de validar el producto antes de un compromiso mayor.
- **Professional:** centros de diagnóstico de volumen medio y hospitales docentes, con necesidad de revisión analítica y comparación longitudinal sistemática.
- **Enterprise:** instituciones grandes o redes de centros, con volumen alto y requisitos adicionales de soporte, seguridad y acuerdos de nivel de servicio.

La segmentación reutiliza los mismos supuestos de adquisición, *churn* y volumen de estudios por cliente en todos los escenarios financieros de este capítulo (Sección 14.9); lo que cambia entre escenarios es el precio y el volumen incluido por plan, no la definición de los segmentos.

14.5 Pricing por volumen de estudios

El esquema de *pricing* combina una cuota de suscripción mensual, un volumen de estudios incluido y un cargo por estudio excedente. La Tabla 14.2 presenta la estructura de planes correspondiente a la **Base Comercial Objetivo** (Sección 14.12), que es la propuesta de *pricing* final de este capítulo.

TABLA 14.2: Planes comerciales propuestos (Base Comercial Objetivo).

Plan	Cuota mensual	Estudios incluidos	Excedente/estudio	Destinatario	Estado de validación
Starter	USD 700	120	USD 9	Centro pequeño o piloto institucional	Objetivo comercial; pendiente de validación <i>willingness-to-pay</i>
Professional	USD 1.850	500	USD 7	Centro de diagnóstico de volumen medio u hospital docente	Objetivo comercial; pendiente de validación <i>willingness-to-pay</i>
Enterprise	USD 5.200	1.500	USD 4,50	Institución grande o red de centros	Objetivo comercial; pendiente de validación <i>willingness-to-pay</i>

Estos valores reemplazan, como propuesta final, un conjunto de precios más conservador utilizado en el escenario Base original del modelo financiero (Starter USD 600, Professional USD 1.600, Enterprise USD 4.500, con excedentes de USD 8, 6 y 4 respectivamente). La Sección 14.11 explica por qué se propuso este ajuste y la Sección 14.13 compara ambos conjuntos de resultados de forma explícita. Ninguno de los dos conjuntos de precios está validado por mercado; la

diferencia entre ellos es una decisión de modelado informada por el análisis de sensibilidad, no evidencia comercial nueva.

14.6 Estructura de ingresos

El ingreso mensual de cada cliente activo se compone de dos partidas:

- **Ingreso por suscripción:** la cuota mensual fija del plan contratado, independiente del volumen efectivamente procesado dentro del límite incluido.
- **Ingreso por excedente:** el producto entre los estudios procesados por encima del volumen incluido y el precio de excedente del plan, calculado como $\max(0, \text{estudios reales} - \text{estudios incluidos}) \times \text{precio de excedente}$.

El ingreso recurrente mensual total (*Monthly Recurring Revenue*, MRR) es la suma de ingresos por suscripción y por excedente de todos los clientes activos en un mes dado. El ingreso recurrente anualizado (*Annual Recurring Revenue*, ARR *run-rate*) se estima como el MRR de un mes multiplicado por doce, bajo el supuesto de que ese nivel de ingreso se sostiene durante el año siguiente sin cambios –una proyección, no un contrato anual real.

14.7 Estructura de costos

Los costos del modelo se dividen en variables, que escalan con el volumen de estudios procesados, y fijos, que no dependen de dicho volumen dentro del horizonte modelado.

14.7.1 Costos variables: infraestructura Cloud medida

El componente Cloud del costo variable no es una estimación teórica: proviene de una medición real ejecutada sobre el entorno de Google Cloud desplegado para este proyecto (Backend, IA privada, Cloud SQL y almacenamiento durable en GCS), utilizando una *fixture* DICOM sintética y no identificable, en 35 ejecuciones exitosas distribuidas en dos lotes independientes de 10 y 25 estudios, cuyos resultados convergieron de forma consistente. La validación técnica de extremo a extremo que sustenta esta medición (autenticación privada, persistencia durable, reinicio y reproceso) se presenta en el Capítulo 13, Sección 13.9; esta sección reutiliza esa evidencia para su traducción económica, sin remedirla.

TABLA 14.3: Costos Cloud observados (evidencia experimental, Etapa 10/10B).

Componente	Costo por estudio (USD)	Observación
Backend (Cloud Run)	0,000485	Tiempo de cómputo asignado durante la ingesta y la espera sincrónica de la respuesta de IA.
IA (Cloud Run, privado)	0,001869	Componente dominante del costo variable; inferencia real sobre <i>checkpoint</i> PyTorch.
Almacenamiento (GCS)	0,0000078	391.490 bytes por estudio, valor idéntico entre ambos lotes medidos.

Componente	Costo por estudio (USD)	Observación
Total variable observado	0,00236	Piso empírico; no representa resolución clínica productiva (ver aclaración más abajo).
Costo fijo Cloud	11,08 a 13,08 USD/mes	Dominado por Cloud SQL; no escala con el volumen de estudios.

Aclaración obligatoria sobre el valor observado. El costo variable de USD 0,00236 por estudio proviene de una *fixture* DICOM sintética de menor resolución y complejidad que un estudio clínico real –imágenes de prueba de baja resolución diseñadas para ejercitar el mismo camino de código que un estudio real, no para representar su volumen de datos–. El tiempo de inferencia observado está dominado por la carga del modelo y el arranque de PyTorch, no por el procesamiento de píxeles de una imagen de resolución clínica. En consecuencia, este valor debe leerse como **piso observado o referencia experimental de la mecánica de costos**, y no como el costo definitivo de procesar estudios clínicos reales en producción. El modelo financiero de este capítulo compensa esa limitación aplicando un margen de escenario explícito (Sección 14.7.2), en lugar de proyectar directamente el valor medido.

Adicionalmente, se confirmó durante esta medición que el costo fijo de Cloud (USD 11,08–13,08 por mes) es órdenes de magnitud menor que el costo operativo fijo total del negocio (Sección 14.7.3): la infraestructura técnica representa una fracción marginal de la estructura de costos fijos, hallazgo que se retoma en la Sección 14.11.

14.7.2 Costo variable por escenario

Para incorporar la incertidumbre sobre el costo real de procesar imágenes de resolución clínica, el modelo financiero define tres escenarios de costo Cloud, cada uno preservando la misma composición relativa Backend/IA/almacenamiento observada:

TABLA 14.4: Costo variable Cloud por escenario.

Escenario	Costo variable/estudio (USD)	Interpretación
Optimista	0,0024	Igual al valor medido; supone que la resolución clínica no incrementa materialmente el tiempo de inferencia.
Base	0,0067	Aproximadamente 2,8 veces el valor medido; margen moderado para mayor resolución de imagen real.
Pesimista	0,020	Aproximadamente 8,5 veces el valor medido; margen conservador ante incertidumbre de producción.

El escenario financiero Base de este capítulo (Sección 14.10) utiliza el costo Cloud Base de esta tabla, no el valor optimista medido directamente.

14.7.3 Costos fijos del negocio

Más allá de la infraestructura Cloud, el modelo incorpora costos fijos operativos mensuales que sostienen el negocio como organización, no como sistema técnico:

- Mantenimiento y desarrollo de software.
- Soporte base a clientes.
- Administración, contabilidad y aspectos legales.
- Comercialización y actividades de adquisición de clientes.
- Gastos fijos misceláneos.

En el escenario Base, estos rubros –sumados al costo fijo de Cloud– totalizan aproximadamente USD 8.112 por mes, de los cuales el costo técnico de Cloud representa apenas cerca del 0,15 % del total. Este dato sostiene numéricamente la afirmación central de la Sección 14.11: la infraestructura técnica no es la restricción económica relevante del negocio.

A esto se suma un costo variable de soporte por cliente activo, que escala con la cantidad de clientes y no con el volumen de estudios, y una inversión inicial (CAPEX) que cubre desarrollo remanente, configuración de infraestructura Cloud y preparación de lanzamiento.

14.8 Metodología financiera a 36 meses

El modelo proyecta un flujo de fondos mensual a 36 meses, con la siguiente estructura de cálculo:

$$\text{Clientes activos}(t) = \text{Clientes activos}(t-1) + \text{Nuevos}(t) - \text{Bajas}(t)$$

$$\text{Ingreso por suscripción}(t) = \sum_{\text{planes}} \text{clientes activos} \times \text{cuota mensual}$$

$$\text{Ingreso por excedente}(t) = \max(0, \text{estudios reales} - \text{estudios incluidos}) \times \text{precio de excedente}$$

$$\text{Ingreso total}(t) = \text{Ingreso por suscripción}(t) + \text{Ingreso por excedente}(t)$$

$$\text{Costos variables}(t) = \text{estudios procesados} \times \text{costo variable/estudio} + \text{soporte variable}$$

$$\text{Flujo operativo}(t) = \text{Ingreso total}(t) - \text{Costos variables}(t) - \text{Costos fijos}(t)$$

$$\text{Flujo neto}(t) = \text{Flujo operativo}(t) - \text{CAPEX/gastos únicos}(t)$$

$$\text{Flujo acumulado}(t) = \text{Flujo acumulado}(t-1) + \text{Flujo neto}(t)$$

Sobre esta serie mensual se calculan cuatro indicadores financieros estándar:

- **Punto de equilibrio operativo:** el primer mes en que el ingreso total cubre los costos variables y fijos del mes ($\text{Ingreso total} \geq \text{Costos variables} + \text{Costos fijos}$).
- **Payback (recuperación de la inversión):** el primer mes en que el flujo de fondos

acumulado es mayor o igual a cero.

- **Valor Actual Neto (VAN):** la inversión inicial negativa más la suma de los flujos de fondos netos mensuales descontados a una tasa mensual derivada de la tasa de descuento anual seleccionada, $VAN = -\text{Inversión inicial} + \sum_{t=1}^{36} \frac{\text{Flujo neto}(t)}{(1 + r_m)^t}$, con $r_m = (1 + r_a)^{1/12} - 1$.
- **Tasa Interna de Retorno (TIR):** la tasa de descuento mensual que hace el VAN igual a cero, reportada además en su forma anualizada, $TIR_{\text{anual}} = (1 + TIR_{\text{mensual}})^{12} - 1$.

La tasa de descuento anual utilizada en el escenario Base es del 25 %, seleccionada como tasa de riesgo ajustada para un producto en etapa de prototipo, y no como una tasa de mercado validada externamente.

14.9 Escenarios financieros: Pesimista, Base y Optimista

El modelo define tres escenarios de adopción y costo sobre el mismo horizonte de 36 meses, variando simultáneamente adquisición de clientes, volumen de estudios por cliente, *churn*, *pricing* y costo variable Cloud (Tabla 14.4):

- **Pesimista:** adquisición lenta de clientes, volumen de estudios por cliente bajo, mayor *churn*, menor tarifa efectiva y mayor costo variable por estudio. Sirve para evaluar el riesgo a la baja y la estructura operativa mínima viable.
- **Base:** adopción gradual, volumen de estudios moderado, suscripción estable, costos variables controlados y algo de ingreso por excedente. Es el caso central antes de validar supuestos comerciales.
- **Optimista:** adquisición más rápida, mayor volumen de estudios, mayor proporción de clientes en planes superiores, menor *churn* y mejor eficiencia de infraestructura por estudio. Sirve para evaluar escalabilidad y atractivo de inversión bajo condiciones favorables.

La Tabla 14.5 resume los indicadores de los tres escenarios sobre la estructura de *pricing* conservadora original, junto con el escenario Base Comercial Objetivo que se introduce en la Sección 14.12.

TABLA 14.5: Comparación de escenarios financieros a 36 meses.

Escenario	MRR mes 36 (USD)	ARR run-rate (USD)	VAN (USD)	TIR anual.	Payback
Pesimista	2.147	25.769	-105.094	n/a (sin cambio de signo)	no alcanzado en 36 meses
Base (conservador)	16.175	194.098	-18.492	7,3 %	mes 35
Optimista	74.020	888.237	+678.867	541,3 %	mes 11
Base Comercial Objetivo	18.735	224.826	+17.477	41,9 %	mes 29

El escenario Pesimista no alcanza punto de equilibrio operativo ni recupera la inversión

dentro de los 36 meses modelados, y su patrón de flujo de fondos no permite calcular una TIR con significado económico. El escenario Optimista muestra la mejor combinación posible bajo supuestos favorables simultáneos y no debe leerse como el resultado esperado. El escenario Base conservador y el Base Comercial Objetivo se desarrollan en detalle en las secciones siguientes, porque son los que sostienen la interpretación final de este capítulo.

14.10 Resultado del escenario Base conservador

El escenario Base conservador utiliza los supuestos centrales de adquisición, *churn* y volumen de estudios descritos en la Sección 14.9, el costo variable Cloud Base de la Tabla 14.4 y la estructura de *pricing* conservadora original mencionada en la Sección 14.5 (Starter USD 600, Professional USD 1.600, Enterprise USD 4.500).

TABLA 14.6: Indicadores del escenario Base conservador, mes 36.

Indicador	Valor
MRR mes 36	USD 16.175
ARR <i>run-rate</i>	USD 194.098
Clientes activos mes 36	13,41
Estudios procesados mes 36	4.185
Punto de equilibrio operativo	mes 16
<i>Payback</i> (recuperación de la inversión)	mes 35
Valor Actual Neto (VAN)	-USD 18.492
Tasa Interna de Retorno anualizada (TIR)	7,3 %

El escenario Base conservador alcanza equilibrio operativo relativamente temprano, en el mes 16, y recupera la inversión inicial dentro del horizonte modelado, en el mes 35. Sin embargo, el Valor Actual Neto resulta negativo bajo la tasa de descuento del 25 % anual seleccionada, y la TIR anualizada de 7,3 % queda por debajo de esa tasa de descuento. En otras palabras: el negocio, bajo estos supuestos, se aproxima al equilibrio financiero pero no lo alcanza en términos de valor presente neto ni de retorno ajustado por riesgo, con la estructura de precios conservadora original.

14.11 Análisis de sensibilidad

Para identificar qué variable condiciona más la viabilidad del escenario Base, se recalculó el VAN variando una única palanca por vez, manteniendo el resto de los supuestos sin cambios: primero el *pricing* en $\pm 20\%$, luego el costo variable Cloud en $\pm 30\%$.

TABLA 14.7: Sensibilidad del VAN sobre el escenario Base.

Palanca	VAN (USD)	Punto de equilibrio	<i>Payback</i>
<i>Pricing</i> -20 %	-63.896	mes 21	no alcanzado en 36 meses

Palanca	VAN (USD)	Punto de equilibrio	Payback
Base (referencia)	-18.492	mes 16	mes 35
Pricing +20 %	+26.911	mes 12	mes 28
Costo Cloud/estudio -30 %	-18.376	mes 16	mes 35
Costo Cloud/estudio base	-18.492	mes 16	mes 35
Costo Cloud/estudio +30 %	-18.609	mes 16	mes 35

El contraste es contundente. Una variación de $\pm 20\%$ en el *pricing* desplaza el VAN en más de USD 90.000 entre sus extremos –de -USD 63.896 a +USD 26.911– y cambia el resultado cualitativo del proyecto, de claramente inviable a claramente viable bajo la tasa de descuento seleccionada. Una variación de $\pm 30\%$ en el costo variable Cloud, en cambio, mueve el VAN apenas USD 233 en total –de -USD 18.376 a -USD 18.609– sin alterar el mes de equilibrio operativo ni el mes de *payback* en ninguno de los dos sentidos.

La conclusión técnica de este análisis es clara: **la sensibilidad del VAN al *pricing* institucional es varios órdenes de magnitud mayor que su sensibilidad al costo de infraestructura Cloud**. La variable técnica que este trabajo controla directamente –el costo de cómputo, IA y almacenamiento por estudio– tiene un efecto marginal sobre la viabilidad económica del negocio. Los principales condicionantes pasan a ser el *pricing* institucional, la velocidad de adquisición de clientes, el *churn*, y la estructura de costos de mantenimiento, soporte y comercialización, ninguno de los cuales fue medido empíricamente en este trabajo.

14.12 Propuesta de Base Comercial Objetivo

A partir del hallazgo de la Sección 14.11, se construyó un escenario comercial objetivo que modifica únicamente el *pricing* y el cargo por excedente respecto del escenario Base conservador, manteniendo sin cambios la adquisición de clientes, el *churn*, el volumen de estudios, el costo variable Cloud, el costo de soporte y la estructura de costos fijos operativos.

La propuesta utiliza los planes de la Tabla 14.2 (Starter USD 700/120 estudios/USD 9 excedente; Professional USD 1.850/500 estudios/USD 7 excedente; Enterprise USD 5.200/1.500 estudios/USD 4,50 excedente), redondeados a partir de un barrido de incrementos de *pricing* sobre el Base conservador que exploró aumentos del +10 %, +12,5 % y +15 % antes de fijar el valor propuesto.

Esta propuesta de *pricing* es un objetivo comercial derivado del modelo financiero y del análisis de sensibilidad, no un resultado validado por investigación de mercado, entrevistas de *willingness-to-pay* ni procesos reales de adquisición institucional. Se presenta como hipótesis de trabajo a validar, no como conclusión comercial.

14.13 Comparación entre el Base conservador y el Base Comercial Objetivo

TABLA 14.8: Base conservador frente a Base Comercial Objetivo.

Indicador	Base conservador	Base Comercial Objetivo
MRR mes 36	USD 16.175	USD 18.735
ARR <i>run-rate</i>	USD 194.098	USD 224.826
Clientes activos mes 36	13,41	13,41 (sin cambio)
Estudios procesados mes 36	4.185	4.185 (sin cambio)
VAN	-USD 18.492	+USD 17.477
TIR anualizada	7,3 %	41,9 %
Punto de equilibrio operativo	mes 16	mes 13
<i>Payback</i>	mes 35	mes 29
Margen bruto técnico mes 36	≈99,83 %	≈99,85 %

Los clientes activos y el volumen de estudios procesados son idénticos entre ambos escenarios por construcción: la única variable que cambia es el *pricing* y el cargo por excedente. Bajo ese único ajuste, el VAN pasa de negativo a positivo, la TIR anualizada pasa de 7,3 % a 41,9 % –superando ampliamente la tasa de descuento del 25 % anual utilizada–, el punto de equilibrio operativo se adelanta tres meses y el *payback* se adelanta seis meses. El margen bruto técnico –ingreso menos costo variable de cómputo, IA y almacenamiento– permanece por encima del 99 % en ambos casos, lo que confirma nuevamente que el costo de infraestructura no es la variable que separa un escenario viable de uno inviable en este modelo.

14.14 Limitaciones del modelo económico

1. Ningún precio de este capítulo está validado por investigación de mercado, entrevistas de *willingness-to-pay* con compradores institucionales reales, ni procesos de adquisición o licitación efectivamente realizados.
2. No existen clientes, contratos, cartas de intención ni ventas reales asociadas a este producto; todo el flujo de fondos es una proyección construida sobre supuestos de adopción, *churn* y volumen no observados.
3. El costo variable Cloud medido (Sección 14.7.1) proviene de una *fixture* sintética de menor resolución que un estudio clínico real; el modelo compensa esta limitación con escenarios de margen (Sección 14.7.2), pero esos márgenes son supuestos de modelado, no mediciones adicionales.
4. Los costos fijos de mantenimiento, soporte, administración y comercialización (Sección 14.7.3) son supuestos de negocio sin respaldo en una estructura de equipo o proveedores contratados; no provienen de cotizaciones reales.
5. La tasa de descuento anual del 25 % utilizada en el escenario Base es una elección de modelado –tasa de riesgo ajustada para un prototipo en etapa temprana– y no una tasa de mercado, de costo de capital institucional ni de referencia sectorial validada externamente.

6. El horizonte de 36 meses y la ausencia de eventos posteriores –nuevas rondas de inversión, cambios regulatorios, competencia entrante– son simplificaciones del modelo, no proyecciones de la realidad completa del mercado.
7. Un Valor Actual Neto positivo bajo estos supuestos no garantiza éxito comercial; únicamente indica que, si los supuestos se cumplieran, el proyecto generaría valor presente positivo bajo la tasa de descuento elegida.
8. El modelo no incorpora costos regulatorios ni de certificación sanitaria que podrían ser exigidos según jurisdicción, y que quedan fuera del alcance de este capítulo.
9. La estructura de *pricing* por volumen de estudios no fue comparada de forma sistemática contra herramientas competidoras de segmentación o flujo de trabajo en imagenología, más allá de la referencia general al Capítulo 13.
10. El costo de infraestructura Cloud fue medido sobre un único entorno de desarrollo (*DEV*), no sobre un entorno productivo con los volúmenes, redundancia y requisitos de disponibilidad de una operación institucional real; la Sección 14.7.3 no incorpora, por ejemplo, alta disponibilidad de base de datos ni monitoreo productivo.

14.15 Interpretación final

La evaluación económica indica que la infraestructura técnica no constituye el principal condicionante de la sostenibilidad financiera del producto. Bajo el escenario Base conservador, el proyecto alcanza equilibrio operativo y recupera la inversión dentro del horizonte analizado, aunque no genera Valor Actual Neto positivo bajo la tasa de descuento seleccionada. El análisis de sensibilidad muestra que la variable de mayor impacto es el *pricing* institucional, mientras que las variaciones del costo Cloud presentan un efecto marginal. A partir de estos resultados se propone un esquema comercial objetivo basado en suscripción SaaS por volumen de estudios, que permite alcanzar indicadores financieros positivos sin modificar los supuestos de adopción, *churn* o estructura operativa. No obstante, dicho *pricing* constituye una propuesta derivada del modelo y requiere validación comercial mediante entrevistas de *willingness-to-pay* y procesos reales de adquisición institucional.

En síntesis, este capítulo no concluye que el proyecto no sea viable, ni que ya sea comercialmente viable. Concluye que la factibilidad técnica y de infraestructura fue validada de forma empírica sobre Google Cloud; que el costo de esa infraestructura no representa una barrera económica relevante frente a los demás costos operativos del negocio; que el escenario financiero conservador se aproxima al equilibrio sin alcanzar valor presente positivo; y que un ajuste moderado y explícito de *pricing* –todavía sin validar comercialmente– alcanzaría indicadores financieros positivos bajo los mismos supuestos de adopción y costos. La validación de ese *pricing* con compradores institucionales reales queda, junto con la validación clínica descrita en

el Capítulo 13, como trabajo futuro explícito y no resuelto por este trabajo.

15 Planificación académica general

15.1 Criterio de planificación

La planificación conserva el calendario académico comprendido entre marzo y diciembre de 2026, pero diferencia dos niveles. El primero reúne los hitos formales de la asignatura: propuesta, entregas del 25 %, 50 % y 75 %, exposición y defensa. El segundo organiza la evolución técnica del producto mediante checkpoints, dependencias entre repositorios y evidencia de cierre.

Esta separación evita medir el avance únicamente por cantidad de código. Cada bloque se considera cerrado cuando cuenta con implementación o documentación, criterio de aceptación, evidencia y conexión con el roadmap general.

15.2 Planificación por entregables

TABLA 15.1: Estado consolidado de entregables y actividades de cierre del proyecto.

Entregable	Estado	Evidencia
Fundamentación y entrega del 25 %	terminado	capítulos 1–9 y propuesta aprobada.
User research inicial	realizado; corte consolidado para la entrega del 50 %	cinco entrevistas y encuesta cuantitativa con 167 respuestas.
Modelo sagital	entrenado y evaluado; supera el umbral de calidad del proyecto	checkpoint, manifest y métricas sobre partición retenida por paciente.
Modelo axial	entrenado y evaluado; el artifact permanece por debajo del umbral de calidad	checkpoint, manifest y métricas; ver Capítulo 13.
P9 integración multiplanar	terminado	ejecución, persistencia, workspace y reapertura.
P10 seguridad y observabilidad	consolidado para P10.9	criterios de seguridad del checkpoint P10.9 consolidados; hardening productivo posterior
P10.5-A contrato volumétrico	terminado	commits coordinados en AI Module, backend y frontend.
P10.5-B a P10.5-F evolución del visor volumétrico	implementado	catálogo de series, serving de cortes, shell de visor, vinculación por corte y reapertura E2E Implementados y congelados por checkpoint en sus ramas correspondientes; navegación volumétrica disponible además en la rama principal del frontend.
Documentación del 100 %	en integración	documento maestro, capítulos revisados, matrices y diagramas.
Google Cloud	cerrado técnicamente / validado	Artifact Registry/WIF, Backend Cloud Run DEV y Frontend Cloud Run DEV desplegados; AI privado, Cloud SQL, Secret Manager, storage productivo, DEMO environment y monitoring live pendientes.
Validación profesional sobre producto	revisión cualitativa realizada; validación cruzada final pendiente	dos sesiones sobre versión funcional/intermedia; observaciones y ajustes priorizados; no equivale a validación clínica ni cruzada.
Entrega del 75 % y defensa	futura	producto consolidado, resultados, discusión y presentación.

Entregable	Estado	Evidencia
P10.6 clasificador subarticular (Axial T2)	modelo entrenado y evaluado; capacidad automática bloqueada	checkpoint congelado sobre RSNA / LumbarDISC; falta ROI axial automática validada
P10.7 hallazgos degenerativos asistivos por nivel	implementado pero bloqueado para inferencia productiva automática	checkpoint y contratos existen; <code>blocked_preprocessing_parity</code> y <code>automaticInferenceEnabled=false</code> ; no se presenta como productivo.
P10.8 preflight y guardas	cerrado sin entrenamiento adicional	verificación de factibilidad y guardas de contrato Cerrado sin entrenamiento adicional; estado congelado en su rama de checkpoint.
P10.9 consolidación de producto (Backend + AI)	congelado para traspaso de Frontend	commits coordinados; Backend↔AI validado; contrato público sanitizado; fixtures P10.9 Backend + AI congelados para handoff de Frontend en rama de checkpoint identificable, con commit y evidencia del runner técnico; base posteriormente integrada en Frontend.
Integración P10.9 en Frontend	implementada	contratos P10.9 consumidos por el Frontend, catálogo full-series, visor navegable y reapertura integrada; Patient queda parcial porque el historial/longitudinal visible usa principalmente <code>subjectRef</code> .
Recorrido Full Product UI E2E sobre stack real	validado funcionalmente	Playwright final 11/11 PASS sobre el recorrido demo/producto; no equivale a validación clínica ni a Patient browser-level completo.

15.3 Gestión de cambios

Los cambios de alcance deben registrarse con su origen. La incorporación axial se vincula con user research y factibilidad de datos. El visor volumétrico se vincula con la constatación de que los MHA ya contienen múltiples cortes y con la necesidad de aproximar la experiencia a un lector real. La comparación longitudinal fue implementada y validada funcionalmente en Demo Mode y flujo basado en `subjectRef`; para entradas reales no-demo depende de una localización anatómica resuelta.

Cada cambio debe actualizar requerimientos, roadmap, arquitectura, contratos, pruebas y documentación. No corresponde modificar solo la interfaz cuando la capacidad depende de nuevos assets o persistencia.

15.4 Riesgos de planificación

Los principales riesgos son: sobrealcance clínico, apertura de funcionalidades antes de cerrar dependencias, falta de evidencia, divergencia entre repositorios, costos cloud no controlados, ausencia de validación cruzada profesional final e inconsistencias entre documentación y producto.

Las mitigaciones son: checkpoints compartidos, commits coordinados, criterios de aceptación, separación entre implementado y planificado, control presupuestario, pruebas por capas y uso del documento maestro como fuente editorial común.

15.5 Conclusión de la planificación

La planificación no reinicia el proyecto después del 25 %: toma como base los modelos, la integración multiplanar y la arquitectura ya desarrollados. El camino crítico ya no pasa por generar y persistir las vistas previas de todos los cortes ni por integrar los contratos P10.9 en el Frontend, capacidades actualmente implementadas. El tramo pendiente consiste en cerrar y documentar la evidencia Browser E2E, realizar la validación cruzada profesional final, consolidar la documentación y completar la discusión, las conclusiones y la defensa. La región de interés axial automática constituye una línea paralela que no condiciona ninguno de esos pasos.

A Cronograma del proyecto

Este anexo reúne el cronograma pormenorizado del Proyecto Final de Ingeniería. La primera sección presenta el calendario académico con los hitos formales de la asignatura; la segunda, el diagrama de Gantt con la distribución temporal de las actividades técnicas y documentales; la tercera, los desvíos registrados respecto de la planificación original y su justificación técnica.

A.1 Calendario académico

ootnotesize

TABLA A.1: Hitos académicos del proyecto.

Fecha	Hito académico	Estado
13/06/2026	Entrega del avance del 25 %	Cumplido
18/08/2026	Carga de la presentación y del avance del 50 %	En curso
25/08/2026 y 05/09/2026	Instancias de exposición del avance del 50 %	Previsto
20/10/2026	Entrega recomendada del avance escrito del 75 %	Previsto
27/10/2026 y 03/11/2026	Exposiciones del avance del 75 %	Previsto
Diciembre de 2026	Corrección final, entrega y defensa según llamado	Previsto

A.2 Diagrama de Gantt

Actividad	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Definición del tema, propuesta, objetivos y alcance	X	X								
Revisión normativa y aspectos éticos	X	X								
Relevamiento bibliográfico y datasets		X	X	X						
Estado del arte y marco teórico			X	X	X					
Entrega y correcciones del avance 25 %				X						
User research: encuestas y entrevistas profesionales			X	X	X	X				
Documentación y sistematización de entrevistas				X	X	X	X			
Análisis de feedback y definición de requerimientos				X	X	X				
Diseño de arquitectura y contratos del sistema					X	X	X			
Preparación de datasets y preprocesamiento					X	X				
Entrenamiento y evaluación de modelos de IA					X	X				
Segmentación sagital, axial y procesamiento volumétrico					X	X	X			
Clasificación asistida de hallazgos degenerativos					X	X	X			
Integración AI Module–Backend y persistencia					X	X	X			
Visor, mediciones y revisión profesional						X	X	X		
Integración P10.9 en Frontend / cierre Full Product UI E2E / documentación técnica final						X	X	X		
Presentación y correcciones del avance 50 %						X	X			
Despliegue y validación en Google Cloud						X	X	X		
Validación técnica y revisión con profesionales							X	X		
Presentación y exposición del avance 75 %								X	X	
Resultados, discusión y conclusiones								X	X	
Correcciones finales, documentación y defensa									X	X

Figura A.1: Diagrama de Gantt del Proyecto Final de Ingeniería, marzo a diciembre de 2026.
Fuente: elaboración propia.

El cronograma distingue dos carriles coordinados, según el criterio de planificación expuesto en el Capítulo 15. El carril técnico agrupa el desarrollo del pipeline, los modelos, la integración multiplanar, la seguridad, el visor volumétrico y el despliegue. El carril documental organiza la producción de los capítulos, las matrices de trazabilidad, los diagramas y la evidencia asociada a cada instancia de entrega.

TABLA A.2: Distribución temporal de las actividades por carril.

Período	Carril técnico	Carril documental
Marzo – abril de 2026	Relevamiento de datasets, verificación técnica de SPIDER y de Sudirman / Al-Kafri, definición del pipeline.	Propuesta, planteamiento del problema, objetivos y alcance.
Mayo – junio de 2026	Primer MVP sagital: carga, preprocesamiento, segmentación, mediciones y visualización superpuesta.	Estado del arte, marco teórico y entrega del 25 %.
Julio de 2026	Módulo axial complementario e integración multiplanar.	User research, elicitación y análisis preliminar de requerimientos.
Julio – agosto de 2026	Persistencia, reapertura, seguridad y visor volumétrico.	Requerimientos formalizados, arquitectura, modelo de datos y diagramas.
Agosto de 2026	Consolidación de Backend y AI Module, integración P10.9 en Frontend y flujo Patient–Study.	Desarrollo del producto, metodología, implementación técnica y entrega del 50 %.

Período	Carril técnico	Carril documental
Septiembre – octubre de 2026	Cierre y evidencia del recorrido Full Product UI E2E sobre el stack real, seguido de validación profesional sobre el producto integrado.	Resultados, validación y entrega del 75 %.
Noviembre – diciembre de 2026	Consolidación de observabilidad, evidencia final y cierre de validaciones.	Discusión, conclusiones, trabajos futuros y defensa.

A.3 Desvíos respecto de la planificación original

TABLA A.3: Desvíos registrados y justificación técnica.

Desvío	Planificación original	Situación real	Justificación
Incorporación del plano axial	El alcance inicial contemplaba únicamente el plano sagital.	Se incorporó un módulo axial complementario sobre los niveles discuales inferiores.	Hallazgo del relevamiento con profesionales y disponibilidad de un dataset público con anotaciones axiales nativas y co-registro T1-T2 verificado.
Adelanto de la integración multiplanar	Se preveía completar el plano sagital y evaluar el axial en una etapa posterior.	La integración de producto avanzó más rápido y permitió cerrar capacidades previstas para etapas siguientes.	El uso de contratos compartidos entre repositorios redujo el costo de integración respecto de lo estimado.
Incorporación de un tercer dataset	Se preveían dos datasets base.	RSNA / LumbarDISC se incorporó como dataset complementario.	Habilitó la línea de hallazgos degenerativos por nivel y aportó un estudio DICOM real para la validación técnica de la ingesta.
Región de interés axial automática	Se preveía disponible para la entrega del 50 %.	El clasificador subarticular quedó entrenado y evaluado, pero la generación automática de la región de interés permanece pendiente.	La capacidad depende de una etapa de localización anatómica no contemplada en la estimación inicial. Se documenta como línea paralela que no condiciona el recorrido principal.
Recorrido extremo a extremo con interfaz	Se preveía cerrado para la entrega del 50 %.	El Backend, el AI Module y la integración P10.9 en Frontend se encuentran implementados; el recorrido funcional browser E2E final fue validado con Playwright 11/11.	La ampliación del alcance al visor volumétrico, la navegación por cortes y la consolidación contractual requirió priorizar la integración por capas. La integración P10.9 en Frontend se completó y la evidencia E2E funcional se consolidó en el cierre técnico final; queda pendiente la validación profesional final y el cierre de negocio/conclusiones.

B Glosario de términos

Se reúnen aquí, en orden alfabético, los términos técnicos empleados a lo largo del documento, con una definición breve orientada a un lector no especializado. Se incluyen tanto el vocabulario de imagen médica y aprendizaje profundo como los términos de ingeniería y de gestión del proyecto utilizados en los capítulos de arquitectura, desarrollo y metodología.

AAP (Área entre elementos anterior y posterior)

Espacio anatómico comprendido entre el cuerpo vertebral y los elementos posteriores dentro del canal lumbar. En el dataset Sudirman, constituye una de las regiones de interés anotadas específicamente en los cortes axiales.

Artifact

Archivo generado o consumido por el módulo de inteligencia artificial (pesos del modelo, manifiesto de configuración, máscara, superposición o metadatos de una corrida) que se conserva de forma verificable para poder reproducir el resultado.

Backlog

Lista priorizada de trabajo pendiente. En este proyecto se emplean dos: uno técnico, con funcionalidades y deuda técnica, y uno documental, con los capítulos y la evidencia de la tesis.

Benchmark

Conjunto de pruebas y métricas estandarizadas que permite comparar de forma objetiva el desempeño de distintos modelos o algoritmos sobre los mismos datos.

Canal espinal o canal raquídeo

Conducto formado por la superposición de las vértebras por el que discurren la médula espinal y las raíces nerviosas. Su estrechamiento puede comprimir estructuras nerviosas.

Cauda equina (cola de caballo)

Estructura formada por el conjunto de raíces nerviosas que se originan al final de la médula espinal. Su compresión por estrechamiento del canal se vincula clínicamente con sintomatología dolorosa y compromiso neurológico.

Checkpoint

Estado del sistema identificado por commits concretos en los tres repositorios, que puede reproducirse y sirve como frontera común desde la cual continuar el desarrollo. Los checkpoints del proyecto se identifican con

códigos del tipo P9, P10 o P10.5.

CNN, red neuronal convolucional

Tipo de red neuronal especializada en procesar imágenes, que aprende a detectar patrones visuales como bordes, texturas y formas mediante operaciones llamadas convoluciones.

Co-registro DICOM

Alineación espacial nativa entre distintas series de un mismo estudio, como las secuencias axiales T1 y T2. Esta propiedad geométrica permite la transferencia directa de máscaras de segmentación entre series sin requerir algoritmos de registro adicionales.

Coefficiente Dice

Métrica que mide el grado de solapamiento entre la segmentación generada por el modelo y la anotación de referencia. Vale 1 cuando coinciden por completo y 0 cuando no se superponen.

Contrato

Definición acordada del formato de los datos que intercambian dos componentes (por ejemplo, el backend y el módulo de inteligencia artificial), junto con los casos de prueba que verifican su cumplimiento.

Corrida

Ejecución completa del análisis sobre un estudio: preprocesamiento, inferencia, generación de máscaras y mediciones, y persistencia de los resultados.

DICOM

Estándar internacional para almacenar e intercambiar imágenes médicas junto con sus metadatos, como datos del paciente, parámetros de adquisición, orientación y espaciado.

Disco intervertebral

Estructura fibrocartilaginosa situada entre dos cuerpos vertebrales que actúa como amortiguador y permite el movimiento de la columna.

Distancia de Hausdorff y HD95

Métricas que cuantifican el error de contorno de una segmentación midiendo la mayor distancia entre los bordes predicho y de referencia. HD95 usa el percentil 95 para reducir la influencia de valores atípicos.

Elemento posterior (PE)

Componentes dorsales de la vértebra que integran las láminas, procesos espinosos y apófisis articulares. Su hipertrofia degenerativa es un factor etiológico relevante en la reducción del área disponible del canal.

Encoder-decoder	Arquitectura de red neuronal en la que una primera parte, el encoder, comprime la imagen en una representación abstracta y una segunda, el decoder, la reconstruye, por ejemplo como una máscara de segmentación.
End-to-end (E2E)	Prueba o recorrido que atraviesa el sistema completo, desde la carga del estudio hasta la revisión del resultado, en lugar de verificar un componente aislado.
Estado degradado	Situación en la que el sistema no puede completar una operación y lo informa de forma explícita, en lugar de devolver un resultado incompleto presentado como válido.
Estenosis	Reducción del diámetro o área del canal raquídeo o los forámenes neurales. Su evaluación técnica integra la cuantificación de dimensiones anatómicas con la inspección visual cualitativa de las imágenes de resonancia.
Fixture	Conjunto de datos de prueba fijo y de-identificado que se utiliza para verificar que un componente sigue comportándose igual después de un cambio.
Forámenes neurales (neuroforámenes)	Conductos laterales situados entre vértebras adyacentes destinados al paso de las raíces nerviosas. El plano de adquisición axial resulta óptimo para su delimitación y análisis morfológico en comparación con el sagital.
Ground truth, anotación de referencia	Segmentación o etiqueta considerada correcta, generalmente realizada o validada por expertos, que se usa para entrenar y evaluar los modelos.
Hardening	Conjunto de medidas de endurecimiento de la configuración de seguridad aplicadas antes de exponer un sistema a un entorno productivo.
Humano en el circuito, human-in-the-loop	Esquema de trabajo en el que el resultado automático del sistema es revisado, corregido o aprobado por una persona antes de usarse, manteniendo el control profesional.
IoU, intersección sobre unión	Métrica de solapamiento que divide el área común entre predicción y referencia por el área total que ambas cubren. Vale 1 en coincidencia perfecta.

Máscara de segmentación

Imagen del mismo tamaño que la original en la que cada píxel o vóxel indica a qué estructura pertenece, delimitando así las regiones de interés.

MVP, producto mínimo viable

Versión inicial de un producto con las funciones mínimas necesarias para validar su utilidad y obtener retroalimentación antes de desarrollarlo por completo.

NIfTI

Formato de archivo habitual en neuroimagen e investigación que almacena imágenes médicas tridimensionales junto con su información espacial.

nnU-Net

Marco de segmentación basado en U-Net que se autoconfigura, incluyendo preprocesamiento, arquitectura e hiperparámetros, según las características del conjunto de datos.

Normalized Surface Dice, NSD

Métrica que evalúa cuán bien coinciden las superficies de dos segmentaciones admitiendo una tolerancia de distancia, útil para valorar la calidad del contorno.

Overlay, superposición

Representación de la máscara de segmentación dibujada sobre la imagen original, de modo que puedan compararse en el mismo encuadre.

PFI, Proyecto Final de Ingeniería

Trabajo integrador con el que se concluye la carrera de ingeniería; en este documento designa al prototipo desarrollado.

Píxel

Unidad mínima de una imagen bidimensional; cada píxel representa un punto con un valor de intensidad.

Plano sagital

Plano que divide el cuerpo en mitades izquierda y derecha. En RM lumbar permite observar de perfil la pila de vértebras, los discos y el canal espinal.

Preflight

Verificación previa a la ejecución que comprueba que estén disponibles los modelos, artifacts y series necesarios, y que interrumpe el proceso antes de generar un resultado no válido.

Preinforme

Texto estructurado generado automáticamente a partir de las estructuras segmentadas y de las mediciones derivadas, editable por el profesional. No constituye un informe clínico.

Protrusión discal	Alteración morfológica donde el material del disco intervertebral se desplaza focalmente conservando la integridad del anillo fibroso; representa el hallazgo de desplazamiento discal más recurrente en la región lumbar.
Radiculopatía	Cuadro clínico caracterizado por alteraciones sensoriales o motoras derivadas de la irritación de una raíz nerviosa, frecuentemente secundaria a procesos de estenosis o hernias de disco.
RM, resonancia magnética	Técnica de diagnóstico por imagen que utiliza campos magnéticos y ondas de radiofrecuencia para obtener imágenes detalladas de los tejidos blandos, sin radiación ionizante.
ROI, región de interés	Zona acotada de la imagen sobre la cual se concentra un análisis, delimitada para reducir el área que el modelo debe procesar.
Saco tecal (saco dural)	Envoltura membranosa que contiene el líquido cefalorraquídeo y las raíces nerviosas. La medición de su área en sección transversal constituye un parámetro cuantitativo crítico para la valoración de la estenosis lumbar.
Secuencias T1 y T2	Modos de adquisición de la RM que resaltan distintos tejidos. En T1 la grasa aparece brillante; en T2 el líquido y el agua aparecen brillantes, lo que ayuda a distinguir estructuras.
Segmentación	Proceso de delimitar en una imagen las regiones que corresponden a cada estructura de interés, asignando cada píxel o vóxel a una clase.
Spacing, espaciado	Distancia física que representa cada píxel o vóxel, por ejemplo en milímetros. Es imprescindible para convertir mediciones de la imagen a unidades reales.
Split	División de un conjunto de datos en subconjuntos de entrenamiento, validación y prueba, definida de manera fija para que los resultados puedan reproducirse.
STIR (Short Tau Inversion Recovery)	Técnica de adquisición que permite la supresión de la señal grasa para enfatizar procesos edematosos. Funciona como complemento clínico a T1 y T2 en la detección de patologías inflamatorias agudas.

TRA (transverse)	Designación técnica empleada en los metadatos de las series DICOM para identificar las adquisiciones realizadas en el plano transversal o axial.
Transformer / mecanismo de atención	Componente de aprendizaje profundo que pondera la relación entre distintas partes de la entrada; combinado con CNN mejora la captura de contexto en imágenes.
Trazabilidad	Propiedad por la cual cada resultado puede vincularse con su origen: la imagen, la máscara, la estructura, el corte y la eventual corrección profesional que lo produjeron.
U-Net	Arquitectura encoder-decoder con conexiones directas entre ambas partes, muy utilizada en segmentación de imágenes médicas por su buen desempeño con pocos datos.
Vértebra	Cada uno de los huesos que forman la columna. La región lumbar tiene cinco, L1 a L5, y soporta gran parte del peso del tronco.
Vóxel	Unidad mínima de una imagen tridimensional; es el equivalente al píxel, pero con volumen, ya que representa un pequeño bloque del espacio en lugar de un punto en un plano.
Worklist	Listado de estudios disponibles para el profesional, con su estado de procesamiento y de revisión.
Archivo .ima	Sufijo de archivo característico de las imágenes generadas por equipamiento Siemens, el cual mantiene plena equivalencia técnica con el estándar DICOM convencional (.dcm).
510(k)	Vía regulatoria de la FDA (Estados Unidos) por la que un dispositivo médico demuestra ser sustancialmente equivalente a otro ya autorizado para poder comercializarse.

C Anatomía de la columna lumbar y los discos intervertebrales

Este anexo resume las nociones anatómicas mínimas necesarias para comprender el dominio del prototipo. Está dirigido a lectores sin formación médica y no pretende ser exhaustivo desde el punto de vista clínico.

La columna vertebral es una estructura ósea que sostiene el tronco, permite el movimiento y protege la médula espinal. Se organiza en regiones; la región lumbar es la parte baja de la espalda y está formada por cinco vértebras, denominadas L1 a L5, ubicadas entre la columna torácica y el sacro. Por soportar gran parte del peso corporal y concentrar mucha movilidad, es una zona especialmente propensa al dolor y a la degeneración.

Cada vértebra está compuesta, a grandes rasgos, por un cuerpo vertebral anterior, de forma cilíndrica, que soporta la carga, y un arco posterior que rodea y protege el canal espinal. Las vértebras se apilan una sobre otra y, en conjunto, conforman el eje que da soporte al cuerpo.

Entre cada par de cuerpos vertebrales se encuentra un disco intervertebral. El disco está formado por un anillo fibroso externo (anulus fibrosus) y un núcleo gelatinoso central (nucleus pulposus), que actúa como amortiguador: distribuye las cargas y permite que la columna se flexione y gire. Con la edad o por sobrecarga, los discos pueden perder altura, deshidratarse o desplazarse, lo que se asocia con frecuencia al dolor lumbar y a la compresión de estructuras nerviosas.

El canal espinal es el conducto que recorre la columna por detrás de los cuerpos vertebrales y aloja la médula espinal y las raíces nerviosas. Su estrechamiento, denominado estenosis, puede comprimir esas estructuras y producir síntomas. Por su disposición, las vértebras, los discos y el canal espinal se aprecian con claridad en las imágenes de resonancia magnética en plano sagital y, de forma complementaria, en plano axial, que son las entradas sobre las que opera el prototipo descrito en este trabajo.

C.1 Esquema simplificado de columna lumbar sagital

Las figuras de este anexo son esquemáticas y tienen finalidad exclusivamente explicativa. No representan un estudio clínico real ni deben utilizarse para interpretación diagnóstica. Su objetivo es facilitar la comprensión general de las estructuras anatómicas consideradas por el prototipo y del flujo conceptual de segmentación utilizado en el proyecto.




Figura esquemática, sin escala. No representa un estudio clínico real.

Figura C.1: Esquema simplificado de vértebras lumbares, discos intervertebrales y canal espinal en vista sagital. Fuente: elaboración propia.

C.2 Esquema conceptual de segmentación.




Figura esquemática con fines explicativos. Elaboración propia.

Figura C.2: Esquema conceptual del pasaje desde una RM lumbar hacia máscaras de segmentación. Fuente: elaboración propia.

D Transcripciones de las entrevistas

Criterio de depuración. Las siguientes transcripciones se presentan en formato de diálogo directo, en primera persona para entrevistadores y profesionales entrevistados. Se eliminaron pruebas técnicas de cámara o audio, repeticiones sin valor analítico, muletillas excesivas y errores evidentes de la transcripción automática. No se reemplazaron las respuestas por síntesis en tercera persona, ya que el anexo funciona como registro primario del relevamiento cualitativo. Cuando una frase del audio resultaba dudosa, se conservó el sentido más probable sin agregar conclusiones externas.

Identificación de participantes. Los nombres e instituciones se consignan según la información provista por los autores del PFI para esta versión de trabajo. El cuerpo de cada entrevista mantiene el intercambio en primera persona y no incluye análisis interpretativo; dicho análisis se desarrollará en el capítulo de user research.

D.1 Entrevista 1 (EN-01) - Dra. Susana Torres (M.N. 179537)

Dra. Susana Torres: Ustedes serían la parte de programación específica, o sea, desarrollar la idea. ¿Qué es lo que necesitan? ¿Ciertos parámetros? ¿Qué tienen que tener en cuenta al momento de evaluar una persona en columna lumbar? Más que nada, si es para estenosis, cuántas patologías abarcarían. Me pregunté un montón de cosas.

Enzo Asplanatti: Por ahora nosotros mantenemos la parte ingenieril, que sería automatizar ese proceso y, con ayuda de la computadora, lograr encontrar la mayor cantidad de hallazgos posibles. Todavía no tenemos el alcance completamente acotado a patologías específicas. Por ahora lo estamos achicando a esto.

Francisco Fabrello: Estamos esperando la respuesta de la cátedra. Presentamos el proyecto, nos dijeron que avancemos y que después nos iban a dar correcciones finas. Entonces, por ahora, la idea es entrenar el modelo con datos ya etiquetados para que aprenda a detectar, y después llevarlo hacia lo que nos recomienden. También nos pidieron validar con profesionales, haciendo entrevistas con algunas preguntas, para ver qué opinan y qué podríamos agregar o quitar.

Dra. Susana Torres: ¿Ustedes tienen una lista de preguntas?

Francisco Fabrello: Sí, más o menos. La primera sería: ¿cómo trabajás con resonancias y qué lugar ocupan dentro de tu práctica?

Dra. Susana Torres: Resonancias lumbares, hoy por hoy estoy trabajando en FLENI. El principal volumen son los cerebros, pero después le sigue seguro la resonancia lumbar por hernias discales. Hay otros hallazgos no pensados dentro del diagnóstico presuntivo, pero la mayoría es por radiculopatía o compresión radicular.

Francisco Fabrello: Entonces, ¿cuál sería más o menos el caso que encontrás más frecuente?

Dra. Susana Torres: Protrusiones discales.

Francisco Fabrello: ¿Y eso sería, en palabras más simples?

Dra. Susana Torres: La hernia discal es como la entidad general. Hay distintos grados: está el abombamiento, la protrusión y la extrusión. La protrusión es la más frecuente.

Francisco Fabrello: Perfecto. Y cuando tenés que hacer el análisis de una resonancia, ¿cómo sería el recorrido para visualizarla?

Dra. Susana Torres: Lo que ya viene estudiado, que también hace poco se usa en FLENI, es más que nada la parte de volumetría encefálica, que tira resultados de cuantificación de sustancia gris, sustancia blanca, etcétera; pero para resonancia lumbar todavía no he trabajado con eso. Mi orden de trabajo generalmente es dividir la pantalla. El axial T2 es el que siempre estoy corroborando y en la otra pantalla veo el sagital T2, el sagital T1 y el sagital STIR para ver si hay edema óseo o cambios degenerativos a nivel de los cuerpos vertebrales. Una vez visto eso, los espacios y la alineación, paso al sagital T2 y al axial T2. En el axial puedo ver si hay alguna compresión, cómo está el canal, si hay alguna estrechez a nivel del canal y cómo están los neuroforámenes.

Francisco Fabrello: Perfecto. ¿Qué considerás más importante para que el informe sea útil?

Dra. Susana Torres: Tener en cuenta la clínica del paciente y el diagnóstico presuntivo. Eso es lo que le está doliendo. Puede haber un montón de cambios degenerativos, pero si el paciente viene por una hernia L5-S1, voy enfocada ahí. Ahí hago mi conclusión: dónde le duele y por qué le duele.

Francisco Fabrello: Si este sistema pudiera delimitar automáticamente las vértebras, los discos, el canal espinal y, a partir de eso, calcular mediciones como la altura de discos, el diámetro AP del canal o la alineación, ¿qué utilidad real podría tener o qué dudas te generaría?

Dra. Susana Torres: A eso que nombraste le agregaría, además de la altura de los discos, la intensidad de señal de los discos. Pueden tener altura respetada, pero ya verse signos de deshidratación, que es súper común y así empiezan los cambios degenerativos. El diámetro AP del canal, en cuanto a lumbar, sería más que nada el área. Muchas veces hay cambios degenerativos en los elementos posteriores y facetas que se hipertrofian. Eso genera una disminución del diámetro transversal del canal. Entonces, por ahí el AP está bien, pero como tenés cambios degenerativos atrás, las raíces de la cola de caballo se apiñan y eso ya es una estenosis leve. También hay que tener en cuenta que el paciente está acostado; con ciertos movimientos o parado puede cambiar. En cuanto a la alineación, me parece re importante, porque el paciente está acostado y no tiene la sobrecarga de la gravedad. La alineación posterior también es súper importante para sospechar algún tipo de lisis o listesis.

Francisco Fabrello: Si el sistema trabajara principalmente con cortes sagitales T1 y T2, pero no con cortes axiales, ¿qué podría evaluarse y qué quedaría incompleto o riesgoso?

Dra. Susana Torres: Bastante quedaría incompleto. Al hacer el análisis nivel por nivel, si me

hacés elegir, es el sagital T2 y el axial T2. Ahí veo también la extensión hacia los neuroforámenes. Incluir la estenosis a nivel de los neuroforámenes es re importante y se ve mejor correlacionando los dos planos.

Francisco Fabrello: ¿Qué errores de una herramienta de este tipo serían graves o inaceptables desde el punto de vista clínico?

Dra. Susana Torres: Los mismos que tenemos nosotros, básicamente: sobredimensionar algo o infravalorar algún hallazgo. Lo importante está todo en la calidad de los datos que le carguen, básicamente. Y qué ground truth es la que utilizan.

Francisco Fabrello: Claro. Yendo más al lado de la interfaz, ¿qué tendría que mostrar o permitir el sistema para que resulte confiable y no agregue ruido o haga más tediosa la rutina?

Dra. Susana Torres: Pienso en lo que evalúo a diario. Por ejemplo, si me dice que tiene una estenosis grado 2 de los neuroforámenes, poder verlo. Que me lo marque primero y, si estoy de acuerdo, lo dejo; si no, hago una corrección manual y digo que es grado 1 o grado 2. Igual ahí también hay sesgo, porque si una IA te dice que es grado 2 y quizás es grado 1, depende de la experiencia y de cómo se interprete el software.

Francisco Fabrello: Para que este software sea viable desde el punto de vista clínico, ¿contra qué tendríamos que validarlo? Por ejemplo, segmentaciones manuales de especialistas o mediciones de expertos.

Dra. Susana Torres: Sí, segmentación manual de especialistas sería ideal. Yo trabajo para una empresa que se llama Prenuvo, que hace total body segmentations con resonancias y distintos tipos de informes para hallazgos positivos. Las segmentaciones las hacemos entre médicos, pero siempre hay como un pool; cada estudio está tres veces chequeado. La calidad de los datos me parece lo más importante. Se nota cuando el que primero hizo la revisión es un médico general, un residente de radiología o un especialista.

Francisco Fabrello: ¿Qué alcance te parecería más defendible? ¿Qué sacarías para no prometer de más?

Dra. Susana Torres: Lo acotaría. Como les preguntaba al principio: ¿cuál era el objetivo? ¿Valorar estenosis? ¿Delimitar estenosis de canal y estenosis neuroforaminal? Porque si no hay un montón de patologías y un montón de cuestiones que se pueden evaluar. Generalmente, si me preguntás qué es lo que más vemos y lo que generalmente causa dolor o consulta del paciente, son cambios degenerativos. También cambios tipo Modic de las plataformas. Lo acotaría, porque si no va a ser muy difícil abarcar todo y se les va a hacer eterno.

Francisco Fabrello: ¿Alguna red flag que te haría decir que el proyecto no debería plantearse así?

Dra. Susana Torres: No veo que tuviera alguna red flag. La verdad es un tema bastante estudiado. Ya hay distintos modelos e instituciones afuera que están trabajando así, con informes y resultados estructurados. Ayudaría un montón. Recalco nuevamente la calidad de los datos de entrenamiento,

pero el resto me parece fantástico.

Francisco Fabrello: ¿Qué dirías que sería un diferencial del proyecto? Por ejemplo, que genere el informe y muestre paso a paso lo que hizo, o que deje visualizar la resonancia con el análisis encima.

Dra. Susana Torres: Visualmente, creo que hablo por la mayoría de los radiólogos: nosotros nos guiamos mucho por lo visual. Si las segmentaciones están como máscaras dentro de los hallazgos y yo veo que tiene pérdida de altura del disco y me muestran dónde lo está viendo, eso me genera confianza. Lo mismo con las estenosis, ya sea del canal o de los forámenes.

Francisco Fabrello: ¿Qué opinás de que el sistema permita cargar una resonancia anterior y una actual para hacer una comparativa?

Dra. Susana Torres: Buenísimo. Eso ayudaría a decir qué era lo que le dolía antes, qué aumentó y cómo fueron evolucionando esos cambios degenerativos. Sumaría un montón.

Enzo Asplanatti: ¿Cómo continúa después, si avanza el proyecto?

Dra. Susana Torres: Si el proyecto continúa y progresa, yo me dedico a segmentación y control de calidad, así que tienen mi contacto. Me interesa mucho la inteligencia artificial porque es lo que se viene. Cualquier cosa que necesiten, tienen mi contacto.

Francisco Fabrello: La idea es que primero validemos con profesionales la viabilidad y después, más adelante, con un producto semiarmado, podamos volver a hacer preguntas tipo checklist del uno al cinco para evaluar qué mejorar.

Dra. Susana Torres: Claro, cuál es la practicidad en el día a día.

Francisco Fabrello: También pensamos que el sistema muestre la máscara encima, una tabla de datos y que el profesional pueda corregir el dato que predijo, porque vimos que el modelo a veces falla.

Dra. Susana Torres: O sea, que pasa.

Francisco Fabrello: Por ejemplo, mide el canal, lo pinta, pero le falta un pedacito. Entiendo que depende de la resonancia, de si es T1 o T2, y de qué estructuras se ven mejor.

Dra. Susana Torres: Claro. En cuanto a lo lumbar, les recalco que no solamente importa el diámetro, sino también la pérdida de líquido entre las raíces. A nivel cervical puede ser solamente diámetro, pero a nivel lumbar tenés la cola de caballo. Entonces hay que medir cuán juntas están las raíces y si se sigue viendo líquido entre ellas.

Francisco Fabrello: Lo vamos a tener en cuenta para entrenar la IA.

Enzo Asplanatti: Eso está bueno.

Dra. Susana Torres: Bueno, muchas gracias.

Francisco Fabrello: Gracias. ¿En un futuro te podríamos escribir para seguir validando?

Dra. Susana Torres: Sí, encantada, ningún problema. Me interesa mucho.

Francisco Fabrello: Muchas gracias.

Dra. Susana Torres: Dale, nos vemos.

Enzo Asplanatti: Chau, chau.

D.2 Entrevista 2 (EN-02) - Dr. Gonzalo Brito

Enzo Asplanatti: Estamos en el último año de Ingeniería Informática en UADE y estamos haciendo la tesis. Desde la cátedra nos piden generar una validación con profesionales. Nuestra idea es desarrollar una herramienta de inteligencia artificial que, a partir de resonancias magnéticas, pueda detectar lesiones o generar mediciones y producir un preinforme para que después el profesional lo vea, lo valide y lo corrija si hace falta. Buscamos agilizar el proceso y automatizar tareas que pueden ser lentas o tediosas. La idea de estas preguntas es validar la propuesta.

Dr. Gonzalo Brito: Bien. Entonces lo apuntan más al informe médico y no tanto a la adquisición de imágenes. En resonancia también se puede usar inteligencia artificial para adquirir secuencias, pero ustedes lo orientan más a pasar datos, analizarlos y apoyar el informe. Está bueno. La inteligencia artificial se empieza a ver y a escuchar mucho en nuestra especialidad porque trabajamos con computadoras, archivos y software. En nuestra empresa lo hemos usado en radiografía. Se testeó aplicarlo a placas simples y estaba bueno, pero tenía limitaciones: daba muchos falsos positivos y se empezó a dejar de usar. Habría que pulirlo. Igual, como preinforme o ayuda, puede servir. A veces se nos pueden escapar cosas y está bueno que un programa te marque una anormalidad o una imagen sospechosa para que después el médico la interprete y confirme si es patológica o si es un artefacto. En resonancia hay muchos artefactos, imágenes que parecen algo y probablemente no lo sean. La iniciativa es muy buena. Creo que a futuro se va a usar cada vez más y en congresos se habla mucho de esto.

Dr. Gonzalo Brito: Al principio, hace algunos años, el miedo de los radiólogos era que la inteligencia artificial nos reemplazara. Pero ahora lo que se empieza a decir es que quizás la inteligencia artificial no va a reemplazar a los radiólogos, sino a los radiólogos que no se adaptan a la inteligencia artificial. Si empieza a aparecer, ya no hay vuelta: está para quedarse. Probablemente los radiólogos que usen inteligencia artificial les saquen ventaja a los que no la usen.

Francisco Fabrello: Nosotros vamos por ese lado, que sea una herramienta para ayudar y no para reemplazar. Tampoco confiaríamos en que diga directamente «tenés tal cosa» hasta que lo revise una persona.

Dr. Gonzalo Brito: Claro. Como algo previo lo veo útil. No creo que en este momento salga un informe completo sin que lo revise ninguna persona. Se ponen en juego muchas cosas. Pero sí creo que promete y que va a venir cada vez más. Habrá que pulirlo para que sea útil para nosotros y para el paciente. También habrá que estudiar si permite diagnosticar más ciertas patologías o detectar lesiones pequeñas que al ojo humano se le pueden pasar. Si la inteligencia artificial te marca una lesión de dos milímetros y después el médico decide si es relevante o no, puede ser muy útil.

Francisco Fabrello: Primero, para poner un poco el eje, ¿cómo sería tu trabajo con resonancia y qué lugar ocupa dentro de tu práctica?

Dr. Gonzalo Brito: Ahora trabajo de lunes a jueves con resonancia magnética. Informo cuatro horas por día. A la mañana hago ecografías y, en la parte de imágenes, también informo tomografía. Hago bastante más tomografía, pero la resonancia me lleva un tiempo similar según la complejidad. Puedo hacer cinco o seis resonancias por hora, dependiendo del estudio. Hay estudios más largos, estudios oncológicos que requieren comparar y otros más sencillos que se ven más rápido.

Francisco Fabrello: ¿Cómo sería tu recorrido desde que revisás el estudio hasta que redactás el informe?

Dr. Gonzalo Brito: Abro el estudio desde el sistema que tenemos, que se llama EGES. Ahí se organizan los pacientes, las órdenes y los estudios previos. Tener estudios previos es fundamental; siempre decimos que el mejor amigo del radiólogo son los estudios previos. Después abro el estudio, cargo las secuencias y empiezo a analizarlas. Luego grabo el informe con micrófono. El sistema permite grabar y eso va a un equipo de tipistas. Si digo que lo confirmen, el informe queda confirmado. Si no, queda sin confirmar y después entro manualmente, modifico lo que haga falta y cuando lo confirmo queda cargado en el sistema para que otros médicos lo vean en el portal.

Francisco Fabrello: ¿Lo hacés con varias vistas o con alguna vista particular? Por ejemplo, axial y sagital al mismo tiempo.

Dr. Gonzalo Brito: Todas las reconstrucciones son fundamentales. Los cortes axiales suelen ser los que más usamos porque generalmente se planifica todo en cortes axiales y después se hacen reconstrucciones sagitales y coronales. En algunas situaciones específicas se hacen reconstrucciones oblicuas o siguiendo el eje de una estructura que quieras evaluar. Lo mejor es ver todos los planos porque te dan mucha información.

Francisco Fabrello: En columna, ¿qué hallazgo considerás más importante para que el informe sea clínicamente útil?

Dr. Gonzalo Brito: Depende mucho del estudio, pero en columna lo que más busca el traumatólogo o el médico derivante es ver si están comprometidos los neuroforámenes y si las raíces nerviosas están comprometidas por algún disco. También puede haber patología oncológica, lesiones secundarias o hallazgos relevantes en columna. En general depende de qué estés buscando.

Dr. Gonzalo Brito: En estudios donde importa lo oncológico o infeccioso, una secuencia que miro mucho es difusión y mapa de ADC. La difusión permite ver si hay restricción al movimiento de las moléculas de agua, lo que puede asociarse a patología neoplásica, infecciosa, abscesos o tumores. Es una secuencia que da mucha información y es de lo que menos me quiero dejar pasar.

Francisco Fabrello: ¿Qué error de una herramienta de este tipo sería clínicamente grave o inaceptable?

Dr. Gonzalo Brito: Creo que lo más grave sería que se pase algo importante. Pienso en lo oncológico, por ejemplo. Hay criterios para ver si una patología está en remisión, progresando o igual. Si la herramienta no permite evaluar o comparar bien lesiones muy pequeñas, donde quizás un milímetro más es significativo, eso sería grave. Para mí lo más grave es que no detecte un hallazgo importante.

Francisco Fabrello: ¿Sería peor un falso negativo que un falso positivo?

Dr. Gonzalo Brito: Sí. Un falso positivo, si lo marca, después lo desestimás. El problema es cuando algo no lo detecta. También nos pasó con un programa de radiografías: lo podían ver médicos derivantes en el portal, y a veces marcaba fractura donde no había fractura por una imagen superpuesta o un artefacto. Para el radiólogo no es tan grave porque lo revisa, pero si lo ve alguien que no es radiólogo y actúa en base a eso, puede ser grave. Lo más delicado es que lo usen personas que no son radiólogas y se queden con ese resultado sin revisión.

Francisco Fabrello: ¿Qué tendría que mostrar o permitir el sistema para que te resulte confiable, fácil de usar y no te agregue ruido en la rutina?

Dr. Gonzalo Brito: Creo que sería útil que pueda medir las imágenes que se ven o sacar volúmenes. Eso podría ahorrar tiempo. Si marca una lesión, que la delimite y saque medidas en los tres ejes. Eso sería útil para agilizar. También debería ser algo sencillo.

Francisco Fabrello: Por ejemplo, que genere contornos superpuestos sobre la imagen original, que permita corrección manual o que muestre un indicador de confianza.

Dr. Gonzalo Brito: Sí, eso podría servir. También algo que dé diagnósticos diferenciales podría estar bueno. Yo a veces saco una foto de una imagen, se la mando a ChatGPT y le pido diagnósticos diferenciales. Me tira opciones y después reviso bibliografía para ver cómo deberían verse. Muchas veces ayuda. Si el programa lo hiciera automáticamente, con una pestaña de diagnósticos potenciales, podría ser útil. No para quedarse con eso, sino como ayuda para que se escapen menos cosas o para recordar diagnósticos raros.

Francisco Fabrello: Para que el programa sea defendible desde el punto de vista clínico, ¿contra qué debería validarse? ¿Más del lado de datos o de profesionales?

Dr. Gonzalo Brito: Creo que más por el lado de los profesionales. Que lo usen, que lo prueben los médicos. Si es una herramienta para médicos, la validación debería venir primero por ahí: que sea cómodo, práctico y que no cambie demasiado la rutina. A veces nos quieren imponer herramientas que terminan tardando más. Si me tarda un minuto más por informe, al final del día pesa. Tiene que ser práctico y no engorroso.

Francisco Fabrello: ¿Qué alcance te parece más defendible? ¿Qué agregarías, qué sacarías o qué sería una red flag?

Dr. Gonzalo Brito: Me parece que está bueno que tenga mediciones, que detecte imágenes y que

además pueda dar información. También podría incorporar una base teórica o enlazarse con sitios radiológicos. Nosotros usamos mucho Radiopaedia, que es como nuestra biblia: están muchos hallazgos y casos. Si pudiera conectarse o buscar ahí, estaría bueno.

Dr. Gonzalo Brito: Como red flag, vuelvo a lo de los falsos negativos: que no detecte algo importante. También estaría bueno poder reportar errores. Cuando usábamos el programa de placas, tenía un QR para reportar errores. Eso era clave porque le servía a quienes desarrollaban el sistema para mejorarlo. Reportar en qué se equivoca el sistema es muy importante.

Francisco Fabrello: Eso sería todo. Como conclusión rápida, varias entrevistas van por el mismo lado: que no deje de detectar algo importante, que se pueda corregir, que no retrase el flujo y que ayude con los planos axiales.

Dr. Gonzalo Brito: Cualquier otra duda me escriben. Si necesitan algo, no hay problema.

Francisco Fabrello: Por ahora estamos en una etapa teórica, pero seguramente cuando avancemos en el desarrollo notemos nuevas dudas y podamos volver a consultar.

Dr. Gonzalo Brito: Sí, me escriben por mail o WhatsApp.

Francisco Fabrello: ¿Querés comentar algo más que no hayamos preguntado?

Dr. Gonzalo Brito: No, creo que hablamos bastante. Como comentario, apoyo la iniciativa. Me parece algo buenísimo y creo que cada vez va a venir más. En un futuro no muy lejano seguramente vamos a estar trabajando con estos programas. Métanle, está bueno.

Francisco Fabrello: Muchas gracias.

Dr. Gonzalo Brito: Éxitos. Cualquier cosa seguimos en contacto.

D.3 Entrevista 3 (EN-03) - Dra. Claudia Cejas

Dra. Claudia Cejas: Actualmente estoy como Presidenta de la Sociedad Argentina de Radiología y, dentro de las imágenes, me dedico a todo lo que es patología neuromuscular y de columna. Eso es lo que hago desde hace 15 años. Antes hacía todo lo que es región de cabeza y cuello. Bueno, ¿se quieren presentar?

Francisco Fabrello: Yo soy Francisco Fabrello y mi compañero es Enzo Asplanatti. Estamos cursando nuestro último año de Ingeniería Informática en UADE y estamos haciendo nuestra tesis sobre resonancias magnéticas, específicamente de columna lumbar. Empezamos este ciclo de entrevistas para validar un poco el proyecto y ver qué cambios hacen falta, porque es un área nueva para nosotros.

Enzo Asplanatti: La idea es desarrollar una herramienta acompañada con inteligencia artificial que permita detectar patrones a través de mediciones y generar un preinforme que después tenga validación profesional. Nosotros venimos a acompañar y automatizar parte del proceso, no a reemplazar el criterio médico.

Dra. Claudia Cejas: ¿Con respecto a la modalidad, están hablando de radiología, tomografía o resonancia?

Enzo Asplanatti: Por ahora vamos a trabajar con resonancias. Después, si se puede llevar a tomografía o radiografías, bienvenido, pero por ahora nos manejamos con resonancia.

Dra. Claudia Cejas: Perfecto. Resonancia es lo que se pide, así que está bueno. Los escucho: ¿qué necesitan de mí?

Francisco Fabrello: Tengo una serie de preguntas estructuradas. Para comenzar: ¿cómo es tu trabajo habitual con resonancias magnéticas y qué lugar ocupan dentro de tu práctica?

Dra. Claudia Cejas: Dentro de neuromuscular veo mucha resonancia de columna, así que es una de las áreas que evalúo en mi día a día. Estoy muchas horas en FLENI y parte de ese horario lo dedico a hacer informes de resonancia. Dentro de esas resonancias veo resonancia de columna.

Francisco Fabrello: Cuando abris una resonancia, ¿cómo es tu recorrido habitual desde que empezás a revisar hasta que redactás el informe?

Dra. Claudia Cejas: Todos los radiólogos tenemos un algoritmo. En mi caso empiezo por el hueso. Evalúo la alineación de la columna, si está bien alineada o no. Luego me fijo cómo está el cuerpo vertebral, si tiene alguna patología, y después todo el aparato posterior. Luego paso a los discos y los veo uno por uno: la señal, la altura, si hay abombamientos, protrusiones, extrusiones y si generan compresión de raíces. Después paso a la médula. En lumbar se ve poco, pero en cervical y dorsal se ve mucho. Todo esto lo estudio en los planos que usamos: sagital y axial; si el paciente tiene escoliosis, también coronal. Después miro la parte posterior de la columna, músculos paravertebrales, ligamentos y estructuras alrededor, como riñones o aorta, porque a veces el paciente viene por una cosa y encontrás otra.

Francisco Fabrello: ¿Eso lo hacés al mismo tiempo con dos pantallas o separando la imagen en un monitor?

Dra. Claudia Cejas: Uso dos pantallas. Divido cada pantalla en cuatro y voy cargando las imágenes. Como tenemos un sistema PACS, cuando estoy en el sagital puedo ver en qué nivel estoy. Entonces voy jugando para ver si la afectación está dentro de los neuroforámenes, en la parte superior, media o inferior.

Francisco Fabrello: ¿Qué hallazgos considerarás más importantes para el informe que haría este sistema? Por ejemplo, degeneración discal, hernias, protrusiones, estenosis, canal espinal o forámenes.

Dra. Claudia Cejas: Te puedo hacer un listado. Pensando en mi algoritmo, primero la alineación de la columna, porque muchas veces en un informe previo no se informó que estaba desalineada. Eso es importante porque habla de un problema funcional. Después vería la presencia de protrusiones, sus características y si son protrusiones o extrusiones. Luego iría al grado de estenosis, ya sea del foramen, del espacio lateral o del canal central. Tener esas medidas estaría bueno porque nosotros muchas veces lo graduamos a ojo: leve, moderado o severo. Necesitaría un sistema para poder protocolizarlo.

Dra. Claudia Cejas: También detectaría lesiones en la médula: lesiones desmielinizantes o

tumorales. Si vamos a columna degenerativa, me enfocaría en discos; pero si pensamos en un centro neurológico, una lesión en la médula no debería omitirse. También podría estar bueno detectar lesiones óseas, no solo en cuerpos vertebrales sino en pedículos y láminas. Las láminas se pueden romper y generar inestabilidad, y muchas veces eso nos cuesta verlo en resonancia.

Francisco Fabrello: Si el sistema trabajara solo con cortes sagitales y no con cortes axiales, ¿se podría evaluar razonablemente?

Dra. Claudia Cejas: Depende del tipo de secuencia. Si tenés secuencias volumétricas 3D, podés programar una secuencia en el plano sagital y reconstruirla en coronal y axial con la misma resolución. Eso es válido. Ahora, hacer solamente un corte sagital 2D, no. Te quedás corto. Es raro que haya lugares que hagan un solo plano.

Francisco Fabrello: Con las entrevistas nos quedó más claro que el axial es necesario para un buen análisis.

Dra. Claudia Cejas: Sí. Si tenés secuencias 3D podés reconstruir, pero si no, el axial es importante.

Francisco Fabrello: ¿Qué error de una herramienta de este tipo sería clínicamente grave o inaceptable?

Dra. Claudia Cejas: Si ustedes incluyen médula, lo más grave sería no ver una lesión en la médula. Si tenés una lesión en la región cervical, una persona puede quedar parapléjica o sin mover brazos y piernas. Creo que eso es lo que no debería perderse. Todo lo demás es más perdonable.

Francisco Fabrello: ¿Qué podría mostrar o permitir el sistema para que te resulte confiable y mejore la rutina?

Dra. Claudia Cejas: Que me marque con algún color. Por ejemplo, que me delimite el disco. También me imagino que me delimite el borde posterior de la columna en sagital para ver si hay desviación. Eso me encantaría. Si me delinea el disco, puedo ver rápidamente si hay solo un abombamiento o si el disco coincide con el cuerpo vertebral, que sería normal. Si está por fuera o tiene una deformidad, me llama la atención para ver una protrusión. También me serviría que me marque la médula o alguna lesión.

Francisco Fabrello: La idea sería tener la resonancia y aplicar una máscara arriba, pintando las partes. También pensamos en que marque un nivel de confianza del resultado, por ejemplo, una medida con cierto porcentaje de confianza.

Dra. Claudia Cejas: Sí, eso estaría bueno. ¿Y la idea de ustedes es hacer un reporte agregado a eso?

Francisco Fabrello: Sí. Una idea era que oriente al médico con posibles casos o diagnósticos diferenciales, pero sin decir automáticamente «tiene esto». La idea es ayudar a plantear opciones para que el médico llegue a la conclusión.

Dra. Claudia Cejas: Yo creo que lo ideal, para acelerar el trabajo hoy, es que la herramienta

esté destinada a la detección, no a decir qué es. Para llegar a decir qué es nos basamos mucho en la clínica. Una lesión sola puede no coincidir con la clínica. En un hospital, además, uno lee la historia clínica y eso cambia el diagnóstico. Hoy no esperaría que una inteligencia artificial inicial me diga el diagnóstico. Esperaría que me detecte lesiones, que me muestre lo que yo sé ver pero que podría omitir por carga laboral o burnout. Me parece que ese debería ser el enfoque. El diagnóstico con clínica, laboratorio y todo lo demás puede venir en una segunda etapa.

Dra. Claudia Cejas: Nosotros trabajamos con inteligencia artificial en neuro. Validamos estudios de una empresa que detecta atrofia cerebral y lesiones desmielinizantes cerebrales. Nos hace un reporte estructurado y después nosotros vemos si ese reporte queda. En atrofia es muy útil porque antes lo hacíamos a ojo y había mucha discordancia. El sistema mide atrofia global y por áreas específicas. Eso acelera muchísimo.

Francisco Fabrello: Para que el producto sea defendible desde el punto de vista clínico, ¿contra qué considerás que deberíamos validarlo?

Dra. Claudia Cejas: Con expertos. Si es un producto que no está desarrollado, lo validaría con un grupo de expertos.

Francisco Fabrello: Nos habían mencionado Radiopaedia como referencia.

Dra. Claudia Cejas: Radiopaedia está buena. Habla de la patología y al costado pone casos clínicos. La usan mucho los residentes para buscar diagnósticos diferenciales. Está muy bien hecha.

Francisco Fabrello: ¿Qué alcance te parece más defendible? ¿Qué sacarías para no prometer de más?

Dra. Claudia Cejas: Lo que pretendería es que puedan dar toda la información que les mencioné, pero no sé si es viable. Tendrían que limitarse a algo. Si es un centro neurológico como el nuestro, algo que no debería omitirse es una lesión en la médula. Ahora, en un centro de diagnóstico, donde la patología degenerativa es lo más común en columna, me dedicaría a los discos.

Dra. Claudia Cejas: Otra opción sería medir el canal. Si el canal está estrecho, quien lo ve va a buscar por qué está estrecho. Puede ser porque está desalineado, porque tiene estenosis o porque tiene un tumor. Para simplificarlo, podrían medir el canal lumbar. Está estandarizado en bibliografía y saben cuánto tiene que medir en un adulto. Si lo hacen, háganlo en adultos, porque pediatría es otro mundo. Acótenlo a región lumbar y a un tema específico.

Francisco Fabrello: ¿Querés comentarnos algo más?

Dra. Claudia Cejas: Me parece hermoso el proyecto que van a armar. Está buenísimo. ¿Qué herramientas van a usar? ¿Python, R? ¿Cómo van a desarrollarlo?

Francisco Fabrello: Para la parte de IA pensamos en Python. Para la interfaz estamos viendo algo más web, para que no tenga que correr localmente ni requiera un equipo potente. La idea es que el usuario cargue el estudio y se procese en la nube.

Dra. Claudia Cejas: Ah, ok.

Francisco Fabrello: También pensamos en la posibilidad de cargar una resonancia anterior y la actual para que haga una comparativa: qué cambió, qué no y qué se mantuvo.

Dra. Claudia Cejas: Eso es espectacular. No sé si es sencillo de hacer, pero es espectacular, porque nos pasa mucho que piden controles y tenemos que ir viendo hacia atrás.

Francisco Fabrello: Vamos a ver si es técnicamente viable.

Dra. Claudia Cejas: Nosotros tenemos un sistema que entra al PACS, lee el estudio, lo analiza y nos lo devuelve. También conozco otros sistemas en la nube donde cargás el estudio, lo analiza y lo devuelve. También está bueno.

Francisco Fabrello: Estamos yendo más hacia la nube porque correr IA localmente requiere muchos recursos. Estamos haciendo entrenamientos preliminares y creemos que puede funcionar.

Dra. Claudia Cejas: Bueno, mucha suerte.

Francisco Fabrello: ¿Te podríamos contactar en una futura entrevista para mostrarte cómo avanzamos y recibir feedback?

Dra. Claudia Cejas: Sí, claro que sí. No hay problema.

Francisco Fabrello: Muchas gracias.

Dra. Claudia Cejas: Gracias a ustedes. Que tengan buen día.

D.4 Entrevista 4 (EN-04) - Dr. Bruno Bregonzi

Enzo Asplanatti: Bien. Para empezar, ¿qué volumen de resonancias de columna lumbar, torácica o cervical solés informar?

Dr. Bruno Bregonzi: Más o menos, de unas 70 resonancias que puedo informar en un día, 30 serán de columna lumbar. Es una gran proporción, porque el lumbago es una de las causas más normales de dolor lumbar y genera muchos problemas laborales, incluso ausentismo. Además, trabajo con mucha población deportiva, así que la hernia discal es una patología de todos los días, el pan nuestro de cada día. Por lo menos un 30 % de las resonancias son de columna lumbar todos los días.

Enzo Asplanatti: Bueno, nos sirve porque estamos apuntando a un alcance bastante grande y queremos saber si realmente es algo frecuente.

Enzo Asplanatti: Después, ¿cuál es tu recorrido habitual desde que empezás a revisar la resonancia hasta que redactás el informe?

Dr. Bruno Bregonzi: Primero siempre me fijo en las características del hueso: si es un hueso más joven o más viejo, lo describo y veo si tiene signos de degeneración. Después hablo de los discos: cómo está la señal de los discos y si los núcleos pulposos están bien hidratados o deshidratados. Después evalúo las protrusiones discales, nivel por nivel, desde T12-L1 hasta L5-S1. También describo la altura de los cuerpos intervertebrales y la alineación posterior. Después menciono la señal del cono medular, que siempre es importante en los informes de columna. Por último, hablo del ángulo de curvatura de la lordosis lumbar, si está respetado o rectificado, de la convexidad en

el plano coronal y de las articulaciones interfacetarias.

Enzo Asplanatti: Ok, nos sirve. Muchas veces la información de Internet es muy amplia y nosotros queremos entender qué se mira realmente en un informe concreto.

Dr. Bruno Bregonzi: Nosotros hacemos un informe muy al hueso. Siempre miramos la orden y qué es lo que nos piden. A veces dice solamente «columna lumbar» o «RM lumbar», y otras veces te piden algo más específico. Por ejemplo, si te ponen un ganglión sinovial, tenés que buscar bien las interfacetarias y mirarlas con más detalle. Pero lo más frecuente es lo del día a día.

Enzo Asplanatti: ¿Y qué hallazgos considerás más importantes para que el informe sea clínicamente útil?

Dr. Bruno Bregonzi: Lo más importante es hablar de la patología discal y de la relación que tiene con las raíces nerviosas. Eso, sin duda, es lo más importante.

Enzo Asplanatti: Si un sistema pudiera delimitar automáticamente las vértebras, los discos intervertebrales y el canal espinal, y a partir de eso calcular mediciones, por ejemplo altura discal, diámetro anteroposterior del canal o alineación, ¿qué utilidad real le verías?

Dr. Bruno Bregonzi: Si funcionara como un co-work, o como una herramienta de apoyo, lo leería primero y después sí o sí le pasaría mis ojos. Para mí tendría utilidad si me sirve como una referencia inicial. En mi día a día, lo que más me ayudaría serían las mediciones puras, como ángulos o superposición de imágenes. Por ejemplo, en rodilla también me resultaría útil algo así, porque me liberaría un poco de trabajo.

Enzo Asplanatti: Sí, es lo que buscamos. La idea no es que reemplace al profesional, sino que genere un modelo interactivo o una asistencia para revisar después.

Dr. Bruno Bregonzi: Claro. Si en el futuro lo hacen para rodilla, se lo pasan al siguiente grupo y que se encargue de rodilla.

Enzo Asplanatti: Después, si el sistema trabajara principalmente con cortes sagitales T1 o T2 y no con cortes axiales, ¿qué podría evaluarse razonablemente y qué quedaría incompleto?

Dr. Bruno Bregonzi: Depende del protocolo. A veces los axiales no se pueden hacer porque el paciente se mueve o porque no tolera el estudio. Con los sagitales podés tener puntos de referencia, pero hay cosas que quedan limitadas. Por ejemplo, para saber bien si es raíz derecha o izquierda, el axial ayuda mucho. Con sagital T1, sagital T2 y STIR tenés información útil; esas tres secuencias se usan bastante. Pero el axial es muy importante para completar la evaluación.

Enzo Asplanatti: Está bueno eso, porque en otras entrevistas nos dijeron que los cortes sagitales y axiales serían el ideal. Nosotros estamos tratando de entender qué sería lo ideal y qué sería el mínimo aceptable para algunos casos.

Dr. Bruno Bregonzi: Claro, el ideal es tener todo. Pero hay veces que el paciente es claustrofóbico, no se banca el estudio y lo tienen que sacar antes. Entonces quizá no tenés todas las secuencias. El ideal puede ser uno, pero en la práctica a veces hay que acostumbrarse a trabajar

con lo que hay.

Enzo Asplanatti: ¿Qué errores de una herramienta de este tipo serían clínicamente graves o inaceptables?

Dr. Bruno Bregonzi: Para mí, la culpa no sería de la herramienta sino del profesional que informa. Si la usás todos los días, la responsabilidad final la tenés vos. La herramienta puede ayudar, pero el error clínico no se lo adjudicaría a la herramienta.

Enzo Asplanatti: Y pensando más en la interfaz, ¿qué tendría que mostrar o permitir el sistema para que te resulte confiable y no te genere ruido en la rutina?

Dr. Bruno Bregonzi: No me generaría ruido si funciona como un alivianador. Si lo usás como referencia primero y después informás, puede servir.

Enzo Asplanatti: Estamos pensando una especie de prototipo donde se vea la resonancia en el medio o a un costado, y una ventana desplegable con las mediciones. La duda era no generar demasiada información en pantalla para que no termine siendo un problema o una pérdida de tiempo.

Dr. Bruno Bregonzi: Claro. La idea sería que no muestre de más. Lo importante es que se vea la segmentación ya hecha y que eso sirva como guía, no que agregue más trabajo.

Enzo Asplanatti: Para que un prototipo de este tipo sea mínimamente defendible desde el punto de vista clínico, ¿contra quién o contra qué debería validarse?

Dr. Bruno Bregonzi: Contra el profesional que informa. Si el profesional dice que está bien, eso es lo central para validar la utilidad práctica.

Enzo Asplanatti: Y para un proyecto final de grado o una tesis, ¿qué alcance te parecería más defendible? ¿Qué sacarías para no prometer de más?

Dr. Bruno Bregonzi: Yo lo orientaría a un área: neuro o músculo esquelético. Elegiría una de las dos y lo probaría en algún centro o con algún grupo de médicos que empiece a informar con eso, para ver si realmente le puede sacar jugo. Empezaría con un alcance más acotado, en un centro, y después que vaya creciendo de boca en boca.

Enzo Asplanatti: Sí, la idea es empezar de a poco. Si resulta útil, después puede crecer.

Dr. Bruno Bregonzi: Si es muy útil, sale solo. Olvidate.

Enzo Asplanatti: Una pregunta extra: ¿qué opinás de comparar una resonancia anterior con una actual del mismo paciente?

Dr. Bruno Bregonzi: Me parece 100 % útil. Capaz el dolor del paciente no es el mismo, o progresó la patología discal que tenía. Siempre es muy importante leer el interrogatorio del paciente para saber si cambió el dolor, si es el mismo, si se intensificó o si nunca se fue. Eso te orienta a buscar si progresó la misma patología discal de base o si apareció alguna discopatía nueva. La comparación con estudios anteriores siempre es muy importante.

Enzo Asplanatti: Bueno, eso es todo. Fue rapidísimo. Ahora estamos en etapa de desarrollo y más adelante, cuando tengamos un prototipo, nos van a pedir otra etapa de validación con

profesionales. En ese caso, ¿podríamos volver a contactarte?

Dr. Bruno Bregonzi: Sí, comuníquense. Yo ahora estoy con bastante trabajo, pero no hay problema. Me avisan y lo vemos.

D.5 Entrevista 5 (EN-05) - Dr. Eduardo Luis Castiglione

Dr. Eduardo Luis Castiglione: Las columnas lumbares son una gran parte del volumen que se hace en neurorradiología. Yo soy neurorradiólogo y vemos estudios de cerebro, columna y cabeza y cuello, pero el volumen de columna es bastante importante; de hecho, te diría que es lo que más se ve. Los estudios se filtran en base a distintas cosas, principalmente fechas, y después los distintos médicos del plantel nos dividimos los estudios. Te pueden tocar más o menos columnas lumbares, pero es una parte importante del trabajo.

Francisco Fabrello: Cuando te toca abrir una resonancia, ¿cómo es tu recorrido habitual desde que empezás a revisarla hasta que redactás el informe? ¿Qué es lo primero que mirás o dónde hacés más énfasis?

Dr. Eduardo Luis Castiglione: Cada radiólogo tiene su forma particular de ver una imagen. Yo, al principio, divido la ventana de visualización en dos y pongo un sagital T1 y un sagital T2. Eso me sirve para valorar la alineación vertebral en el plano sagital, ver la señal global de la médula ósea y algunas características generales de los cuerpos vertebrales y los discos.

Dr. Eduardo Luis Castiglione: Después utilizo mucho el sagital STIR, en particular para ver si hay edema óseo, inflamación ósea, derrames en las articulaciones facetarias o bursitis interespinosa. Luego siempre pongo un sagital T2 en correlación con un axial T2. Eso es fundamental, sobre todo para ver la patología discal en los dos planos y la relación con las estructuras vecinas. Siempre hay que correlacionar el sagital con el axial para evaluar la patología discal, porque hay que verla en distintos planos.

Dr. Eduardo Luis Castiglione: El axial T1 también sirve mucho, más que nada para ver la estructura ósea, porque el T1 es la secuencia más anatómica. Una vez analizado eso, miro en el axial T1 y en el axial T2 los tejidos blandos paravertebrales. Ese sería el protocolo estándar de resonancia. En el hospital tenemos tres sagitales: T1, T2 y STIR; después un axial T1 y un axial T2. Opcionalmente, si el paciente tiene escoliosis, se hace también un coronal T2. En realidad no es que se vea más una secuencia que otra: todas son complementarias, se miran todas y sirven para distintas cosas.

Francisco Fabrello: En base a la resonancia, ¿qué hallazgo considerarás más importante a la hora de redactar el informe? Por ejemplo, el peso de la degeneración discal, una hernia o una protrusión.

Dr. Eduardo Luis Castiglione: En realidad ningún hallazgo por sí mismo es significativo si no está dentro del contexto clínico del paciente. Especialmente en pacientes adultos, siempre vas a encontrar algún hallazgo en la columna: alguna discopatía, algún osteofito o algún cambio

degenerativo facetario. El hallazgo radiológico por sí solo no significa demasiado, porque puede verse en pacientes con o sin síntomas. Siempre nos referimos al contexto clínico y, en base a eso, priorizamos.

Dr. Eduardo Luis Castiglione: Por ejemplo, si un paciente tiene una lumbociatalgia derecha y presenta múltiples hallazgos, osteofitos o artrosis facetaria, pero tiene un disco en L5-S1 que comprime una raíz nerviosa, eso pasa a ser fundamental. Ahí el axial T2 y el sagital T2 son claves para ver el disco y los forámenes. En general, dirigimos mucho la visualización del estudio hacia la sospecha clínica, sin dejar de revisar toda la información que aportan las secuencias.

Francisco Fabrello: Si el sistema pudiera delimitar automáticamente las vértebras, los discos y el canal espinal, y a partir de eso sacar mediciones como la altura del disco, el diámetro anteroposterior del canal o la alineación, ¿considerás que tendría utilidad real o te generaría dudas?

Dr. Eduardo Luis Castiglione: Vamos por partes. La delimitación automática de las vértebras ya hay muchos proveedores de PACS que la hacen automáticamente. En nuestro caso, con un botón en el PACS ya se delimitan los distintos niveles vertebrales. No sé si un sistema externo aportaría demasiado en eso, porque ya viene incluido en el paquete de visualización del PACS, por lo menos en el que usamos nosotros.

Dr. Eduardo Luis Castiglione: Respecto de los discos, si ya tenés delimitadas las vértebras, el disco queda identificado por el nivel superior e inferior, por ejemplo L1-L2, L2-L3, L3-L4, y así. Entonces no sé si ahí aportaría mucho. En cuanto al canal espinal, medir el diámetro del canal es tan simple como poner un caliper en la región de interés y medirlo. Pero si una herramienta pudiera medir automáticamente el diámetro del canal, no estaría mal. Otra cosa que sí estaría buena es el área del canal.

Dr. Eduardo Luis Castiglione: El área también se puede calcular manualmente, pero si la herramienta lo da automáticamente sería útil. Para medir un área se puede usar un ROI, que es una región de interés. Básicamente delimitás un área determinada y el sistema te devuelve distintos parámetros, entre ellos el área. Si con un clic pudieras tocar el área del canal y que automáticamente calcule diámetros mínimos, máximos y área, no estaría mal. Se puede hacer con herramientas del PACS, pero requiere colaboración humana.

Francisco Fabrello: ¿Qué errores de una herramienta de este tipo serían clínicamente graves o inaceptables? Por ejemplo, equivocarse en el nivel anatómico, segmentar mal, delimitar mal L5-S1, medir mal el canal o no detectar una compresión relevante.

Dr. Eduardo Luis Castiglione: Todo lo que es inteligencia artificial aplicada a medicina, al menos por ahora, siempre tiene un respaldo médico. Siempre hay algún tipo de revisión antes de que llegue al paciente. Nosotros vamos a estar atrás de la herramienta para decir si está midiendo bien o no.

Dr. Eduardo Luis Castiglione: Si tuviera que elegir algo que debería hacer bien desde el inicio,

diría que el nivel anatómico es básico y fundamental, y no debería tener errores en eso. Respecto de los diámetros del canal, también es importante que la segmentación agarre bien el área y que no tenga sobreestimación ni infraestimación. Si sobreestima o infraestima, los diámetros más fáciles los hacemos manualmente nosotros mismos y listo.

Francisco Fabrello: Por ahora el sistema segmenta, da ancho, alto y área de los discos y las vértebras, y también da el diámetro y el área del canal, como mencionaste. Eso lo hace por ahora tanto para sagital como axial. Lo que estamos por agregar es que intente detectar qué está pasando o qué patología podría tener el paciente.

Francisco Fabrello: Pensando en la interfaz, ¿qué tendría que mostrar o permitir el sistema para que te resulte confiable, facilite la tarea y no agregue ruido a la rutina? Comparado con un PACS, ¿qué le agregarías o qué paso sacarías porque te complica el análisis?

Dr. Eduardo Luis Castiglione: El 90 % de las columnas que vemos nosotros, por lo menos en nuestro centro, corresponde a patología degenerativa discal. Algo que a mí me serviría mucho en el día a día no sería solamente el análisis de la imagen, sino una correlación con el informe radiológico.

Dr. Eduardo Luis Castiglione: Por ejemplo, que la herramienta detecte lo que está pasando en determinado nivel y haga una interpretación diagnóstica de ese nivel, en cuanto a las nomenclaturas anatómicas y patológicas que usamos. Te doy un ejemplo: si el sistema detecta una patología en L5-S1, que de alguna manera lo plasme en el informe radiológico con una frase, como «protrusión discal subarticular derecha que condiciona reducción parcial del receso lateral y signos de compresión de la raíz S1».

Dr. Eduardo Luis Castiglione: La idea sería que haga una interpretación de lo que está pasando ahí y que eso quede plasmado de alguna forma en el informe radiológico. Después nosotros lo revisamos y modificamos la frase si hace falta. Creo que una herramienta que facilite la traducción de lo que vemos a un lenguaje terminológico más universal, como el que se usa en los informes, y que lo vuelque automáticamente en una plantilla, sería útil.

Francisco Fabrello: Para que el prototipo de esta tesis sea mínimamente defendible desde el punto de vista clínico, ¿contra qué considerás que deberíamos validarlo? Por ejemplo, contra segmentaciones manuales de especialistas, mediciones manuales, informes radiológicos o algo similar.

Dr. Eduardo Luis Castiglione: Considero que la comparación tiene que ser contra mediciones realizadas por especialistas. En la gran mayoría de los ensayos clínicos, cuando se intentan validar tests diagnósticos en medicina, se hacen estudios de doble o triple ciego. Se ponen dos o tres médicos a analizar las variables que se quieren estudiar sin conocer el resultado final y, en base a eso, se compara contra lo que dio el test diagnóstico para ver si coincide o no.

Dr. Eduardo Luis Castiglione: También hay comparaciones intraobservador e interobservador. Creo que su modelo tiene que ser comparado contra análisis hechos por especialistas humanos.

Por ejemplo, si se quiere medir el canal, se compara la medición del modelo contra lo que mide un especialista. Esa debería ser la variable de comparación.

Francisco Fabrello: Para un proyecto final de grado, ¿qué alcance te parece más defendible? ¿Sacarías algo o ves alguna red flag en que el proyecto esté planteado con segmentación y con una etapa posterior donde intente dar posibles diagnósticos?

Dr. Eduardo Luis Castiglione: Como planteo general está bien. La limitante de todo lo que está saliendo ahora con inteligencia artificial en medicina, especialmente en diagnóstico, es que hasta el momento no debería llegarle al paciente algo generado por IA sin estar validado antes por un profesional.

Francisco Fabrello: Sí, el proyecto está planteado para que lo use el médico. Es para ayudar al médico a hacer el análisis, no para que el paciente cargue la resonancia en el sistema.

Dr. Eduardo Luis Castiglione: Claro. Como planteo está bien. A lo mejor algunas variables de medición que usan, como la medición de niveles y discos, ya las hacen algunos sistemas de PACS. No conozco en profundidad el proyecto, los datasets que utilizaron, las patologías ni los resultados que obtuvieron hasta ahora como para emitir una opinión general. Pero lo que sí debería tener, para evitar una posible red flag, es la comparación de resultados contra profesionales.

Dr. Eduardo Luis Castiglione: Si están midiendo diámetros y áreas, no pasa nada. Pero si están midiendo patologías propiamente dichas, creo que deberían demostrar algún número o algún muestreo de sus análisis comparado con medidas hechas por profesionales.

Francisco Fabrello: O sea, sería analizar con nuestro sistema y con médicos el mismo estudio, y comparar las respuestas.

Dr. Eduardo Luis Castiglione: Sí, a eso quería llegar.

Francisco Fabrello: Ya estarían las preguntas. ¿Querés comentarnos algo más en base a lo que hablamos, alguna opinión o algo particular que no hayamos preguntado?

Dr. Eduardo Luis Castiglione: Mi pregunta es si, una vez que rindan la tesis, lo van a seguir desarrollando o cuál es la idea final. Si queda solo como tesis o si piensan llevarlo más adelante.

Francisco Fabrello: La verdad es que, si pudiéramos llevarlo más adelante, estaríamos abiertos a seguir. Por ahora no encontramos un freno que nos diga que no podemos resolverlo. Claramente hay particularidades, pero estaría bueno llevarlo un poco más a la realidad. Por ahora es algo académico, pero sería interesante probarlo con un grupo de médicos abiertos a colaborar y ver si sería viable o si no tiene sentido seguir desarrollándolo.

Dr. Eduardo Luis Castiglione: Perfecto.

Francisco Fabrello: ¿Tendrías alguna otra pregunta para hacernos o algo que haya quedado pendiente?

Dr. Eduardo Luis Castiglione: No, por ahora no.

Francisco Fabrello: Una última pregunta: si en algún momento te podemos contactar de vuelta

para hacer una siguiente entrevista o mostrar avances del prototipo.

Nota de cierre: la transcripción automática provista finaliza en la pregunta sobre un posible contacto futuro; no se agregó una respuesta de cierre porque no aparece en la fuente entregada.

E Configuración de entrenamiento de los modelos

Este anexo reúne la configuración con la que se entrenaron los dos modelos de segmentación, con el detalle necesario para que un tercero pueda reproducir los resultados informados en el Capítulo 13. Se incluyen los parámetros de optimización, la estrategia de aumentación de datos y los controles de calidad aplicados al cierre del entrenamiento.

E.1 Parámetros de entrenamiento

TABLA E.1: Configuración comparada del entrenamiento de ambos modelos.

Parámetro	Modelo sagital	Modelo axial
Conjunto de datos	SPIDER	Sudirman y Al-Kafri
Arquitectura	U-Net bidimensional, variante sagital	U-Net bidimensional, variante axial
Número de clases	4	6
Canales base	16	16
Dimensión de entrada	256×256	256×256
Semilla	20260716	2026
Tamaño de lote	8	8
Épocas máximas	80	80
Tasa de aprendizaje	8×10^{-4}	8×10^{-4}
Decaimiento de pesos	1×10^{-4}	1×10^{-4}
Paciencia de detención temprana	12	12
Paciencia del planificador	4	No aplicada
Recorte de gradiente	No aplicado	1,0
Precisión mixta	Sí	Sí
Función de pérdida	$0,5 \times$ entropía cruzada ponderada + $0,5 \times$ Dice sin fondo	Entropía cruzada ponderada + Dice suave sin fondo
Pesos de clase	Estimados del conjunto	Estimados del conjunto, con refuerzo sobre la clase de fondo de origen
Épocas completadas	75, con detención temprana	Detención temprana
Época seleccionada	63	17

La función de pérdida combina en ambos casos un término de entropía cruzada ponderada por clase con un término basado en el coeficiente Dice que excluye el fondo. La combinación responde a que la entropía cruzada por sí sola tiende a favorecer las clases mayoritarias, mientras que el término de Dice equilibra la contribución de las estructuras de menor tamaño.

E.2 Aumentación de datos

La estrategia de aumentación difiere entre ambos modelos, y la diferencia responde a una razón anatómica que conviene explicitar.

TABLA E.2: Transformaciones de aumentación aplicadas durante el entrenamiento.

Transformación	Modelo sagital	Modelo axial
Reflexión horizontal	Habilitada, probabilidad 0,50	Deshabilitada
Reflexión vertical	Habilitada, probabilidad 0,20	Deshabilitada
Rotación	Habilitada, ± 8 grados, probabilidad 0,40	Deshabilitada
Variación de contraste	Habilitada, factor entre 0,85 y 1,15, probabilidad 0,50	Habilitada, factor entre 0,95 y 1,05, probabilidad 0,25
Interpolación	Bilineal para la imagen, vecino más próximo para la máscara	Idéntica

La reflexión horizontal está habilitada en el modelo sagital y deshabilitada en el axial. En un corte axial, el lado izquierdo y el derecho corresponden a regiones anatómicas distintas y clínicamente distinguibles, de modo que reflejar la imagen invierte la lateralidad de cualquier hallazgo. En un corte sagital no existe lateralidad que preservar. Habilitar la reflexión en el plano axial habría multiplicado los datos disponibles a costa de entrenar el modelo para que ignore una distinción que el uso clínico requiere.

La rotación permanece deshabilitada en el módulo axial por un motivo análogo: la angulación de un corte axial es un dato del estudio, no una variación arbitraria, y la asignación de nivel anatómico descrita en la sección 11.6 depende de ella.

Ambas estrategias son deterministas por época. La semilla de cada transformación se deriva de la combinación de la semilla global, el número de época, el índice de la muestra y el identificador del corte, de modo que la reproducción es exacta corte por corte y no únicamente a nivel de ejecución completa.

E.3 Controles de calidad al cierre del entrenamiento

TABLA E.3: Condiciones evaluadas antes de promover un artifact.

Control	Valor o condición	Configurable
Umbral de coeficiente Dice macro de primer plano	0,70	Sí
Partición retenida separada a nivel de paciente	Obligatoria	No
Informe explícito del desempeño sobre la clase de fondo de origen	Obligatorio	No
Informe de intersección sobre unión además del coeficiente Dice	Obligatorio	No
Generación de una partición nueva	Deshabilitada por omisión	Requiere habilitación manual

El cuaderno de entrenamiento incorpora además verificaciones de fuga cruzada entre particiones, de particiones vacías y de clases ausentes en alguna de ellas, así como una restricción en tiempo de ejecución que impide reevaluar la partición retenida de una ejecución ya evaluada sin confirmación explícita.

Según se informa en la sección 13.4, el umbral no se alcanzó en el modelo axial bajo su lectura de primer plano completo, y el artifact quedó registrado en esa condición sin que el valor del umbral se modificara.

E.4 Trazabilidad de los artifacts

Cada artifact final conserva en su manifest la correspondencia de clases, la configuración de la arquitectura, la dimensión de entrada, las métricas obtenidas, el estado de entrenamiento y un conjunto de identificadores criptográficos que vinculan el modelo con el código y los datos que lo produjeron: el resumen del índice de entrenamiento, el del código de la arquitectura, el commit del repositorio y la referencia al cuaderno de origen.

El runtime valida esa correspondencia antes de habilitar un modelo. Si los nombres de clase declarados en el código no coinciden con los del manifest, el modelo queda deshabilitado en lugar de ejecutarse con una interpretación distinta de sus salidas.

F Evolución técnica del desarrollo

Este anexo reúne la reconstrucción cronológica del desarrollo: cómo el proyecto pasó de una colección de cuadernos de experimentación a un producto distribuido en tres repositorios. Se ubica fuera del cuerpo principal porque describe el proceso y no las capacidades del prototipo, que el Capítulo 11 desarrolla. Su lectura resulta útil para comprender el origen de cada componente y la nomenclatura de los bloques de trabajo empleada en el Capítulo 12.

F.1 Evolución técnica alcanzada

Esta sección reconstruye la evolución técnica del producto desde los primeros desarrollos hasta el estado congelado para la entrega del 50 %. La reconstrucción se apoya en el historial de los tres repositorios del proyecto y en la documentación de checkpoints que cada uno conserva. El criterio expositivo no es cronológico ni cuantitativo: cada etapa se presenta indicando qué limitación resolvía, qué componente la resolvió primero, qué cambio exigió en los repositorios restantes y qué capacidad de producto quedó disponible como resultado.

Antes de recorrer las etapas conviene advertir que la nomenclatura de trabajo no fue uniforme durante todo el desarrollo, y que el documento utiliza tres sistemas de identificación que no deben confundirse entre sí. Esa distinción se detalla en la sección 12.2 y se resume aquí porque condiciona la lectura de toda la sección: las épicas E1 a E10 son unidades académicas derivadas del user research; los identificadores AI-, BE-, DEV-, FE-RD- y FE-P corresponden a backlogs internos de cada repositorio; y los checkpoints P8, P9, P10 y la secuencia P10.5 a P10.9 son bloques coordinados de producto.

F.1.1 Etapa fundacional y separación en tres repositorios

El proyecto no comenzó como un producto distribuido. La primera etapa se concentró en un único repositorio de experimentación, donde el trabajo se organizó como una serie de notebooks numerados que la documentación interna identifica con el prefijo E seguido de un número. Conviene señalar de inmediato que estos hitos E del módulo de IA no guardan relación con las épicas académicas E1 a E10 definidas en el Capítulo 8: son sistemas de numeración independientes que coinciden por casualidad en la letra inicial.

La secuencia experimental avanzó desde la exploración y visualización del dataset y el preprocesamiento y normalización de los volúmenes, hacia un baseline de segmentación sagital que fue sucesivamente diagnosticado, mejorado y validado contra un conjunto de retención. Sobre esa base se abrió un spike axial que exigió inventariar un dataset distinto, resolver el emparejamiento entre imágenes y máscaras, decodificar correctamente las etiquetas y recién entonces entrenar un baseline axial propio. El cierre de esta etapa produjo los dos entrenamientos

finales por plano, el mapeo de clases axiales y un primer pipeline de inferencia multiplanar.

La limitación que cerró esta etapa fue de naturaleza arquitectónica, no algorítmica: los modelos funcionaban dentro de notebooks, pero un notebook no es un producto. Los hitos finales de la serie experimental se dedicaron precisamente a resolver ese pasaje, incorporando un orquestador del agente de IA, una traducción del comportamiento hacia un servicio consumible por backend, un smoke de integración, y sendos andamiajes iniciales de servicio Spring Boot y de interfaz de worklist. Esa constatación motivó la separación en tres repositorios independientes (módulo de IA, backend y frontend), con la responsabilidad de cada capa delimitada por contrato.

La separación habilitó el desarrollo en paralelo, pero introdujo el problema que domina el resto de la evolución: mantener coherentes tres repositorios que avanzan a ritmos distintos.

F.1.2 Backlogs técnicos por repositorio

Tras la separación, y antes de que existiera coordinación formal entre repositorios, cada uno adoptó su propio sistema de identificadores: AI- en el módulo de inteligencia artificial, BE- en el backend, FE- y FE-RD- en el frontend, y DEV- para la contenedorización y la orquestación comunes a los tres. Ese período explica por qué el producto no apareció terminado alrededor de P9: cada repositorio resolvía su propia progresión antes de que existiera un bloque coordinado.

El módulo de IA avanzó desde la inspección de los checkpoints entrenados hacia el endurecimiento de los manifests con verificación de hash, la carga estricta por plano y la corrida multiplanar con identificador común. El backend partió de congelar los tipos del contrato y avanzó hacia la persistencia verificada sobre PostgreSQL con migraciones versionadas. El frontend construyó los tipos del contrato, el espacio de trabajo por caso, la ejecución, el render de superposiciones y el visor sagital y axial con control de opacidad.

Existe además una serie identificada como FE-P1 a FE-P8, correspondiente a una épica de pulido visual del frontend. Su numeración es interna de ese repositorio y no guarda relación con los checkpoints coordinados de producto: FE-P8 designa un documento de control de calidad de la interfaz, mientras que P8 designa el checkpoint de persistencia.

F.1.3 Bloques coordinados de producto

A partir de P8 el desarrollo se organiza en bloques coordinados entre repositorios. Cada bloque parte de una limitación concreta del producto, se resuelve en el componente que puede resolverla y deja disponible una capacidad nueva junto con la dependencia que abre para el bloque siguiente. La Tabla F.1 recorre esa secuencia.

TABLA F.1: Bloques coordinados de producto, de P8 a P10.9.

Bloque	Limitación que resolvía	Resolución	Capacidad resultante	Estado
P8 · Persistencia	El sistema funcionaba pero no recordaba: cerrar el prototipo equivalía a perder el trabajo, y la revisión profesional es por definición diferida.	Backend y frontend, sin participación del módulo de IA. Worklist servida desde la base, persistencia de assets y revisiones, historial por referencia de sujeto. El frontend dejó de completar con valores fabricados los campos ausentes.	Reapertura de un estudio procesado con sus resultados, assets y estado de revisión.	Terminado
P9 · Contrato multiplanar	El acoplamiento entre capas se sostenía en acuerdos implícitos: cada cambio en la salida de la inferencia obligaba a corregir en tres lugares.	El módulo de IA normalizó la segunda versión del contrato; el backend lo validó y canonizó en lugar de retransmitirlo; el frontend consumió una forma única.	Espacio de trabajo multiplanar estable.	Terminado
P10 · Seguridad y trazabilidad	Un error interno podía revelar detalles de implementación y no existía forma de reconstruir qué había ocurrido en una corrida fallida.	Autenticación, activación de cuentas, tratamiento de errores, traza distribuida, sanitización de mensajes, auditoría y observabilidad. Contrapartida de sesión en el frontend.	Fronteras explícitas de seguridad y degradación controlada.	Consolidado

Bloque	Limitación que resolvía	Resolución	Capacidad resultante	Estado
P10.5 · Evolución volumétrica	El producto exponía únicamente el corte analizado, cuando el volumen contiene muchos y un resultado sin contexto de vecindad es difícil de evaluar.	Seis bloques encadenados. P10.5-A definió el contrato navegable y es el único cerrado en los tres repositorios a la vez; P10.5-B a P10.5-F distribuyeron catálogo, serving, visor, vinculación por corte y reapertura.	Navegación por cortes con el resultado vinculado a su corte de origen.	Implementado
P10.6 · Estenosis subarticular	—	Modelo entrenado y evaluado internamente sobre RSNA / LumbarDISC, con checkpoint congelado.	Capacidad no disponible de forma automática: el modelo axial no incluye clase de vértebra y falta la generación de la región de interés que el clasificador requiere.	Bloqueado
P10.7 · Hallazgos por nivel	—	Ocho tipos de hallazgo degenerativo, sujetos a revisión profesional y con estado de despliegue asociado. Las probabilidades internas no se exponen.	Salida asistiva por nivel. Los ocho tipos no tienen el mismo soporte empírico y el flujo real permanece bloqueado por paridad de preprocesamiento.	Implementado, no productivo
P10.8 · Preflight y guardas	—	Cierre del preflight de expansión clínica e incorporación de guardas, sin entrenamiento adicional.	Verificación de factibilidad previa a la ejecución.	Cerrado

Bloque	Limitación que resolvía	Resolución	Capacidad resultante	Estado
P10.9 · Consolidación	—	Congelamiento del backend y del módulo de IA para el traspaso al frontend, con recorrido técnico verificado mediante un runner automatizado.	Frontera contractual común posteriormente integrada en Frontend.	Integrado en Frontend; E2E funcional final 11/11 PASS

P10.5 respondió a una limitación que permanecía después de la integración multiplanar: aunque el sistema podía ejecutar inferencia y presentar resultados sagitales y axiales, la experiencia seguía centrada principalmente en la imagen o el corte asociado al resultado. Una resonancia lumbar, en cambio, está formada por series completas de múltiples cortes que el profesional necesita recorrer para interpretar cada salida dentro de su contexto. El objetivo de P10.5 fue, por lo tanto, evolucionar desde una integración basada en resultados aislados hacia un estudio navegable, preservando de manera explícita la relación entre serie, corte, imagen, resultado y medición.

P10.5-A estableció el contrato volumétrico común entre Frontend, Backend y AI Module. El contrato definió la representación de series y cortes, el número total de imágenes, el índice seleccionado, la disponibilidad de previews y assets, la existencia o ausencia de resultados por corte y los identificadores necesarios para conservar la trazabilidad. Este bloque funcionó como fuente común para los tres repositorios antes de desarrollar las capacidades posteriores.

Sobre esa base, P10.5-B a P10.5-F distribuyeron la implementación entre las capas del producto. El AI Module incorporó el procesamiento full-series y la generación de metadata y assets para los cortes de las series soportadas; el Backend incorporó la persistencia y el serving controlado del catálogo y sus assets; el Frontend desarrolló el visor navegable con selección de serie y corte; y la integración vinculó cada resultado y medición con su imagen de origen. El último bloque verificó además la reapertura de resultados persistidos sin necesidad de repetir la inferencia.

El resultado de P10.5 fue una capacidad de navegación volumétrica que permite recorrer el estudio conservando el contexto de cada salida automática. P10.5-A quedó consolidado como contrato común entre los tres repositorios, mientras que los bloques P10.5-B a P10.5-F fueron implementados y verificados dentro de sus respectivos alcances técnicos. Esto no implica que todas esas capacidades hayan quedado consolidadas simultáneamente sobre una única línea integrada de los tres repositorios. En particular, P10.5-F verificó la persistencia, reapertura y

vinculación de resultados dentro del alcance de ese bloque; esta verificación no equivale al Full Product UI E2E pendiente luego de P10.9. La integración del contrato P10.9 en el Frontend fue completada posteriormente. Esta integración no equivale por sí sola al cierre del Full Product UI E2E: esa evidencia se consolidó posteriormente con el recorrido browser E2E final 11/11 PASS, dentro del alcance funcional demo/producto.

F.1.4 Estado resultante para la entrega del 50 %

El estado del proyecto al cierre de esta versión admite tres categorías que no deben mezclarse. Este estado corresponde específicamente al hito de entrega del 50 % y se conserva aquí como registro histórico; el estado final de la validación profesional y del despliegue Cloud, alcanzado en etapas posteriores del proyecto, se documenta en el Capítulo 13 y en el Capítulo 10 respectivamente.

Hecho. La separación en tres repositorios con responsabilidades delimitadas por contrato; los modelos sagital y axial entrenados, congelados y ejecutables sobre entrada real; el runtime de inferencia con gestión de artefactos verificados por hash; la persistencia de estudios, corridas, assets y revisiones sobre PostgreSQL con migraciones versionadas; la reapertura de estudios ya procesados; la navegación por cortes con el resultado vinculado a su corte de origen; la integración P10.9 en Frontend; la implementación Backend/API/persistencia del dominio Patient; la asociación explícita y auditable de Studies mediante patientId; la persistencia de un flujo visible que todavía usa principalmente subjectRef para historial y longitudinal; y la revisión profesional obligatoria.

Pendiente. La validación profesional sobre el producto integrado, el análisis de negocio, el cierre final de conclusiones y el despliegue Cloud completo. El recorrido funcional Full Product UI E2E ya cuenta con evidencia final.

Bloqueado. La automatización de P10.6, por ausencia de una región de interés axial automática validada. Es un bloqueo de capacidad y no un trabajo pendiente de ejecución: su resolución depende de una etapa de localización anatómica que no está disponible y cuyos sustitutos se descartaron por razones metodológicas.

La tabla siguiente resume la correlación entre repositorios a lo largo de las etapas descritas, indicando en cada caso qué capacidad de producto quedó disponible y qué dependencia la habilitó.

F.2 Evolución del producto visible

La primera versión del proyecto se concentró en demostrar la viabilidad técnica de un flujo sagital: recibir un volumen de resonancia magnética lumbar, seleccionar un corte representativo, ejecutar un modelo de segmentación 2D y presentar una salida visual revisable. Este recorte permitió validar el pipeline mínimo de datos, inferencia y visualización sin incorporar

desde el inicio todas las funciones de una plataforma. Las capacidades que se describen en el resto del capítulo no provienen de un único checkpoint: se acumularon a lo largo de la evolución reconstruida en este anexo, que separa responsabilidades entre repositorios, incorpora el plano axial, consolida la persistencia, normaliza el contrato multiplanar, endurece seguridad y trazabilidad, y evoluciona hacia la navegación volumétrica antes de llegar al tramo P10.6 a P10.9.

El user research modificó ese alcance inicial. Los profesionales entrevistados señalaron que la revisión de una RM lumbar no se limita a un único plano y que los cortes axiales aportan información relevante para la lateralidad, la relación con raíces y la correlación de hallazgos. A partir de esa evidencia se incorporó un segundo módulo de inferencia axial y se reorganizó la interfaz alrededor de una corrida multiplanar.

La evolución del producto puede resumirse en los siguientes hitos:

- MVP sagital con inferencia y salida visual básica.
- Incorporación del Backend como orquestador y punto único de acceso.
- Separación del AI Module como servicio de inferencia independiente.
- Persistencia de usuarios, estudios, corridas, resultados y revisiones.
- Incorporación del modelo axial y coordinación sagital–axial.
- Reapertura de resultados sin repetir la inferencia.
- Autenticación, roles y autorización por recurso.
- Workspace multiplanar con overlays, mediciones y revisión profesional.
- Definición del contrato volumétrico P10.5-A.
- Ingesta de estudio DICOM completo y procesamiento full-series (Backend + AI Module), línea de hallazgos degenerativos por nivel (P10.7) bloqueada para inferencia automática real, visor navegable e integración P10.9 en Frontend, seguida por el dominio Patient parcial y la asociación Study–Patient validada en Backend; el cierre funcional Full Product UI E2E fue completado.

En una etapa posterior se incorporó Patient como entidad de-identificada explícita en Backend, con id interno UUID y patientReference como referencia seudónima de trabajo. Los Studies pueden asociarse mediante patientId y esa relación se persiste. Sin embargo, el Frontend final conserva historial y longitudinal principalmente mediante subjectRef; por eso el dominio Patient queda como implementación parcial y no como gestión browser-level completa.

La incorporación axial no reemplaza el modelo sagital ni implica que ambos modelos segmenten las mismas clases. Cada plano conserva su dataset, preprocesamiento, artifact, clases de salida y criterios de validación. El prototipo integra los resultados en una experiencia común, pero no fusiona artificialmente modelos incompatibles.

F.3 Evolución del pipeline de inferencia

El desarrollo se organizó en dos ciclos complementarios que, vistos desde este componente, recorren la cadena experimentación en notebooks, backlog técnico propio con prefijo AI-, runtime real, normalización del contrato en P9, endurecimiento en P10, evolución volumétrica en P10.5 y extensión en el tramo P10.6 a P10.9; la correlación con los demás repositorios se desarrolla en este anexo y no se repite aquí. El primero resolvió incertidumbres sobre datasets, máscaras, taxonomías, orientación, preprocesamiento y entrenamiento. El segundo convirtió ese conocimiento en un producto integrado y, en el tramo P10.6–P10.9, incorporó una línea de hallazgos degenerativos asistivos por nivel (P10.7) a partir de Sagital T1 y Sagital T2 independientes, un modelo de estenosis subarticular en Axial T2 evaluado internamente pero aún sin ROI automática (P10.6), el cierre de preflight y guardas sin entrenamiento adicional (P10.8) y la consolidación y congelamiento del componente para el traspaso al Frontend (P10.9).

TABLA F.2: Evolución de la implementación del pipeline de IA.

Etapas	Resultado de implementación	Evidencia principal	Estado al 50 %
Exploración y preparación	Comprensión de formatos, máscaras, clases y orientación de los datasets.	Notebooks, inventarios, figuras de control y decisiones de pairing.	Consolidado experimentalmente.
Entrenamiento y consolidación	Modelos 2D multiclase diferenciados por plano.	Checkpoints E5, E10 y E12; métricas por clase.	Consolidado experimentalmente.
Registro final	Nombres estables, modelKey, manifests y artifacts finales identificados.	Directorio models/final y notebook de registro final.	Consolidado.
Productización	Lógica experimental trasladada a módulos reutilizables del servicio.	Registry, materializador, arquitecturas, runtime y API FastAPI.	Implementado.
Ejecución real	Carga de state_dict, model.eval(), torch.inference_mode() y generación de outputs.	Runtime PyTorch y pruebas automatizadas.	Implementado; evidencia final se consolida en el Capítulo 13.
Orquestación multiplanar	Corridas sagital y axial coordinadas bajo un contexto común.	run_multiplanar_pipeline y endpoint multiplanar.	Implementado.

Etap	Resultado de implementación	Evidencia principal	Estado al 50 %
Evolución volumétrica	Catálogo de series, serving de cortes y procesamiento full-series integrados en Backend, AI Module y visor.	P10.5-A y fixtures compartidos.	Implementado (full-series).

F.4 Organización interna del módulo de inteligencia artificial

El módulo de inteligencia artificial agrupa responsabilidades que no corresponden al backend de producto, de modo que el código de inferencia pueda probarse sin depender de la interfaz y que la identidad del modelo no quede implícita en rutas o convenciones manuales. Un registro de modelos resuelve la clave, la versión, las clases y la dimensión de entrada de cada artifact; un materializador lo descarga desde el almacenamiento externo mediante archivo temporal y reemplazo atómico, de modo que nunca queda un artifact parcial; el runtime resuelve el dispositivo, carga y mantiene en caché los modelos y ejecuta la inferencia; un orquestador agrupa ambos planos bajo identificadores comunes sin fusionar sus taxonomías; y una capa de servicio expone los accesos que el backend consume.

La reconstrucción de las arquitecturas se realiza con carga estricta: si los nombres de capa del artifact no coinciden con los de la arquitectura declarada, la carga falla de forma explícita en lugar de completar los pesos faltantes con valores iniciales. Cada artifact conserva un manifest con sus clases, su configuración, sus métricas y su resumen criptográfico, y el sistema verifica esa correspondencia antes de habilitar el modelo.

La condición de disponibilidad se comprueba antes de aceptar una solicitud: deben existir el artifact local completo, un manifest coherente y una arquitectura compatible. Si alguna de las tres falta, el servicio lo informa como estado de indisponibilidad y no como resultado de análisis.

F.5 Cierre tecnico final y fuente canonica

El cierre técnico posterior a la entrega del 50 % siguió una secuencia trazable: post-E50, extensiones de producto, integración integration/final-2026, reconciliación del Backend y congelamiento en main. La fuente técnica canónica final quedó documentada en el repositorio Backend como docs/final/FINAL_PRODUCT_TECHNICAL_SOURCE_OF_TRUTH.md.

Los SHAs finales usados como base documental son: Backend 33081f7cc3702afe4db04a2b63de4762 Frontend ff191e1195a4e6bf06312ae8e266d37894c5b7b1 y AI Module 22b12e04ce37f5c9ba6a02f356a. En el caso del Backend, ese SHA corresponde a un commit documental sobre el merge funcional previo: distingue la fuente de verdad escrita del estado funcional ya reconciliado.

El estado final no se deriva de un único repositorio. Backend aporta seguridad, persistencia, Patient API, reportes, PDF/JSON, Cloud Run DEV y orquestación; Frontend aporta el flujo

visible, historial basado en subjectRef, review panels, longitudinal, Grad-CAM wiring y Playwright final 11/11; AI aporta modelos, runtime, Demo Mode, product-analysis, 67B2/67C/P10.7 con sus gates y limitaciones. Esta separación evita degradar o inflar una capacidad por mirar solo una capa.

G Registro de decisiones arquitectónicas

Este anexo documenta las principales decisiones de arquitectura adoptadas durante el desarrollo del prototipo mediante Architecture Decision Records (ADR). El objetivo es conservar, además de la decisión final, el contexto que la motivó, las alternativas consideradas y sus principales consecuencias. Los ADR describen decisiones técnicas del prototipo y pueden revisarse si cambian sus requerimientos o condiciones de despliegue.

ADR-001 — Separación de Frontend, Backend y AI Module

Estado: aceptado.

Contexto. La solución combina una interfaz interactiva, funciones de autenticación y persistencia, y un runtime de procesamiento de imágenes e inteligencia artificial. Estos componentes presentan responsabilidades, dependencias y ciclos de evolución diferentes.

Decisión. Mantener Frontend, Backend y AI Module como componentes diferenciados y alojados en repositorios independientes. Cada componente conserva sus propias dependencias, configuración y pruebas, y la integración se realiza mediante contratos explícitos.

Alternativas consideradas. Unificar el sistema en un único servicio o repositorio; integrar el runtime de IA directamente en el Backend.

Consecuencias. La separación permite modificar modelos o componentes de interfaz sin incorporar sus dependencias al resto del sistema y facilita pruebas y despliegues independientes. Como contrapartida, exige mantener contratos compatibles y coordinar cambios entre repositorios.

ADR-002 — Spring Boot para el Backend y Python/FastAPI para el AI Module

Estado: aceptado.

Contexto. El Backend concentra responsabilidades de producto —autenticación, autorización, persistencia, auditoría, reglas de negocio y exposición de contratos— mientras que el módulo de IA depende del ecosistema utilizado para procesamiento de imágenes, entrenamiento e inferencia.

Decisión. Utilizar Spring Boot y Java para el Backend de producto, y Python con FastAPI para el AI Module.

Alternativas consideradas. Implementar ambos servicios con Python y FastAPI; ejecutar también la inferencia desde Java.

Consecuencias. Cada componente utiliza un stack alineado con sus responsabilidades y dependencias. PyTorch y SimpleITK permanecen aislados en el servicio de IA, mientras las funciones de producto se mantienen independientes del runtime científico. La principal

contrapartida es mantener dos stacks tecnológicos y su integración HTTP.

ADR-003 — Backend como única frontera pública hacia el AI Module

Estado: aceptado.

Contexto. Los resultados de inferencia contienen información técnica y referencias internas que no necesariamente deben exponerse al cliente web. Además, las operaciones sobre estudios y resultados requieren autenticación, autorización, persistencia y trazabilidad.

Decisión. El Frontend se comunica con el Backend y no consume directamente el AI Module. El Backend autentica y autoriza las operaciones, orquesta las llamadas al servicio de IA, persiste los resultados y expone al Frontend únicamente el contrato público correspondiente.

Alternativas consideradas. Permitir que el Frontend consuma directamente los endpoints del AI Module.

Consecuencias. Se mantiene una única frontera de seguridad y un contrato público controlado, y el runtime de IA puede evolucionar sin convertirse en una dependencia directa de la interfaz. Como contrapartida, el Backend incorpora responsabilidades adicionales de orquestación y existe un salto de comunicación adicional.

ADR-004 — PostgreSQL para persistencia transaccional

Estado: aceptado.

Contexto. El producto debe conservar relaciones entre usuarios, roles, sujetos de-identificados, estudios, corridas, modelos, mediciones, revisiones, assets y eventos de auditoría.

Decisión. Utilizar PostgreSQL como base de datos transaccional del sistema.

Alternativas consideradas. Persistencia basada únicamente en archivos, almacenamiento en memoria o una base de datos no relacional como mecanismo principal.

Consecuencias. El modelo relacional permite aplicar restricciones de integridad y mantener relaciones consistentes entre las entidades del flujo. Como contrapartida, requiere gestionar el esquema, sus migraciones y la disponibilidad de la instancia de base de datos.

ADR-005 — PyTorch como runtime de inferencia y ONNX Runtime diferido

Estado: aceptado para PyTorch; ONNX Runtime diferido.

Contexto. Los modelos utilizados por el prototipo fueron entrenados, evaluados y registrados mediante PyTorch, y los checkpoints actuales dependen de dicho runtime.

Decisión. Mantener PyTorch como runtime de inferencia durante esta etapa. Una eventual migración a ONNX Runtime deberá realizarse únicamente después de verificar la equivalencia de las salidas de los modelos convertidos.

Alternativas consideradas. Migrar inmediatamente los modelos a ONNX Runtime o reconstruir la inferencia utilizando otro ecosistema.

Consecuencias. Se evita introducir una conversión adicional sobre modelos ya evaluados y se conserva la reproducibilidad entre entrenamiento e inferencia. Como contrapartida, el despliegue mantiene las dependencias y requerimientos de recursos propios de PyTorch.

ADR-006 — Separación entre código fuente y artifacts de datos y modelos

Estado: aceptado.

Contexto. Los checkpoints, datasets, volúmenes y demás artifacts poseen tamaños y ciclos de vida distintos de los del código fuente y requieren controles específicos de acceso, integridad y versionado.

Decisión. Mantener el código y la configuración versionable en los repositorios del proyecto, y almacenar modelos, datasets y artifacts de mayor tamaño en almacenamiento externo controlado. Los modelos se identifican mediante manifests, versiones y hashes verificables.

Alternativas consideradas. Incorporar directamente los archivos de modelos y datasets dentro de los repositorios o depender exclusivamente del filesystem local de cada servicio.

Consecuencias. Los repositorios permanecen manejables y los artifacts pueden evolucionar de forma independiente, conservando mecanismos explícitos de trazabilidad. Como contrapartida, la ejecución requiere gestionar disponibilidad, permisos e integridad del almacenamiento externo.

ADR-007 — Google Cloud como arquitectura objetivo de despliegue

Estado: aceptado; implementación DEV realizada y validada. El entorno DEMO separado y el monitoreo/alerting productivo en vivo continúan sin desplegarse.

Contexto. El prototipo requiere una arquitectura que permita desplegar componentes separados, almacenar artifacts de forma durable, disponer de una base PostgreSQL y controlar el consumo de recursos sin asumir inicialmente una infraestructura de alta disponibilidad propia de un entorno clínico productivo. La plataforma se planteó inicialmente como arquitectura objetivo y fue luego implementada y validada de forma progresiva.

Decisión. Utilizar Google Cloud como plataforma de despliegue, manteniendo servicios diferenciados para Frontend, Backend y AI Module, una instancia administrada de PostgreSQL, almacenamiento privado para modelos y assets, registro de contenedores y gestión externa de secretos. Al cierre técnico se validaron de punta a punta Artifact Registry/WIF, Backend Cloud Run DEV (legacy y Green), Frontend Cloud Run DEV, AI Cloud Run privado, Cloud SQL, Secret Manager y el storage durable, según el detalle del Capítulo 10 (Estado real del despliegue Cloud) y la evidencia técnica del Capítulo 13. El entorno DEMO separado y el monitoreo/alerting en vivo permanecen no desplegados.

Alternativas consideradas. Mantener el sistema exclusivamente en ejecución local, administrar infraestructura propia o trasladar la misma arquitectura a otro proveedor de nube.

Consecuencias. La plataforma permite utilizar servicios administrados y ajustar los recursos por componente, evitando incorporar inicialmente infraestructura que no esté justificada para el prototipo. Como contrapartida, introduce configuración específica de nube, necesidad de controlar costos y dependencia de los servicios seleccionados. El despliegue DEV validado cubre el alcance técnico definido para esta entrega; el entorno DEMO separado y el monitoreo/alerting productivo en vivo permanecen fuera del estado implementado.

ADR-008 — Inferencia fail-closed y revision profesional obligatoria

Estado: aceptado.

Contexto. Algunas capacidades de IA poseen checkpoints, metricas offline o contratos implementados, pero no cuentan con paridad runtime o preprocesamiento validado para uso automatico real.

Decisión. Mantener un comportamiento fail-closed: si un modelo o etapa no puede demostrar artifact, manifest, preprocesamiento y paridad runtime, el sistema debe abstenerse, bloquear o declarar estado parcial en lugar de fabricar una salida. Toda salida asistiva permanece sujeta a revision profesional obligatoria.

Consecuencias. Esta decision reduce el riesgo de sobreinterpretar resultados experimentales. Como contrapartida, algunas capacidades quedan visibles como bloqueadas o experimentales aunque existan componentes tecnicos parciales.

ADR-009 — Demo Mode deterministico y no clinico

Estado: aceptado.

Contexto. El producto necesita un recorrido reproducible para testing, defensa academica y validacion funcional, pero la localizacion anatomica real permanece bloqueada por falta de paridad runtime.

Decisión. Incorporar Demo Mode con fixtures deterministicos, cuatro studies y dos subjects, `source=DEMO_FIXTURE`, `validated=false` y advertencias explicitas de no inferencia real.

Consecuencias. Demo Mode permite Playwright E2E y demostracion completa de producto sin afirmar inferencia clinica. No debe usarse como evidencia de validacion clinica ni como reemplazo de datos reales.

ADR-010 — Integracion parcial del dominio Patient

Estado: aceptado como estado actual.

Contexto. Backend implementa Patient, `/api/patients`, `Study.patientId` y persistencia Patient–Study. El Frontend final conserva historial y longitudinal basados principalmente en `subjectRef`.

Decisión. Documentar Patient como dominio implementado parcialmente y evitar describirlo como gestion integral de pacientes end-to-end en browser.

Consecuencias. La tesis mantiene una afirmacion fiel al producto real: hay base Backend para evolucionar hacia Patient completo, pero el flujo visible actual no consume plenamente ese dominio.

ADR-011 — No aprendizaje automatico desde correcciones profesionales

Estado: aceptado.

Contexto. El sistema registra revisiones, correcciones y candidatos de curacion profesional.

Decisión. No utilizar esas correcciones para reentrenamiento automatico ni aprendizaje online. La curacion alimenta una linea futura controlada, no un bucle activo de actualizacion de modelos.

Consecuencias. Se preserva reproducibilidad, trazabilidad y control de calidad de artifacts. Cualquier entrenamiento posterior requerira dataset, versionado y validacion explicitos.

H Validación profesional cualitativa

Este anexo amplía la evidencia sintetizada en la sección 13.11 del Capítulo 13. El cuerpo del Capítulo 13 presenta la síntesis; este anexo conserva el detalle de cada sesión, la trazabilidad hacia decisiones de producto y las limitaciones que acotan su alcance.

H.1 Propósito y alcance

Este trabajo distingue tres instancias de validación que no deben mezclarse entre sí:

- **User research inicial (EN-01 a EN-05).** Entrevistas exploratorias documentadas en el Anexo D y en el Capítulo 8. Su objetivo fue descubrir necesidades y ajustar el alcance del prototipo antes de su desarrollo.
- **Validación profesional cualitativa (VP-01 y VP-02).** Las dos sesiones documentadas en este anexo. Su objetivo fue revisar una versión funcional/intermedia del producto ya construido, observando utilidad, flujo, comprensión, riesgos, confianza y prioridades de mejora.
- **Validación cruzada profesional final.** Todavía pendiente. Su objetivo futuro es que profesionales y el sistema analicen de forma independiente los mismos estudios, para luego revisar y documentar las discrepancias entre ambas lecturas (sección H.8).

Se utiliza la identificación VP-01 y VP-02 para las sesiones de este anexo, reservando la numeración EN- para las entrevistas exploratorias iniciales y evitando así que ambas instancias se confundan en la trazabilidad del proyecto.

Ninguna de las tres instancias, ni individual ni en conjunto, constituye validación clínica, validación diagnóstica, ensayo clínico, comparación contra ground truth ni evaluación de eficacia clínica.

H.2 Metodología de las sesiones

Las sesiones VP-01 y VP-02 se organizaron como observación y comentario guiado de una versión funcional/intermedia del producto, utilizando como marco de referencia los criterios ya empleados en el proyecto para este tipo de instancia:

- plausibilidad y claridad de la asistencia visual (overlays y máscaras);
- utilidad percibida de las mediciones ofrecidas;
- comprensión del flujo de trabajo propuesto;
- confianza en los resultados y fuentes concretas de desconfianza;
- posibilidad de corregir manualmente cada resultado;

- riesgo de sobreconfianza en la asistencia automática;
- funcionalidades consideradas indispensables por la profesional;
- utilidad general del producto como herramienta asistiva, no diagnóstica.

El material del proyecto incluye además una plantilla de referencia, PF033_professional_validation_template.md, organizada en torno a los ejes de comprensión, utilidad, confianza, riesgo, flujo, primera versión y valor general. Esos ejes se retoman aquí como marco metodológico y de observación para estructurar las fichas de las secciones H.3 y H.4. No se afirma que cada profesional haya respondido literalmente cada uno de esos puntos ni que haya asignado puntuaciones numéricas: no existe evidencia documental de una escala de puntuación aplicada en estas sesiones, por lo que las fichas se presentan en formato narrativo y cualitativo, sin inventar valores cuantitativos, fechas, duración, matrícula, especialidad, institución ni citas textuales que no consten en la evidencia disponible.

H.3 VP-01 — Sesión con la Dra. Susana Torres

Profesional

Dra. Susana Torres.

Contexto

Sesión posterior a las entrevistas exploratorias iniciales (EN-01 a EN-05), metodológicamente distinta de ellas. La profesional observó y comentó una versión funcional/intermedia del prototipo, con foco en utilidad, flujo de revisión, visualización, confianza y priorización de mejoras.

Funciones mostradas o discutidas

Segmentación como apoyo visual, overlays o máscaras sobre la imagen, posibilidad de apagar máscaras, corrección manual de mediciones, comparación longitudinal, correlación sagital–axial, revisión de múltiples cortes y salida revisable por el profesional.

Hallazgos documentados

- Interés en la comparación con resonancias previas y valor del historial longitudinal para observar la evolución de cambios degenerativos.
- La segmentación fue valorada como apoyo visual revisable, con preferencia por revisar primero la imagen sin asistencia y poder activarla después, para evitar sesgo en la lectura inicial.
- Posibilidad de apagar máscaras, corrección manual de mediciones y colores consistentes entre estructuras.

- Necesidad de evitar superposiciones que generen confusión visual.
- Relevancia del diámetro anteroposterior y transversal del saco o canal, y diferenciación de los neuroforámenes como entidad propia.
- Grasa alrededor de raíces y utilidad del producto para valorar estenosis.
- Importancia de revisar múltiples cortes en lugar de limitarse al corte central.
- Cambios degenerativos, hipertrofia del ligamento amarillo mencionada como posible extensión futura, y cambios Modic.
- Pérdida de altura discal.
- Correlación sagital–axial y respeto de la inclinación del disco en dicha correlación.
- Revisión profesional obligatoria como condición para confiar en el sistema.

Las sugerencias vinculadas a capacidades no implementadas (por ejemplo, hipertrofia del ligamento amarillo) se consignan como futuras y no deben interpretarse como funciones ya disponibles en el producto.

Problemas detectados

Riesgo de sesgo si la máscara aparece antes de la lectura profesional; riesgo de confusión visual ante superposición excesiva; necesidad de evitar que la asistencia se interprete como diagnóstico; necesidad de no reducir la revisión a un único corte central.

Valoración general

Favorable hacia un sistema de asistencia visual y documental, siempre que el profesional conserve la lectura, la corrección y la decisión final.

Limitaciones de esta sesión

Sesión cualitativa, con una sola profesional, sobre una versión intermedia del producto. No incluye comparación contra lectura independiente, ground truth, sensibilidad ni especificidad, y no constituye validación clínica.

H.4 VP-02 — Sesión con la Dra. Claudia Cejas

Profesional

Dra. Claudia Cejas.

Contexto

Sesión posterior a las entrevistas exploratorias iniciales (EN-01 a EN-05), orientada a evaluar utilidad y priorización funcional de una versión funcional/intermedia del prototipo.

Funciones mostradas o discutidas

Identificación de nivel o contador, segmentación visual, corrección manual de mediciones, medición del canal, revisión de múltiples cortes, detección asistida de protrusiones focales o laterales, distinción entre canal central, canal lateral y neuroforamen, comparación longitudinal e informe estructurado editable.

Hallazgos documentados

- Utilidad del contador o identificación de nivel como apoyo práctico, y de la segmentación visual en general.
- Corrección manual de mediciones y prioridad del diámetro del canal.
- Recomendación de medir perpendicular al eje del canal.
- Necesidad de verificar bibliográficamente cualquier número o rango mencionado verbalmente antes de convertirlo en umbral del sistema.
- Importancia del neuroforamen, la estenosis foraminal y el receso subarticular o canal lateral.
- Necesidad de distinguir explícitamente canal central, canal lateral y neuroforamen.
- Revisión de múltiples cortes y detección de protrusiones focales o laterales.
- Cambios Modic, degeneración discal y pérdida de altura.
- Asociación entre el uso de colores/asistencia visual y la reducción de omisiones en contextos de carga laboral y fatiga.
- Cierta sobredetección considerada tolerable si el profesional conserva la posibilidad de revisar, corregir o descartar.
- Preferencia por detección y asistencia antes que diagnóstico automático.
- Utilidad potencial de la comparación longitudinal y valor de un informe estructurado editable.

Problemas detectados

Riesgo de omisión de patología relevante; necesidad de revisar más de un corte; riesgo de convertir rangos mencionados verbalmente en umbrales sin respaldo bibliográfico; necesidad de mantener al profesional dentro del circuito de decisión.

Valoración general

Favorable hacia una herramienta asistiva que reduzca omisiones y ordene el reporte, especialmente en contextos de carga laboral, siempre que no reemplace al profesional.

Limitaciones de esta sesión

Sesión cualitativa, con una sola profesional, sobre una versión intermedia del producto. No constituye prueba clínica, comparación contra ground truth ni evaluación de sensibilidad o especificidad.

H.5 Síntesis transversal de hallazgos

Usabilidad

Las dos sesiones respaldan overlays útiles, máscaras activables o desactivables, edición manual, precisión visual y colores consistentes. El prototipo debe evitar superposiciones confusas y permitir que el profesional controle la asistencia visual.

Valor clínico-operativo

Ambas profesionales valoraron la detección asistida, la reducción de omisiones, el apoyo ante carga laboral, el seguimiento longitudinal y la correlación sagital–axial. Esa valoración se interpreta como utilidad potencial de producto, no como validación clínica.

Mediciones prioritarias

Se priorizan canal central, neuroforamen, receso lateral o subarticular y altura discal. Otras mediciones deben incorporarse solo si aportan valor real y pueden verificarse técnica o bibliográficamente.

Hallazgos relevantes

Aparecen protrusión o herniación, estenosis, pérdida de altura, cambios degenerativos o Modic, forámenes y raíces. Algunos se encuentran fuera del producto validado y quedan como futuras líneas de trabajo.

Confianza y revisión humana

La confianza depende de la revisión profesional obligatoria, la posibilidad de corregir, la transparencia sobre el estado de la IA y la ausencia de diagnóstico autónomo. Mostrar confianza puede ser útil cuando corresponda, pero no debe sustituir la revisión.

Diferencia de énfasis entre sesiones

La Dra. Torres profundizó en comparación longitudinal, control visual de máscaras, correlación sagital–axial e inclinación discal. La Dra. Cejas enfatizó la protocolización de mediciones, la distinción entre canal central, canal lateral y neuroforamen, la carga laboral y la aceptabilidad de cierta sobredetección bajo revisión profesional.

H.6 Trazabilidad entre observaciones y decisiones de producto

La Tabla H.1 retoma la trazabilidad ya presentada en la Tabla 13.7 del Capítulo 13, entre cada observación profesional y la decisión de producto que motivó, junto con su estado actual. Los estados posibles son IMPLEMENTED, PARTIAL, PLANNED y OUT_OF_SCOPE; ningún estado se promueve sin evidencia técnica que lo respalde.

TABLA H.1: Trazabilidad entre observaciones profesionales y decisiones de producto.

Observación profesional	Profesional	Decisión de producto	Estado actual
Activar/desactivar máscaras y evitar confusión visual	Torres	Mantener overlays revisables y controles de visibilidad por estructura.	PARTIAL: overlays implementados; controles finos por estructura quedan como mejora de interfaz.
Corrección manual de mediciones	Torres/Cejas	Permitir que el profesional corrija valores y conserve trazabilidad.	IMPLEMENTED: mediciones editables y revisión profesional implementadas.
Evidencia visual verificable	Torres/Cejas	Mostrar máscaras, assets y regiones de evidencia asociadas al resultado.	IMPLEMENTED: overlays y evidencia visual servidos por Backend; limitados por registro AI efímero.
Comparación con estudios previos	Torres/Cejas	Mantener historial y comparación longitudinal descriptiva.	PARTIAL: implementado en Demo Mode/subjectRef; no es evaluación clínica de progresión.
Correlación sagital-axial y múltiples cortes	Torres/Cejas	Priorizar visor volumétrico, revisión por corte y no solo corte central.	PARTIAL: visor y catálogo full-series implementados; pairing sagital-axial 67C sigue experimental.
Medición de neuroforamen	Torres/Cejas	Registrar como medición prioritaria futura si se valida técnica y bibliográficamente.	PLANNED: no debe presentarse como medición productiva validada.
Receso lateral/subarticular	Cejas	Mantener línea subarticular como capacidad asistiva bajo gates.	PARTIAL: clasificador subarticular existe, pero P10.7/product path sigue bloqueado.
Transparencia Demo/IA y revisión humana	Torres/Cejas	Declarar modo demo/no clínico y mantener revisión obligatoria.	PARTIAL: flags técnicos existen; indicador persistente de Demo Mode en UI queda pendiente.
Informe estructurado editable	Cejas	Generar salida estructurada revisable y exportable.	IMPLEMENTED: reporte pfi.study-report.v1, PDF/JSON y revisión profesional.
Mostrar confianza cuando corresponda	Cejas	Comunicar confianza/estado solo cuando el modelo lo respalde.	PARTIAL: existen estados y gates; visualización sistemática de confianza queda pendiente.
Cambios Modic	Torres/Cejas	Documentar como hallazgo relevante, sin exponerlo productivamente sin validación.	PLANNED: P10.7 contiene tarea relacionada pero no está habilitada productivamente.
Hipertrofia del ligamento amarillo	Torres	Registrar como posible extensión futura.	PLANNED: no implementado en producto.

Observación profesional	Profesional	Decisión de producto	Estado actual
Diagnóstico automático	Torres/Cejas	Mantener enfoque asistivo, no diagnóstico.	OUT_OF_SCOPE: el sistema no diagnostica ni recomienda tratamiento.

H.7 Limitaciones de esta instancia

- La muestra es de solo dos profesionales.
- La selección de profesionales fue intencional, no probabilística.
- La evaluación es cualitativa y se informa narrativamente, no mediante puntuaciones ni porcentajes.
- Ambas sesiones observaron una versión funcional/intermedia del producto, no la versión final consolidada.
- No se midió sensibilidad ni especificidad diagnóstica.
- No se comparó contra ground truth ni contra lectura profesional independiente sobre los mismos estudios.
- No se evaluó eficacia clínica.
- Los hallazgos no permiten generalizar a la totalidad de los profesionales potencialmente usuarios del producto.
- Algunas funcionalidades discutidas (por ejemplo, neuroforamen productivo, hipertrofia del ligamento amarillo) son parciales o futuras y no deben presentarse como implementadas por el solo hecho de haber sido propuestas o discutidas.

H.8 Validación cruzada profesional final pendiente

La validación cruzada profesional final continúa pendiente. El protocolo previsto para esa instancia futura consiste en:

1. Seleccionar un mismo conjunto de estudios.
2. Entregar esos estudios a profesionales para una lectura independiente, sin asistencia del sistema.
3. Ejecutar los mismos estudios en el sistema.
4. Registrar hallazgos y mediciones de ambos lados de forma separada.
5. Comparar los resultados y documentar las discrepancias.
6. Realizar una revisión posterior conjunta de esas discrepancias.
7. Clasificar cada discrepancia según corresponda: coincidencia, omisión, sobredetección o diferencia de medición.

Esta instancia no ha sido ejecutada al cierre de la presente versión, por lo que no se presentan resultados ni métricas de esa validación cruzada.

Referencias

1. GRAAF, Jasper W. van der; HOOFF, Miranda L. van; BUCKENS, Constantinus F. M.; RUTTEN, Matthieu; SUSANTE, Job L. C. van; KROEZE, Robert Jan; KLEUVER, Marinus de; GINNEKEN, Bram van y LESSMANN, Nikolas. Lumbar spine segmentation in MR images: a dataset and a public benchmark. *Scientific Data* [En línea]. 2024, vol. 11, n.º 264 [consultado 2026-06-05]. Disponible en: DOI: 10.1038/s41597-024-03090-w.
2. RICHARDS, Tyler J.; FLANDERS, Adam E.; COLAK, Errol; PREVEDELLO, Luciano M.; BALL, Robyn L.; KITAMURA, Felipe; MONGAN, John; VAZIRABAD, Maryam; LIN, Hui-Ming; KENDELL, Anne; KANTHAWANG, Thanat; ANGKURAWARANON, Salita; ALTINMAKAS, Emre; DOGAN, Hakan; AGUIAR KURIKI, Paulo Eduardo de; SOMASUNDARAM, Arjuna; RUSTON, Christopher; BULJA, Deniz; SPAHOVIC, Naida; SOMMER, Jennifer; JIANG, Sirui; FARINA, Eduardo Moreno Judice de Mattos; NUNES, Eduardo Caminha; BRASSIL, Michael; MCNAMARA, Megan; ORTIZ, Johanna; PEOPLES, Jacob; UYTANA, Vinson L.; KAM, Anthony; DOLA, Venkata N. S.; MURPHY, Daniel; VU, David y TALBOTT, Jason F. The RSNA Lumbar Degenerative Imaging Spine Classification (LumbarDISC) Dataset. *Radiology: Artificial Intelligence*. 2026, vol. 8, n.º 2. Disponible en: DOI: 10.1148/ryai.250480.
3. AL-KAFRI, Ala S.; SUDIRMAN, Sud; HUSSAIN, Abir; AL-JUMEILY, Dhiya; NATALIA, Friska; MEIDIA, Hira; AFRILIANA, Nunik; AL-RASHDAN, Wasfi; BASH-TAWI, Mohammad y AL-JUMAILY, Mohammed. Boundary Delineation of MRI Images for Lumbar Spinal Stenosis Detection Through Semantic Segmentation Using Deep Neural Networks. *IEEE Access*. 2019, vol. 7, págs. 43487-43501. Disponible en: DOI: 10.1109/ACCESS.2019.2908002.
4. ISENSEE, Fabian; JAEGER, Paul F.; KOHL, Simon A. A.; PETERSEN, Jens y MAIERHEIN, Klaus H. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*. 2021, vol. 18, págs. 203-211. Disponible en: DOI: 10.1038/s41592-020-01008-z.
5. MÖLLER, Hendrik; GRAF, Robert; SCHMITT, Joachim; KEINERT, Benjamin; ATAD, Matan; SEKUBOYINA, Anjany; STRECKENBACH, Felix; SCHÖN, Hanna; KOFLER, Florian; KRÖNCKE, Thomas; BETTE, Stefanie; WILLICH, Stefan; KEIL, Thomas; NIEN-DORF, Thoralf; PISCHON, Tobias; ENDEMANN, Beate; MENZE, Björn; RUECKERT, Daniel y KIRSCHKE, Jan S. SPINEPS: Automatic Whole Spine Segmentation of T2-weighted MR images using a Two-Phase Approach to Multi-class Semantic and Instance

- Segmentation. *European Radiology*. 2025, vol. 35, págs. 1178-1189. Disponible en: DOI: 10.1007/s00330-024-11155-y.
6. JAMALUDIN, Amir; KADIR, Timor y ZISSERMAN, Andrew. SpineNet: Automated classification and evidence visualization in spinal MRIs. *Medical Image Analysis*. 2017, vol. 41, págs. 63-73. Disponible en: DOI: 10.1016/j.media.2017.07.002.
7. WINDSOR, Rhydian; JAMALUDIN, Amir; KADIR, Timor y ZISSERMAN, Andrew. Automated detection, labelling and radiological grading of clinical spinal MRIs. *Scientific Reports*. 2024, vol. 14. Disponible en: DOI: 10.1038/s41598-024-64580-w.
8. NATALIA, Friska; MEIDIA, Hira; AFRILIANA, Nunik; AL-KAFRI, Ala S.; SUDIRMAN, Sud; SIMPSON, Andrew; SOPHIAN, Ali; AL-JUMAILY, Mohammed; AL-RASHDAN, Wasfi y BASHTAWI, Mohammad. Automated measurement of anteroposterior diameter and foraminal widths in MRI images for lumbar spinal stenosis diagnosis. *PLOS ONE*. 2020, vol. 15, n.º 11. Disponible en: DOI: 10.1371/journal.pone.0241309.
9. PERUMAL, Sundara Raja *et al.* Automated deep learning pipeline for measuring lumbar thecal sac AP diameter on mid-sagittal MR images. *BMC Medical Imaging*. 2026, vol. 26, n.º 134. Disponible en: DOI: 10.1186/s12880-026-02220-7.
10. U.S. FOOD AND DRUG ADMINISTRATION. *CoLumbo, 510(k) Premarket Notification K220497* [En línea]. 2022. [consultado 2026-06-05]. Disponible en: https://www.accessdata.fda.gov/cdrh_docs/pdf22/K220497.pdf.
11. U.S. FOOD AND DRUG ADMINISTRATION. *MSKai, 510(k) Premarket Notification K240793* [En línea]. 2024. [consultado 2026-06-05]. Disponible en: https://www.accessdata.fda.gov/cdrh_docs/pdf24/K240793.pdf.
12. U.S. FOOD AND DRUG ADMINISTRATION. *RemedyLogic AI MRI Lumbar Spine Reader, 510(k) Premarket Notification K241108* [En línea]. 2024. [consultado 2026-06-05]. Disponible en: https://www.accessdata.fda.gov/cdrh_docs/pdf24/K241108.pdf.
13. DALE, Brian M.; BROWN, Mark A. y SEMELKA, Richard C. *MRI: basic principles and applications*. 5.ª ed. Hoboken: Wiley-Blackwell, 2016.
14. MCROBBIE, Donald W.; MOORE, Elizabeth A.; GRAVES, Martin J. y PRINCE, Martin R. *MRI from Picture to Proton*. 3.ª ed. Cambridge: Cambridge University Press, 2017. Disponible en: DOI: 10.1017/9781107706958.
15. MODIC, Michael T.; MASARYK, Thomas J.; ROSS, Jeffrey S. y CARTER, John R. Imaging of degenerative disk disease. *Radiology*. 1988, vol. 168, n.º 1, págs. 177-186. Disponible en: DOI: 10.1148/radiology.168.1.3289089.

16. JARVIK, Jeffrey G. y DEYO, Richard A. Diagnostic evaluation of low back pain with emphasis on imaging. *Annals of Internal Medicine*. 2002, vol. 137, n.º 7, págs. 586-597. Disponible en: DOI: 10.7326/0003-4819-137-7-200210010-00010.
17. STANDRING, Susan (ed.). *Gray's Anatomy: The Anatomical Basis of Clinical Practice*. 42.^a ed. Edinburgh: Elsevier, 2020.
18. HOY, Damian *et al.* The global burden of low back pain: estimates from the Global Burden of Disease 2010 study. *Annals of the Rheumatic Diseases*. 2014, vol. 73, n.º 6, págs. 968-974. Disponible en: DOI: 10.1136/annrheumdis-2013-204428.
19. NATIONAL ELECTRICAL MANUFACTURERS ASSOCIATION. *Digital Imaging and Communications in Medicine (DICOM) Standard* [En línea]. 2024. [consultado 2026-06-05]. Disponible en: <https://www.dicomstandard.org/>.
20. COX, Robert W. *et al.* A (sort of) new image data format standard: NIFTI-1. *NeuroImage*. 2004, vol. 22, e1440.
21. LITJENS, Geert *et al.* A survey on deep learning in medical image analysis. *Medical Image Analysis*. 2017, vol. 42, págs. 60-88. Disponible en: DOI: 10.1016/j.media.2017.07.005.
22. SZELISKI, Richard. *Computer Vision: Algorithms and Applications*. 2.^a ed. Cham: Springer, 2022. Disponible en: DOI: 10.1007/978-3-030-34372-9.
23. KIRILLOV, Alexander; HE, Kaiming; GIRSHICK, Ross; ROTHER, Carsten y DOLLÁR, Piotr. Panoptic segmentation. En: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, págs. 9399-9408. Disponible en: DOI: 10.1109/CVPR.2019.00963.
24. LECUN, Yann; BENGIO, Yoshua e HINTON, Geoffrey. Deep learning. *Nature*. 2015, vol. 521, págs. 436-444. Disponible en: DOI: 10.1038/nature14539.
25. RONNEBERGER, Olaf; FISCHER, Philipp y BROX, Thomas. U-Net: Convolutional Networks for Biomedical Image Segmentation. En: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Cham: Springer, 2015, vol. 9351, págs. 234-241. Lecture Notes in Computer Science. Disponible en: DOI: 10.1007/978-3-319-24574-4_28.
26. OKTAY, Ozan *et al.* Attention U-Net: Learning where to look for the pancreas. En: *Medical Imaging with Deep Learning (MIDL)* [En línea]. Amsterdam, 2018 [consultado 2026-06-05]. Disponible en: <https://openreview.net/forum?id=Skft7cijM>.

27. DOSOVITSKIY, Alexey *et al.* An image is worth 16x16 words: Transformers for image recognition at scale. En: *International Conference on Learning Representations* [En línea]. 2021 [consultado 2026-06-05]. Disponible en: <https://openreview.net/forum?id=YicbFdNTTy>.
28. MONAI CONSORTIUM. *MONAI: Medical Open Network for AI: Framework de código abierto para aprendizaje profundo en imagen médica* [En línea]. [consultado 2026-06-05]. Disponible en: <https://monai.io>.
29. STEURER, Johann; RÖNER, Simon; GNANNT, Ralph y HODLER, Juerg. Quantitative radiologic criteria for the diagnosis of lumbar spinal stenosis: a systematic literature review. *BMC Musculoskeletal Disorders*. 2011, vol. 12, pág. 175. Disponible en: DOI: 10.1186/1471-2474-12-175.
30. TAHA, Abdel Aziz y HANBURY, Allan. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. *BMC Medical Imaging*. 2015, vol. 15, n.º 29. Disponible en: DOI: 10.1186/s12880-015-0068-x.
31. MAIER-HEIN, Lena *et al.* Metrics reloaded: recommendations for image analysis validation. *Nature Methods*. 2024, vol. 21, págs. 195-212. Disponible en: DOI: 10.1038/s41592-023-02150-0.
32. BERNER, Eta S. (ed.). *Clinical Decision Support Systems: Theory and Practice*. 2.ª ed. New York: Springer, 2007. Disponible en: DOI: 10.1007/978-0-387-38319-4.
33. REPÚBLICA ARGENTINA. *Ley N.º 25.326 de Protección de los Datos Personales* [En línea]. [consultado 2026-06-05]. Disponible en: <https://servicios.infoleg.gob.ar/infolegInternet/anexos/60000-64999/64790/texact.htm>.
34. REPÚBLICA ARGENTINA. *Código Civil y Comercial de la Nación, artículo 53: Derecho a la imagen* [En línea]. [consultado 2026-06-05]. Disponible en: <https://servicios.infoleg.gob.ar/infolegInternet/anexos/235000-239999/235975/texact.htm>.
35. GOODMAN, Elizabeth; KUNIAVSKY, Mike y MOED, Andrea. *Observing the user experience: a practitioner's guide to user research*. 2.ª ed. Waltham: Morgan Kaufmann, 2012.
36. COCHRAN, William G. *Sampling techniques*. 3.ª ed. Nueva York: John Wiley & Sons, 1977.
37. WIEGERS, Karl y BEATTY, Joy. *Software requirements*. 3.ª ed. Redmond: Microsoft Press, 2013.

38. KRUCHTEN, Philippe. The 4+1 view model of architecture. *IEEE Software*. 1995, vol. 12, n.º 6, págs. 42-50. Disponible en: DOI: 10.1109/52.469759.
39. LARMAN, Craig y BASILI, Victor R. Iterative and incremental development: a brief history. *Computer*. 2003, vol. 36, n.º 6, págs. 47-56. Disponible en: DOI: 10.1109/MC.2003.1204375.
40. PFIRRMANN, Christian W. A.; METZDORF, Alexander; ZANETTI, Marco; HODLER, Juerg y BOOS, Norbert. Magnetic resonance classification of lumbar intervertebral disc degeneration. *Spine*. 2001, vol. 26, n.º 17, págs. 1873-1878. Disponible en: DOI: 10.1097/00007632-200109010-00011.